

中山大學 人工智能學院
SUN YAT-SEN UNIVERSITY SCHOOL ARTIFICIAL INTELLIGENCE

自然语言处理

Natural Language Processing (NLP)

赵宝全

中山大学人工智能学院

2026年春季学期

课程概述


自然语言处理是人工智能领域中的重要方向之一，被誉为**人工智能皇冠上的“明珠”**

- 探索人类自身语言能力和语言思维活动的本质，研究**模仿人类语言认知过程**，并通过**建立计算框架和方法**来实现和不断完善**语言模型**，并以此设计各种可供评测的**实用系统**
- 是一门与语言学、计算机科学、数学等相联系的**交叉性学科**




达特茅斯会议（达特茅斯夏季人工智能研究计划），1956

1956 Dartmouth Conference:
The Founding Fathers of AI



主要议题

- ◇ 自动计算机
- ◇ **自然语言处理**
- ◇ 神经网络
- ◇ 计算理论
- ◇ 自我改造
- ◇ 抽象
- ◇ 随机性
- ◇ 创造性



课程目标

本课程将系统介绍自然语言处理的**基本概念**、**关键技术**和**重要应用**

- ✧ 重点掌握词汇、句法、语义分析等的**基本知识**，理解统计自然语言处理的**关键算法**；
- ✧ 在大规模语料库的支持下，掌握**统计语言模型**在语言知识自动学习中的应用；
- ✧ 结合文本分类、机器翻译、信息检索、问答系统等目前互联网热门应用技术，进一步加深对自然语言处理系统的**设计策略**和**实现技术**的了解；
- ✧ 了解当前国内外语言处理技术的发展概貌，接触语言处理技术的**前沿研究**，具备运用基本原理和主要方法解决科研工作中出现的实际问题的能力。

课程教材及教辅资料



✧ **主讲教材：**《自然语言处理导论》，张奇，桂韬，黄萱菁 著，电子工业出版社，2023-08-01

✧ **参考教材：**

✧ 《自然语言处理综论》（第2版），Daniel Jurafsky, James H. Martin 著，冯志伟 译，电子工业出版社

✧ 《大规模语言模型：从理论到实践》，张奇，桂韬，郑锐，黄萱菁 著，电子工业出版社，2024-01-01

✧ 《预训练语言模型》，邵浩 著，电子工业出版社，2021-05-01




课程内容安排

基础技术	第2章 词汇分析	第3章 句法分析	第4章 语义分析
	第5章 篇章分析	第6章 语言模型 	
核心技术	第7章 信息抽取	第8章 机器翻译	第9章 情感分析
	第10章 智能问答	第11章 文本摘要	第12章 知识图谱
模型分析	第13章 模型稳健性	第14章 可解释模型	不讲授

成绩评定

- **期末考查成绩：** 占总成绩的**50%**
- **平时成绩：** 占总成绩的**50%**，其中：
 - **课程出勤：** 占总成绩的**10%**（随机考勤2次，每次占总成绩的5%）
 - **课程作业：** 占总成绩的**40%**（共2次作业，每次作业占总成绩的20%）



中山大學 人工智能學院
SUN YAT-SEN UNIVERSITY SCHOOL ARTIFICIAL INTELLIGENCE

「自然语言处理」

第 1 章 绪论

赵宝全

中山大学人工智能学院

2026年春季学期

本章主要内容

1.1

自然语言处理概述

1.2

自然语言处理的基本范式

本章主要内容

1.1

自然语言处理概述


- 1.1.1 自然语言处理的基本概念和发展历程
- 1.1.2 自然语言处理的主要研究内容
- 1.1.3 自然语言处理的典型应用
- 1.1.4 自然语言处理面临的挑战

1.2

自然语言处理的基本范式



✧ 自然语言是人类社会发展过程中**自然产生**的语言，是最能体现人类智慧和文明的产物




语言是思维的载体

人类交流思想、表达情感
最自然、最直接、最方便
的工具

占知识总量80%

人类历史上以语言文字
形式记载和流传的知识





自然语言语系分类

孤立语

Isolating language

(如: 汉语)

- ✧ 几乎没有词形变化
- ✧ 往往一个词仅包含一个语素
- ✧ 透过语序、助词、句法等来传达多元的意义

屈折语

Inflectional language

(如: 英语、法语、德语)

- ✧ 有词的形态变化
- ✧ 使用不规则或将多个概念的语素融合的方式构词
- ✧ 比较难分析出原始的构词关系

黏着语

Agglutinative language

(如: 日语、韩语)

- ✧ 有词的形态变化
- ✧ 单纯将多个语素以黏着的方式构词
- ✧ 比较容易分析语素之间的关系



定义：自然语言处理 (Natural Language Processing)

研究如何利用计算机技术对语言文本（句子、篇章或话语等）进行处理和加工的一门学科，研究内容包括对词法、句法、语义和语用等信息的识别、分类、提取、转换和生成等各种处理方法和实现技术。

《计算机科学技术百科全书》(宗成庆)

清华大学出版社, 2018.5

自然语言理解 (Natural Language Understanding, NLU)：能够理解自然语言的意义 (**懂人言**)


自然语言生成 (Natural Language Generation, NLG)：以自然语言文本来表达给定的意图、思想等 (**说人话**)



“香蕉形状的椅子”



“木棉花形状的沙发”



“枯藤老树昏鸦，小桥流水人家，
古道西风瘦马，夕阳西下”

化妆品领域[面膜]			数码产品领域[电脑包]			
	标题	让你的手机电量续航18岁		标题	电脑包推荐	
输入	关键词	[果汁, 美白, 面膜, 肌肤, 祛斑, 生活, 饮食, 护理]	输入	关键词	[充电宝, 便携, 耐用, 快充, 安全, 轻便, 续航, 品牌]	
	知识图谱	[很多女性, 困扰, 很多亚洲女性] [很多女性, 关心, 祛斑美白的问题]			知识图谱	
	孟子	最近入手了一款超好用的充电宝，就是这款充电宝，我平时工作比较忙，所以经常需要出差，但是又不带太多东西，这个包的容量还是很大的，可以放下我的ipad，还有一个保温杯和一些日常用品，而且它的样子也是非常的好看，是那种很有质感的牛皮材质，摸起来手感也很好，很高级的感觉。我买的是蓝色的新款，因为我平时工作，也不太喜欢太花里胡哨的东西，这样一拿就不会显得突兀了，反而会让整体的搭配更加的和谐，它里面的内部空间也是充足的呢，有两个小的充电宝，充电宝和ipad是完全没问题的，平常出门的时候我就会带上它，不仅方便携带而且产品还超级小巧可爱，比如说我们的ipad，平时出门的时候，真的方便太多了，最满意的一点是，它送了两根充电线，我平时出门再也不用担心会没电了，而且我最近买的这款充电宝还可以拆卸的小包了，最近有很多小伙伴都在问，这款充电宝怎么样，我也很乐意去给大家分享我的使用心得，这款充电宝真的很好用，如果你也想拥有同款的话，建议你们去试一试，毕竟这么好的价格，性价比太高了！我现在已经成为了它的最忠实的粉丝了！			孟子	最近入手了一款充电宝，容量很大，平时可以放下手机、手机、充电宝、保温杯、口红、钥匙、钱包等等，这款充电宝的材质是牛皮的，摸起来手感很好，而且颜色也很低调，我平时上班的时候比较多，所以这款充电宝真的很大，这个包也是超酷的，可以放充电宝，也可以放手机，还可以放充电宝，还有两个小包，一个装充电宝和手机，平时放在包里也很方便。
	GPT	肌肤问题一直是困扰很多亚洲女性的，所以很多女性都很关心祛斑的问题，那么如何能让肌肤今天变白呢？今天给大家推荐一款面膜，让你的手机电量续航18岁！1. 饮食方面：多吃新鲜蔬菜和水果，少吃辛辣刺激性食物，多吃富含维生素C的食物，如猕猴桃、西兰花、橙子、西红柿等。2. 护肤方面：注意防晒，做好防晒工作。3. 日常护肤：坚持使用美白产品，如美白精华、美白面膜、美白霜等。4. 日常保持良好心态，保持愉快的心情，不要熬夜。		GPT		





自然语言处理的研究历史可以追溯到1947 年

- 计算机问世(1946)的第二年，美国工程师W. Weaver最早提出了利用计算机进行自动翻译，并于1949年发布《Translation》（翻译）备忘录
- 1950年 Alan Turing 发表《Computing Machinery and Intelligence》提出通过人机对话对机器进行智能测评
- 1954年 Georgetown University与IBM 合作的机器翻译演示系统将60 多个俄语句子的翻译成了英文



Warren Weaver (1894~1978)
信息论先驱



诺伯特·维纳 (Norbert Wiener)
(1894年11月26日 ~ 1964年3月18日)

[Reproduced by permission of the Rockefeller Foundation Archives]

March 4, 1947

Dear Norbert:

I was terribly sorry, when in Cambridge recently, that I got unavoidably held up by several unexpected jobs, and did not get a chance to see you.

One thing I wanted to ask you about is this. A most serious problem, for UNESCO and for the constructive and peaceful future of the planet, is the problem of translation, as it unavoidably affects the

I wondered if it were unthinkable to design a computer which would translate

Also knowing nothing official about, but having guessed and inferred considerable about, powerful new mechanized methods in cryptography - methods which I believe succeed even when one does not know what language has been coded - one naturally wonders if the problem of translation could conceivably be treated as a problem in cryptography. When I look at an article in Russian, I say "This is really written in English, but it has been coded in some strange symbols. I will now proceed to decode."

Have you ever thought about this? As a linguist and expert on computers, do you think it is worth thinking about?


Cordially,

Warren Weaver.

Professor Norbert Wiener
Massachusetts Institute of Technology
Cambridge 39, Massachusetts


WW:AZB

图灵测试 (Turing Test)



艾伦·图灵
(Alan Turing)
(1912年 ~ 1954年)
计算机科学与人工智能之父


如果一个计算机系统的**表现**(act)、**反应**(react)和**互相作用**(interaction)都和**有意识的个体**一样，那么，它应该被认为是**有意识的**。



C使用问题来判断A或B是人类还是机械



20世纪50年代末到60年代的**初创期**、20世纪70年代到80年代的**理性主义时代**、20世纪90年代到21世纪初的**经验主义时代**以及2006年至今的**深度学习时代**。





符号学派和随机学派

- **Noam Chomsky**为代表的符号学派提出了形式语言理论，基于1957年发表的《Syntactic Structures》（句法结构）介绍了生成语法的概念，并提出了一种特定的生成语法称为转换语法。开启了使用数学方法研究语言的先河。
- 随机学派则是以1959年 **Bledsoe** 和 **Browning** 将贝叶斯方法（Bayesian method）应用于字符识别问题为代表。试图通过贝叶斯方法来解决自然语言处理中的问题。

计算语言学（Computational Linguistics）概念也被正式，1962年ACL成立，1965年第一届国际计算语言学大会（The International Conference on Computational Linguistics, COLING）




- 通常通过一些特殊的语句或语言现象的研究来得到对人的语言能力的认识
- 问题求解的思路：基于规则的分析方法建立符号处理系统

- 规则库开发: $N+N \rightarrow NP$
- 词典标注: #工作, $N(uc); V;$
- 推导算法设计: 归约、推导、歧义消解方法...

系统理论基础：Chomsky 的文法理论

There is a book on the desk.



#a, Det, 一
#book, N, 书; V, 预订
#desk, N, 桌子
#on, P, 在 X 上
#There be, V, 有

输出译文：在桌子上有一本书。



经验主义 (empiricist) 方法

- 偏重于对大规模语言数据中人们所实际使用的普通语句的统计
- 问题求解的思路：基于大规模真实语料(语言数据)建立计算方法

- 大规模真实数据的收集、标注：真实性、代表性、标注信息.....
- 统计模型建立：模型的复杂性、有效性、参数训练方法.....

语料库 + 统计模型 → NLP

理论基础：统计学、信息论、机器学习

There is a book on the desk.

语言模型
 $p(C)$

翻译模型
 $p(E|C)$

解码器
 $\hat{C} = \arg \max_c P(C)P(E|C)$


输出译文：在桌子上有一本书。





基于机器学习和数据驱动

- 1989年机器翻译任务中引入语料库方法
- 朴素贝叶斯、K 近邻、支撑向量机、最大熵模型、神经网络、条件随机场、感知机等方法





深度神经网络+向量表示

- 2006年基于深度信念网络（Deep Belief Networks, DBN）方法
- 2011年《Natural language processing (almost) from scratch》
- 2014 年 Seq2Seq（序列到序列）的模型在机器翻译任务上取得了非常好的效果，并且完全不依赖任何人工特征
- 循环神经网络、长短时记忆网络、递归神经网络、卷积神经网络、图神经网络等



超大规模语言模型

- 2018年上下文相关的文本表示方法ELMo
- BERT、GPT、XLNet、ERNIE等预训练微调范式
- GPT3、Palm等超大规模语言模型




Input Prompt: Recite the first law of robotics




Output:

1 - Semi-supervised training on large amounts of text (books, wikipedia, etc.).

The model is trained on a certain task that enables it to grasp patterns in language. By the end of the training process, BERT has language-processing abilities capable of empowering many models we later need to build and train in a supervised way.



2 - Supervised training on a specific task with a labeled dataset.





Embedding of "stick" in "Let's stick to" - Step #1

LSTM Layer #2

LSTM Layer #1

Embedding






自然语言处理的**研究内容十分庞杂**

- **整体**：基础算法研究和应用技术研究
- **语言单位角度**：字、词、短语、句子、段落以及篇章等不同粒度
- **语言学研究角度**：形态学、语法学、语义学、语用学等不同层面
- **机器学习方法层面**：有监督、无监督、半监督、强化学习等

自然语言处理研究与机器学习和语言学研究交织在一起，使得自然语言处理的研究内容涉及范围广，学科交叉度大。



自然语言处理主要研究内容



Our team has less projects this quarter.

• GRAMMAR

~~less~~ → fewer

It appears that the quantifier **less** does not fit with the countable noun **projects**. Consider changing the quantifier or the noun.

检查语法、拼写和标点符号

PREMIUM

If you have any questions about my rate or if you find it necessary to increase or decrease the scope for this project, please let me know.

• CLARITY

If you have any questions about my rate or ~~if you~~ find it necessary to increase or decrease ~~the scope for this project~~ **this project's scope**, please let me know.

Rephrase sentence

写作建议

Can we catch up this afternoon? I'd love your input on my presentation for tomorrow's meeting. I'd especially love it if you could double-check the sales numb
There's a coffee in it for you!

• TONE DETECTOR

Here's how your text may sound to readers

👊 Confident	●●●●
😊 Joyful	●●●●
✌ Optimistic	●●●●

调整语气

PREMIUM

The crispy cauliflower tacos recipe looks very good.

• VOCABULARY

~~very good~~ → perfect delicious

Words such as **very**, **extremely**, and **totally** are meant to intensify the adjectives you use, but they often have the opposite effect.

用词润色



✧ 在商贸、体育、文化、旅游、教育等各个领域的广泛应用

◇ 据统计，“一带一路”涉及60多个国家、44亿人口、110余种语言



检测到中文(简体)



英语

翻 译

人工翻译

通用领域

生物医药



黛玉自在枕上感念宝钗……又听见窗外竹梢焦叶之上，雨声淅沥，消寒透幕，不觉又滴下泪来。



Daiyu felt grateful for Baochai on her pillow... She heard the sound of rain on the scorched leaves on the bamboo shoots outside the window, and the cold cleared through the curtain. Then she burst into tears again.

双语对照 ☐



LaMDA (1370 亿个参数)



Chat with any PDF

PDF size is limited to 200 pages due to high demand. For more, use [your own key](#).



Drop PDF here

[Browse my Computer](#)

[From URL](#) [Find a PDF](#)

A chatting PDF? Why?

This is the age of the AI revolution! Intelligence will be free and ubiquitous soon, restructuring our society and enabling new possibilities of interaction.

With ChatPDF, your documents are becoming intelligent! Just talk to your PDF file as if it were a human with perfect understanding of the content.

What is this useful for?

It works great to quickly extract information from large PDF files. Try talking to manuals, essays, legal contracts, books or research papers.

ChatPDF can not yet understand images in PDFs and might struggle with questions that require understanding more than a few paragraphs at the same time.

How does it work?

The PDF is analyzed first to create a semantic index of every paragraph. When asking a question the relevant paragraphs are presented to the ChatGPT API.

Your data is saved in a secure cloud storage and deleted after 7 days.

Chat with Mosquito brains encode unique features of human odour to drive host seeking... [Reset](#) [Close](#)

...ing humans by strongly preferring human odour over animal odour. The study shows that human and animal odors evoke activity in distinct combinations of olfactory glomeruli within the mosquito's antennal lobe.

Here are three example questions you may have about this article:

- How do mosquitoes distinguish between human and animal odors?
- What are olfactory glomeruli and how do they play a role in mosquito host seeking?
- Could this research lead to new methods for controlling mosquito populations and reducing the spread of diseases they carry?

可以用中文解释吗?

当然可以! 我是一份有用的PDF文件, 可以回答你的问题。如果你有任何问题, 我会查找给定的页面并从中提供答案。如果页面中包含答案, 我会引用相应的页码并提供简明扼要的答案。如果页面中没有相关信息, 我会告诉你, 并尽力回答你的问题。请随意向我提问!


这篇论文主要讲了什么?



Ask any question...



<https://www.chatpdf.com/>



餐厅评价

全部 (10101)

晒图 (7454)

低分 (296)

最新

大众点评 2021/10/31

优质评价

中午过了饭点去的, 店里绳子还是很好呀, 不用等位。
团了个198的套餐, 性价比很棒。
十三天梯 肉肉虾蔬菜搭配很好, 肉都很嫩! 提前腌制过的肉肉, 烤出来巨好吃 😊
鱼豆腐 这个品质很高, 淀粉加得不多, 鱼肉肉做的, 很鲜美。
秘制牛五花 肥瘦适中, 提前腌制的, 特别入味。
甜品大福 四个口味, 都很好吃! Q弹弹, 甜而不腻, 干吃汤原的赶脚。推荐!
芝士玉米 烤完之后, 芝士化了, 拔丝, 很好吃。我家猪头平时不吃玉米 🌽 的, 竟然都特别爱吃。。。很神奇。。。哈哈哈哈哈
店环境很好, 服务员换篮子很勤快。
火 🔥 很旺, 烤肉很快, 特别棒呆!!
肉嫩, 新鲜, 味道好。推荐哈 😊
唯一的不足, 就是店开在小区里面。。。如果疫情封小区, 就没得吃了叭。。。

餐厅评价

全部 (10102)

晒图 (7455)

低分 (296)

最新

大众点评 17小时前

优质评价

这家店在小区里, 不是很好找, 但是周五晚上也是从五六点一直排队到半夜。
口味: 调味牛排很不错, 方便烤也很好吃。骰子牛肉挺嫩的, 但是烤起来要一直翻, 不然会粘在篮子上, 这点有点麻烦。五花肉质量也挺好, 虽然说肉还可以更肥一点。自助的南瓜汤和小菜都很好吃, 我们还看到有小区里的大哥来打包生肉和两大盒南瓜汤回家。
环境: 在烤肉店里算中上, 虽然店面不是很大, 但是不拥挤, 装修不错, 桌椅也都挺舒服, 还有提供宝宝椅。
服务: 因为小料小菜和烤肉都是自助, 所以对服务要求不高。不过 **服务人员都还挺热情的**, 拿东西换篮子什么的, 虽然忙忙碌碌但是基本上能 **做到有求必应**。尤其是老板娘, 一直在店里忙内忙外, 想方设法满足客人的需求, 很热情, 也很健谈。
特别一提, 最近有店庆, 可以用券, 几乎是半



在他们之间平均85%链接均不相同

百Google度搜索

1.1.3

自然语言处理的典型应用——信息检索



However, others say that a hot dog is in its own category because a sandwich has a top and a bottom while a hot dog is on a split in.



Ask a follow up Is a hotdog a sandwich or a





Generative AI is experimental

Kumquats are small citrus fruits that look like tiny oranges. They are about the size of a grape or olive. The peel is thin and sweet, while the flesh is tart. The entire fruit, including the peel and seeds, is edible.

Kumquats are easy to eat whole. You can also slice them and add to salads, bake into muffins, blend into dressings, and muddle into cocktails.



Ask a follow up What is the small citrus you



Here are some dresses to consider with 2-day delivery:



Reformation Marguerite S... \$298
J.Crew Women's Collectio... \$398

Ask a follow up Matching accessory

Generative AI may be inaccurate or offensive

Sure! Here is a poem about your mischievous cat named Whiskers:

Whiskers,

A cat of great mystery,
With whiskers so long and fluffy.


<https://blog.google/products/search/generative-ai-search/>

1.1.3

自然语言处理的典型应用——数据挖掘与文本分析




美国情报人士大揭密



<https://www.bilibili.com/video/BV1LP411v7qA>





我终于读懂 外交部 反击美国的“黑话”








“步入大数据智能时代，承继司法信息化的建设逻辑，依托先进的图（OCR）、文（NLP）、声（语音识别）、像（视频解构）等技术促进诉讼服务、司法公开、审判执行、司法管理的智能化成为可能”



刘艳红. "人工智能法学的“时代三问”." 东方法学 (2021).

Zhong, Haoxi, et al. "How does NLP benefit legal system: A summary of legal artificial intelligence." arXiv preprint arXiv:2004.12158 (2020).



美国联邦上诉法院60,000件判决书
(时间跨度50年)



纸本文献

数字化文献

结构化数据

智慧化数据

- ◇ “利用**知识图谱**理念结合**大数据**技术进行建设，克服了结构化**数据碎片化**的缺点，具备大数据分析、智慧搜索、智能推荐、人机交互、决策支持等功能”



综合运用**计量统计、定位查询、聚类查询、空间分析、数据关联、网络分析、机器标引、众筹众包、版本比勘**等技术，将明代的文学文献和研究成果图谱化、智能化，打造一个集浏览、查询、研究、欣赏于一体的明代文学智慧大数据平台。平台的数据包括供读者阅读的**图像和文本基础数据**及后台相关联的**结构化数据**两类。数据处理经过“**文献-OCR识别-机器标点-人工校对-机器标引-人工标引-前台发布**”的流程，涉及到**文本切割、自动标点、分词**等自然语言处理技术，是以知识图谱为核心的智慧文学素材库建设。

“建设过程应由机器完成85%的工作，人工完成最后15%，以加快古籍数据整理进度”

古汉语自然语言处理






- ◇ 断句和标点
- ◇ 命名实体识别
- ◇ 古文分类
- ◇ 古诗情感分类
- ◇ 文白检索

GuwenModels

古文应用模型在线演示 [项目地址](#)

殆知阁古代文献





图例

- ☒ 症状
- ☒ 体征
- ☒ 查体项目
- ☒ 疾病
- ☒ 诊断
- ☒ 检验项目
- ☒ 检验指标
- ☒ 检验结果
- ☒ 检查项目
- ☒ 检查指标
- ☒ 检查结果
- ☒ 治疗方法
- ☒ 药物
- ☒ 操作
- ☒ 手术

001-入院记录-现病史

[上一个](#) [下一个](#)

病历内容

主诉:反复咳嗽、咳痰、喘息10年余,加重3天。现病史:患者于2006年春季起受凉后反复咳嗽,咳大量白痰,前往XX社区医院就诊,查胸片示肺纹理增粗,给予头孢类抗生素抗感染治疗后症状逐渐缓解。2006年秋季患者受凉后再次发作上述症状,伴喘息,活动后症状加重,症状于抗感染治疗后1个月逐渐缓解。此后上述症状于冬春季节反复发作,每年发作时间约3个月,喘息症状逐渐加重,平地行走时常因呼吸困难而停下休息,休息后可缓解,咳痰量逐渐增多,每次抗生

素抗感染治疗的时间加长。2010年12月患者受凉后再次出现发作性胸闷、喘息,伴明显咳嗽,咳大量白痰,夜间咳嗽症状重,就诊于XX医院体检时,查胸片示肺纹理增粗、紊乱,查肺功能示残气量增高,使用支气管扩张药后FEV1/FVC<0.70,FEV1%预计值=75%,诊断为慢性阻塞性肺疾病,建议戒烟,长期家庭氧疗及常规使用茶碱缓释片治疗,患者依从性不佳,未规律用药,症状仍有反复发作。2012年起患者受凉后出现发热,伴咳嗽、咳痰、喘息,日常活动明显受限,不能自理,口唇发绀,家属送往XX市医院急诊,查血气分析示“II型呼吸衰竭”,给予无创机械通气治疗,以及平喘、化痰、抗感染治疗,患者症状改善,出院后长期家庭氧疗,仍未戒烟,2013~2015年曾反复住院多次。2016年5月22日患者受凉后再次出现咳嗽,咳大量黄痰,伴喘息,穿衣服时即可导致症状加重,平卧后症状加重,自行口服茶碱及头孢呋辛,症状未缓解。今日就诊于我院急诊,查血常规示白细胞 $9.87 \times 10^9/L$,中性粒细胞百分比0.90,查血气分析示动脉血二氧化碳分压75mmHg,动脉血氧分压55mmHg,动脉血氧饱和度89%,查肺CT示双肺散在斑片影,多发慢性肺气肿。为进步治疗,急诊以“慢性阻塞性肺疾病急性发作、II型呼吸衰竭”收住我科。自发病以来,患者精神状态差,饮食睡眠不佳。二便正常。

病历来源:国家医药管理局编《病历书写基本规范详解》,人民卫生出版社。

实体属性抽取

咳嗽

发生频率:反复

时间:10年余

转归状态:加重

转归时间:3天

1.1.3

自然语言处理的典型应用——人工智能内容生成 (AIGC)




文本→文本

化妆品领域[面膜]		
输入	标题	让你的肌肤重返18岁
	关键词	[姜汁, 美白, 面膜, 肌肤, 祛斑, 生活, 饮食, 护理]
	知识图谱	[肌肤问题, 困扰, 很多亚洲女性] [很多女性, 关心, 祛斑美白的问题]
孟子	现在困扰很多亚洲女性的肌肤问题之一就是黑色素的沉淀, 所以在日常生活中, 我们需要做到以下几点: 1. 注意饮食, 多吃新鲜蔬菜水果, 少吃辛辣刺激性食物; 2. 保持良好的作息时, 不要熬夜; 3. 坚持每天敷面膜, 每周敷2-3次; 4. 多运动, 增强身体的新陈代谢; 5. 合理的护肤, 选择适合自己肤质的产品; 6. 适当的做一些面部按摩, 促进血液循环, 改善皮肤的状态; 7. 调整好心态, 放轻松的心情, 做事情要有计划; 8. 不过度的追求完美, 要学会享受当下的美好时光; 9. 在平时的日子里尽量保证充足的睡眠和休息, 这样才能更好地保护自身的身心健康, 提高自我修复的能力; 10. 每个人的体质都不一样, 如果你是敏感肌的话, 可以用温和的洗面奶进行清洁, 然后再用姜汁洗脸, 用生理盐水浸湿化妆棉, 敷在脸上15分钟左右, 洗掉之后再涂上一层保湿的面霜, 最后在用一个补水的精华液, 就ok了。另外, 还有一点很重要的, 那当然是要保护好护理, 因为我发现现代人都比较注重自律的人, 在这个过程当中我也会更加的关注一下我的生物钟, 比如说我是属于那种经常会失眠的类型, 而且我还是一名职场白领, 平常的工作压力也是非常大的, 在我看来, 只要我能够调节好我平日里的三餐, 也就不会担心会长斑啦。	
GPT	肌肤问题一直是困扰着很多亚洲女性的, 所以很多女性都很关心祛斑美白的问题, 那么如何美白肌肤呢? 今天我就来给大家分享一下我的美白小妙招, 让你的肌肤重回18岁! 1. 饮食方面: 饮食清淡, 少吃辛辣刺激性食物, 多吃富含维生素C的食物, 如胡萝卜、西兰花、番茄、西红柿等。2. 日常护理: 注意防晒, 做好防晒工作。3. 日常护肤: 坚持使用美白产品, 比如美白精华、美白面膜、姜汁面膜等等。4. 日常保养: 保持良好的心情, 保持愉快的心情, 不要熬夜。	

数码产品领域[电脑包]		
输入	标题	电脑包推荐
	关键词	[电脑, 保温杯, 电脑包, 包包, 平时, 袋子, 入手, 背着]
孟子	最近入手了一款超级好用的电脑包, 就是这款电脑包。我平时工作比较忙, 所以经常需要出差, 但是又不想带太多的东西, 这个包的容量还是很大的, 可以放下我的ipad, 还有一个保温杯和一些日常用品, 而且它的袋子也是非常的好看, 是那种很有质感的牛皮材质, 摸起来手感也很好, 很高级的感觉。我买的是黑色的那款, 因为我是学生党嘛, 也不太喜欢太花里胡哨的装饰品。这样一来就不会显得很突兀, 反而会让整体的搭配更加和谐。它里面的内部空间也挺充足的呢, 有两个小的收纳袋, 放笔记本和ipad是完全没问题的嘛。平常出门的时候我都会带上它, 不仅能装下笔记本和电子产品还能放些小零食, 比如我们的口红啊, 钥匙啊等等, 真的太方便了。最重要的一点是, 它还送了两根挂绳, 背着它去哪里都不用担心会掉下来呢。而我更喜爱的还要数它那个可拆卸的小包袋了, 里边有很多小袋袋的设计, 像我这种手残党也能轻松驾驭, 出去旅游或者是去公司办公都很适合背它哦! 最后我想说一下, 如果你也想拥有同款的话, 建议你们也去试一试, 毕竟这么便宜的价格, 性价比也太高了吧! 我现在已经成为了它们家的忠实粉丝了呢!	
GPT	最近入手了一款电脑包, 容量很大, 平时可以装下电脑、手机、充电宝、保温杯、口红、粉饼、钥匙、纸巾等等。这款包包的材质是牛皮的, 摸起来手感很好, 而且很轻, 背着也不会觉得重。我平时上班背电脑比较多, 所以这款包的容量也很大。这个包包是双面的, 可以放电脑, 也可以放手机, 还可以放充电宝, 还有两个袋子, 一个袋子装着电脑和手机, 平时背着它去上班, 也很方便。	


文本→图像



文本→音视频




文本→三维模型





Sora

OpenAI's text-to-video model



1.1.3

自然语言处理的典型应用——人工智能内容编辑



 Adobe Firefly

1.1.3 自然语言处理的典型应用——语音合成




Script


Hey there! Welcome to HeyGen!
This is what we sound like in
another language.

Generate voice

▶ English



▶ Spanish



▶ French



▶ Japanese





- ✧ 由于不同的研究方向所关注的侧重点不同，因此，一般将语音识别、语音合成和说话人识别等以语音信号为主要研究对象的**语音技术独立**出来，而其他以**文本(词汇/句子/篇章等)**为主要处理对象的研究内容作为自然语言处理的**主体**
- ✧ 文字识别（OCR）更多地涉及图像识别与理解的问题
- ✧ 信息检索（IR）与自然语言处理之间既有密切关联，又各自相对独立



- ✧ 由于不同的研究方向所关注的侧重点不同，因此，一般将语音识别、语音合成和说话人识别等以语音信号为主要研究对象的语音技术独立出来，而其他以文本(词汇/句子/篇章等)为主要处理对象的研究内容作为自然语言处理的主体
- ✧ 文字识别（OCR）更多地涉及图像识别与理解的问题
- ✧ 信息检索（IR）与自然语言处理之间既有密切关联，又各自相对独立



自然语言处理难的**根本原因**：自然语言在各个层面都广泛存在的各种各样的**歧义性**

- 自然语言文本从形式上是由字符（包括中文汉字、英文字母、符号）组成的字符串
- 由字母或者汉字可以组成词，由词可以组成词组，由词组可以组成句子，进而组成段落、篇章
- 无论哪种粒度的语言单元，还是从一个层级向上一个层级转变中都存在**歧义**和**多义**现象

形式上一样的字符串，可以理解为不同的词串、词组串，并有不同的意义

Joseph F. Kess 和 Ronald A. Hoppe 甚至还提出了 “**语言无处不歧义**” 理论



词语切分歧义 (Word Segmentation Ambiguity) 是由字符组成词语时的歧义现象。

- 英语等印欧语系的语言来说，绝大部分单词之间都由空格或标点分割
- 汉语、日语等语言来说，单词之间通常没有分隔符。

例如：
语言学是一门基础学科
这门语言学起来很困难
南京市长江大桥





词语切分歧义 (Word Segmentation Ambiguity) 是由字符组成词语时的歧义现象。

- 英语等印欧语系的语言来说，绝大部分单词之间都由空格或标点分割
- 汉语、日语等语言来说，单词之间通常没有分隔符。





词义歧义 (Word Sense Ambiguity) 是指词语具有相同形式但是不同意义。

例如：“打”字在《现代汉语词典（第七版）》中，有两个读音“dá”和“dǎ”，分别作为量词、动词和介词，在作为动词时“打”字有 24 个意项

打 dǎ 动词：

- (1) 用手或器具撞击物体：~ 门 | ~ 鼓
- (2) 器皿、蛋类等因撞击而破碎：碗 ~ 了 | 鸡飞蛋 ~
- (3) 殴打；攻打：~ 架 | ~ 援
- (4) 发生与人交涉的行为：~ 官司 | ~ 交道
- (5) 汲取；盛取：~ 米 | ~ 酱油

他说：“她这个人真有意思(funny)”。她说：“他这个人怪有意思的(funny)”。于是人们以为他们有了意思(wish)，并让他向她意思意思(express)。他火了：“我根本没有那个意思(thought)！”她也生气了：“你们这么说是什么意思(intention)”？事后有人说：“真有意思(funny)”。也有人说：“真没意思(nonsense)”。



结构歧义 (Structural Ambiguity) 是由词组成词组或者句子时，由于其组成的词或词组间可能存在不同的语法或语义关系而出现的（潜在）歧义现象。

- “VP+ 的 + 是 +NP” 型歧义结构没有分隔符

例如：反对 | 的 | 是 | 少数人

- “VP+N1+ 的 +N2” 型歧义结构

例如：咬死了 | 猎人 | 的 | 狗

- “N1+ 和 +N2+ 的 +N3” 型歧义结构

例如：桌子 | 和 | 椅子 | 的 | 腿

(1) 喜欢乡下的孩子。

(2) 关于鲁迅的文章。

(3) 今天中午吃馒头。 (4) 今天中午吃食堂。

(5) 今天中午吃大碗。 (6) 今天中午吃了闭门羹。

(7) 写文章/写毛笔/写黑板

(8) I saw a man with a telescope.

→ I saw [a man with a telescope].

→ I [saw a man] with a telescope.

I saw a man with a telescope in the park. ?



指代歧义 (Demonstrative Ambiguity) 是指代词 (如我, 你, 他等) 和代词词组 (如 “那件事”, “这一点” 等) 所指的事件可能存在歧义

例如: 猴子吃了香蕉, 因为它 饿了。
猴子吃了香蕉, 因为它 熟透了。

省略歧义 (Ellipsis Ambiguity) 是指自然语言中由于省略所产生的歧义

例如: 县政府同意乡政府报告。



语用歧义 (Pragmatic Ambiguity) 是指由于上下文、说话人属性、场景等语用方面的原因造成的歧义。一句话在不同的场合、由不同的人说、不同的语境，都可能产生不同的理解

例如：女子致电男友：地铁站见。如果你到了我还没到，你就等着吧。如果我到了你还没到，你就等着吧！！

自然语言并不是一成不变的，而是在动态发展中，存在大量**未知语言现象**。新词汇、新含义、新用法、新句型等层出不穷

例如：新词汇：双碳、双减、绝绝子、社恐、元宇宙
新含义：躺平、打工人、凡尔赛、青蛙、潜水、盖楼
新用法：走召弓虽、YYDS、回忆杀、求扩列、orz



语音歧义 (Phonetic Ambiguity) 主要体现在口语中，是由于语言中同音异义词 (Homophone)、爆破音不完全、重音位置不明确等原因造成的。

- 汉语中只有413 个不同的音（节），如果结合声调的变化组合，也仅有 1277 个音（节），但是汉字则多达数万个
- 英语中连读、爆破音、重音位置等造成的语音异义也非常常见

例如：请问您贵姓？ 免贵姓 zhang

chéng shì：城市、程式、成事、城事

Please hand me the flower. 请把花递给我。

Please hand me the flour. 请把面粉递给我。



施氏食狮史

石室诗士施氏，嗜狮，誓食十
狮。氏时时适市视狮，十时，适十
狮适市，是时，适施氏适市，施氏
视是十狮，拭矢试，使是十狮逝世
，适石室，石室湿，氏使侍拭石室
，石室拭，始食是十狮尸，始识是
十狮尸实十石狮尸，试释是事。



赵元任

(1892-1982)

中国语言学家，精研北方话与吴语
方言的音系。一生会讲33种汉语
方言。被称为「汉语言学」之父。



一字多音

例如：

- 人要是行，干一行行一行，一行行行行行
- 要是不行，干一行不行一行，一行不行行行不行

韵律、声调、语气、重音

例如：

- 药材好药才好
- 今日说法
- 聊吧/说吧

本章主要内容

1.1

自然语言处理概述

1.2

自然语言处理的基本范式

- 1.2.1 基于规则的方法
- 1.2.2 基于机器学习的方法
- 1.2.3 基于深度学习的方法
- 1.2.4 基于大模型的方法



- 自然语言处理的发展经历了从**理性主义**到**经验主义**，再到**深度学习**三大历史阶段
- 基于**规则**的方法、基于**机器学习**的方法以及基于**深度学习**的方法三种范式
- 三种范式基本对应了自然语言处理的不同发展阶段的重点

需要特别说明的是：


- 虽然以上三种范式来源于自然语言处理的不同发展阶段，有明显的发展先后顺序
- 在大部分自然语言处理任务的标准评测集合中**基于深度学习**的方法都好于基于机器学习的方法，更优于基于规则的方法很多
- 但是，这三种范式各有利弊，在实际应用中需要根据任务的特点、计算量、可控制性以及可解释性等具体情况进行选择



- 在机器学习和深度学习范式下，甚至对模型预测目标进行微小修正，通常都需要对模型进行重新训练
- 对于未知任务的零样本学习（Zero-shot Learning）能力很少在上述范式中进行讨论和研究
- 随着ChatGPT的发布，大模型所展现出来的文本生成能力以及对未知任务的泛化能力使得未来的自然语言处理的研究范式很可能会发生非常大的变化



通过词汇、形式文法等制定的规则引入语言学知识，从而完成相应的自然语言处理任务



基于规则的自然语言处理算法基本流程



对于机器翻译任务可以构造如下规则库：

- IF 源语言主语 = 我 THEN 英语译文主语 = I
- IF 英语译文主语 = I THEN 英语译文 be 动词为 am/was
- IF 源语言 = 苹果 AND 没有修饰量词 THEN 英语译文 = apples


基于规则的方法从某种程度上可以说是在**试图模拟人类完成某个任务时的思维过程**

优点：直观、可解释、不依赖大规模数据。利用规则所表达出来的语言知识具有一定的可读性，不同的人之间可以相互理解。

缺点：覆盖率差、大规模规则构建代价大、难度高等



将自然语言处理任务转化为某种分类任务



基于机器学习的自然语言处理算法基本流程



分为四个步骤：数据构建、数据预处理、特征构建以及模型学习：


- (1) **数据构建阶段**主要工作是针对任务的要求构建训练语料，也称为语料库（Corpus）
- (2) **数据预处理阶段**主要工作是利用自然语言处理基础算法对原始输入，从词汇、句法、结构、语义等层面进行处理，为特征构建提供基础。
- (3) **特征构建阶段**主要工作是针对不同任务从原始输入、词性标注、句法分析、语义分析等结果和数据中提取对于机器学习模型有用的特征。
- (4) **模型学习阶段**主要工作是根据任务，选择合适的机器学习模型，确定学习准则，采用相应的优化算法，利用语料库训练模型参数。



- 以人工特征构建为核心，针对所需的信息利用自然语言处理基础算法对原始数据进行预处理，并需要选择合适的机器学习模型，确定学习准则，以及采用相应的优化算法
- 整个流程中需要人工参与和选择的环节非常多，从特征设计到模型，再到优化方法以及超参数，并且这些选择非常依赖经验，缺乏有效的理论支持
- 对于复杂的自然语言处理任务需要在数据预处理阶段引入很多不同的模块，这些模块之间需要单独优化，其目标并不一定与任务总体目标一致，多模块的级联会造成错误传播



将特征学习和预测模型融合，通过优化算法使得模型自动地学习出好的特征表示，并基于此进行结果预测




基于深度学习的自然语言处理算法基本流程



- 基于深度学习方法的流程简化很多，通常仅包含数据构建、数据预处理和模型学习三个部分
- 在数据预处理方面也大幅度简化，仅包含非常少量的模块
- 通过多层的特征转换，将原始数据转换为更抽象的表示。这些学习到的表示可以在一定程度上完全代替人工设计的特征，这个过程也叫做表示学习（Representation Learning）
- 首先利用自监督任务对模型进行预训练，通过海量的语料学习到更为通用的语言表示，然后根据下游任务对预训练网络进行调整。这种预训练范式在几乎所有自然语言处理任务上都表现非常出色



将大量各类型自然语言处理任务，统一为生成式自然语言理解框架



基于大模型的自然语言处理算法基本流程



- ChatGPT 所展现出来的**通用任务理解能力**和**未知任务泛化能力**，使得未来自然语言处理的研究范式可能进一步发生变化
- 在大规模语言模型构建阶段，通过大量的文本内容，训练模型长文本的建模能力，使得模型具有**语言生成能力**，并使得模型获得隐式的世界知识
- 在通用能力注入阶段，利用包括阅读理解、情感分析、信息抽取等现有任务的标注数据，结合**人工设计的指令词**对模型进行多任务训练，从而使得模型具有很好的任务泛化能力
- 特定任务使用阶段则变得非常简单，由于模型具备了通用任务能力，只需要根据任务需求设计任务指令，将任务中所需处理的文本内容与指令结合，然后就可以利用大模型得到所需结果

本章小结

自然语言处理（Natural Language Processing, NLP）是计算机科学领域和人工智能领域的重要研究方向之一，**旨在探索实现人与计算机之间用自然语言进行有效交流的理论与方法**。它融合了语言学、计算机科学、机器学习、数学、认知心理学等多学科内容，涉及从字、词、短语到句子、段落、篇章的多种语言单位，以及处理、理解、生成等不同层面的知识点，研究内容涉及的知识点多且复杂。自 20 世纪 90 年代以来，自然语言处理发展迅猛，各类任务和算法和研究范式层出不穷，在搜索引擎、医疗、金融、教育、司法等众多领域展示出重要作用。