

中山大學 人工智能學院
SUN YAT-SEN UNIVERSITY SCHOOL ARTIFICIAL INTELLIGENCE

「自然语言处理」

第 2 章 词汇分析

赵宝全

中山大学人工智能学院

2026年春季学期

本章主要内容

2.1	语言中的词汇
2.2	词语规范化
2.3	中文分词
2.4	词性标注



- **词**是表达完整含义的最小单位
 - ✧ 字的粒度太小，无法表达完整含义
 - 比如“鼠”可以是“老鼠”，也可以是“鼠标”。
 - ✧ 句子的粒度太大，承载的信息量多，很难复用
 - “猫和老鼠里的老鼠每次都能成功逃走”
- **自动词法分析**就是利用计算机对自然语言的形态(morphology) 进行分析，判断词的**结构**和**类别**等
- **词性**或称词类(Part-of-Speech, POS)是词汇最重要的特性，是**连接词汇到句法的桥梁**



自动分词

李克强总理说中山大学是南天一柱

李克强 总理 说 中山大学 是 南天 一柱

词性标注

李克强 总理 说 中山大学 是 南天 一柱
↓ ↓ ↓ ↓ ↓ ↓ ↓
PER N V ORG V LOC N

命名实体识别

李克强 总理 说 中山大学 是 南天 一柱
↓ ↓ ↓ ↓ ↓ ↓ ↓
PER N V ORG V LOC N




序列标注问题

在第7章信息抽取部分进行介绍



词法分析和词性标注的重要性

- ✧ 分词是句子分析的**基础**
- ✧ 文献处理以词语为文本**特征**
- ✧ “**以词定字、以词定音**”，用于文本校对、多音字辨识、简繁体转换
- ✧ 具有**广泛的应用**（词频统计，词典编纂，文章风格研究、信息检索、自动问答、机器翻译等）





■ 不同语言的词法分析





■ 中英文分词的典型区别

✧ 分词方式不同，中文更难

- 英文有天然的空格作为分隔符，但是中文没有

✧ 英文单词有多种形态


- 英文单词存在丰富的变形变换
- 词性还原 (Lemmatization): does, done, doing, did → do
- 词干提取 (Stemming): cats, catlike, catty → cat; finshing, fisher → fish

✧ 中文分词需要考虑粒度问题

- 比如，“酒仙桥北路”是否要切成“酒仙桥”和“北路”
- 在搜索场景，粗粒度的分词，搜索结果会更准确、更相关，但容易出现少结果和无结果



■ 中文词法分析与词性标注研究现状





■ 古代汉语信息处理

- ✧ 现代汉语的自动分析成果无法直接移植于古代汉语领域
- ✧ 缺乏标准数据集

漢EVAHAN

第一届国际古代汉语分词和词性标注评测EvaHan设置了两个测试集与两种评测模态，以《左传》前十卷为训练集，后两卷为基测集，《史记》和《资治通鉴》中的部分语料选作盲测集。

本章主要内容

2.1

语言中的词汇

2.1.1 词的形态学

2.1.2 词的词性

2.2

词语规范化

2.3

中文分词

2.4

词性标注



词 (word) 是**形式**和**意义**相结合的单位, 也是语言中**能够独立运用**的最小单位。

掌握一个词汇意味着知道其读音和语义

例如: 英文单词 ``cat" 具有的语义是 ``猫", 读音为 ``/kæt/"

自然语言处理算法中词通常也是**基本单元**

词的处理也是自然语言处理中重要的**底层任务**, 是句法分析、文本分类、语言模型等任务的基础。



- 词通常是由**语素** (Morpheme, 又称词素) 构成
- 语素是**语言中意义的最小单元**
 - 语素与词不同, 语素不能够独立运用而词可以。
 - 只包含一个语素的词语称为**简单词** (Simple word)
 - 包含多个语素的词称为**复杂词** (Complex word)

例如: “电灯”, 包含 “电” 和 “灯” 两个语素



虽然单词的形式和意义之间的关系本质上是任意的，但是由于社会的**约定俗成**，词的形式具有服从于**某种规则的内在结构**。研究单词的内部结构及其构成方式的学科称为**形态学 (Morphology)**，又称构词学。

- 词是由一个或多个语素构成，语素主要分成两类：词根 (Lemma) 和词缀 (Affix) 。
 - **词根**也称为原形或字典形，是指能在字典中查的到的语素，通常是一个词最主要的语素。
 - **词缀**是其他附着在原形上的语素，帮助在原形基础上衍生出新词，包含前缀、中缀、后缀等。



例如：

英语单词 unhappy 中，happy 为原形，-un 为前缀

邦托克语单词 fumikas（是强壮的）中，fikas（强壮）为原形，-um-为中缀

俄语单词 barabanshchik（鼓手）中，baraban（鼓）为原形，-shchik为后缀

有些语言的单词通常只包含一个或者两个语素，但是有一些语言的单词则包含多达十个以上的语素。

汉语中每个单词的语素都很少，也不会根据性、数、格、人称等发生形态变化。



表 2.1 英语中常见词形变换

词形变化	说明	举例
屈折 Inflection	通过“词根 + 词缀”的方式构成和原形“同一类型”的词	名词后加 -s 后缀 复数名词 (cat+s) 动词后加 -ed 后缀 动词的过去式 (walk+ed)
派生 Derivation	通过“词根 + 词缀”的方式构成和原形“不同类型”的词	employ 添加后缀 -ee 变为 employee meaning 添加后缀 -less 变为 meaningless
复合 Compounding	通过组合多个词根构成一个新词, 也称组合词	home + work → homework water + proof → waterproof
附着 Cliticization	通过“词根 + 附着语”的方式“附着”在词根上	I'm 中的'm 代表 am 附着在 I 上 We're 中're 代表 are
截搭 Blending	两个词语各自的一部分拼接起来构成新词	smoke (烟) + fog (雾) → smog (烟雾) spoon (勺子) + fork (叉子) → spork (叉勺)
缩略 Acronym	短语中多个单词首字母组合在一起组合成词	NLP 代表 Natural Language Processing IT 代表 Information Technology
截短 Clipping	将长的单词截为较短的单词	demonstration 简化为 demo refrigerator 简化为 fridge



词性 (Part of Speech, POS) 也称词类, 是根据词在句子中扮演的语法角色以及
与周围词的关系对词的分类。

例如: 表示事物的名字 (“钢琴”), 地点 (“上海”) 通常被归为**名词**
而表示动作 (“踢”), 状态 (“存在”) 的词被归为**动词**

词可以分为实义词 (Content Words) 和功能词 (Function Words)

- **实义词表达具体的意义**。由于实义词可以不断地增加, 因此这类词又被称作开类词 (Open class words)。实义词主要包含名词、动词、形容词等。
- **功能词则主要是为了满足语法功能需求**。由于功能词相对比较稳定, 一个语言中通常很少增加新的功能词, 因此功能词又被称作闭类词 (Close Class Words)。如介词、冠词、连接词等, 一般作为**停用词**处理。



名词 (Noun) 是表示人、物、地点以及抽象概念的一类词。

例如：

- 1) 专有名词: Shanghai (上海) New York (纽约)
- 2) 类名词: city (城市) bird (鸟)
- 3) 集体名词: family (家庭) army (军队)
- 4) 物质名词: water (水) light (光)
- 5) 抽象名词: music (音乐) honesty (诚实)



动词 (Verb) 是表示动作或状态的一类词，是英语中最复杂的一类词。

例如：

- 1) Boys fly kites. (男孩们放风筝)
- 2) 不及物动词: Birds fly. (鸟会飞)
- 3) 连系动词: The rose smells sweet. (玫瑰花香)
- 4) 助动词: I may have meet him before. (我以前应该见过他)
- 5) 限定动词: John reads papers every day. (约翰每天都读论文)
- 6) 不限定动词: I hope to see you this morning. (我希望早上见到你)
- 7) 短语动词: Tom called up George. (汤姆给乔治打了电话)



形容词 (Adjective) 是用来描写或修饰名词的一类词。

例如：

1) 简单形容词：

a) 由一个单词构成 good (好的) long (长的)

b) 由现在分词构成 interesting (令人感兴趣的)

c) 由过去分词构成 learned (博学的)

2) 复合形容词：duty-free (免税的) hand-made (手工制作的)

3) 限制性形容词：an Italian dish (一道意大利菜)

4) 描述性形容词：a delicious Italian dish (一道美味的意大利菜)



副词 (Adverb) 是用来修饰动词、形容词、其他副词以及全句的词。

例如：

- 1) 简单副词: just (刚刚) only (仅仅)
- 2) 复合副词: somehow (不知怎地) somewhere (在某处)
- 3) 派生副词: interesting '→ ' interestingly (有趣地)
- 4) 方式副词: quickly (迅速) awkwardly (笨拙地)
- 5) 方向副词: outside (外面) inside (里面)
- 6) 时间副词: recently (最近) always (总是)
- 7) 强调副词: very (很) fairly (相当)



数词 (Numeral) 是表示数目多少或者先后顺序的一类词。

例如：

- 1) 基数词: one (1) nineteen (19)
- 2) 序数词: first (第一) fiftieth (第五十)



代词 (Pronoun) 是代替名词以及起名词作用的短语、子句和句子的一类词。

例如：

- 1) 人称代词：
 - a) 主格: I, you, he, she, it, we, they
 - b) 宾格: me, you, him, her, it, us, them
- 2) 物主代词：
 - a) 形容词性物主代词: my, your, his, her, its, our, their
 - b) 名词性物主代词: mine, yours, his, hers, its, ours, theirs
- 3) 自身代词: myself, yourself, himself, herself, itself, ourselves, yourselves, themselves, oneself
- 4) 相互代词: each other, one another
- 5) 指示代词: this, that, these, those
- 6) 疑问代词: who, whom, whose, which, what
- 7) 关系代词: who, whom, whose, which, that, as
- 8) 不定代词: some, something, somebody, someone, any, anything, anybody, anyone, no, nothing, nobody, no one



冠词 (Article) 是置于名词之前，说明名词所指的人或事物的一种功能词。

冠词不能够离开名词而独立存在。英语中冠词有三种冠词：**定冠词** (Definite article) “the”、**不定冠词** (Indefinite article) “a/an”和**零冠词** (Zero article) 。

Water boils at 100°C.

The water in this river is undrinkable.



介词 (Preposition) 又称前置词，是用于表示名词或相当于名词的词语与句中其它词语的关系的一类词。介词在句子中不单独作为任何句子成分。介词后面的名词或者相当于名词的词语叫做介词宾语，与介词共同组合成介词短语。

例如：

- 1) 简单介词: at, in, of, since
- 2) 复合介词: as for, as to, out of
- 3) 二重介词: from under, from behind
- 4) 短语介词: according to, because of
- 5) 分词介词: including, regarding



连词 (Conjunction) 是连接单词、短语、从句或句子的一类词。在句子中也不单独作为句子成分。

例如：

- 1) 简单连词: and, or, but, if
- 2) 关联连词: both ... and, not only ... but also
- 3) 分词连词: supposing, considering
- 4) 短语连词: as if, as long as, in order that
- 5) 并列连词: and, or, but, for
- 6) 从属连词: that, whether, when, because



感叹词 (Interjection) 是用来表示喜怒哀乐等情绪或情感的一类词。感叹词也没有实际意义，也不能在句子中构成任何句子成分，但是与全句有关联。

例如：

'Oh ', it' s you. 啊，是你

'Ah ', how pitiful! 呀，多可惜



在语言学研究中，对于词性划分的标准、依据甚至目的等都存在大量分歧。到目前为止，还没有一个被广泛认可的统一划分标准。

在不同的语料集中所采用的划分粒度和标记符号也都不尽相同。

- 英语宾州树库（Penn TreeBank）使用了 48 种不同的词性
- 汉语宾州树库（Chinese Penn Treebank）中汉语词性被划分为 33 类
- 布朗语料库（Brown Corpus）中则使用了具有 87 个词性



词语规范化 (Word Normalization) 任务是将单词或词形转化为标准形式，针对有多种形式的单词使用一种单一的形式进行表示。

在对自然语言文本进行分析前，通常需要对文本进行规范化的处理。文本的规范化处理主要包含**句子切分**、**词语切分**、**词语规范化**等步骤。

由于绝大部分语言的句子结束符数量有限，符号歧义性相对容易处理，因此句子切分通过词典结合模板或者有监督分类方法都可以达到较高的准确率。

本章主要内容

2.1

语言中的词汇

2.2

词语规范化

2.2.1 词语切分

2.2.2 词形还原

2.2.3 词干提取

2.3

中文分词

2.4

词性标注



对于绝大部分的印欧语系语言来说，词语之间通常由分隔符区分开来。

- 英语是**印欧语系** (Indo-European languages) 的典型代表，英语句子中绝大部分单词之间都由空格或标点分割。
- 汉语为代表的**汉藏语系** (Sino-Tibetan languages) 的语言中，单词之间通常没有分隔符。因此在对文本进行分析前，通常需要将句子切分为单词序列，称之为**词语切分** (Word Tokenization) 。

输入： Let's first understand what's NLP.

输出： Let_'s_first_understand_what_'s_NLP_.



英语句子中绝大部分的单词可以通过**空格**和**标点符号**为分隔符进行识别，但是还是存在一些例外情况

例如：缩写（Prof.），日期（02/18/2022），数字（562,000），连字符（upper-case）等。


需要特别注意的是，上例中Let's被切分为 Let_ 's

词形(Token)指的是在一个特定文档中的某个能够表达语义含义的字符序列。

大部分情况下**词形**和**单词**没有区别，但对于某些场景和算法有必要对单词和词形进行区分。



WhisperX



```

35 00:01:51.604 --> Five years ago.
36 00:01:53.187 --> Last time you came to TED, I asked you about full self-driving, and you said,
37 00:01:58.347 --> yep, this very year, I am confident that we will have a car going from LA to New York
38 00:02:05.789 --> without any intervention.
39 00:02:07.629 --> Yeah, I don't want to blow your mind, but I'm not always right.
40 00:02:12.350 --> So what's the difference between those two?
41 00:02:15.510 --> Why has full self-driving, in particular, been so hard to predict?
42 00:02:20.112 --> I mean, the thing that really got me, and I think it's going to get a lot of other people,
43 00:02:23.353 --> is that there are just so many false dawns with self-driving, where you think you've
44 00:02:30.555 --> got the problem, have a handle on the problem, and then it, nope, it turns out...
45 00:02:36.379 --> uh... you just hit a ceiling uh... and and uh...
46 00:02:40.463 --> uh...
47 00:02:40.663 --> because what happened if you were to plot the progress
48 00:02:44.287 --> the progress looks like a log curve
49 00:02:45.989 --> so it's like a series of log curves so
50 00:02:49.412 --> uh... most people don't know what a log curve is i suppose but
51 00:02:53.938 --> It goes up sort of a fairly straight way and then it starts tailing off and you start getting diminishing returns.
52 00:03:02.346 --> In retrospect, they seem obvious, but in order to solve full self-driving properly, you actually have to solve real-world AI.
53 00:03:12.196 --> Because you say, like, what are the road networks designed to work with?
54 00:03:16.859 --> They're designed to work with a biological neural net, our brains, and with vision, our eyes.

```



在英语中，一些特殊的符号和数字也需要完整的保留到一起。

- 比如数字（67.20）、时间（22:37）、微博话题标签（#北京2022年冬奥会#）、Email地址（cs_nlp@fudan.edu.cn）等。
- 在特定的应用中有时也会将 Hong Kong, Head, Shoulders, Knees and Toes划分为一个词形

通常情况下针对英语等印欧语系语言的词语切分任务可以采用基于有限状态自动机（Finite State Automata）融合正则表达式的方法完成。



词形还原 (Lemmatization) 是将词的各种变化形式还原其**词根**的过程。通过词形还原可以实现词语的规范化，单词的不同变化形式统一为词根。

例如：原始输入句：They are working on interesting tasks

词形还原后：they **be work** on interesting **task**

词形分析是将一个词分解成为语素的过程。对于英语来说，构造包含所有绝大多数词形的词典能够有效地支撑许多应用场景。

例如：土耳其语词汇 *uygarlaştıramadıklarımızdanmışsınızcasına* 是由以下 10 项变换组合而成^[45]：

uygar	+la	+tr	+ama	+dk	+lar	+mz	+dan	+m	+snz	+casna
civilized	+BEC	+CAUS	+NABL	+PART	+PL	+P1PL	+ABL	+PAST	+2PL	+AsIf



对于某些语言（特别是土耳其语、阿拉伯语等黏着语系的语言）枚举所有词的词形变换则是不可能的

例如：土耳其语词汇 `uygarlaştıramadıklarımızdanmışsınızcasına` 是由以下 10 项变换组合而成^[45]：

<code>uygar</code>	<code>+la</code>	<code>+tr</code>	<code>+ama</code>	<code>+dk</code>	<code>+lar</code>	<code>+mz</code>	<code>+dan</code>	<code>+m</code>	<code>+snz</code>	<code>+casna</code>
<code>civilized</code>	<code>+BEC</code>	<code>+CAUS</code>	<code>+NABL</code>	<code>+PART</code>	<code>+PL</code>	<code>+P1PL</code>	<code>+ABL</code>	<code>+PAST</code>	<code>+2PL</code>	<code>+AsIf</code>

`+BEC` “变成”(become)

`+CAUS` 标识使役动词

`+NABL` “不能”(not able)

`+PART` 过去分词

`+PL` 名词复数

`+P1PL` 第一人称复数所有格

`+ABL` 表来源的离格 (ablative (from/among) case maker)

`+PAST` 带过去时的间接引语 (indirect/inferential past)

`+AsIf` 从限定动词 (finite verb) 派生出的副词



词干提取 (Stemming) 是词形分析的简化版本，其目标是将具有词形变化（通常是屈折或派生）的词语还原为其词干 (Word Stem)

与词形分析不同，词干提取并不要求还原的词干一定与其语言学词根完全一致，只需要将相关的单词映射为统一的词干。

例如：词干提取算法 Porter Stemmer

argue, argued, argues, arguing, 以及 argus 都转换为 argu.



最简单的词干提取算法可以通过查询词表的方法获得

另外一种方法是**后缀剥离** (Suffix-stripping) , 通过定义一组规则, 将特定的后缀从词形中删除

例如:

如果单词以ed 结尾, 则删除ed

如果单词以ing 结尾, 则删除ing

如果单词以ly结尾, 则删除ly

但是无法处理特殊变形 (如: ran, took 等)



后缀替代 (Suffix Substitution) 算法将单词后缀替换为另外一个后缀。

例如：

如果单词以 'ational' 结尾, 则替换为 'ate' (relational → relate)

如果单词以 'ing' 结尾, 则替换为 'ε' (working → work)

如果单词以 'zzes' 结尾, 则替换为 'Z' (quizzes → quiz)

本章主要内容

2.1

语言中的词汇

2.2

词语规范化

2.3

中文分词

2.3.1 中文分词概述

2.3.2 基于最大匹配的中文分词

2.3.3 基于线性链条件随机场的中文分词

2.3.4 基于感知器的中文分词

2.3.5 基于双向长短期记忆网络的中文分词

2.3.6 中文分词评价方法

2.3.7 中文分词语料库

2.4

词性标注



以英语为代表的印欧语系中词之间通常有分隔符（空格等）来区分，词可以比较容易地从句子中分割得到。

以汉语为代表的汉藏语系，以及以阿拉伯语为代表的闪-含语系（Semito-Hamitic languages）中却不包含明显的词之间的分隔符，而是由一串连续的字符构成。

因此，针对汉语等语言的处理算法通常首先需要进行词语切分。



中文分词 (Chinese Word Segmentation, CWS) 是指将连续字序列转换为对应的词序列的过程，也可以看做在输入的序列中添加空格或其他边界标记的过程。

例如：

复旦大学是中国人自主创办的第一所高等院校

分词结果：复旦大学 | 是 | 中国人 | 自主 | 创办 | 的 | 第一 | 所 | 高等 | 院校

由于汉语中语素绝大部分是单个汉字，很多情况下单独使用时也是词语，不单独使用时又是构词成分，这使得汉语构词具有很大的灵活性和很强的组词能力。



正是因为汉语的这些特点，中文分词任务面临了巨大的挑战
主要困难来自以下三个方面：**分词规范**、**歧义切分**和**未登录词识别**。

什么是词？（词的具体界定）

两个不清的界限

✧ 单字词与词素之间的划界

如：新华社25日**讯** vs. 通**讯**

✧ 词与短语（词组）的划界

短语是词和词结合起来构成的，可是词和词联在一起并非都是短语。如：铁路，人家、大雨、大衣

“大雨”可以说成“大的雨”，是短语

“大衣”不能说成“大的衣”，是词



正是因为汉语的这些特点，中文分词任务面临了巨大的挑战
主要困难来自以下三个方面：**分词规范**、**歧义切分**和**未登录词识别**。

汉语中对词的具体界定目前还没有定论。1992 年国家标准局颁布的《信息处理用现代汉语分词规范》中大部分规定都是通过举例和定性描述来体现。

例如：“二字或三字词，以及结合紧密、使用稳定的二字或三字词组，一律为分词单位。”

如何定量计算？



北京大学计算语言研究所《北京大学语料库加工规范》

- (1) 人名 (nr): 汉族方式的“姓”和“名”单独切分, “姓”标注为 nrf, “名”标注为 nrg。例如: 李/nrf 明/nrg, 欧阳/nrf 洪涛/nrg;
- (2) 地名 (ns): 国名不论长短, 作为一个切分单位, 地名后有“省”、“市”等单字的现代行政区划名称时, 不切分开, 如果地名后的行政区划有两个以上的汉字, 则将地名同行政区划名称切开。例如: 中华人民共和国/ns, 上海市/ns, [深圳/ns 特区/n]ns;
- (3) 机构名 (nt): 一般是短语型的, 较长, 且含有地名或人名等专名, 按照参考文献 [47] 给出的规范需要先切分, 再组合, 加方括号标注为 nt。例如: [中国/ns 中文/n 信息/n 学会/n]nt, [复旦/ns 大学/n]nt;
- (4) 数词与数量词组: 基数、序数、小数、分数、百分数一律不予切分, 约数, 前加副词、形容词或后加“来、多、左右”等助数词的应予切分。例如: 一百二十三/m, 约/d 一百/m 多/m 万/m;
- (5) 时间词: 年月日时分秒, 按年、月、日、时、分、秒切分, “牛年、虎年”等一律不予切分, 标注为 t。例如: 2021 年/t 9 月/t 16 日/t, 牛年/t;
- (6) 成语习语: 四个字的成语或习用语为一个切分单位, 除标注其词类标记 i 或 l 外, 还要求根据其在句子中的功能进一步标注子类, 超过四个字的成语或习用语, 一般不予切分, 不分子类。例如: 胸有成竹/iv, 近水楼台先得月/i;



由于汉语构词方式的灵活性，使得同一个汉语句子很可能产生多个不同的分词结果，这些不同的分词结果也被称为**切分歧义**。

例如：南京市长江大桥

切分方式 1：南京市 | 长江大桥

切分方式 2：南京 | 市长 | 江大桥



交集型切分歧义是指汉字串 AJB 中，AJ、JB 都可以分别组成词汇，则汉字串 AJB 被称为**交集型切分歧义**，此时汉字串 J 称作**交集串**。

交集型切分歧义也被称为**偶发歧义**，当两个有交集的词“偶然”的相邻出现时这样的歧义才会发生。

例：中国人为了实现自己的梦想

✓ 中国 / 人为 / 了 / 实现 / 自己 / 的 / 梦想

✓ 中国人 / 为了 / 实现 / 自己 / 的 / 梦想


✓ 中 / 国人 / 为了 / 实现 / 自己 / 的 / 梦想

再例如：“大学生”、“研究生物”、“从小学起”、“为人民工作”、“中国产品质量”、“部分居民生活水平”等等



链长

一个交集型切分歧义所拥有的交集串的集合称为**交集串链**，它的**个数称为链长**。



- ✧ “结合”、“合成”、“成分”和“分子”均构成词
- ✧ 交集串的集合为 {合, 成, 分}
- ✧ 因此, 链长为3

类似地,

“为人民工作”

交集串链: {人, 民, 工}, 链长: 3

“中国产品质量”

交集串链: {国, 产, 品, 质}, 链长: 4

“部分居民生活水平”

交集串链: {分, 居, 民, 生, 活, 水}, 链长: 6



组合型切分歧义是指如果汉字串 AB 满足 A, B, AB 同时为词, 则汉字串 AB 被称为**组合型切分歧义**。

组合性切分歧义也称为**固有歧义**, 指的是词固有的属性, 不依赖于“偶然”发生的上下文。

例: 门把手弄坏了

✓ 门 / 把手 / 弄 / 坏 / 了

✓ 门 / 把 / 手 / 弄 / 坏 / 了

再例如: “将来”、“现在”、“才能”、“学生会”等, 都是组合型歧义字段。



真歧义是指如果汉字串 ABC 满足多种切分方式下语法和语义均没有问题, 只有**通过上下文环境**才能给出正确的切分结果, 则汉字串 ABC 被称为真歧义。

例如：白天鹅在水里游泳。

切分方式 1：白天 | 鹅 | 在 | 水 | 里 | 游泳 |。

切分方式 2：白天鹅 | 在 | 水 | 里 | 游泳 |。



未登录词 (Out Of Vocabulary, OOV) 又称生词 (Unknown Words), 是指在训练语料中没有出现或者词典当中没有, 但是在测试数据中出现的词。

- 基于词典的分词方法所指的未登录词是指所依赖的词典中没有的单词。
- 对于完全基于统计机器学习的方法, 未登录词是指训练语料中没有出现的单词。
- 对于融合词典特征的统计机器学习方法, 未登录词是指训练语料和词典中均未出现的词。



汉语具有很强的灵活性，未登录词的**类型也十分复杂**，可以粗略地将汉语文本中常见的未登录词分为以下类型：

- **新出现的普通词汇**：语言的使用会随着时代的变化而演化出新的词，这个过程在互联网环境中显得更为快速。（例如：粤康码、奥利给、吃播、云会议、绝绝子，给力，人艰不拆等。）
- **命名实体 (Named Entity)**：人名、地名、机构名等；（例如：盛中国，蔡国庆；高升，高山，夏天；彭太发生；平川三太郎，约翰·斯特朗）
- **专业名词**：出现在专业领域的词语（例如：偶氮二甲酸二乙酯，胞质溶胶）；
- **其他专有名词**：新出现的产品名、电影名、书籍名等。

宗成庆教授在新闻领域的语料也进行了分词错误分析，结果发现未登录词造成的分词错误超过 **98%**



最大匹配 (Maximum Matching) 分词算法试图根据给定的词典，利用贪心搜索策略找到分词方案

他是研究生的一位科学家

表 2.2 前向最大匹配分词过程示例

时间步	开始位置	候选匹配	输出
1	1	他是研究, 他是研, 他是, 他	他
2	2	是研究生, 是研究, 是研, 是	是
3	3	研究生物, 研究生, 研究, 研	研究
4	5	生物化学, 生物化, 生物, 生	生物化学
5	9	的一位科, 的一位, 的一, 的	的
6	10	一位科学, 一位科, 一位, 一	一
7	11	位科学家, 位科学, 位科, 位	位
8	12	科学家, 科学, 科	科学家

一有词典切分，机械切分

- 正向最大匹配算法 (Forward MM, FMM)
- 逆向最大匹配算法 (Backward MM, BMM)
- 双向最大匹配算法 (Bi-directional MM)

假设句子: $S = c_1c_2 \cdots c_n$, 某一词:



$w_i = c_1c_2 \cdots c_m$, m 为词典中最长词的字数。



例：假设词典中最长单词的字数为 7。

输入字符串：他是研究生物化学的一位科学家。

切分过程：



他/ 是研究生物化学的一位科学家。



FMM 切分结果：他/ 是/ 研究生/ 物化/ 学/ 的/ 一/ 位 / 科学家/ 。

BMM 切分：他是研究生物化学的一位科学家。



BMM 切分结果：他/ 是/ 研究/ 生物/ 化学/ 的/ 一/ 位/ 科学家/ 。



➤ 优点：

- 程序简单易行，开发周期短；
- 仅需要很少的语言资源（词表），不需要任何词法、句法、语义资源；


➤ 弱点：

- 歧义消解的能力差；
- 切分正确率不高，一般在95%左右。




例：(1) 输入字串：他只会诊断一般的疾病。


①准备：词典



②构建词图：



③贪婪组合：



输出候选： 他/ 只会/ 诊断/ 一般/ 的/ 疾病/。 (词个数： 7)

他/ 只/ 会诊/ 断/ 一般/ 的/ 疾病/。 (词个数： 8)

最终结果： 他/ 只会/ 诊断/ 一般/ 的/ 疾病/。



➤优点:

- 切分原则符合汉语自身规律;
- 需要的语言资源 (词表) 也不多。

➤弱点:

- 对许多歧义字段难以区分, 最短路径有多条时, 选择最终的输出结果缺乏应有的标准;
- 字串长度较大和选取的最短路径数增大时, 长度相同的路径数急剧增加, 选择最终正确的结果困难越来越大。

例(2) 输入字串: 他说的确实在理。

输出候选: 他/ 说/ 的/ 确实/ 在理/ 。 (词个数: 6)

他/ 说/ 的确/ 实在/ 理/ 。 (词个数: 6)

系统无法做正确性判断。




将分词过程转换为**对字的分类**问题（序列标注问题）

- 对于输入句子中的每一个字 c_i , 根据它在分词结果中的位置赋予不同的标签

开始 (B)、中间 (I)、结尾 (E) 以及单独成词 (S)

BEMS	解释
B	Begin, 表示词开始
M	Middle/Intermediate, 表示词中间
E	End, 表示词结尾
S	Single, 表示词是单个字





条件随机场 (Conditional Random Field, CRF) 试图对多个变量在给定观测值后的条件概率进行建模。 $x = \{x_1, x_2, \dots, x_n\}$ 为观测序列, $y = \{y_1, y_2, \dots, y_n\}$ 为对应的标记序列, 条件随机场的目标是构建条件概率模型 $P(y|x)$ 。




图 2.1 线性链条件随机场结构图



条件随机场使用势函数和图结构上的团来定义条件概率 $P(y|x)$ 。给定观测序列 x ，线性链式条件随机场主要包含两种关于标记变量的团：单个标记变量 y_i 和相邻的标记变量 y_{i-1}, y_i 。选用指数势函数并引入特征函数 (Feature Function)。

$$P(y|x) = \frac{1}{Z(x)} \exp \left(\sum_j \sum_{i=2}^n \lambda_j t_j(x, y_i, y_{i-1}, i) + \sum_k \sum_{i=1}^n \mu_k s_k(x, y_i, i) \right) \quad (2.1)$$

$$Z(x) = \sum_y \exp \left(\sum_j \sum_{i=2}^n \lambda_j t_j(x, y_i, y_{i-1}, i) + \sum_k \sum_{i=1}^n \mu_k s_k(x, y_i, i) \right) \quad (2.2)$$

$t_j(x, y_i, y_{i-1}, i)$ 是**转移特征函数** (Transition feature function)，用于刻画相邻标记之间的相关关系观测序列对它们的影响；

$s_k(x, y_i, i)$ 是**状态特征函数** (Status feature function)，用于刻画观测序列对标记变量的影响；

$Z(x)$ 为**规范化因子**，在所有可能的输出序列上进行求和



针对中文分词任务，典型的转移特征如下：

$$t_j(x, y_i, y_{i-1}, i) = \begin{cases} 1 & \text{if } x_i = \text{“复”} \text{ 并且 } y_i = \text{“B”} \text{ 并且 } y_{i-1} = \text{“E”} \\ 0 & \text{otherwise} \end{cases}$$

表示第 i 个观测值为 “复” 时，相应的标记 y_i 和 y_{i-1} 很可能分别为 B 和 E

典型的状态特征如下：

$$s_j(x, y_i, i) = \begin{cases} 1 & \text{if } x_i = \text{“上”} \text{ 并且 } y_i = \text{“B”} \\ 0 & \text{otherwise} \end{cases}$$


表示第 i 个观测值为 “上” 时，相应的标记 y_i 很可能为 B。




观察序列X (汉字)

方案1标签序列Y₁ (BE/BE/BE)方案2标签序列Y₂ (BME/S/BE)

示例句子: "研究生命科学"



方案2: 研究生/命/科学





步骤1：定义特征函数

基于"研究生命科学"例子

状态特征函数 $s(x, y_i, i)$

$s_1(x, y_i, i) = 1$ 如果 $x_i = \text{"研"}$ 且 $y_i = \text{"B"}$; 否则为0

$s_2(x, y_i, i) = 1$ 如果 $x_i = \text{"究"}$ 且 $y_i = \text{"E"}$; 否则为0

$s_3(x, y_i, i) = 1$ 如果 $x_i = \text{"究"}$ 且 $y_i = \text{"M"}$; 否则为0

$s_4(x, y_i, i) = 1$ 如果 $x_i = \text{"生"}$ 且 $y_i = \text{"B"}$; 否则为0

$s_5(x, y_i, i) = 1$ 如果 $x_i = \text{"生"}$ 且 $y_i = \text{"E"}$; 否则为0

$s_6(x, y_i, i) = 1$ 如果 $x_i = \text{"命"}$ 且 $y_i = \text{"B"}$; 否则为0

$s_7(x, y_i, i) = 1$ 如果 $x_i = \text{"命"}$ 且 $y_i = \text{"E"}$; 否则为0

$s_8(x, y_i, i) = 1$ 如果 $x_i = \text{"命"}$ 且 $y_i = \text{"S"}$; 否则为0

转移特征函数 $t(x, y_i, y_{\{i-1\}}, i)$

$t_1(x, y_i, y_{\{i-1\}}, i) = 1$ 如果 $y_{\{i-1\}} = \text{"B"}$ 且 $y_i = \text{"E"}$; 否则为0

$t_2(x, y_i, y_{\{i-1\}}, i) = 1$ 如果 $y_{\{i-1\}} = \text{"B"}$ 且 $y_i = \text{"M"}$; 否则为0

$t_3(x, y_i, y_{\{i-1\}}, i) = 1$ 如果 $y_{\{i-1\}} = \text{"M"}$ 且 $y_i = \text{"E"}$; 否则为0

$t_4(x, y_i, y_{\{i-1\}}, i) = 1$ 如果 $y_{\{i-1\}} = \text{"E"}$ 且 $y_i = \text{"B"}$; 否则为0

$t_5(x, y_i, y_{\{i-1\}}, i) = 1$ 如果 $y_{\{i-1\}} = \text{"E"}$ 且 $y_i = \text{"S"}$; 否则为0

步骤2：设定特征权重

特征函数的学习权重值

状态特征权重		
特征函数	描述	权重 μ
s_1	研-B	1.5
s_2	究-E	1.2
s_3	究-M	0.8
s_4	生-B	1.3
s_5	生-E	1.1
s_6, s_7, s_8	命-B, 命-E, 命-S	0.9, 1.0, 0.7

转移特征权重		
特征函数	描述	权重 λ
t_1	B-E转移	1.4
t_2, t_3	B-M转移, M-E转移	0.9, 1.0
t_4, t_5	E-B转移, E-S转移	1.2, 0.8



步骤3：计算方案1的非归一化概率

方案1："研究/生命/科学" (B-E-B-E-B-E)

研 B	究 E	生 B	命 E	科 B	学 E
--------	--------	--------	--------	--------	--------

状态特征计算			
位置	激活的特征	权重	贡献
i=1 (研-B)	$s_1(x, y_1, 1)=1$	$\mu_1=1.5$	1.5
i=2 (究-E)	$s_2(x, y_2, 2)=1$	$\mu_2=1.2$	1.2
i=3 (生-B)	$s_4(x, y_3, 3)=1$	$\mu_4=1.3$	1.3
i=4 (命-E)	$s_7(x, y_4, 4)=1$	$\mu_7=1.0$	1.0
状态特征总贡献:			5.0

转移特征计算			
位置	激活的特征	权重	贡献
i=2 (B→E)	$t_1(x, y_2, y_1, 2)=1$	$\lambda_1=1.4$	1.4
i=3 (E→B)	$t_4(x, y_3, y_2, 3)=1$	$\lambda_4=1.2$	1.2
i=4,5,6	B→E,E→B,B→E	$\lambda=1.4, 1.2, 1.4$	4.0
转移特征总贡献:			6.6

总得分: $5.0 + 6.6 = 11.6$ 非归一化概率: $\exp(11.6) \approx 109,196.83$



步骤1：定义特征函数

基于"研究生命科学"例子

研究生/命/科学

步骤2：设定特征权重

特征函数的学习权重值

状态特征函数 $s(x, y_i, i)$ $s_1(x, y_i, i) = 1$ 如果 $x_i = \text{"研"}$ 且 $y_i = \text{"B"}$; 否则为0 $s_2(x, y_i, i) = 1$ 如果 $x_i = \text{"究"}$ 且 $y_i = \text{"E"}$; 否则为0 $s_3(x, y_i, i) = 1$ 如果 $x_i = \text{"究"}$ 且 $y_i = \text{"M"}$; 否则为0 $s_4(x, y_i, i) = 1$ 如果 $x_i = \text{"生"}$ 且 $y_i = \text{"B"}$; 否则为0 $s_5(x, y_i, i) = 1$ 如果 $x_i = \text{"生"}$ 且 $y_i = \text{"E"}$; 否则为0 $s_6(x, y_i, i) = 1$ 如果 $x_i = \text{"命"}$ 且 $y_i = \text{"B"}$; 否则为0 $s_7(x, y_i, i) = 1$ 如果 $x_i = \text{"命"}$ 且 $y_i = \text{"E"}$; 否则为0 $s_8(x, y_i, i) = 1$ 如果 $x_i = \text{"命"}$ 且 $y_i = \text{"S"}$; 否则为0

状态特征权重

特征函数	描述	权重 μ
s_1	研-B	1.5
s_2	究-E	1.2
s_3	究-M	0.8
s_4	生-B	1.3
s_5	生-E	1.1
s_6, s_7, s_8	命-B, 命-E, 命-S	0.9, 1.0, 0.7

转移特征函数 $t(x, y_i, y_{i-1}, i)$ $t_1(x, y_i, y_{i-1}, i) = 1$ 如果 $y_{i-1} = \text{"B"}$ 且 $y_i = \text{"E"}$; 否则为0 $t_2(x, y_i, y_{i-1}, i) = 1$ 如果 $y_{i-1} = \text{"B"}$ 且 $y_i = \text{"M"}$; 否则为0 $t_3(x, y_i, y_{i-1}, i) = 1$ 如果 $y_{i-1} = \text{"M"}$ 且 $y_i = \text{"E"}$; 否则为0 $t_4(x, y_i, y_{i-1}, i) = 1$ 如果 $y_{i-1} = \text{"E"}$ 且 $y_i = \text{"B"}$; 否则为0 $t_5(x, y_i, y_{i-1}, i) = 1$ 如果 $y_{i-1} = \text{"E"}$ 且 $y_i = \text{"S"}$; 否则为0

转移特征权重

特征函数	描述	权重 λ
t_1	B-E转移	1.4
t_2, t_3	B-M转移, M-E转移	0.9, 1.0
t_4, t_5	E-B转移, E-S转移	1.2, 0.8



步骤3b: 计算方案2的非归一化概率

方案2: "研究生/命/科学" (B-M-E-S-B-E)

研	究	生	命	科	学
B	M	E	S	B	E

状态特征计算

位置	激活的特征	权重	贡献
i=1 (研-B)	$s_1(x, y_1, 1)=1$	$\mu_1=1.5$	1.5
i=2 (究-M)	$s_3(x, y_2, 2)=1$	$\mu_3=0.8$	0.8
i=3 (生-E)	$s_5(x, y_3, 3)=1$	$\mu_5=1.1$	1.1
i=4 (命-S)	$s_8(x, y_4, 4)=1$	$\mu_8=0.7$	0.7
状态特征总贡献:			4.1

转移特征计算

位置	激活的特征	权重	贡献
i=2 (B→M)	$t_2(x, y_2, y_1, 2)=1$	$\lambda_2=0.9$	0.9
i=3 (M→E)	$t_3(x, y_3, y_2, 3)=1$	$\lambda_3=1.0$	1.0
i=4 (E→S)	$t_5(x, y_4, y_3, 4)=1$	$\lambda_5=0.8$	0.8
i=6 (B→E)	$t_1(x, y_6, y_5, 6)=1$	$\lambda_1=1.4$	1.4
转移特征总贡献:			4.1

总得分: $4.1 + 4.1 = 8.2$ 非归一化概率: $\exp(8.2) \approx 3,641.37$



步骤4：计算归一化因子 $Z(x)$

$Z(x)$ = 所有可能标记序列 Y 的非归一化概率之和

$$Z(x) = \sum_{y,j,i,k} \exp(\sum \lambda_j t_j(x, y_i, y_{i-1}, i) + \sum \mu_k s_k(x, y_i, i))$$

归一化因子计算

标记序列	特征得分	非归一化概率	贡献
方案1: B-E-B-E-B-E	11.6	$\exp(11.6) \approx 109,196.83$	109,196.83
方案2: B-M-E-S-B-E	8.2	$\exp(8.2) \approx 3,641.37$	3,641.37

$$\text{归一化因子 } Z(x) = 109,196.83 + 3,641.37 = 112,838.20$$

注：实际情况中可能存在更多的标记序列，这里只考虑两个主要方案



步骤5：计算条件概率 $P(Y|X)$

计算标记序列的真实条件概率

$$P(Y|X) = \exp\left(\sum_{j,i} \lambda_j t_j(x, y_i, y_{i-1}, i) + \sum_{k,i} \mu_k s_k(x, y_i, i)\right) / Z(X)$$

方案1: 研究/生命/科学 (B-E-B-E-B-E)

$$P(Y_1|X) = \exp(11.6) / Z(X) = 109,196.83 / 112,838.20 \approx 0.9676 = 96.76\%$$

方案2: 研究生/命/科学 (B-M-E-S-B-E)

$$P(Y_2|X) = \exp(8.2) / Z(X) = 3,641.37 / 112,838.20 \approx 0.0324 = 3.24\%$$



中文分词可以定义为将**连续字序列转换为对应的词序列**的过程。

$x = \{c_1, c_2, \dots, c_n\}$ 表示输入字序列, $y = \{w_1, w_2, \dots, w_m\}$ 表示输出词序列

$F(x)$ 表示最优分词结果

中文分词可以形式化地表达为:

$$F(x) = \arg \max_{y \in \text{GEN}(x)} \text{SCORE}(y)$$

$\text{GEN}(x)$ 代表对于每一个输入句子 x 可能的所有候选输出, $\text{SCORE}(y)$ 为针对分词结果 y 的评分函数。

将每一个分词后的单词序列 y 定义为一个特征向量 $\Phi(x, y)$

$$\text{SCORE}(y) = \Phi(x, y) \cdot \alpha$$



将中文分词任务转化为上述问题后，需要解决如下三个问题：

问题 1：词序列预测 在给定模型参数 α 和输入字序列 $x = \{c_1, c_2, \dots, c_n\}$ 的情况下，如何得到最优的词序列 $y = \{w_1, w_2, \dots, w_m\}$ ，即模型解码算法。

问题 2：模型参数学习 在给定训练语料 $\{x_i, y_i\}$ 的情况下，如何调整模型参数 α ，使其能针对训练语料得到最好的分词结果，即模型参数学习算法。

问题 3：特征定义 给定输入字序列 x 和分词后的词序列 y ，如何定义特征对词序列进行描述，并能够区分分词序列的优劣，即构建特征向量 $\Phi(x, y) \in \mathbb{R}^d$ 。



问题 1：词序列预测 在给定模型参数 α 和输入字序列 $x = \{c_1, c_2, \dots, c_n\}$ 的情况下，如何得到最优的词序列 $y = \{w_1, w_2, \dots, w_m\}$ ，即模型解码算法。

使用**集束搜索**（Beam Search）算法进行解码，在每一步解码过程中，从上一步解码的所有候选集中选取前 K 个得分最高的结果继续解码

代码 2.1: 基于感知器中文分词解码算法

```
输入: 待分词汉字序列  $x = \{c_1, c_2, \dots, c_n\}$ 
输出: 分词结果  $y = \{w_1, w_2, \dots, w_m\}$ 
src = [], tgt = []; // 初始化;
for  $i = 1$  to  $n$  do
    foreach  $item \in src$  do
        item1 =  $c_i$ ;                // 当前字作为新词的开始;
        item2 = item[item.length] +  $c_i$ ; // 当前字附加到 item 最后一个候选词上;
        tgt 中添加 item1 和 item2;
    end
    使用评分函数 SCORE 对 tgt 中所有分词结果进行打分;
    对 tgt 中的评分结果进行排序, 保留前  $K$  个;
    src = tgt;
    tgt = [];
end
return src[1]; // 返回 src 中最好结果
```

基本思路:

针对输入的句子 x ，解码器每次读入一个字 c_i ，根据候选词队列，采用两种方法扩充候选结果：

- (1) 作为下一个词的开始;
- (2) 添加到上一个候选词的末尾。

对现有的候选分词结果进行评分，保留得分最高的前 K 个候选分词结果。

重复上述过程，直到句子结束，输出得分最高的分词结果。



输入句子: "我喜欢自然语言处理"

集束宽度 $K = 2$ (保留前2个最高得分候选)

步骤1: 处理字符"我"

候选1: [我]

得分: 5.2

操作: 作为单独一词

候选2: []

得分: 0.0

操作: 开始一个新词



步骤2: 处理字符"喜"

候选1: [我][喜]

得分: $5.2 + 1.5 = 6.7$

操作: "喜"作为新词

候选2: [我喜]

得分: 2.8

操作: "喜"添加到"我"后



步骤3: 处理字符"欢"

从候选1扩展: [我][喜欢], [我][喜][欢]

从候选2扩展: [我喜欢], [我喜][欢]

候选1: [我][喜欢]

得分: $5.2 + 4.8 = 10.0$

操作: "欢"添加到"喜"后

候选2: [我喜欢]

得分: 4.1

操作: "欢"添加到"我喜"后



步骤4-7: 继续处理"自然语言处理"...

类似地, 继续处理后续字符, 生成候选并评分

每一步只保留得分最高的K个候选 (本例中K=2)


处理完所有字符后, 返回得分最高的候选作为最终结果

最终结果

最优分词结果: [我][喜欢][自然语言][处理]

总得分: 21.8

注: 在实际应用中, 集束宽度K通常为10~50, 以权衡精度和效率



图例:

- 得分最高的候选
- 得分第二的候选
- 得分第三的候选
- 未被选择的候选 (得分较低)
- 最终选择的最优解

集束搜索解码过程 (K=3):

1. 从左到右处理每个字符
2. 每个候选在扩展时有两种选择:
 - 将当前字符作为新词的开始
 - 将当前字符添加到已有词的末尾
3. 每步只保留得分最高的K个候选 (本例中K=3)
4. 处理完所有字符后, 选择得分最高的路径作为最终结果
5. 较大的K值增加准确率, 但也增加计算复杂度



问题 2：模型参数学习 在给定训练语料 $\{x_i, y_i\}$ 的情况下，如何调整模型参数 α ，使其能针对训练语料得到最好的分词结果，即模型参数学习算法。

代码 2.2: 基于感知器算法的评分函数训练算法

输入: 训练数据 $D = (x_i, y_i)$

输出: 模型参数 α

for $i = 1$ **to** T **do** // T 轮迭代;

foreach $(x, y) \in D$ **do**

$z = \arg \max_{y \in \text{GEN}(x)} \text{SCORE}(y);$ // 使用算法 2.1 给出的解码算法;

if $z \neq y$ **then**

$\alpha = \alpha + \Phi(x, y) - \Phi(x, z);$

end

end

end

return α

对训练语料中每一个句子，根据现有模型参数进行解码得到分词结果，与正确答案进行比对，如果结果错误则更新参数 α



问题 3：特征定义 给定输入字序列 x 和分词后的词序列 y ，如何定义特征对词序列进行描述，并能够区分分词序列的优劣，即构建特征向量 $\Phi(x, y) \in \mathbb{R}^d$ 。

表 2.4 基于感知器的中文分词算法所使用特征模板样例^[52]

编号	模板	编号	模板
1	单词 w	8	所有单词的第一个与最后一个字符 c_1 和 c_2
2	二元单词 w_1w_2	9	字符 c 的前一个词 w
3	单字符单词 w	10	单词 w 之后的第一个字 c
4	初始字符 c 以及长度 l	11	两个连续单词的第一个字符 c_1 和 c_2
5	终止字符 c 以及长度 l	12	两个连续单词的最后一个字符 c_1 和 c_2
6	由空格隔开的字符 c_1 和 c_2	13	单词长度 l 以及之前的词 w
7	二元字符 c_1c_2	14	单词的长度 l 以及之后的单词 w

基于感知器的方法可以**使用词**作为特征，而基于线性链条件随机场的方法**只能使用字**作为特征



将分词过程转换为**对字的分类**问题





图 2.3 基于 BiLSTM+CRF 的神经网络分词模型框架



基于 BiLSTM+CRF 的神经网络命名实体识别模型框架



步骤1：输入处理

将输入句子拆分为单个字符序列

我爱自然语言处理



我

爱

自

然

语

言


处

理



步骤2：字符嵌入


将每个字符转换为低维稠密向量表示





步骤3：双向LSTM处理

前向LSTM从左到右处理序列，后向LSTM从右到左处理序列



在解析"自"字时的上下文信息:

前向LSTM已经看到了"我爱自"的上下文
后向LSTM已经看到了"自然语言处理"的上下文




图 2.2 LSTM 网络循环单元结构

输入门 i_t 、输出门 o_t 和遗忘门 f_t 的计算方式为：

$$i_t = \sigma(W_i x_i + U_i h_{t-1} + b_i)$$

$$f_t = \sigma(W_f x_i + U_f h_{t-1} + b_f)$$

$$o_t = \sigma(W_o x_i + U_o h_{t-1} + b_o)$$

候选状态 $\tilde{c}_t$ 、内部状态 c_t 以及隐藏输出 h_t ：

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c)$$

$$c_t = f_t \otimes c_{t-1} + i_t \otimes \tilde{c}_t$$

$$h_t = o_t \otimes \tanh(c_t)$$





图 1.6 本书的知识体系

<https://nndl.github.io/nndl-book.pdf>



$$\text{精确率 (P)} = \frac{\text{算法输出的正确分词结果个数}}{\text{算法输出的全部分词结果个数}} \times 100\%$$

$$\text{召回率 (R)} = \frac{\text{算法输出的正确分词结果个数}}{\text{测试集合中全部答案个数}} \times 100\%$$

$$F_{\beta} = \frac{(\beta^2 + 1) \times P \times R}{P + R} \times 100\%$$

$$\text{未登录词召回率 (R}_{\text{OOV}}) = \frac{\text{算法输出的未登录词正确结果个数}}{\text{测试集合中未登录词个数}} \times 100\%$$



表 2.5 常用中文分词语料库汇总

语料库名称	单词数量	简/繁体
北京大学分词语料库 (PKU)	110 万	简体
香港城市大学分词语料库 (CITYU)	145 万	繁体
微软研究院分词语料库 (MSR)	237 万	简体
Academia Sinica (AS)	545 万	繁体
中文宾州树库 6.0 (CTB 6.0)	78 万	简体
中文宾州树库 7.0 (CTB 7.0)	120 万	简体
中文宾州树库 8.0 (CTB 8.0)	162 万	简体
中文宾州树库 9.0 (CTB 9.0)	208 万	简体
微博分词语料库 (WordSeg-Weibo)	46 万	简体

本章主要内容

2.1

语言中的词汇

2.2

词语规范化

2.3

中文分词

2.4

词性标注

2.4.1 基于规则的词性标注

2.4.2 基于隐马尔可夫模型的词性标注

2.4.3 基于卷积神经网络的词性标注

2.4.4 词性标注评价方法

2.4.5 词性标注语料库



词性是词语的基本属性，根据其在句子中所扮演的语法角色以及与周围词的关系进行分类。**词性标注 (Part-of-speech Tagging, POS Tagging)** 是指在给定的语境中确定句子中各词的词性

词性标注的主要难点在于**歧义性**，即一个词可能在不同的上下文具有不同的词性。

- 兼类词（一个词有两种或两种以上的词性）多为常用词，而且越是常用词，其用法就越多
 - 北京大学计算语言学研究院 200 万字语料库统计，发现兼类词所占比例仅有 11%，但是出现的次数却达到了 47%
 - Brown 语料库的统计也发现超过 80% 的词通常只有一个词性

还没有一个被广泛认可的统一词性划分标准，在不同的语料集中所采用的划分粒度和标记符号也都不尽相同



表 2.6 宾州树库中的词性标签

标签	描述	标签	描述
CC	并列连词	CD	数字
DT	限定词	EX	<u>there</u>
FW	外来词	IN	介词或从属连词
JJ	形容词	JJR	形容词比较级
JJS	形容词最高级	LS	列表项标记
MD	情态助动词	NN	名词单数
NNS	名词复数	NNP	专有名词单数
NNPS	专有名词复数	PDT	前限定词
POS	所有格结束词	PRP	人称代名词
PRP\$	物主代词	RB	副词
RBR	副词比较级	RBS	副词最高级
RP	小品词	SYM	符号
TO	to	UH	叹词
VB	动词	VBD	动词过去式
VBG	动词现在进行式	VBN	动词过去分词
VBP	动词一般现在式 非第三人称单数	VBZ	动词一般现在式 第三人称单数
WDT	Wh-限定词	WP	Wh-代词
WP\$	所有格 Wh-代词	WRB	Wh-副词



利用**词典和搭配规则**针对词语和上下文进行分析，从而得到句子中每个词语词性

Brill Tagger在 Brown 语料库上仅使用 71 个规则就得到接近 95% 的分析准确率

(1) 初始化：对于词典中包含的词语，根据词语最常使用的词性设置初始值；对于词典中没有的单词根据词性分析结果设置初始值（例如：以大写字母开头的设置为专有名词）。

(2) 规则转换：根据补丁规则对初始标注进行转换，补丁规则包含以下三类：

(a) 如果某单词词性为 a ，并且其所在上下文为 C ，那么将其词性转换为 b ；

(b) 如果某单词词性为 a ，并且其具有词汇属性 P ，那么将其词性转换为 b ；

(c) 如果某单词词性为 a ，并且其周边范围 R 内有一个词汇具有属性 P ，那么将其词性转换为 b ；

例如：补丁规则 “NN VB PREV-TAG TO” 表示，如果一个单词被标注为了 NN（名词），并且它前面的单词标注为了 TO（不定式 “to”），那么将这个单词的词性转换为 VB（动词）。




隐马尔可夫模型 (Hidden Markov Model, HMM) 又称隐马尔科夫模型, 是马尔可夫过程扩充而来的一种随机过程。在自然语言处理众多序列标注任务中也得到了广泛应用并取得了非常好的效果。

隐马尔可夫模型可用如下 5 个参数定义:

- N : 状态数。所有的状态记为 $S = \{s_1, s_2, \dots, s_N\}$ 。系统在 t 时刻的状态记为 q_t 。 $Q = \{q_1, q_2, \dots, q_T\}$, 为长度为 T 的状态序列。
- M : 观察值数。所有的可能观察值记为 $V = \{v_1, v_2, \dots, v_M\}$ 。系统在 t 时刻的观测值记为 o_t 。 $O = \{o_1, o_2, \dots, o_T\}$, 为长度为 T 的观测序列。
- π : 初始状态概率。 $\pi = [\pi_i]_{1 \times N}$, $\pi_i = P(q_1 = s_i)$, $1 \leq i \leq N$, 表示初始时刻 $t = 1$ 时处于某个状态 s_i 的概率。
- A : 状态转移概率矩阵。 $A = [a_{ij}]_{N \times N}$, $a_{ij} = P(q_{t+1} = s_j | q_t = s_i)$, $1 \leq i, j \leq N$, 表示在时刻 t 处于状态 s_i 的条件下, 下一时刻 $t + 1$ 转移到状态 s_j 的概率。
- B : 观测概率矩阵。 $B = [b_j(k)]_{N \times M}$, $b_j(k) = P(o_t = v_k | q_t = s_j)$, $1 \leq j \leq N, 1 \leq k \leq M$, 表示在时刻 t 处于状态 s_j 的条件下, 观测到 v_k 的概率。



例如： N 个袋子，每个袋子中有 M 种不同颜色的球。一实验员根据某一概率分布选择一个袋子，然后根据袋子中不同颜色球的概率分布随机取出一个球，并报告该球的颜色。对局外人：可观察的过程是不同颜色球的序列，而袋子的序列是不可观察的。每只袋子对应HMM中的一个状态；球的颜色对应于 HMM 中状态的输出。






◆HMM 的组成

1. 模型中的状态数为 N (袋子的数量)
2. 从每一个状态可能输出的不同的符号数 M (不同颜色球的数目)
3. 状态转移概率矩阵 $A=a_{ij}$, a_{ij} 为实验员从一只袋子 (状态 S_i) 转向另一只袋子 (状态 S_j) 取球的概率。
其中,

$$\begin{cases} a_{ij} = p(q_{t+1} = S_j | q_t = S_i), & 1 \leq i, j \leq N \\ a_{ij} \geq 0 \\ \sum_{j=1}^N a_{ij} = 1 \end{cases} \quad \dots (6.6)$$



4. 从状态 S_j 观察到某一特定符号 v_k 的概率分布矩阵为: $B=b_j(k)$
其中, $b_j(k)$ 为实验员从第 j 个袋子中取出第 k 种颜色的球的概率。那么,

$$\begin{cases} b_j(k) = p(O_t = v_k | q_t = S_j), & 1 \leq j \leq N, \quad 1 \leq k \leq M \\ b_j(k) \geq 0 \\ \sum_{k=1}^M b_j(k) = 1 \end{cases} \quad \dots (6.7)$$




◆HMM 的组成

1. 模型中的状态数为 N (袋子的数量)
2. 从每一个状态可能输出的不同的符号数 M (不同颜色球的数目)
5. 初始状态的概率分布为: $\pi = \pi_i$, 其中,

$$\begin{cases} \pi_i = p(q_1 = S_i), \quad 1 \leq i \leq N \\ \pi_i \geq 0 \\ \sum_{i=1}^N \pi_i = 1 \end{cases} \quad \dots (6.8)$$



为了方便, 一般将 HMM 记为: $\mu = (A, B, \pi)$
或者 $\mu = (S, O, A, B, \pi)$ 用以指出模型的参数集合。



◆给定HMM求观察序列

给定模型 $\mu = (A, B, \pi)$, 产生观察序列 $O = O_1 O_2 \dots O_T$:

- (1) 令 $t=1$;
- (2) 根据初始状态分布 $\pi = \pi_i$ 选择初始状态 $q_1 = S_i$;
- (3) 根据状态 S_i 的输出概率分布 $b_i(k)$, 输出 $O_t = v_k$;
- (4) 根据状态转移概率 a_{ij} , 转移到新状态 $q_{t+1} = S_j$;
- (5) $t = t+1$, 如果 $t < T$, 重复步骤 (3) (4), 否则结束。



图例说明:

D6 一个隐含状态

1 一个可见状态

→ 从一个隐含状态到下一个隐含状态的转换

↓ 从一个隐含状态到一个可见状态的输出

Q1: 掷出这个结果的概率?

Q2: 每次掷出来的都是哪种骰子?

Q3: 模型参数?



为了简化起见, 隐马尔可夫模型可以表示成 $\lambda = (A, B, \pi)$ 。 M, N 也隐含地已经包含在 A, B, π 中。隐马尔可夫模型的三个主要问题是:

问题 1: 观测概率计算 在给定模型 $\lambda = (A, B, \pi)$ 的情况下, 如何根据观测序列 $O = \{o_1, o_2, \dots, o_T\}$ 计算 $P(O|\lambda)$, 即在给定模型情况下, 如何观测序列的概率。 **似然度问题**

问题 2: 状态序列预测 在给定模型 $\lambda = (A, B, \pi)$ 和观测序列 $O = \{o_1, o_2, \dots, o_T\}$ 的情况下, 如何得到与该观测序列最匹配的状态序列 $Q = \{q_1, q_2, \dots, q_T\}$, 即如何根据观测序列推断出隐藏的状态序列。 **解码问题**

问题 3: 模型参数学习 在给定观测序列 $O = \{o_1, o_2, \dots, o_T\}$ 情况下, 如何调整模型参数 $\lambda = (A, B, \pi)$ 使得该序列的 $P(O|\lambda)$ 最大, 即如何训练模型使其能最好地建模观测序列。 **学习问题**

关于问题 1, 问题 2 以及问题 3 的求解方法可以参阅李航博士《统计学习方法 (第二版) 》第 10 章



N 为词性数, $S = \{s_1, s_2, \dots, s_N\}$ 为词性表, M 为单词数, $V = \{v_1, v_2, \dots, v_M\}$ 为单词词表。

给定一个由 T 个单词组成的句子 $W = w_1, w_2, \dots, w_T$, 即相当于**观测序列** $O = \{o_1, o_2, \dots, o_T\}$ 。

状态序列 $Q = \{q_1, q_2, \dots, q_T\}$ 则表示输入句子中单词对应的词性。





图 2.4 词性标注隐马尔可夫模型概率图模型样例

长句子和未登录词问题实际应用中需要解决问题



表查询 (Lookup Table)

将单词通过表查询转换为词性向量表示

$$LT_{\mathbf{W}}(w) = \langle \mathbf{W} \rangle_w^1$$

给定的任意一句包含 T 个单词的句子

$$LT_{\mathbf{W}}([w]_1^T) = \left(\langle \mathbf{W} \rangle_{[w]_1}^1, \langle \mathbf{W} \rangle_{[w]_2}^1 \dots \langle \mathbf{W} \rangle_{[w]_T}^1 \right)$$

除了单词本身之外，还可以提供一些其他特征

$$LT_{\mathbf{W}^1, \dots, \mathbf{W}^K}(w) = \begin{pmatrix} LT_{\mathbf{W}^1}(w_1) \\ \vdots \\ LT_{\mathbf{W}^K}(w_K) \end{pmatrix} = \begin{pmatrix} \langle \mathbf{W}^1 \rangle_{w_1}^1 \\ \vdots \\ \langle \mathbf{W}^K \rangle_{w_K}^1 \end{pmatrix}$$

表查询层输出

$$LT_{\mathbf{W}^1, \dots, \mathbf{W}^K}([w]_1^T) = \begin{pmatrix} \langle \mathbf{W}^1 \rangle_{[w]_1}^1 & \dots & \langle \mathbf{W}^1 \rangle_{[w]_T}^1 \\ \vdots & & \vdots \\ \langle \mathbf{W}^K \rangle_{[w]_1}^1 & \dots & \langle \mathbf{W}^K \rangle_{[w]_T}^1 \end{pmatrix}$$



卷积层 (Convolutional Layer)

根据所设置的窗口大小 d_{win} ，将每个单词周边的单词拼接起来构成具有 $d_{wrd}d_{win}$ 维度的向量

$$f_{\theta}^1 = \langle LT_W([w]_1^T) \rangle_t^{d_{win}} = \begin{pmatrix} \langle \mathbf{W} \rangle_{[w]_{t-d_{win}/2}}^1 \\ \vdots \\ \langle \mathbf{W} \rangle_{[w]_t}^1 \\ \vdots \\ \langle \mathbf{W} \rangle_{[w]_{t+d_{win}/2}}^1 \end{pmatrix}$$


第1层的第 t 列向量可以根据如下公式


$$\langle f_{\theta}^l \rangle_t^1 = \mathbf{W}^l \langle f_{\theta}^{l-1} \rangle_t^{d_{win}} + b^l \quad \forall t$$

非线性变化

$$[f_{\theta}^l]_i = \text{HardTanh}([f_{\theta}^l]_i),$$

$$\text{HardTanh}(x) = \begin{cases} -1 & \text{if } x < -1 \\ x & \text{if } -1 \leq x \leq 1 \\ - & \text{if } x > 1 \end{cases}$$





池化层 (Pooling Layer)

随时间推移最大化 (Max Over Time)

$$[f_{\theta}^l]_i = \max_x [f_{\theta}^{l-1}]_{i,t} \quad 1 \leq i \leq n_{hu}^{l-1}$$

线性变换

$$f_{\theta}^l = \mathbf{W}^l f_{\theta}^{l-1} + b^l$$

分类阶段

句子级别对数似然方法
(Sentence-Level Log-Likelihood)



$$\text{准确率 (Accuracy)} = \frac{\text{算法输出的正确结果个数}}{\text{算法输出的全部结果总数}} \times 100\%$$

$$P_{\text{名词}} = \frac{\text{算法输出的正确名词结果个数}}{\text{算法输出的名词结果总数}} \times 100\%$$

$$R_{\text{名词}} = \frac{\text{算法输出的正确名词结果个数}}{\text{测试集合中正确名词结果总数}} \times 100\%$$

$$F1_{\text{名词}} = \frac{2 \times P_{\text{名词}} \times R_{\text{名词}}}{P_{\text{名词}} + R_{\text{名词}}}$$

宏平均 F1 (Macro-F1) 的具体计算方法如下:

$$\text{Macro-F1} = \frac{1}{n} \sum_{i \in POS} F1_i$$



表 2.7 常见词性标注语料库汇总

语料库名称	单词数量	语言
英语宾州树库 (PTB)	117 万	英文
通用依存树库 (UD V2.0 CoNLL 2017)	281 万	多语言
RIT-Twitter	1 万	英文
ARK-Twitter	3 万	英文
中文宾州树库 6.0 (CTB 6.0)	78 万	中文
中文宾州树库 7.0 (CTB 7.0)	120 万	中文
中文宾州树库 8.0 (CTB 8.0)	162 万	中文
中文宾州树库 9.0 (CTB 9.0)	208 万	中文

本章小结

词汇是语言知识中的重要环节，**词**是语言运用的基本单位，自然语言处理算法中词通常也是基本单元。因此，词的处理也是自然语言处理中重要的底层任务，其分析效果对后续任务有很大影响，长期以来都是自然语言处理研究的重点。本章中介绍了中文分词和词性标注任务，这两个任务都是典型的序列标注任务，除了基于词典的中文分词算法之外，本章中介绍的其他算法都采用有监督分类算法。