

中山大學 人工智能學院  
SUN YAT-SEN UNIVERSITY SCHOOL ARTIFICIAL INTELLIGENCE

「自然语言处理」

# 第 3 章 句法分析

赵宝全

中山大学人工智能学院

2026年春季学期

# 本章主要内容

---

**3.1**

**句法概述**

**3.2**

**成分句法分析**

**3.3**

**依存句法分析**

**3.4**

**句法分析语料库**

# 本章主要内容

---

## 3.1

### 句法概述

#### 3.1.1 成分语法理论概述

#### 3.1.2 依存语法理论概述

## 3.2

### 成分句法分析

## 3.3

### 依存句法分析

## 3.4

### 句法分析语料库



**句法 (Syntax)** 就是研究自然语言中不同成分组成句子的方式以及支配句子结构并决定句子是否成立的规则

任何人类语言都具备构造**无限数量**句子的能力

- 可以通过增加形容词、副词、关系小句、介词短语等方法把任意的句子进一步地创造。

无法将一种语言**按照词典**的方式把所有句子存储起来

通过语言学研究发现, 句子**并非词语的随意组合**, 而是由按照一定**规则**结合起来的离散单位组成





句法是现代语言学研究中的重要课题，有大量的句法理论（Syntactic Theory）相关研究



**语法（Grammar）**就是指自然语言中句子、短语以及词等语法单位的语法结构与语法意义的规律。根据语法就可以**判断不同成分组成句子的方式**以及**决定句子是否成立**

狭义的语法学研究**基本等同于**句法学。语言学家自19世纪50年代以来，构建了大量表达明确并且形式化的语法理论，对自然语言句法分析提供了理论支撑。语法理论在构建时，一个重要的问题是该理论是**基于成分关系**还是**基于依存关系**



## ■ 应用：


- ✧ **语法检查**：如果一个句子不能被剖析，它就很可能有语法错误（或者至少阅读起来有困难）  grammarly
- ✧ **机器翻译**：通过句法分析把句子结构确定下来，然后逐个词翻译，再根据句法结构整理和修改翻译结果
- ✧ **问答系统**：“谢霆锋的儿子是谁？” vs. “谢霆锋是谁的儿子？”





## ■ 应用：

✧ 主干抽取：“给我推荐一家能够听到古典音乐的餐厅”



一般来说，句法分析并不是一个自然语言处理任务的最终目标。但是，它往往是实现最终目标的重要环节。



Noam Chomsky于1957年发表的《Syntactic Structures》奠定了成分语法的基础

**成分 (Constituent)** 又称短语结构，是指一个句子内部的结构成分。成分可以独立存在，或者可以用代词替代，又或者可以在句子中的不同位置移动。

例如：他正在写一本小说。

“一本小说” 是一个成分



根据不同成分之间是否可以进行相互替代而**不会影响句子语法正确性**，可以进一步地将成分进行分类，**某一类短语就属于一个句法范畴** (Syntactic Category)。

比如“一本小说”、“一所大学”等都属于一个句法范畴：名词短语 (None Phrase, NP)。

句法范畴不仅仅包含名词短语 (NP)、动词短语 (VP)、介词短语 (PP) 等**短语范畴**，也包含名词 (N)、动词 (V)、形容词 (Adj) 等**词汇范畴**。除此之外还包含**功能范畴** (包括冠词、助动词等)。



句法范畴之间不是完全对等的，而是**具有层级关系**。

例如：一个句子可以由一个名词短语和一个动词短语组成，一个名词短语可以由一个限定词和一个名词组成，一个动词短语又可以由一个动词和一个名词短语组成。

**短语结构规则 (Phrase Structure Rules)** 又称**改写规则**或**重写规则**，对句法范畴间的关系进行形式化描述。

通常可以用  $X \rightarrow Y Z W \dots$  表示，其中  $X$  表示短语名称， $\rightarrow$  表示改写为， $Y Z W \dots$  定义了短语  $X$  的结构，如果  $YZW$  是短语，则还需要构造出它们的规则。



例如：

( 1 )  $S \rightarrow NP VP$

( 2 )  $NP \rightarrow Det N$

( 3 )  $VP \rightarrow V NP$




图 3.1 Penn Treebank 3.0 成分句法树样例

**成分语法**就是由句法范畴以及短语结构规则定义的语法。由于短语结构规则具有**递归性**，可以使短语和句子无限循环组合。这也说明了语言的创造性和无限性。



由于成分语法局限于表层结构分析，**不能彻底解决句法和语义问题**，因此存在非连续成分、结构歧义等问题。




图 3.3 句子 The boy saw the man with telescope 的第一种成分句法树




图 3.4 句子 The boy saw the man with telescope 的第二种成分句法树






Lucien Tesnière 1959 年发表的《Eléments de syntaxe structurale》奠定了句法依存关系研究的基础

在基于依存关系的语法中，句子中的每个成分对应句法结构中的**唯一一个节点**。两个成分之间的**依存关系是二元的非对称关系，具有方向性**，一个成分是中心语，另一个成分依附于中心语存在，**关系从中心语成分指向依存成分**。

- **中心成分**称为中心词或支配者 (Governor, Regent, Head)
- **依存成分**也称为修饰词或从属者 (Modifier, Subordinate, Dependency)



(a)

读  
|  
书

(b)

读  
  \  
      书

(c)

读  
  \  
   -  
  读  书  
  |  |  
  书  书

(d)

图 3.5 “读书”的依存关系表示实例

两个单词之间是否存在依存关系？单词之间谁处于支配地位？谁处于从属地位？建立这些词与词之间关系的依据是什么？

**配价 (Valency) 理论**是其中最为经典的论著之一，**价**是词语的一个属性，表示某个词语与其他词语结合的能力。**配价模式 (Valency pattern)**则是描述了某一个具有特定意义的词的出现语境，以及当一个词出现在一个特定的模式下时，还有哪些词语会出现在这个模式下及其语义角色。



- **零价动词**：不强制要求与某种性质的名词性词语关联的一类动词。例如“地震、刮风、下雨”等。这类动词大多反映自然现象。在汉语等语言中，这类动词可以单独成句，不需要主语，例如“刮风了。”而在英语中，这类动词需要添加形式主语it，如“It rains.”
- **一价动词**：强制要求与一种性质的名词性词语关联的一类动词。例如“病、醉、休息、游泳”等。一般指不及物动词（自动词）
- **二价动词**：强制要求与两种性质的名词性词语关联的一类动词。例如“爱、参观、讨论”等。一般指（单）及物动词（他动词）
- **三价动词**：强制要求与三种性质的名词性词语关联的一类动词。例如“给、告诉、买”等。一般说的双及物动词。“他给了我一本书”
- **四价动词**：强制要求与四种性质的名词性词语关联的一类动词。例如“我跟你打赌三百块明天会下雨”。这种动词很不常见



词语间的依存关系还可以根据语法关系定义为不同的类型，Carroll等人将依存关系细分为**20种，并给出了关系之间的层级结构**。Marneffe等人在上述工作的基础上对依存关系进行了进一步的细化，定义了**48种**依存关系，主要分为**论元依存关系**和**修饰语依存关系**两大类。




图 3.6 句子“他也喜欢读书”的依存句法树

# 本章主要内容

---

3.1

句法概述

3.2

成分句法分析

3.2.1 基于上下文无关文法的成分句法分析

3.2.2 基于概率上下文无关文法的成分句法分析

3.2.3 成分句法分析评价方法

3.3

依存句法分析

3.4

句法分析语料库



**成分句法分析 (Constituency Parsing)** 是对给定句子根据成分语法中制定的规则构建其所对应的**结构树**的过程。

通常可以用  $X \rightarrow Y Z W \dots$  表示，与数学系统中的**上下文无关文法** (Context- Free Grammar, CFG) 组成非常类似

终结符  $\Sigma$  (Terminal Symbols): 与语言中词汇对应的符号, 用  $u, v, w$  等小写罗马字母表示;

例如: 上海, walk

非终结符  $N$  (Non-terminals): 对应词组等聚集类或概括性符号, 用  $A, B, C$  等大写字母表示;

例如: NP (名词短语), VP (动词短语), N (名词), 介词 (P)

初始符  $S$  (Start symbol): 语法中指定的初始符, 通常用  $S$  表示;

规则  $R$  (rules): 对应语法中的短语结构规则, 从初始符号开始可以构造出合法句子的规则集合, 在上下文无关语法中, 一个规则的左边是一个单独的非终结符, 右边是一个或者多个终结符或非终结符组成的有序序列  $(\Sigma \cup N)^*$ 。用  $\alpha, \beta, \gamma$  等小写希腊字母表示  $(\Sigma \cup N)^*$ 。

例如:  $S \rightarrow NP VP$ ,  $NP \rightarrow Det Adj N$ ,  $Det \rightarrow the$



对一个句子进行句法分析的过程可以看做对一个句子**搜索所有可能的路径空间**，从中发现正确的句法树的过程。

搜索过程受到两个约束限制，一个是**句子本身**，另外一个**是语法**。根据成分句法的定义，**叶子节点一定是句子中的单词，中间节点与其子节点需要符合语法定义**。

这两种约束也产生了大多数分析算法所采用的搜索策略：**自底向上** (Bottom-up) 和**自顶向下** (Top-down) 。



由于句法结构具有歧义，因此句法分析中最重要的工作之一也是如何消除歧义。成分语法中的结构歧义主要有两种：**附着歧义** (Attachment ambiguity) 以及**并列连接歧义** (Coordination ambiguity)

附着歧义：The boy saw the man with the telescope

并列连接歧义：重要政策和措施





在给定上下文无关文法  $G$  的情况下，对于给定的句子  $W = \{w_1, w_2, \dots, w_n\}$ ，输出其对应的句法结构，通常有两大类搜索方法：**自顶向下**和**自底向上**。

- **自顶向下**搜索试图从根节点  $S$  出发，搜索语法中的所有规则直到叶子节点，并行构造所有可能的树
- **自底向上**的方法是从输入的单词开始，每次都是用语法规则，直到成功构造了以初始符  $S$  为根的树



**CYK 算法** (CYK 是 Cocke–Younger–Kasami 的缩写, 有时也称为 CKY) 是由 John Cocke、Daniel Younger 以及 Tadao Kasami 分别独立提出的基于动态规划思想的**自底向上**语法分析算法

CYK算法要求所使用的语法必须**符合乔姆斯基范式** (Chomsky Normal Form, CNF) :

假设文法  $G(S)$  的规则只有两种形式:

$$A \rightarrow w, \quad w \in V_T$$

$$A \rightarrow BC, \quad B, C \in V_N$$

可以通过范式化处理, 使CFG 规则满足上述形式。这种假设的文法形式称为乔姆斯基范式 (Chomsky normal form, CNF)。

根据 CNF 语法形式, 句法树的叶子节点为单词, 单词的父节点为词性符号, 在词性符号层之上每一个非终结符都有两个子节点。因此 CYK 算法采用了**二维矩阵**对整个树结构进行编码。




对于一个长度为  $n$  的句子，构造一个  $(n + 1) \times (n + 1)$  的**二维矩阵  $T$**

矩阵主对角线以下全部为 0，**主对角线上的元素**由输入句子的终结符号(单词)构成

**主对角线以上的元素  $T_{ij}$** 包含由文法  $G$  的非终结符构成的集合，这个集合表示输入句子中横跨在位置  $i$  到  $j$  之间的单词的组成成分。

输入句子中索引从 0 开始，索引位于输入句子的单词之间，也可以看成单词之间的间隔指针

例如：0 她 1 喜欢 2 跳 3 芭蕾 4


**return**  $T$




非终结符:  $N = \{S, N, P, V, VP\}$

终结符: {她, 喜欢, 跳, 芭蕾}


规则集合:  $\{S \rightarrow P \ VP, VP \rightarrow V \ V, VP \rightarrow VP \ N, P \rightarrow \text{她}, V \rightarrow \text{喜欢}, V \rightarrow \text{跳}, N \rightarrow \text{芭蕾}\}$




(a)




(b)



(c)



(d)



(e)



给定文法  $G(S)$ :

$$(1) S \rightarrow P \ VP$$

$$(2) VP \rightarrow V \ V$$

$$(3) VP \rightarrow VP \ N$$

$$(4) P \rightarrow \text{他}$$

$$(5) V \rightarrow \text{喜欢}$$

$$(6) V \rightarrow \text{读}$$

$$(7) N \rightarrow \text{书}$$

请用 CYK 算法分析句子：他喜欢读书



(1) 汉语分词和词性标注以后:

他/P 喜欢/V 读/V 书/N  $n=4$

(2) 构造识别矩阵:

(3) 执行分析过程。

- (1)  $S \rightarrow P VP$   
 (2)  $VP \rightarrow V V$   
 (3)  $VP \rightarrow VP N$

|   | 0 | 1 | 2      | 3 | 4 |
|---|---|---|--------|---|---|
| 0 | 0 | P |        |   |   |
| 1 |   | 他 | V → VP |   |   |
| 2 |   |   | 喜欢     | V |   |
| 3 |   |   |        | 读 | N |
| 4 |   |   |        |   | 书 |

|   | 0 | 1     | 2      | 3 | 4 |
|---|---|-------|--------|---|---|
| 0 | 0 | P → P |        |   |   |
| 1 |   | 他     | V → VP |   |   |
| 2 |   |       | 喜欢     | V | N |
| 3 |   |       |        | 读 | N |
| 4 |   |       |        |   | 书 |



(1) 汉语分词和词性标注以后：

他/P 喜欢/V 读/V 书/N  $n=4$

(2) 构造识别矩阵：

(3) 执行分析过程。

- (1)  $S \rightarrow P VP$   
 (2)  $VP \rightarrow V V$   
 (3)  $VP \rightarrow VP N$

|   | 0 | 1 | 2  | 3  | 4 |
|---|---|---|----|----|---|
| 0 | 0 | P | P  | S  |   |
| 1 |   | 他 | V  | VP | ? |
| 2 |   |   | 喜欢 | V  | N |
| 3 |   |   |    | 读  | N |
| 4 |   |   |    |    | 书 |





(1) 汉语分词和词性标注以后:

他/P 喜欢/V 读/V 书/N  $n=4$

(2) 构造识别矩阵:

(3) 执行分析过程。

(1)  $S \rightarrow P VP$

(2)  $VP \rightarrow V V$

(3)  $VP \rightarrow VP N$

|   | 0 | 1     | 2           | 3 | 4 |
|---|---|-------|-------------|---|---|
| 0 | 0 | P → P |             |   |   |
| 1 |   | 他     | V → VP → VP |   |   |
| 2 |   |       | 喜欢          | V | N |
| 3 |   |       |             | 读 | N |
| 4 |   |       |             |   | 书 |

Diagram illustrating the parsing process for the sentence "他喜欢读书" (He likes to read a book). The matrix shows the construction of the parse tree using the grammar rules. A green box highlights the subproblem for the phrase "喜欢读书" (likes to read a book), and a red circle highlights the subproblem for the phrase "喜欢" (likes).



(1) 汉语分词和词性标注以后:

他/P 喜欢/V 读/V 书/N  $n=4$

(2) 构造识别矩阵:

(3) 执行分析过程。

(1)  $S \rightarrow P \ VP$

(2)  $VP \rightarrow V \ V$

(3)  $VP \rightarrow VP \ N$

|   | 0 | 1   | 2   | 3    | 4  |
|---|---|-----|-----|------|----|
| 0 | 0 | P → | P → | P    |    |
| 1 |   | 他   | V → | VP → | VP |
| 2 |   |     | 喜欢  | V    | N  |
| 3 |   |     |     | 读    | N  |
| 4 |   |     |     |      | 书  |



(1) 汉语分词和词性标注以后:

他/P 喜欢/V 读/V 书/N  $n=4$

(2) 构造识别矩阵:


(3) 执行分析过程。

(1)  $S \rightarrow P VP$

(2)  $VP \rightarrow V V$

(3)  $VP \rightarrow VP N$

|   | 0 | 1             | 2           | 3     | 4 |
|---|---|---------------|-------------|-------|---|
| 0 | 0 | P → P → P → S |             |       |   |
| 1 |   | 他             | V → VP → VP |       |   |
| 2 |   |               | 喜欢          | V → N |   |
| 3 |   |               |             | 读     | N |
| 4 |   |               |             |       | 书 |



### ◆ CYK 算法的评价

#### ◆ 优点

- 简单易行，执行效率高

#### ◆ 弱点

- 必须对文法进行范式化处理
- 无法区分歧义

### 3.2.1 基于上下文无关文法的成分句法分析



**移进-归约成分句法分析算法**的基本思想是从左到右扫描输入的包含单词词性对的句子，使用**堆栈**和一系列的**移进 (Shift)** 和**归约 (Reduce)** 操作序列构建句法树。

算法初始时堆栈S为空，队列Q中包含整个句子所有单词。在算法结束时堆栈S中包含一个完整的句法树，队列Q为空。所采用的操作包含以下四个：

- **移进 (Shift)**：将非空队列Q最左端的单词移入堆栈S中
- **归约 (Reduce)**：根据推导规则右侧所包含非终结符数量，将堆栈S中的最顶端相应数量元素移出，然后将利用推导规则产生的新结构压入堆栈中
- **接受 (Accept)**：队列中所有单词都已被移到堆栈中，并且堆栈中只剩下一个由非终结符S为根的树，表示分析成功
- **拒绝 (Reject)**：队列中所有单词都已被移到堆栈中，但是堆栈中并非只有一个以非终结符S为根的树，并且无法继续归约，表示分析失败

|    | 堆栈                                                                                                                                                             | 动作          | 队列          |
|----|----------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------|-------------|
| 0. | $\emptyset$                                                                                                                                                    | $\emptyset$ | 她 喜欢 跳 芭蕾   |
| 1. | 她                                                                                                                                                              | shift       | 喜欢 跳 芭蕾     |
| 2. | $\begin{array}{c} P \\   \\ 她 \end{array}$                                                                                                                     | reduce      | 喜欢 跳 芭蕾     |
| 3. | $\begin{array}{c} P \\   \\ 她 \end{array} \quad \text{喜欢}$                                                                                                     | shift       | 跳 芭蕾        |
| 4. | $\begin{array}{c} P \\   \\ 她 \end{array} \quad \begin{array}{c} V \\   \\ 喜欢 \end{array}$                                                                     | reduce      | 跳 芭蕾        |
| 5. | $\begin{array}{c} P \\   \\ 她 \end{array} \quad \begin{array}{c} V \\   \\ 喜欢 \end{array} \quad \text{跳}$                                                      | shift       | 芭蕾          |
| 6. | $\begin{array}{c} P \\   \\ 她 \end{array} \quad \begin{array}{c} V \\   \\ 喜欢 \end{array} \quad \begin{array}{c} V \\   \\ 跳 \end{array}$                      | reduce      | 芭蕾          |
| 7. | $\begin{array}{c} P \\   \\ 她 \end{array} \quad \begin{array}{c} VP \\ / \quad \backslash \\ V \quad V \\   \quad   \\ 喜欢 \quad 跳 \end{array}$                 | reduce      | 芭蕾          |
| 8. | $\begin{array}{c} P \\   \\ 她 \end{array} \quad \begin{array}{c} VP \\ / \quad \backslash \\ V \quad V \\   \quad   \\ 喜欢 \quad 跳 \end{array} \quad \text{芭蕾}$ | shift       | $\emptyset$ |



|    | 堆栈                                                                                  | 动作          | 队列          |
|----|-------------------------------------------------------------------------------------|-------------|-------------|
| 0. | $\emptyset$                                                                         | $\emptyset$ | 她 喜欢 跳 芭蕾   |
| 1. | 她                                                                                   | shift       | 喜欢 跳 芭蕾     |
| 2. | P<br> <br>她                                                                         | reduce      | 喜欢 跳 芭蕾     |
| 3. | P    喜欢<br> <br>她                                                                   | shift       | 跳 芭蕾        |
| 4. | P    V<br>      <br>她   喜欢                                                          | reduce      | 跳 芭蕾        |
| 5. | P    V    跳<br>      <br>她   喜欢                                                     | shift       | 芭蕾          |
| 6. | P    V    V<br>           <br>她   喜欢   跳                                            | reduce      | 芭蕾          |
| 7. | P            VP<br>             /  \<br>她        V     V<br>       <br>喜欢   跳       | reduce      | 芭蕾          |
| 8. | P            VP    芭蕾<br>             /  \<br>她        V     V<br>       <br>喜欢   跳 | shift       | $\emptyset$ |

非终结符:  $N = \{S, N, P, V, VP\}$

终结符: {她, 喜欢, 跳, 芭蕾}

规则集合:  $\{S \rightarrow P \ VP, VP \rightarrow V \ V, VP \rightarrow VP \ N, P \rightarrow 她, V \rightarrow 喜欢, V \rightarrow 跳, N \rightarrow 芭蕾\}$



|     | 堆栈                                                                                                                           | 动作     | 队列          |
|-----|------------------------------------------------------------------------------------------------------------------------------|--------|-------------|
| 9.  | <pre>       P      VP      N              / \            她    V   V   芭蕾                            喜欢 跳           </pre>    | reduce | $\emptyset$ |
| 10. | <pre>       P      VP              / \       她    VP  N            / \              V   V  芭蕾          喜欢 跳           </pre> | reduce | $\emptyset$ |
| 11. | <pre>       S      / \     P   VP         / \     她 VP  N        / \          V   V  芭蕾      喜欢 跳           </pre>           | reduce | $\emptyset$ |
| 12. | <pre>       S      / \     P   VP         / \     她 VP  N        / \          V   V  芭蕾      喜欢 跳           </pre>           | accept | $\emptyset$ |

非终结符:  $N = \{S, N, P, V, VP\}$

终结符: {她, 喜欢, 跳, 芭蕾}

规则集合:  $\{S \rightarrow P \ VP, VP \rightarrow V \ V, VP \rightarrow VP \ N, P \rightarrow 她, V \rightarrow 喜欢, V \rightarrow 跳, N \rightarrow 芭蕾\}$



如何根据当前堆栈  $S$  和队列  $Q$  中的状态，选择下一步的操作是移进-归约分析算法中最重要的部分。由于移进和归约操作并不是完全互斥的，在很多状态下两种操作都可以选择，这就造成了**移进归约冲突 (Shift Reduce Conflict)**。

### 设置执行策略解决冲突：

- 采用深度优先策略，只有在不能归约时才移进，当有多种归约时选择最长的语法规则等
- 采用回溯策略，分析失败时回溯顺次尝试不同的选择





**基于概率上下文无关文法** (Probabilistic Context-Free Grammar, **PCFG**) 的句法分析则可以结合规则方法和统计方法

PCFG 是 CFG 的扩展, 因此 PCFG 的文法也是由终结符集合  $\Sigma$ 、非终结符集合  $N$ 、初始符  $S$  以及规则集合  $R$  组成。只是在 CFG 的基础上对每条规则增加了概率, 其规则用如下形式表示:

$$A \rightarrow \alpha, p$$

其中  $A$  为非终结符,  $\alpha \in (\Sigma \cup N)^*$  为终结符和非终结符组成的有序序列集合,  $p$  为  $A$  推导出  $\alpha$  的概率, 即  $p = P(A \rightarrow \alpha)$



由于PCFG中每个规则中包含了概率信息 $P(A \rightarrow \alpha)$ ，因此可以根据一个句子及其句法分析树**计算特定句法分析树的概率、句子的概率以及句子片段的概率**。利用特定分析树的概率可以用于**消除分析树的歧义**。




图 3.12 句子 “He eat soup with spoon” 的成分语法树



## PCFG句法分析树概率计算

句法树概率计算还要应用以下三个独立假设：



- (1) **位置不变性** (Place in-variance)：子树的概率不依赖于该子树所在的位置；
- (2) **上下文无关性** (Context-free)：子树的概率不依赖于子树以外的单词；
- (3) **祖先无关性** (Ancestor-free)：子树的概率不依赖于子树的祖先节点。

一个特定句法树  $T$  的概率定义为该句法树  $T$  中用来得到句子  $W$  所使用的  $m$  个规则的概率乘积：

$$P(T) = \prod_{i=1}^m P(A_i \rightarrow \alpha)$$



## PCFG的句法树概率计算



|       |                        |     |                        |     |
|-------|------------------------|-----|------------------------|-----|
| G(S): | $S \rightarrow NP VP$  | 1.0 | $NP \rightarrow He$    | 0.3 |
|       | $VP \rightarrow VP PP$ | 0.8 | $NP \rightarrow soup$  | 0.3 |
|       | $VP \rightarrow V NP$  | 0.2 | $NP \rightarrow spoon$ | 0.2 |
|       | $NP \rightarrow NP PP$ | 0.2 | $V \rightarrow eat$    | 1.0 |
|       | $PP \rightarrow P NP$  | 1.0 | $P \rightarrow with$   | 1.0 |

根据句法树概率计算公式3.2，图3.13所示的两个句法树的概率分别为：

$$\begin{aligned}
 P(T_{Left}) &= P(S \rightarrow NP VP) \times P(NP \rightarrow He) \times P(VP \rightarrow V NP) \times \\
 &\quad P(V \rightarrow eat) \times P(NP \rightarrow NP PP) \times P(NP \rightarrow soup) \times \\
 &\quad P(PP \rightarrow P NP) \times P(P \rightarrow with) \times P(NP \rightarrow spoon) \\
 &= 1.0 \times 0.3 \times 0.2 \times 1.0 \times 0.2 \times 0.3 \times 1.0 \times 1.0 \times 0.2 = 0.00072
 \end{aligned}$$

$$\begin{aligned}
 P(T_{Right}) &= P(S \rightarrow NP VP) \times P(NP \rightarrow He) \times P(VP \rightarrow VP PP) \times \\
 &\quad P(VP \rightarrow V NP) \times P(V \rightarrow eat) \times P(NP \rightarrow soup) \times \\
 &\quad P(PP \rightarrow P NP) \times P(P \rightarrow with) \times P(NP \rightarrow spoon) \\
 &= 1.0 \times 0.3 \times 0.8 \times 0.2 \times 1.0 \times 1.0 \times 0.3 \times 1.0 \times 0.2 = 0.00288
 \end{aligned}$$



## PCFG的三个基本问题:

- 1、给定句子  $W=w_1w_2\dots w_n$  和 PCFG  $G$ , 如何快速计算  $p(W|G)$  ?
- 2、给定句子  $W=w_1w_2\dots w_n$  和 PCFG  $G$ , 如何快速地选择最佳句法结构树?
- 3、给定句子  $W=w_1w_2\dots w_n$  和 PCFG  $G$ , 如何调节  $G$  的参数, 使得  $p(W|G)$  最大?



## PCFG的句子概率计算

句子概率计算是指在给定PCFG 文法G的情况下，计算给定句子W的概率 $P(W|G)$  可以采用**内向算法** (Inside Algorithm) 或**外向算法** (Outside Algorithm)

采用内向算法，首先定义内向变量  $a_{ij}(A)$  为非终结符 A 推导出 W 中子串  $w_i w_{i+1} \cdots w_j$  的概率，即：

$$\alpha_{ij}(A) = P(A \rightarrow w_i w_{i+1} \cdots w_j)$$

句子W的概率则相应的标记为 $a_{1n}(S)$   $P(W|G) = P(S \rightarrow W|G) = \alpha_{1n}(S)$

通过如下递推公式计算得到：

$$\alpha_{ij}(A) = \sum_{B,C} \sum_{i \leq k \leq j} P(A \rightarrow BC) \alpha_{ik}(B) \alpha_{(k+1)j}(C)$$



## PCFG的句子概率计算

句子概率计算是指在给定PCFG 文法 $G$ 的情况下，计算给定句子 $W$ 的概率 $P(W|G)$

### 1、内向算法或外向算法解决第一个问题— 快速地计算句子的句法树概率

#### ◆内向算法

**基本思想：**利用动态规划算法计算由非终结符  $A$  推导出的某个字串片段  $w_i w_{i+1} \cdots w_j$  的概率  $\alpha_{ij}(A)$ 。语句  $W = w_1 w_2 \cdots w_n$  的概率即为文法  $G(S)$  中  $S$  推导出的字串的概率  $\alpha_{1n}(S)$ 。




### PCFG的句子概率计算

句子概率计算是指在给定PCFG 文法G的情况下，计算给定句子W的概率 $P(W|G)$

#### 1、内向算法或外向算法解决第一个问题— 快速地计算句子的句法树概率

##### ◆内向算法

基本思想：利用动态规划算法计算由非终结符  $A$  推导出的某个字串片段  $w_i w_{i+1} \cdots w_j$  的概率  $\alpha_{ij}(A)$ 。语句  $W = w_1 w_2 \cdots w_n$  的概率即为文法  $G(S)$  中  $S$  推导出的字串的概率  $\alpha_{1n}(S)$ 。



内向归纳，自底向上。





## PCFG的句子概率计算

### 内向算法


- 定义：内向变量  $\alpha_{ij}(A)$  是由非终结符  $A$  推导出的语句  $W$  中子字符串  $w_i w_{i+1} \cdots w_j$  的概率：

$$\alpha_{ij}(A) = p(A \xRightarrow{*} w_i w_{i+1} \cdots w_j)$$

计算  $\alpha_{ij}(A)$  的递推公式：

$$\alpha_{ii}(A) = p(A \rightarrow w_i)$$

$$\alpha_{ij}(A) = \sum_{B, C \in V_N} \sum_{i \leq k \leq j} p(A \rightarrow BC) \alpha_{ik}(B) \alpha_{(k+1)j}(C)$$





## PCFG的句子概率计算

### 内向算法

#### ➤解释:

当  $i=j$  时, 字符串  $w_i w_{i+1} \dots w_j$  只是一个字  $w_{ii}$ , 可简单记作  $w_i$ , 由  $A$  推导出  $w_i$  的概率就是产生式  $A \rightarrow w_i$  的概率  $p(A \rightarrow w_i)$ ; 当  $i \neq j$  时, 也就是说, 字符串  $w_i w_{i+1} \dots w_j$  至少有两个词, 根据约定,  $A$  要推导出该词串, 必须首先运用产生式  $A \rightarrow BC$ , 那么, 可用  $B$  推导出前半部  $w_i \dots w_k$ , 用  $C$  推导出后半部  $w_{k+1} \dots w_j$ 。由这一推导过程产生  $w_i w_{i+1} \dots w_j$  的概率为:  $p(A \rightarrow BC) \alpha_{ik}(B) \alpha_{(k+1)j}(C)$ 。考虑到  $B$ 、 $C$  和  $k$  取值的任意性, 应计算各种情况下概率的总和。



---

**代码 3.2:** 面向 PCFG 句子概率求解的内向算法

---

输入: PCFG  $G(S)$  和句子  $w_1w_2\cdots w_n$

输出:  $\alpha_{ij}(A), i \leq i \leq j \leq n$

**for**  $i = 1$  to  $n$  **do**

$\alpha_{ii}(A) = P(A \rightarrow w_i), 1 \leq i \leq n;$

**end**

**for**  $j = 1$  to  $n$  **do**

**for**  $i = 1$  to  $n - j$  **do**

$\alpha_{i(i+j)}(A) = \sum_{B,C} \sum_{i \leq k \leq i+j-1} P(A \rightarrow BC) \alpha_{ik}(B) \alpha_{(k+1)(i+j)}(C);$

**end**

**end**

**return**  $\underline{\alpha}$

---



## PCFG的最佳树结构求解

最佳树结构求解是指对于给定句子 $W = \{w_1, w_2, \dots, w_n\}$  和PCFG文法 $G$ , 求解该句子的最佳树结构, 即如何选择句法结构树使得其概率最大:

$$\hat{t} = \arg \max_{t \in \mathcal{T}_G(W)} P(t|W, G)$$

可以通过利用基于概率的 CYK 算法进行

**return**  $T$




## 使用 CYK 算法求解 PCFG 的最佳树结构分析实例

非终结符号集合:  $N = \{S, P, V, NP, PP, VP\}$


终结符号集合:  $\Sigma = \{ \text{eat, he, soup, spoon, with} \}$

规则集合:  $R = \{ (1) S \rightarrow NP VP 1.0; (2) VP \rightarrow VP PP 0.8; (3) VP \rightarrow V NP 0.2; (4) NP \rightarrow NP PP 0.2; (5) PP \rightarrow P NP 1.0 (6) NP \rightarrow \text{He} 0.3 ;$


(7)  $NP \rightarrow \text{soup} 0.3; (8) NP \rightarrow \text{spoon} 0.2 ; (9) V \rightarrow \text{eat} 1.0;$   
 (10)  $P \rightarrow \text{with} 1.0 \}$




(a)




(b)



(c)




(d)



(e)



## 统计句法分析器实现的一般方法：





给定如下 PCFG  $G(S)$ :

非终结符集合:  $N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$

终结符集合:  $= \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$

规则集:

|                                    |     |                                        |     |
|------------------------------------|-----|----------------------------------------|-----|
| (1) $S \rightarrow NP VP$          | 1.0 | (9) $Vt \rightarrow \text{saw}$        | 1.0 |
| (2) $VP \rightarrow Vi$            | 0.3 | (10) $NN \rightarrow \text{man}$       | 0.1 |
| (3) $VP \rightarrow Vt NP$         | 0.4 | (11) $NN \rightarrow \text{woman}$     | 0.1 |
| (4) $VP \rightarrow VP PP$         | 0.3 | (12) $NN \rightarrow \text{telescope}$ | 0.3 |
| (5) $NP \rightarrow DT NN$         | 0.8 | (13) $NN \rightarrow \text{dog}$       | 0.5 |
| (6) $NP \rightarrow NP PP$         | 0.2 | (14) $DT \rightarrow \text{the}$       | 0.5 |
| (7) $PP \rightarrow IN NP$         | 1.0 | (15) $DT \rightarrow \text{a}$         | 0.5 |
| (8) $Vi \rightarrow \text{sleeps}$ | 1.0 | (16) $IN \rightarrow \text{with}$      | 0.6 |
|                                    |     | (17) $IN \rightarrow \text{in}$        | 0.4 |

输入句子: the man saw the dog with a telescope

|               |            |            |            |             |       |          |                  |
|---------------|------------|------------|------------|-------------|-------|----------|------------------|
| <b>DT 0.5</b> |            |            |            |             |       |          |                  |
| [0,1]         | [0,2]      | [0,3]      | [0,4]      | [0,5]       | [0,6] | [0,7]    | [0,8]            |
| <b>the</b>    |            |            |            |             |       |          |                  |
|               | [1,2]      | [1,3]      | [1,4]      | [1,5]       | [1,6] | [1,7]    | [1,8]            |
| <b>man</b>    |            |            |            |             |       |          |                  |
|               | [2,3]      | [2,4]      | [2,5]      | [2,6]       | [2,7] | [2,8]    |                  |
|               | <b>saw</b> |            |            |             |       |          |                  |
|               |            | [3,4]      | [3,5]      | [3,6]       | [3,7] | [3,8]    |                  |
|               |            | <b>the</b> |            |             |       |          |                  |
|               |            |            | [4,5]      | [4,6]       | [4,7] | [4,8]    |                  |
|               |            |            | <b>dog</b> |             |       |          |                  |
|               |            |            |            | [5,6]       | [5,7] | [5,8]    |                  |
|               |            |            |            | <b>with</b> |       |          |                  |
|               |            |            |            |             | [6,7] | [6,8]    |                  |
|               |            |            |            |             |       |          |                  |
|               |            |            |            |             |       | <b>a</b> |                  |
|               |            |            |            |             |       |          | [7,8]            |
|               |            |            |            |             |       |          | <b>telescope</b> |

第1步:

**DT  $\rightarrow$  the 0.5**





给定如下 PCFG  $G(S)$ :

非终结符集合:  $N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$

终结符集合:  $= \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$

规则集:

|                                    |     |                                        |     |
|------------------------------------|-----|----------------------------------------|-----|
| (1) $S \rightarrow NP VP$          | 1.0 | (9) $Vt \rightarrow \text{saw}$        | 1.0 |
| (2) $VP \rightarrow Vi$            | 0.3 | (10) $NN \rightarrow \text{man}$       | 0.1 |
| (3) $VP \rightarrow Vt NP$         | 0.4 | (11) $NN \rightarrow \text{woman}$     | 0.1 |
| (4) $VP \rightarrow VP PP$         | 0.3 | (12) $NN \rightarrow \text{telescope}$ | 0.3 |
| (5) $NP \rightarrow DT NN$         | 0.8 | (13) $NN \rightarrow \text{dog}$       | 0.5 |
| (6) $NP \rightarrow NP PP$         | 0.2 | (14) $DT \rightarrow \text{the}$       | 0.5 |
| (7) $PP \rightarrow IN NP$         | 1.0 | (15) $DT \rightarrow \text{a}$         | 0.5 |
| (8) $Vi \rightarrow \text{sleeps}$ | 1.0 | (16) $IN \rightarrow \text{with}$      | 0.6 |
|                                    |     | (17) $IN \rightarrow \text{in}$        | 0.4 |

输入句子: the man saw the dog with a telescope

|                        |                        |  |  |  |  |  |  |
|------------------------|------------------------|--|--|--|--|--|--|
| <b>DT 0.5</b><br>[0,1] |                        |  |  |  |  |  |  |
| <b>the</b>             | <b>NN 0.1</b><br>[1,2] |  |  |  |  |  |  |
| <b>man</b>             |                        |  |  |  |  |  |  |
| <b>saw</b>             |                        |  |  |  |  |  |  |
| <b>the</b>             |                        |  |  |  |  |  |  |
| <b>dog</b>             |                        |  |  |  |  |  |  |
| <b>with</b>            |                        |  |  |  |  |  |  |
| <b>a</b>               |                        |  |  |  |  |  |  |
| <b>telescope</b>       |                        |  |  |  |  |  |  |

第2步:  
**NN → man 0.1**



给定如下 PCFG  $G(S)$ :

非终结符集合:  $N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$

终结符集合:  $= \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$

规则集:

|                                    |     |                                        |     |
|------------------------------------|-----|----------------------------------------|-----|
| (1) $S \rightarrow NP VP$          | 1.0 | (9) $Vt \rightarrow \text{saw}$        | 1.0 |
| (2) $VP \rightarrow Vi$            | 0.3 | (10) $NN \rightarrow \text{man}$       | 0.1 |
| (3) $VP \rightarrow Vt NP$         | 0.4 | (11) $NN \rightarrow \text{woman}$     | 0.1 |
| (4) $VP \rightarrow VP PP$         | 0.3 | (12) $NN \rightarrow \text{telescope}$ | 0.3 |
| (5) $NP \rightarrow DT NN$         | 0.8 | (13) $NN \rightarrow \text{dog}$       | 0.5 |
| (6) $NP \rightarrow NP PP$         | 0.2 | (14) $DT \rightarrow \text{the}$       | 0.5 |
| (7) $PP \rightarrow IN NP$         | 1.0 | (15) $DT \rightarrow \text{a}$         | 0.5 |
| (8) $Vi \rightarrow \text{sleeps}$ | 1.0 | (16) $IN \rightarrow \text{with}$      | 0.6 |
|                                    |     | (17) $IN \rightarrow \text{in}$        | 0.4 |

输入句子: the man saw the dog with a telescope

|        |         |       |       |       |       |       |           |
|--------|---------|-------|-------|-------|-------|-------|-----------|
| DT 0.5 | NP 0.04 |       |       |       |       |       |           |
| [0,1]  | [0,2]   | [0,3] | [0,4] | [0,5] | [0,6] | [0,7] | [0,8]     |
| the    | NN 0.1  |       |       |       |       |       |           |
|        | [1,2]   | [1,3] | [1,4] | [1,5] | [1,6] | [1,7] | [1,8]     |
| man    |         | [2,3] | [2,4] | [2,5] | [2,6] | [2,7] | [2,8]     |
|        |         | saw   |       |       |       |       |           |
|        |         |       | [3,4] | [3,5] | [3,6] | [3,7] | [3,8]     |
|        |         |       | the   |       |       |       |           |
|        |         |       |       | [4,5] | [4,6] | [4,7] | [4,8]     |
|        |         |       |       | dog   |       |       |           |
|        |         |       |       |       | [5,6] | [5,7] | [5,8]     |
|        |         |       |       |       | with  |       |           |
|        |         |       |       |       |       | [6,7] | [6,8]     |
|        |         |       |       |       |       | a     |           |
|        |         |       |       |       |       |       | [7,8]     |
|        |         |       |       |       |       |       | telescope |

第3步:

**NP  $\rightarrow$  DT NN 0.8**



给定如下 PCFG  $G(S)$ :

非终结符集合:  $N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$

终结符集合:  $= \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$

规则集:

|                                    |     |                                        |     |
|------------------------------------|-----|----------------------------------------|-----|
| (1) $S \rightarrow NP VP$          | 1.0 | (9) $Vt \rightarrow \text{saw}$        | 1.0 |
| (2) $VP \rightarrow Vi$            | 0.3 | (10) $NN \rightarrow \text{man}$       | 0.1 |
| (3) $VP \rightarrow Vt NP$         | 0.4 | (11) $NN \rightarrow \text{woman}$     | 0.1 |
| (4) $VP \rightarrow VP PP$         | 0.3 | (12) $NN \rightarrow \text{telescope}$ | 0.3 |
| (5) $NP \rightarrow DT NN$         | 0.8 | (13) $NN \rightarrow \text{dog}$       | 0.5 |
| (6) $NP \rightarrow NP PP$         | 0.2 | (14) $DT \rightarrow \text{the}$       | 0.5 |
| (7) $PP \rightarrow IN NP$         | 1.0 | (15) $DT \rightarrow \text{a}$         | 0.5 |
| (8) $Vi \rightarrow \text{sleeps}$ | 1.0 | (16) $IN \rightarrow \text{with}$      | 0.6 |
|                                    |     | (17) $IN \rightarrow \text{in}$        | 0.4 |

输入句子: the man saw the dog with a telescope

|                 |                  |  |  |  |  |  |  |
|-----------------|------------------|--|--|--|--|--|--|
| DT 0.5<br>[0,1] | NP 0.04<br>[0,2] |  |  |  |  |  |  |
| the             | NN 0.1<br>[1,2]  |  |  |  |  |  |  |
| man             | Vt 1.0<br>[2,3]  |  |  |  |  |  |  |
| saw             | DT 0.5<br>[3,4]  |  |  |  |  |  |  |
| the             | NN 0.5<br>[4,5]  |  |  |  |  |  |  |
| dog             |                  |  |  |  |  |  |  |
| with            |                  |  |  |  |  |  |  |
| a               |                  |  |  |  |  |  |  |
| telescope       |                  |  |  |  |  |  |  |

第4~6步:  
 $Vt \rightarrow \text{saw} \quad 1.0$   
 $DT \rightarrow \text{the} \quad 0.5$   
 $NN \rightarrow \text{dog} \quad 0.5$



给定如下 PCFG  $G(S)$ :

非终结符集合:  $N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$

终结符集合:  $= \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$

规则集:

|                                    |     |                                        |     |
|------------------------------------|-----|----------------------------------------|-----|
| (1) $S \rightarrow NP VP$          | 1.0 | (9) $Vt \rightarrow \text{saw}$        | 1.0 |
| (2) $VP \rightarrow Vi$            | 0.3 | (10) $NN \rightarrow \text{man}$       | 0.1 |
| (3) $VP \rightarrow Vt NP$         | 0.4 | (11) $NN \rightarrow \text{woman}$     | 0.1 |
| (4) $VP \rightarrow VP PP$         | 0.3 | (12) $NN \rightarrow \text{telescope}$ | 0.3 |
| (5) $NP \rightarrow DT NN$         | 0.8 | (13) $NN \rightarrow \text{dog}$       | 0.5 |
| (6) $NP \rightarrow NP PP$         | 0.2 | (14) $DT \rightarrow \text{the}$       | 0.5 |
| (7) $PP \rightarrow IN NP$         | 1.0 | (15) $DT \rightarrow \text{a}$         | 0.5 |
| (8) $Vi \rightarrow \text{sleeps}$ | 1.0 | (16) $IN \rightarrow \text{with}$      | 0.6 |
|                                    |     | (17) $IN \rightarrow \text{in}$        | 0.4 |

输入句子: the man saw the dog with a telescope

|           |                 |                  |                 |                 |                 |  |  |
|-----------|-----------------|------------------|-----------------|-----------------|-----------------|--|--|
|           | DT 0.5<br>[0,1] | NP 0.04<br>[0,2] |                 |                 |                 |  |  |
| the       |                 | NN 0.1<br>[1,2]  |                 |                 |                 |  |  |
| man       |                 |                  | Vt 1.0<br>[2,3] |                 |                 |  |  |
| saw       |                 |                  |                 | DT 0.5<br>[3,4] | NP 0.2<br>[3,5] |  |  |
| the       |                 |                  |                 |                 | NN 0.5<br>[4,5] |  |  |
| dog       |                 |                  |                 |                 |                 |  |  |
| with      |                 |                  |                 |                 |                 |  |  |
| a         |                 |                  |                 |                 |                 |  |  |
| telescope |                 |                  |                 |                 |                 |  |  |

第7步:  
 **$NP \rightarrow DT NN$  0.8**



给定如下 PCFG  $G(S)$ :


非终结符集合:  $N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$

终结符集合:  $= \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$

规则集:

|                                    |     |                                        |     |
|------------------------------------|-----|----------------------------------------|-----|
| (1) $S \rightarrow NP VP$          | 1.0 | (9) $Vt \rightarrow \text{saw}$        | 1.0 |
| (2) $VP \rightarrow Vi$            | 0.3 | (10) $NN \rightarrow \text{man}$       | 0.1 |
| (3) $VP \rightarrow Vt NP$         | 0.4 | (11) $NN \rightarrow \text{woman}$     | 0.1 |
| (4) $VP \rightarrow VP PP$         | 0.3 | (12) $NN \rightarrow \text{telescope}$ | 0.3 |
| (5) $NP \rightarrow DT NN$         | 0.8 | (13) $NN \rightarrow \text{dog}$       | 0.5 |
| (6) $NP \rightarrow NP PP$         | 0.2 | (14) $DT \rightarrow \text{the}$       | 0.5 |
| (7) $PP \rightarrow IN NP$         | 1.0 | (15) $DT \rightarrow \text{a}$         | 0.5 |
| (8) $Vi \rightarrow \text{sleeps}$ | 1.0 | (16) $IN \rightarrow \text{with}$      | 0.6 |
|                                    |     | (17) $IN \rightarrow \text{in}$        | 0.4 |

输入句子: the man saw the dog with a telescope





给定如下 PCFG  $G(S)$ :

非终结符集合:  $N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$

终结符集合:  $= \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$

规则集:

|                                    |     |                                        |     |
|------------------------------------|-----|----------------------------------------|-----|
| (1) $S \rightarrow NP VP$          | 1.0 | (9) $Vt \rightarrow \text{saw}$        | 1.0 |
| (2) $VP \rightarrow Vi$            | 0.3 | (10) $NN \rightarrow \text{man}$       | 0.1 |
| (3) $VP \rightarrow Vt NP$         | 0.4 | (11) $NN \rightarrow \text{woman}$     | 0.1 |
| (4) $VP \rightarrow VP PP$         | 0.3 | (12) $NN \rightarrow \text{telescope}$ | 0.3 |
| (5) $NP \rightarrow DT NN$         | 0.8 | (13) $NN \rightarrow \text{dog}$       | 0.5 |
| (6) $NP \rightarrow NP PP$         | 0.2 | (14) $DT \rightarrow \text{the}$       | 0.5 |
| (7) $PP \rightarrow IN NP$         | 1.0 | (15) $DT \rightarrow \text{a}$         | 0.5 |
| (8) $Vi \rightarrow \text{sleeps}$ | 1.0 | (16) $IN \rightarrow \text{with}$      | 0.6 |
|                                    |     | (17) $IN \rightarrow \text{in}$        | 0.4 |

输入句子: the man saw the dog with a telescope

|                 |                  |                 |                  |  |  |  |  |
|-----------------|------------------|-----------------|------------------|--|--|--|--|
| DT 0.5<br>[0,1] | NP 0.04<br>[0,2] |                 |                  |  |  |  |  |
| the             | NN 0.1<br>[1,2]  |                 |                  |  |  |  |  |
| man             | Vt 1.0<br>[2,3]  |                 | VP 0.08<br>[2,5] |  |  |  |  |
| saw             | DT 0.5<br>[3,4]  | NP 0.2<br>[3,5] |                  |  |  |  |  |
| the             | NN 0.5<br>[4,5]  |                 |                  |  |  |  |  |
| dog             | IN 0.6<br>[5,6]  |                 |                  |  |  |  |  |
| with            | DT 0.5<br>[6,7]  |                 |                  |  |  |  |  |
| a               | NN 0.3<br>[7,8]  |                 |                  |  |  |  |  |
| telescope       |                  |                 |                  |  |  |  |  |

第9~11步:

$IN \rightarrow \text{with}$  0.6

$DT \rightarrow \text{a}$  0.5

$NN \rightarrow \text{telescope}$  0.3



给定如下 PCFG  $G(S)$ :


非终结符集合:  $N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$

终结符集合:  $= \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$

规则集:

|                                    |     |                                        |     |
|------------------------------------|-----|----------------------------------------|-----|
| (1) $S \rightarrow NP VP$          | 1.0 | (9) $Vt \rightarrow \text{saw}$        | 1.0 |
| (2) $VP \rightarrow Vi$            | 0.3 | (10) $NN \rightarrow \text{man}$       | 0.1 |
| (3) $VP \rightarrow Vt NP$         | 0.4 | (11) $NN \rightarrow \text{woman}$     | 0.1 |
| (4) $VP \rightarrow VP PP$         | 0.3 | (12) $NN \rightarrow \text{telescope}$ | 0.3 |
| (5) $NP \rightarrow DT NN$         | 0.8 | (13) $NN \rightarrow \text{dog}$       | 0.5 |
| (6) $NP \rightarrow NP PP$         | 0.2 | (14) $DT \rightarrow \text{the}$       | 0.5 |
| (7) $PP \rightarrow IN NP$         | 1.0 | (15) $DT \rightarrow \text{a}$         | 0.5 |
| (8) $Vi \rightarrow \text{sleeps}$ | 1.0 | (16) $IN \rightarrow \text{with}$      | 0.6 |
|                                    |     | (17) $IN \rightarrow \text{in}$        | 0.4 |

输入句子: the man saw the dog with a telescope







给定如下 PCFG  $G(S)$ :


非终结符集合:  $N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$

终结符集合:  $= \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$

规则集:

|                                    |     |                                        |     |
|------------------------------------|-----|----------------------------------------|-----|
| (1) $S \rightarrow NP VP$          | 1.0 | (9) $Vt \rightarrow \text{saw}$        | 1.0 |
| (2) $VP \rightarrow Vi$            | 0.3 | (10) $NN \rightarrow \text{man}$       | 0.1 |
| (3) $VP \rightarrow Vt NP$         | 0.4 | (11) $NN \rightarrow \text{woman}$     | 0.1 |
| (4) $VP \rightarrow VP PP$         | 0.3 | (12) $NN \rightarrow \text{telescope}$ | 0.3 |
| (5) $NP \rightarrow DT NN$         | 0.8 | (13) $NN \rightarrow \text{dog}$       | 0.5 |
| (6) $NP \rightarrow NP PP$         | 0.2 | (14) $DT \rightarrow \text{the}$       | 0.5 |
| (7) $PP \rightarrow IN NP$         | 1.0 | (15) $DT \rightarrow \text{a}$         | 0.5 |
| (8) $Vi \rightarrow \text{sleeps}$ | 1.0 | (16) $IN \rightarrow \text{with}$      | 0.6 |
|                                    |     | (17) $IN \rightarrow \text{in}$        | 0.4 |

输入句子: the man saw the dog with a telescope







给定如下 PCFG  $G(S)$ :


非终结符集合:  $N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$

终结符集合:  $= \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$

规则集:

|                                    |     |                                        |     |
|------------------------------------|-----|----------------------------------------|-----|
| (1) $S \rightarrow NP VP$          | 1.0 | (9) $Vt \rightarrow \text{saw}$        | 1.0 |
| (2) $VP \rightarrow Vi$            | 0.3 | (10) $NN \rightarrow \text{man}$       | 0.1 |
| (3) $VP \rightarrow Vt NP$         | 0.4 | (11) $NN \rightarrow \text{woman}$     | 0.1 |
| (4) $VP \rightarrow VP PP$         | 0.3 | (12) $NN \rightarrow \text{telescope}$ | 0.3 |
| (5) $NP \rightarrow DT NN$         | 0.8 | (13) $NN \rightarrow \text{dog}$       | 0.5 |
| (6) $NP \rightarrow NP PP$         | 0.2 | (14) $DT \rightarrow \text{the}$       | 0.5 |
| (7) $PP \rightarrow IN NP$         | 1.0 | (15) $DT \rightarrow \text{a}$         | 0.5 |
| (8) $Vi \rightarrow \text{sleeps}$ | 1.0 | (16) $IN \rightarrow \text{with}$      | 0.6 |
|                                    |     | (17) $IN \rightarrow \text{in}$        | 0.4 |

输入句子: the man saw the dog with a telescope





给定如下 PCFG  $G(S)$ :


非终结符集合:  $N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$

终结符集合:  $= \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$

规则集:

|                                    |     |                                        |     |
|------------------------------------|-----|----------------------------------------|-----|
| (1) $S \rightarrow NP VP$          | 1.0 | (9) $Vt \rightarrow \text{saw}$        | 1.0 |
| (2) $VP \rightarrow Vi$            | 0.3 | (10) $NN \rightarrow \text{man}$       | 0.1 |
| (3) $VP \rightarrow Vt NP$         | 0.4 | (11) $NN \rightarrow \text{woman}$     | 0.1 |
| (4) $VP \rightarrow VP PP$         | 0.3 | (12) $NN \rightarrow \text{telescope}$ | 0.3 |
| (5) $NP \rightarrow DT NN$         | 0.8 | (13) $NN \rightarrow \text{dog}$       | 0.5 |
| (6) $NP \rightarrow NP PP$         | 0.2 | (14) $DT \rightarrow \text{the}$       | 0.5 |
| (7) $PP \rightarrow IN NP$         | 1.0 | (15) $DT \rightarrow \text{a}$         | 0.5 |
| (8) $Vi \rightarrow \text{sleeps}$ | 1.0 | (16) $IN \rightarrow \text{with}$      | 0.6 |
|                                    |     | (17) $IN \rightarrow \text{in}$        | 0.4 |

输入句子: the man saw the dog with a telescope





给定如下 PCFG  $G(S)$ :


非终结符集合:  $N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$


终结符集合:  $= \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$

规则集:

|                                    |     |                                        |     |
|------------------------------------|-----|----------------------------------------|-----|
| (1) $S \rightarrow NP VP$          | 1.0 | (9) $Vt \rightarrow \text{saw}$        | 1.0 |
| (2) $VP \rightarrow Vi$            | 0.3 | (10) $NN \rightarrow \text{man}$       | 0.1 |
| (3) $VP \rightarrow Vt NP$         | 0.4 | (11) $NN \rightarrow \text{woman}$     | 0.1 |
| (4) $VP \rightarrow VP PP$         | 0.3 | (12) $NN \rightarrow \text{telescope}$ | 0.3 |
| (5) $NP \rightarrow DT NN$         | 0.8 | (13) $NN \rightarrow \text{dog}$       | 0.5 |
| (6) $NP \rightarrow NP PP$         | 0.2 | (14) $DT \rightarrow \text{the}$       | 0.5 |
| (7) $PP \rightarrow IN NP$         | 1.0 | (15) $DT \rightarrow \text{a}$         | 0.5 |
| (8) $Vi \rightarrow \text{sleeps}$ | 1.0 | (16) $IN \rightarrow \text{with}$      | 0.6 |
|                                    |     | (17) $IN \rightarrow \text{in}$        | 0.4 |

输入句子: the man saw the dog with a telescope







给定如下 PCFG  $G(S)$ :


非终结符集合:  $N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$

终结符集合:  $= \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$

规则集:

|                                    |     |                                        |     |
|------------------------------------|-----|----------------------------------------|-----|
| (1) $S \rightarrow NP VP$          | 1.0 | (9) $Vt \rightarrow \text{saw}$        | 1.0 |
| (2) $VP \rightarrow Vi$            | 0.3 | (10) $NN \rightarrow \text{man}$       | 0.1 |
| (3) $VP \rightarrow Vt NP$         | 0.4 | (11) $NN \rightarrow \text{woman}$     | 0.1 |
| (4) $VP \rightarrow VP PP$         | 0.3 | (12) $NN \rightarrow \text{telescope}$ | 0.3 |
| (5) $NP \rightarrow DT NN$         | 0.8 | (13) $NN \rightarrow \text{dog}$       | 0.5 |
| (6) $NP \rightarrow NP PP$         | 0.2 | (14) $DT \rightarrow \text{the}$       | 0.5 |
| (7) $PP \rightarrow IN NP$         | 1.0 | (15) $DT \rightarrow \text{a}$         | 0.5 |
| (8) $Vi \rightarrow \text{sleeps}$ | 1.0 | (16) $IN \rightarrow \text{with}$      | 0.6 |
|                                    |     | (17) $IN \rightarrow \text{in}$        | 0.4 |

输入句子: the man saw the dog with a telescope





给定如下 PCFG  $G(S)$ :


非终结符集合:  $N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$

终结符集合:  $= \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$

规则集:

|                                    |     |                                        |     |
|------------------------------------|-----|----------------------------------------|-----|
| (1) $S \rightarrow NP VP$          | 1.0 | (9) $Vt \rightarrow \text{saw}$        | 1.0 |
| (2) $VP \rightarrow Vi$            | 0.3 | (10) $NN \rightarrow \text{man}$       | 0.1 |
| (3) $VP \rightarrow Vt NP$         | 0.4 | (11) $NN \rightarrow \text{woman}$     | 0.1 |
| (4) $VP \rightarrow VP PP$         | 0.3 | (12) $NN \rightarrow \text{telescope}$ | 0.3 |
| (5) $NP \rightarrow DT NN$         | 0.8 | (13) $NN \rightarrow \text{dog}$       | 0.5 |
| (6) $NP \rightarrow NP PP$         | 0.2 | (14) $DT \rightarrow \text{the}$       | 0.5 |
| (7) $PP \rightarrow IN NP$         | 1.0 | (15) $DT \rightarrow \text{a}$         | 0.5 |
| (8) $Vi \rightarrow \text{sleeps}$ | 1.0 | (16) $IN \rightarrow \text{with}$      | 0.6 |
|                                    |     | (17) $IN \rightarrow \text{in}$        | 0.4 |

输入句子: the man saw the dog with a telescope





给定如下 PCFG  $G(S)$ :


非终结符集合:  $N = \{S, NP, VP, PP, DT, Vi, Vt, NN, IN\}$


终结符集合:  $= \{\text{sleeps, saw, man, woman, dog, telescope, the, with, in}\}$

规则集:

|                                    |     |                                        |     |
|------------------------------------|-----|----------------------------------------|-----|
| (1) $S \rightarrow NP VP$          | 1.0 | (9) $Vt \rightarrow \text{saw}$        | 1.0 |
| (2) $VP \rightarrow Vi$            | 0.3 | (10) $NN \rightarrow \text{man}$       | 0.1 |
| (3) $VP \rightarrow Vt NP$         | 0.4 | (11) $NN \rightarrow \text{woman}$     | 0.1 |
| (4) $VP \rightarrow VP PP$         | 0.3 | (12) $NN \rightarrow \text{telescope}$ | 0.3 |
| (5) $NP \rightarrow DT NN$         | 0.8 | (13) $NN \rightarrow \text{dog}$       | 0.5 |
| (6) $NP \rightarrow NP PP$         | 0.2 | (14) $DT \rightarrow \text{the}$       | 0.5 |
| (7) $PP \rightarrow IN NP$         | 1.0 | (15) $DT \rightarrow \text{a}$         | 0.5 |
| (8) $Vi \rightarrow \text{sleeps}$ | 1.0 | (16) $IN \rightarrow \text{with}$      | 0.6 |
|                                    |     | (17) $IN \rightarrow \text{in}$        | 0.4 |

输入句子: the man saw the dog with a telescope





### ◆ PCFG 的评价

#### ➤ 优点:

- 可利用概率减少分析过程的搜索空间;
- 可利用概率对概率较小的子树剪枝, 加快分析效率;
- 可以定量地比较两个语法的性能。

#### ➤ 弱点:

- 分析树的概率计算条件非常苛刻, 甚至不够合理。





## PCFG的模型参数学习

模型参数学习是指给定 CFG 文法  $G$  下，如何学习  $G$  中规则的概率参数构建 PCFG 文法。有两种常见的方法用于学习文法规则概率：

(1) 有大规模句法树标注数据（树库），可以基于最大似然估计，统计非终结符的出现次数进行概率参数估计

$$P(A \rightarrow \alpha) = \frac{\text{Count}(A \rightarrow \alpha)}{\sum_{\lambda} \text{Count}(A \rightarrow \lambda)} = \frac{\text{Count}(A \rightarrow \alpha)}{\text{Count}(A)}$$

$\text{Count}(A \rightarrow \alpha)$  是指规则  $A \rightarrow \alpha$  在整个树库中出现的次数， $\text{Count}(A)$  是指在树库中非终结符  $A$  出现的次数



## PCFG的模型参数学习

模型参数学习是指给定 CFG 文法  $G$  下，如何学习  $G$  中规则的概率参数构建 PCFG 文法。有两种常见的方法用于学习语法规则概率：

(2) 有大规模的没有标注句法树的句子的情况下，也可以通过**期望最大化算法**（Expectation Maximization, EM）估计规则的概率参数。利用当前的文法  $G_i$  估算每条规则出现的期望值是**期望步**（**Expectation Step, E-步骤**），重新估算概率得到  $G_{i+1}$  的步骤是**最大化步**（**Maximization Step, M-步骤**）

初始时随机地给参数赋值，得到语法  $G_0$ ，依据  $G_0$  和训练语料，得到语法规则使用次数的期望值，以期望次数运用于最大似然估计，得到语法参数新的估计值，由此得到新的语法  $G_1$ ，由  $G_1$  再次得到语法规则的使用次数的期望值，然后又可以重新估计语法参数。循环这个过程，语法参数将收敛于最大似然估计值。



对于第一组实验结果"5正面, 5反面":

- 如果用的是硬币A: 观察到这个结果的概率是  $C(10,5) \times (0.6)^5 \times (0.4)^5 = 0.201$
- 如果用的是硬币B: 观察到这个结果的概率是  $C(10,5) \times (0.5)^5 \times (0.5)^5 = 0.246$

所以, 第一组实验使用硬币A的概率是:  
 $0.201 / (0.201 + 0.246) = 0.45$  使用硬币B的概率是:  $0.246 / (0.201 + 0.246) = 0.55$

### EM算法步骤示意图: 硬币投掷实验

问题: 两枚硬币A和B, 正面概率分别为 $\theta_A$ 和 $\theta_B$  (未知)

5组实验, 每组投10次, 正面次数为: [5, 9, 8, 4, 7]

但不知道每组用的是哪枚硬币 (隐变量)

初始化:  $\theta_A = 0.6, \theta_B = 0.5$

#### E步 (期望步)

1. 计算每组实验结果在当前参数下来自硬币A和硬币B的概率
2. 例如: 第一组(5正面)来自硬币A的概率 =  $C(10,5) \times (0.6)^5 \times (0.4)^5 = 0.201$
3. 计算每组使用硬币A的概率:  $0.201 / (0.201 + 0.246) = 0.45$ , 硬币B概率 = 0.55

#### M步 (最大化步)

1. 基于E步的概率分布, 重新估计参数 $\theta_A$ 和 $\theta_B$
2. 例如:  $\theta_A = (0.45 \times 5 + 0.8 \times 9 + 0.7 \times 8 + 0.4 \times 4 + 0.6 \times 7) / (0.45 \times 10 + \dots + 0.6 \times 10)$
3. 得到新的参数估计:  $\theta_A = 0.69, \theta_B = \dots$

判断收敛: 参数是否稳定?

是 → 结束, 否 → 返回E步



## PARSEVAL 方法

- (1) 标记精确率 (Labeled Precision, LP): 句法器分析结果中正确的短语结构所占比例, 即分析结果与标准句法树中短语匹配的个数占分析器所有输出结果中短语个数的比例, 具体计算公式如下:

$$LP = \frac{\text{分析结果中正确的短语个数}}{\text{分析结果中短语总数}} \times 100\% \quad (3.12)$$


- (2) 标记召回率 (Labeled Recall, LR): 分析结果中正确的短语结构占标准句法树中短语总数的比例, 具体计算公式:

$$LR = \frac{\text{分析结果中正确的短语个数}}{\text{标准结果中短语总数}} \times 100\% \quad (3.13)$$


- (3) 交叉括号数 (Crossing brackets, CBs): 一棵成分句法树中所包含的与标准句法树中边界相交叉的短语个数。

(a) 正确结果: S(0,5), NP(0,1), VP(1,5), VP(1,3), NP(2,3), PP(3,5), NP(4,5)

(b) 算法分析结果: S(0,5), NP(0,1), VP(1,5), NP(2,5), NP(2,3), PP(3,5), NP(4,5)



(a) 正确答案



(b) 算法分析结果

# 本章主要内容

3.1

句法概述

3.2

成分句法分析

3.3

依存句法分析

3.3.1 基于图的依存句法分析的成分句法分析

3.3.2 基于神经网络的图依存句法分析句法分析

3.3.3 基于转移的依存句法分析

3.3.4 基于神经网络的转移依存句法分析

3.3.5 依存句法分析评价方法

3.4

句法分析语料库



**依存句法分析** (Dependency Parsing) 任务目标是依据依存语法理论分析输入句子得到其依存句法结构树

**依存句法理论的基本假设**是句法结构由**单词和单词之间的依存关系**组成。依存关系具有**方向性**，从中心语成分指向依存成分。依存关系根据中心成分和依存成分之间的关系又可以被定义为不同的依存关系类型

依存句法结构使用依存图 (Dependency Graph) 进行表示







图 3.17 句子“她非常喜欢跳芭蕾舞”的依存句法树



**不同于短语结构树，依存句法不关注如何生成句子，而是关注句子中短语的语法联系**



## 依存句法分析和成分句法分析的对比



在本节中，使用  $S = w_0 w_1 \cdots w_n$  表示输入的句子，其中  $w_0 = \text{root}$  表示虚拟根节点， $w_1 \cdots w_n$  为输入句子中的  $n$  个单词。 $R = \{r_0, r_1, \dots, r_m\}$  表示依存关系类型集合， $r \in R$  表示在句子中单词之间的依存关系，也叫做**边标签 (Arc Label)**。

$$(1) V \subseteq \{w_0, w_1, \dots, w_n\}$$

$$(2) R \subseteq V \times R \times V$$

$$(3) \text{ 如果 } (w_i, r, w_j) \in A, \text{ 那么 } (w_i, r', w_j) \notin A, \forall r' \neq r$$




图 3.17 句子“她非常喜欢跳芭蕾舞”的依存句法树

$$(1) G = (V, A)$$

$$(2) V = V_W = \{\text{ROOT}, \text{她}, \text{非常}, \text{喜欢}, \text{跳}, \text{芭蕾舞}\}$$

$$(3) A = \{(\text{ROOT}, \text{root}, \text{喜欢}), (\text{喜欢}, \text{nsubj}, \text{她}), (\text{喜欢}, \text{advmod}, \text{非常}), (\text{喜欢}, \text{xcomp}, \text{跳}), (\text{跳}, \text{dobj}, \text{芭蕾舞})\}$$

如果依存图  $G = (V, A)$  对于输入句子  $S$  和关系集合  $R$ ，**是一个从  $w_0$  出发的有向树，并且包含句子中的所有单词**，那么这个依存图  $G$  就成为形式良好的依存图 (Well-formed Dependency Graph)，也称为**依存树 (Dependency Tree)**。





基于图的依存句法分析**核心是构造评分函数**，对句子S 所有依存句法树 $G = (V, A) \in G_W$  进行评分。这个评分代表了一个句法树作为句子分析正确结果的可能性。

不同的基于图的分析方法采用不同的假设来计算得分。

基于图的依存句法分析算法通常将对依存句法树的 $G = (V, A)$  的评分转化为对其树上的边的评分：

$$\text{score}(G_S) = \sum_{(w_i, r, w_j) \in A} \lambda_{(w_i, r, w_j)}$$

可以将基于图的依存句法分析形式化表示为：

$$\hat{G} = \arg \max_{G=(V, A) \in \mathcal{G}_S} \sum_{(w_i, r, w_j) \in A} \lambda_{(w_i, r, w_j)}$$



可以证明在依存句法树不考虑投射性（Projectivity）的情况下，对于输入句子S的依存句法分析问题等价于基于边评分 $\lambda_{(w_i, r, w_j)}$ 的图GS的**最大生成树**（Maximum Spanning Tree）寻找问题

利用**最大生成树算法**得到的依存句法树**不具备投射性**。

针对**具有投射性要求**的依存句法树，可以利用其与上下文无关语法之间的强相关性，利用**基于CYK 算法**等上下文无关语法分析算法进行依存句法树分析。



## 非投射性依存句法分析方法

**朱-刘/埃德蒙兹算法** (Chu-Liu/Edmonds) 方法是一种常见的带权有向图最小/大生成树寻找算法，因此也常被应用于非投射性依存句法分析。

输入是待分析句子  $S = w_0 w_1 \dots w_n$  以及边之间的权重  $\lambda(w_i, w_j) \in \Lambda$

$w_0$  是句子的虚拟根节点，依存句法树中不存在指向  $w_0$  的边。



- (1) 根据句子中的单词和权重组成有向图  $G_S = (V_S, A_S)$
- (2) 针对图  $G$  中每个顶点选择入边权重最大的边构建子图  $G' = (V_S, A')$ 。如果该子图中没有环，那么该子图就是图  $G$  的最大生成树。
- (3) 否则，说明图  $G'$  中至少包含一个环。那么选择其中任意一个环  $C$ ，其边集合为  $A_C$ ，将环  $C$  用一个节点  $w_c$  来代表，图  $G_C$  中包含所有在图  $G$  中但是不在环  $C$  中的节点以及  $w_c$ ， $G_C$  的边通过以下规则构建：

- (1) 对于所有不在环  $C$  的顶点  $w_j$ ，如果存在一个边  $(w_i, w_j)$ ， $w_i$  在环  $C$  中，那么就添加边  $(w_c, w_j)$  到  $G_C$  中，定义  $ep(w_c, w_j) = \arg \max_{w_i \in C} \lambda_{(w_i, w_j)}$ ，用于记录环  $C$  中相对应的顶点，相应地修改  $(w_c, w_j)$  的边权重  $\lambda_{(w_c, w_j)} = \lambda_{(ep(w_c, w_j), w_j)}$ ；
- (2) 对于所有不在环  $C$  的顶点  $w_i$ ，如果存在一个边  $(w_i, w_j)$ ， $w_j$  在环  $C$  中，那么添加边  $(w_i, w_c)$  到  $G_C$  中，定义  $ep(w_i, w_c) = \arg \max_{w_j \in C} [\lambda_{(w_i, w_j)} - \lambda_{(a(w_j), w_j)}]$ ，相应地修改  $(w_i, w_c)$  的边权重  $\lambda_{(w_i, w_c)} = \lambda_{(w_i, ep(w_i, w_c))} - \lambda_{(a(ep(w_i, w_c)), (ep(w_i, w_c)))} + \sum_{w \in C} \lambda_{(a(w), w)}$ ；
- (3) 对于所有边  $(w_i, w_j)$ ，其顶点  $w_i$  和  $w_j$  都不在环  $C$  中，直接添加该边到图  $G'$  中，保持原有权重不变。

- (4) 将图  $G_C$  作为输入，递归调用上述算法得到其最大生成树  $G = (V, A)$ 。之后根据所返回的最大生








图3.18 朱-刘/埃德蒙兹算法生成依存句法树样例



## 投射性依存句法分析方法

设置虚拟根节点在句子首位的情况下，投射性依存句法分析树等价于**嵌套依存句法分析树 (Nested Dependency Trees)**。因此投射性依存句法分析与上下文无关语法具有非常强的关系，很多用于上下文无关语法分析的算法也可以应用于投射性依存句法分析。

首先定义动态规划表  $C[s][t][i]$  ( $s \leq i \leq t$ )，表示投射性句法树以单词  $w_i$  为根节点覆盖从单词  $w_s$  到单词  $w_t$  的句子片段的最高得分。由此可以得到  $C[0][n][0]$  表示输入句子  $S = w_0, w_1, \dots, w_n$  的依存句法树的最高得分。



## 投射性依存句法分析方法

$$C[s][t][i] = \max_{s \leq k \leq t, s \leq j \leq t} \begin{cases} C[s][k][i] + C[k+1][t][j] + \lambda(w_i, w_j), & \text{如果 } j > i \\ C[s][k][j] + C[k+1][t][i] + \lambda(w_i, w_j), & \text{如果 } j < i \end{cases} \quad (3.16)$$

图3.19给出了合并过程示意图。




图 3.19 面向依存句法分析的 CYK 算法递推样例



## 投射性依存句法分析方法

$A[s][t][i]$  按照如下公式记录树结构:

$$A[s][t][i] = \begin{cases} A[s][k][i] \cup A[k+1][t][j] \cup (w_i, w_j), & \text{如果 } j > i \\ A[s][k][j] \cup A[k+1][t][i] \cup (w_j, w_i), & \text{如果 } j < i \end{cases} \quad (3.17)$$





## 边评分模型学习方法

边评分模型可以使用基于高维特征向量的线性函数进行建模

$$\lambda_{(w_i, r, w_j)} = \mathbf{w} \cdot f(w_i, r, w_j)$$

$f(\cdot)$  包含了边和输入句子  $S$  中各类型相关特征

这些特征还可以组合为更复杂的类型

- $w_i$  = 喜欢
- $w_i$  = 跳
- $w_i$  的词性 = V
- $w_j$  的词性 = V
- $r$  的依存关系类型 = xcomp
- $w_{i-1}$  的词性 = ADV
- $w_{j+1}$  的词性 = N
- $w_i$  和  $w_j$  之间距离 = 1

- $w_i$  的词性 = V &  $w_j$  的词性 = V &  $w_i$  = 喜欢
- $w_i$  = 喜欢 &  $w_j$  = 跳 &  $w_i$  和  $w_j$  之间距离 = 1



## 边评分模型学习方法

基于特征向量的线性函数建模的假设下，对于输入句子的依存句法分析转换为了如下问题：

$$\hat{G} = \arg \max_{G=(V,A) \in \mathcal{G}_S} \sum_{(w_i, r, w_j) \in A} \lambda(w_i, r, w_j) = \arg \max_{G=(V,A) \in \mathcal{G}_S} \sum_{(w_i, r, w_j) \in A} \mathbf{w} \cdot f(w_i, r, w_j) \quad (3.19)$$

$\mathcal{D} = \{(S_d, G_d)\}_{d=1}^{|\mathcal{D}|}$  表示训练语料集合

$S_d$  表示输入句子，所对应的正确的依存句法树用  $G_d$  表示



## 边评分模型学习方法

---

代码 3.5: 感知器算法学习参数向量  $\mathbf{w}$

---

输入: 训练语料  $\mathcal{D} = \{(S_d, G_d)\}_{d=1}^{|\mathcal{D}|}$

输出: 权重向量  $\mathbf{w}$

**Function** Perceptron( $\mathcal{D}$ ) :

```

     $w=0$ ;
    for  $n : 1 \dots N$  do
        for  $d : 1 \dots |\mathcal{D}|$  do
             $G'_d = \arg \max_{G=(V,A) \in \mathcal{G}_{S_d}} \sum_{(w_i, r, w_j) \in A} \mathbf{w} \cdot f(w_i, r, w_j);$ 
            if  $G_d \neq G'_d$  then
                 $\mathbf{w} = \mathbf{w} + \sum_{(w_i, r, w_j) \in A_d} f(w_i, r, w_j) - \sum_{(w_i, r, w_j) \in A'} f(w_i, r, w_j);$ 
            end
        end
    end
    return  $\mathbf{w}$ 
return
```

---





基于图的依存句法分析主要包含**边评分模型**和**句法树生成算法**两个部分组成。其中边评分模型对于分析效果具有决定性的影响。**神经网络方法也可以用于构造边评分。**



## 基于前馈神经网络的方法

模型输入包含两大部分：原子特征（Atomic Features）和短语结构（Phrases）。


- 原子特征部分使用单个词和单个词性。通过查找嵌入矩阵  $M = R^{d \times |D|}$  转换为相应的嵌入（Embedding）表示。 $|D|$  是特征字典大小， $d$  是特征嵌入表示的维度。
- 为了更好地建模依存关系的上下文信息，根据所要预测中心词和修饰词在句子中的位置，将句子切分为前缀（Prefix）、中缀（Infix）和后缀（Suffix）。





## 基于双仿射变换的方法

Deep Biaffine Parser也是采用最大生成树方法构造依存句法树，引入了双向长短时记忆网络，更好地建模句子上下文信息



单词的词嵌入和对应的词性嵌入合并作为双向长短时记忆网络的输入



## 基于双仿射变换的方法

使用多层感知器（MLP）对  $r_i$  用于中心词和修饰词的不同情况，分别进行两种不同的降维

$$h_i^{(arc-head)} = \mathbf{MAP}^{(arc-head)}(r_i)$$

$$h_i^{(arc-dep)} = \mathbf{MAP}^{(arc-dep)}(r_i)$$

所有时刻的  $h_i^{(arc-head)}$  和  $h_i^{(arc-dep)}$  分别合并组成矩阵  $H^{(arc-head)}$  和  $H^{(arc-dep)}$

利用不类别双仿射分类器（Variable-class Biaffine Classifier），得到边评分矩阵：

$$S^{(arc)} = H^{(arc-dep)} \oplus \mathbf{1} \cdot U^{(arc)} \cdot H^{(arc-head)\top}$$

$w_i$  为修饰词  $w_{y_i}$  为中心词的依存类别的分类：

$$s_i^{(label)} = r_{y_i}^\top U^{(1)} r_i + (r_{y_i} \oplus r_i)^\top U^{(2)} + b$$

## 基于图神经网络的方法

基于图神经网络的依存句法分析算法（Graph-based Dependency Parsing with Graph Neural Networks, GNNDP），试图将更多的结构化信息引入到节点表示。




图 3.22 基于图神经网络的依存句法分析网络结构图





## 基于图神经网络的方法

单词序列表示使用双向长短时记忆网络 (BiLSTM) 编码单词序列

$$\mathbf{c}_i^f = \text{LSTM}(\mathbf{x}_i, \mathbf{c}_{i-1}^f; \theta^f)$$

$$\mathbf{c}_i^b = \text{LSTM}(\mathbf{x}_i, \mathbf{c}_{i+1}^b; \theta^b)$$

$$\mathbf{c}_i = \mathbf{c}_i^f \oplus \mathbf{c}_i^b$$

由于依存边有方向性，因此采用两个多层感知器来生成不同的向量从而区分这两种角色

$$\mathbf{h}_i = \text{MLP}_h(\mathbf{c}_i)$$

$$\mathbf{d}_i = \text{MLP}_d(\mathbf{c}_i)$$

$$\sigma(i, j) = \text{Softmax}_i(\mathbf{h}_i^\top \mathbf{A} \mathbf{d}_j + \mathbf{b}_1^\top \mathbf{h}_i + \mathbf{b}_2^\top \mathbf{d}_j)$$

$$\triangleq P(i | j)$$

输出的得分实际上也是依存边 ( $w_i$  支配  $w_j$ ) 的概率



## 基于图神经网络的方法

GNNDP将图神经网络应用到依存句法分析任务，句法分析任务需要在图G上同时处理支配词表征 $\mathbf{h}_i$ 和从属词表示 $\mathbf{d}_i$ ，而不是为每个节点编码一个向量。此外，为了近似精确的高阶分析，分析器需要每个GNNs网络层有关于句子的具体含义。因此，GNNDP采用完全图（即所有节点都是连接的），并用依存边条件概率设置边权。


$$\alpha_{ij}^t = \sigma^t(i, j) = P^t(i | j)$$

GNNDP 关注三类高阶信息，即祖父母、孙子和兄弟关系



## 基于图神经网络的方法

$\sigma^t(j, i)$  不仅考虑一跳父子关系( $j, i$ ), 还考虑两跳 $i$  的祖父母节点 (用 $k$  表示)。同样, 为了在 $\sigma^t(j, i)$  中对两跳的 $j$  的孙子节点进行编码 (也用 $k$  表示), 需要聚合邻居节点的从属词表示。





## 基于图神经网络的方法

为了纳入祖父母的信息（图 3.23(a)），使得  $\sigma^t(j, i)$  不仅考虑一跳父子关系  $(j, i)$ ，还考虑两跳  $i$  的祖父母节点（用  $k$  表示）。同样，为了在  $\sigma^t(j, i)$  中对两跳的  $j$  的孙子节点进行编码（也用  $k$  表示），需要聚合邻居节点的从属词表示。GNNDP 采用了以下更新协议：

$$\begin{cases} h_i^t = g \left( W_1 \sum_{j \in \mathcal{N}(i)} \alpha_{ji}^t h_j^{t-1} + B_1 h_i^{t-1} \right) \\ d_i^t = g \left( W_2 \sum_{j \in \mathcal{N}(i)} \alpha_{ij}^t d_j^{t-1} + B_2 d_i^{t-1} \right) \end{cases} \quad (3.35)$$

为了纳入  $i$  的兄弟节点（同样用  $k$  表示）的信息（图 3.23(c)）， $h_j^t$  的更新涉及到  $d_k^{t-1}$ ，GNNDP 加入了第二个更新协议：

$$\begin{cases} h_i^t = g \left( W_1 \sum_{j \in \mathcal{N}(i)} \alpha_{ij}^t d_j^{t-1} + B_1 h_i^{t-1} \right) \\ d_i^t = g \left( W_2 \sum_{j \in \mathcal{N}(i)} \alpha_{ji}^t h_j^{t-1} + B_2 d_i^{t-1} \right) \end{cases} \quad (3.36)$$



## 基于图神经网络的方法

训练目标由两部分组成。第一部分是在 GNNs 层后面加一个解码器（用  $\tau$  表示），它将对树结构（使用  $P^\tau(i|j)$ ）和边标签（使用  $P(r|i, j)$ ）进行解码。为了预测边标签，使用另一个 MLP 来衡量依存边  $(i, j)$  具有关系  $r$  的可能性。其交叉熵损失函数定义如下：

$$\mathcal{L}_0 = -\frac{1}{n} \sum_{(i,j,r) \in T} (\log P^\tau(i | j) + \log P(r | i, j)) \quad (3.38)$$

第二个部分是对每个 GNNs 层的  $P^t(i|j)$  的准确率进行监督（只对树结构进行监督，忽略边的标签）。每层交叉熵损失函数定义如下：

$$\mathcal{L}' = \sum_{t=1}^{\tau} \mathcal{L}_t = \sum_{t=1}^{\tau} -\frac{1}{n} \sum_{(i,j,r) \in T} \log P^t(i | j) \quad (3.39)$$

最终目标是最小化两者的加权组合  $L = \lambda_1 \mathcal{L}_0 + \lambda_2 \mathcal{L}'$ 。训练完成后，解析器在所有的依存边得分上使用最大生成树算法形成一棵有效的依存树。



## 基于图神经网络的方法

训练目标由两部分组成。第一部分是在 GNNs 层后面加一个解码器（用  $\tau$  表示），它将对树结构（使用  $P^\tau(i|j)$ ）和边标签（使用  $P(r|i, j)$ ）进行解码。为了预测边标签，使用另一个 MLP 来衡量依存边  $(i, j)$  具有关系  $r$  的可能性。其交叉熵损失函数定义如下：

$$\mathcal{L}_0 = -\frac{1}{n} \sum_{(i,j,r) \in T} (\log P^\tau(i | j) + \log P(r | i, j)) \quad (3.38)$$

第二个部分是对每个 GNNs 层的  $P^t(i|j)$  的准确率进行监督（只对树结构进行监督，忽略边的标签）。每层交叉熵损失函数定义如下：

$$\mathcal{L}' = \sum_{t=1}^{\tau} \mathcal{L}_t = \sum_{t=1}^{\tau} -\frac{1}{n} \sum_{(i,j,r) \in T} \log P^t(i | j) \quad (3.39)$$

最终目标是最小化两者的加权组合  $L = \lambda_1 \mathcal{L}_0 + \lambda_2 \mathcal{L}'$ 。训练完成后，解析器在所有的依存边得分上使用最大生成树算法形成一棵有效的依存树。





**转移系统 (Transition System)** 包含**状态集合** (State 或 Configuration) 以及状态之间的**转移动作集合** (Transition)

**标准弧 (Arc-Standard) 转移系统**是其中最常用的投射性依存句法分析转移系统之一

- (1) 左弧 ( $LA_r$ ):  $([\sigma|w_i, w_j|\beta, A) \Rightarrow (\sigma, w_j|\beta, A \cup \{(w_j, r, w_i)\})$ ,  $w_i$  是堆栈  $\sigma$  最上面的单词,  $w_j$  是缓冲器  $\beta$  中最前面的单词, 将  $w_i$  从堆栈中弹出并增加从  $w_j$  到  $w_i$  关系类型为  $r$  的依存关系。前置条件是  $i \neq 0$  并且  $\neg \exists w_k \exists r' [(w_k, r', w_i) \in A]$ , 即  $A$  中不存在以  $w_i$  为修饰词的边。
- (2) 右弧 ( $RA_r$ ):  $(\sigma|w_i, w_j|\beta, A) \Rightarrow (\sigma, w_i|\beta, A \cup \{(w_i, r, w_j)\})$ ,  $w_i$  是堆栈  $\sigma$  最上面的单词,  $w_j$  是缓冲器  $\beta$  中最前面的单词, 将  $w_i$  从堆栈中弹出, 将缓冲器中最前面的单词  $w_j$  替换为  $w_i$ , 增加从  $w_i$  到  $w_j$  关系类型为  $r$  的依存关系。前置条件是  $\neg \exists w_k \exists r' [(w_k, r', w_j) \in A]$ 。
- (3) 移进 (SH):  $(\sigma, w_i|\beta, A) \Rightarrow (\sigma|w_i, \beta, A)$ , 从缓冲器中移除最前面的单词  $w_i$ , 并压入堆栈中。



表 3.1 依存句法分析转移动作序列样例

|                                    | $\sigma$        | $\beta$    | $A$                                                    |
|------------------------------------|-----------------|------------|--------------------------------------------------------|
|                                    | ([ROOT],        | [她, ...],  | $\emptyset$ )                                          |
| SH $\Rightarrow$                   | ([ROOT, 她],     | [非常, ...], | $\emptyset$ )                                          |
| SH $\Rightarrow$                   | ([ROOT, 她, 非常], | [喜欢, ...], | $\emptyset$ )                                          |
| LA <sub>advmod</sub> $\Rightarrow$ | ([ROOT, 她],     | [喜欢, ...], | $A_1 = (\text{喜欢}, \text{advmod}, \text{非常})$          |
| LA <sub>nsubj</sub> $\Rightarrow$  | ([ROOT],        | [喜欢, ...], | $A_2 = A_1 \cup (\text{喜欢}, \text{nsubj}, \text{她})$   |
| SH $\Rightarrow$                   | ([ROOT, 喜欢],    | [跳, ...],  | $A_2$ )                                                |
| SH $\Rightarrow$                   | ([ROOT, 喜欢, 跳], | [芭蕾舞],     | $A_2$ )                                                |
| RA <sub>dobj</sub> $\Rightarrow$   | ([ROOT, 喜欢],    | [跳],       | $A_3 = A_2 \cup (\text{跳}, \text{dobj}, \text{芭蕾舞})$   |
| RA <sub>xcomp</sub> $\Rightarrow$  | ([ROOT],        | [喜欢],      | $A_4 = A_3 \cup (\text{喜欢}, \text{xcomp}, \text{跳})$   |
| RA <sub>root</sub> $\Rightarrow$   | ([],            | [ROOT],    | $A_5 = A_4 \cup (\text{ROOT}, \text{root}, \text{喜欢})$ |
| SH $\Rightarrow$                   | ([ROOT],        | [],        | $A_5$ )                                                |





假设存在**函数** $o$ ，可以根据当前的状态 $c$  正确地确定下一步的转移动作 $t$ ，即 $o(c) = t$ 。那么整个句法分析的过程就可以使用非常简单的贪心算法完成。针对输入句子 $S$ ，首先，构造初始状态 $c_0(S)$ ，调用函数 $o$  得到下一步转移动作 $t = o(c)$ 。之后，利用根据转移动作得到下一个状态  $c = t(c)$ 。如此循环直到达到终止状态形式 $(\sigma, [], A)$ 。

转移动作预测函数可以使用分类器进行建模。构造一个分类器 $f(c)$ ，输入为状态 $c$ ，输出为其所对应的标准转移动作 $o(c)$ 。由此，基于转移的依存句法分析问题转化为了典型的机器学习问题。



针对状态 $c$  的表示问题，可以采用从堆栈 $\sigma$ 、缓存器 $\beta$  以及边集合 $A$ 中对特定位置的单词、单词词性、树结构等抽取信息构造特征向量的方法

表 3.2 Maltparser<sup>[108]</sup> 针对标准弧转移系统采用的特征向量

|                 | 单词 | 词元 | 粗粒度词性 | 细粒度词性 | 词形特征 | 依存关系类型 |
|-----------------|----|----|-------|-------|------|--------|
| $\beta[0]$      | ×  | ×  | ×     | ×     | ×    |        |
| $\beta[1]$      | ×  |    |       | ×     |      |        |
| $\beta[2]$      |    |    |       | ×     |      |        |
| $\beta[3]$      |    |    |       | ×     |      |        |
| $ld(\beta[0])$  |    |    |       |       |      | ×      |
| $rd(\beta[0])$  |    |    |       |       |      | ×      |
| $\sigma[0]$     | ×  | ×  | ×     | ×     | ×    |        |
| $\sigma[1]$     |    |    |       | ×     |      |        |
| $ld(\sigma[0])$ |    |    |       |       |      | ×      |
| $rd(\sigma[0])$ |    |    |       |       |      | ×      |



## 基于前馈神经网络的方法

输出层： $p = \text{softmax}(W_2 h)$

隐藏层： $h = (W_1^\omega x^\omega + W_1^t x^t + W_1^l x^l + b_1)^3$

输入层： $[x^\omega, x^t, x^l]$




图3.24 基于神经网络的依存句法分析算法神经网络结构图

## 基于堆栈长短时记忆网络的方法

基于转移的依存句法分析中需要使用堆栈完成句法分析，因此堆栈长短时记忆网络针对堆栈的压栈（push）和出栈（pop）操作，增加了“栈指针”（stack pointer）来扩充 LSTM。





图3.25 堆栈长短时记忆网络压栈和出栈操作样例



## 基于堆栈长短时记忆网络的方法



带有单个元素的堆栈(左侧)、堆栈执行出栈操作的结果(中部), 以及此后堆栈使用压栈操作的结果(右侧)。**最底层代表堆栈的内容**, 是Stack-LSTM的输入, **中间层是LSTM单元**, **上层是输出层**。使用堆栈指针指向的位置作为输出表示。通过上述操作我们可以看到, **在执行出栈操作时**, Stack-LSTM中间层LSTM单元并不发生改变, 仅是修改堆栈指针TOP的位置。**在执行压栈操作时**, 新增加的元素增加在最右端, 并与前一个TOP指针指向的LSTM单元连接。



## 基于堆栈长短时记忆网络的方法

利用三个堆栈长短时记忆网络分别对状态中堆栈、缓存器以及转移动作历史进行表示






图3.26 基于堆栈长短时记忆网络的状态表示神经网络结构图



- (1) 依存准确率 (Dependency Accuracy, 简称 DA): 正确分析得到其中心词的非根节点词语个数占总非根节点词数的百分比;
- (2) 根准确率 (Root Accuracy, 简称 RA): 正确根节点的个数与句子个数的百分比;
- (3) 完全匹配率 (Complete Match, 简称 CM): 无标记依存结构完全正确的句子占句子总数的百分比;



(a) 正确结果



(b) 算法分析结果

$$\text{依存准确率 (DA)} = \frac{2}{4} \times 100\% = 50\%$$

$$\text{无标记依存准确率 (UAS)} = \frac{3}{5} \times 100\% = 60\%$$

$$\text{有标记依存准确率 (LAS)} = \frac{2}{5} \times 100\% = 40\%$$

# 本章主要内容

---

3.1

句法概述

3.2

成分句法分析

3.3

依存句法分析

3.4

句法分析语料库





表 3.3 常见句法分析语料库汇总

| 语料库名称                       | 单词数量   | 语法类型   | 语言  |
|-----------------------------|--------|--------|-----|
| 英语宾州树库 (PTB)                | 117 万  | 成分语法   | 英文  |
| 通用依存树库 (UD V2.0 CoNLL 2017) | 281 万  | 依存语法   | 多语言 |
| 通用依存树库 (UD V2.2 CoNLL 2018) | 1714 万 | 依存语法   | 多语言 |
| 组合范畴语法树库 (CCGBank)          | 116 万  | 组合范畴语法 | 英文  |
| 中文宾州树库 6.0 (CTB 6.0)        | 78 万   | 成分语法   | 中文  |
| 中文宾州树库 7.0 (CTB 7.0)        | 120 万  | 成分语法   | 中文  |
| 中文宾州树库 8.0 (CTB 8.0)        | 162 万  | 成分语法   | 中文  |
| 中文宾州树库 9.0 (CTB 9.0)        | 208 万  | 成分语法   | 中文  |
| 中文语义依存树库 (SDP)              | 52 万   | 语义依存   | 中文  |

# 本章小结

句法分析是句子结构和语义之间的桥梁，具有非常重要的作用，很多自然语言处理算法需要依赖句法分析结果，因此句法分析效果也直接影响到很多自然语言处理应用。句法分析是自然语言处理中长期关注的核心问题之一。在本章中，句法分析任务限定在得到完整的句法分析树，重点介绍了基于有监督机器学习算法的句法分析方法。对成分句法分析和依存句法分析分别介绍了各类型的分析了评价方法。