

中山大學 人工智能學院
SUN YAT-SEN UNIVERSITY SCHOOL ARTIFICIAL INTELLIGENCE

「自然语言处理」

第 4 章 语义分析

赵宝全

中山大学人工智能学院

2026年春季学期

本章主要内容

4.1

语义学概述

4.2

语义表示

4.3

分布式表示

4.4

词义消歧

4.5

语义角色标注

本章主要内容

4.1

语义学概述

4.1.1 词汇语义学

4.1.2 句子语义学

4.2

语义表示

4.3

分布式表示

4.4

词义消歧

4.5

语义角色标注



✧ I bought a car **with** four wheels.

I bought a car **with** four dollars.

✧ These boys will **be** dedicated persons.

These boys will **be** denied license.

✧ 这件事情让我感到很**头疼**。

✧ 开刀的是她父亲

✧ 我们三个人一组

✧ 这份报告，我写不好



掌握一种语言意味着懂得如何产生并理解数量无限的该种语言句子的意义。研究语言意义的科学被称为**语义学 (Semantics)**。

语义问题也被大多数语言学家认为是语言的核心问题，同时也受到了包括哲学、逻辑学、心理学以及计算机等众多学科的广泛关注。自然语言处理目标就是要**使计算机具有理解和运用自然语言的能力**。因此，语义也是自然语言处理的关键问题和难点问题。

语义研究需要以语义的形式化结构表示为基础。这种形式化结构表示称之为**语义表示 (Semantic Representation)**



什么是**意义**是一个困扰了哲学家和语言学家数千年的问题。

- 我们可以非常容易地理解中文，并且用汉字组成对其他人来说也是有意义的句子。
- 我们也可以知道某个词语、句子是否有意义，还可以通过一个句子衍推出另外一个句子。

意义从何而来？语言的意义本质又是什么？

学术界对这些问题众说纷纭没有定论

中国古代以“字”为核心的训诂语义研究达到了很高的水准，公元前2世纪就有了专门解释**词义的专著《尔雅》**。先秦时期，荀子和墨子就开始对“名”与“实”的关系进行讨论。古希腊哲学家苏格拉底、亚里士多德等也都在其哲学著作中探讨过语言的意义。



语义学的研究目标就是发现和阐述关于意义的知识。1883 年由法国语言学家 Michel Bréal 发表的论文中首次提出了语义学的概念

从语言表达层面划分，语义学的研究大致可以分为三个层面：

- (1) **词汇语义学 (Lexical Semantics)** 主要包括词义问题、词汇间关系、词汇场、成语的语义等；
- (2) **句子语义学 (Sentential Semantics)** 主要以真值条件语义理论、配价理论、生成理论等为基础研究句义关系以及语序等问题；
- (3) **话语语义学 (Discourse Semantics)** 主要研究句子以上层次结构的意义，包括话语衔接、话语连贯、语用过程解释等。



词是语言中能够独立运用的最小的单位，也是**音、形、义**的结合体。

词语通过搭配组合，可以构建出短语、句子、篇章等复杂的语言结构。

语义学自创建之初，就将词汇语义作为重要的研究目标。

词汇语义学主要研究单个词语的意义以及词汇之间的相互关系。



1. 词汇语义理论

词义 (Word Meaning) 有很多的方面，可以从不同的角度分析和定义，因而出现了包括语义场理论、语义成分分析、并置理论、框架语义理论等众多词汇语义理论。

表 4.1 食物语义场示例

食物	水果	苹果
		香蕉
		...
	肉	牛肉
		羊肉
		...
	蔬菜	白菜
		菠菜
		...
	谷物	大米
		小麦
		...

语义场理论 (Semantic Field) 也称作词义场理论 (Lexical Field) 认为语言中词汇的意义是相互联系的，构成一个完整的系统和网络，具有某些相同语义特征的一组词聚而成场。

根据语义场理论，**不能够孤立的研究一个词**的词义，只有通过分析比较词与词之间的关系，才能确定一个词的真正意义。



1. 词汇语义理论

语义成分分析 (Componential Analysis) 理论认为词义可以由最小的语义成分组合而成。这种最小的语义成分又被成为语义特征。

例如：

可以定义 ADULT、YOUNG、MALE、FEMALE 为语义特征，根据这些特征可以表达词汇的意义：

man: ADULT + MALE

woman: ADULT + FEMALE

boy: YOUNG + MALE

girl: YOUNG + FEMALE



1. 词汇语义理论

义元理论 (Theory of Lexical Primitives) 的核心思想是自然语言中包含非常少部分的词语，这些词语可以用于解释绝大部分词汇的意义。

例如：man 和 fish 是义元，而 fishy 和 manliness 则是衍生词。可以使用义元对其他词语进行解释。根据文献 [164] 中的定义，boy、girl、woman、man 使用义元解释如下：

boy: young human being that one thinks of as becoming a man.

girl: young human being that one thinks of as becoming a woman.

woman: human being that could be someone' s mother.

man: human being that could cause a woman to be someone' s mother



1. 词汇语义理论

董振东教授所创建的知网（[HowNet](#)）也结合了义元理论，构建了包含 2540 多个义元的精细的语义描述体系，并为 237974 个汉语和英语词所代表的概念进行了标注。

例如：Hownet 中美味、难题的定义如下所示：

美味: edible| 食物:modifier=GoodTaste| 好吃

难题: problem| 问题:modifier=difficult| 难

HowNet 中义元采用中英双语的形式进行描述。上例子中 “edible| 食物”、“GoodTaste| 好吃” 是义元。“难题” 是由核心义元 “problem| 问题” 以及对核心义元的附加描述义元 “difficult| 难” 组成。



1. 词汇语义理论

框架语义学 (Frame Semantics) 则认为词义只能在相应的知识框架背景中才能得到理解。在意义的理解过程中，概念并不是杂乱无章的，很多概念往往具有一种同现的趋势

例如：顾客、服务员、吃饭、账单等概念都与饭店相关，是理解“饭店”的框架

例如：文献 [166] 中定义的“RISK”的框架是由如下成分组成：

RISK frame:

- Chance (uncertainty about the future)

- Harm

- Victim (of the harm)

- Valued Object (potentially endangered by the risk)

- Situation (which gives rise to the risk)

- Deed (that brings about the Situation)

- Actor (of the Deed)

- Gain (by the Actor in taking the risk)

- Purpose (of the Actor in the Deed)

- Beneficiary and motivation (for the Actor)



1. 词汇语义理论

框架语义学 (Frame Semantics) 则认为词义只能在相应的知识框架背景中才能得到理解。在意义的理解过程中，概念并不是杂乱无章的，很多概念往往具有一种同现的趋势

对于包含动词 risk 的句子，可以根据 RISK 框架对其进行理解。例如：

- (1) You've (Actor/Victim) risked your health (Valued Object) for a few cheap thrills (Gain).
- (2) She (Actor/Victim) has risked so much (Valued Object) for the sake of vanity (Motivation).



2. 词汇间的关系

词汇之间的关系 (Lexical Relations) 是词汇语义学研究的另一个重点问题。

关系类型可以分为三大类：形体关系、意义关系和实体关系

- **形体关系 (Form Relations)** 主要研究词汇的声音形体和拼写之间的关系
- **意义关系 (Sense Relations)** 主要关注词汇意义之间的关联性、相似性、对立性等关系。
- **实体关系 (Object Relations)** 则主要研究词汇之间的客观关系。

表 4.2 词汇之间的主要关系

词汇之间的关系类型			示例
形体关系	Homonymy	同音异义关系	ring 与 wring 发音相同
		同形异义关系	bank (银行) 与 bank (河岸) 词形相同
意义关系	Synonymy	同义关系	“电脑”与“计算机”是同义词
	Antonymy	反义关系	“大”与“小”之间是反义关系
	Hyponymy	下位关系	“燕子”是“鸟”的下位词
	Hypernymy	上位关系	“动物”是“老虎”的上位词
实体关系	Meronymy	部分整体关系	“发动机”与“汽车”



2. 词汇间的关系

WordNet是目前最常用的英语词汇知识资源库。在其中词汇按照义项组合成同义集 (Synset) , 每个义项表达不同的概念。名词、动词、形容词和副词各自独立的组合成网络。

Noun

1. bank (sloping land (especially the slope beside a body of water)) “they pulled the canoe up on the bank”; “he sat on the bank of the river and watched the currents”
2. depository financial institution, bank , banking concern, banking company (a financial institution that accepts deposits and channels the money into lending activities) “he cashed a check at the bank”; “that bank holds the mortgage on my home”
3. bank (a long ridge or pile) “a huge bank of earth”
4. bank, cant, camber (a slope in the turn of a road or track; the outside is higher than the inside in order to reduce the effects of centrifugal force)



2. 词汇间的关系

在 WordNet 中名词和动词可以根据上下位关系或者部分整体关系构成层级结构

bank, cant, camber (a slope in the turn of a road or track)

=> slope, incline, side

=> geological formation, formation

=> object, physical object

=> physical entity

=> entity



句子语义学主要是在句子层面对意义的研究。人们通常通过句子来表达完整语义，相较于词汇句子也复杂得多，因此非常多的工作都是围绕句子语义学从各个角度开展，包括语音、语法、逻辑、认知、心理学等等。本节中，从语言学角度对句子语义学的主要理论进行简要介绍。

语言是对外部世界的编码，句子就是人们对客观世界的概念表征，人们对句子意义的认知始于真假判断。**真值条件语义学 (Truth-conditional Semantics)** 核心就是将意义定义为一个句子或句子所表达的命题为真时所必须满足的一系列条件。

该理论试图通过解释句子何时为真来定义给定句子或命题的意义。提出了一个检验句子真值的通用公---**T公式: S is true iff P** ， S 代表某个句子， P 代表句子的真值条件，iff表示 “if and only if” 。例如：他是学生， S 表示这个句子， P 表示 “他” 所代表的人并且真的是学生的列表。真知条件语义学开创了用数理逻辑方法解释自然语言的语义，用严格数学方法研究自然语言语义的方向。



在词汇语义理论中语义成分分析理论认为**词义可以由最小的语义成分组合而成**，在句子层面同样也存在语义成分，这种语义成分通常称作**语义格 (Semantic Case)**。

格语法 (Case Grammar) 以及从格语法发展而来的框架语义学 (Frame Semantics) 都是以**语义格**为基础。语义格也称语义角色 (Semantic Roles)，又称语义关系、主题关系 (Thematic Relations)。认为**句子中名词短语总是与动词相关**，并且以唯一可以识别的方式表示了名词短语的语义格。“主语”、“宾语”等语法关系实际上都是表层结构上的概念，语言的底层是用“施事”、“受事”、“工具”等概念所表示的句法语义关系。

例如：(1) The **door** opened.

(2) The **key** opened the door.

(3) The **boy** opened the door.

(4) The door was opened by the boy.

(5) The boy opened the door with a key.

➤ the boy: 施事格

➤ the door: 客体格 (受事格)

➤ the key: 工具格



在格语法中对于词库中词汇的每个词条需要标明其格特征，对于名词标明其可以作为的语义格（例如：“街道”需要标明 [+LOCATION]），对于动词需要标明其对应的格框架。

表 4.3 常见语义格定义

名称	定义	示例
施事格 AGENT	动作的发起者	He wrote the book.
受事格 PATIENT	受到动作或状态影响的实体	He wrote the book .
工具格 INSTRUMENT	对动作或状态而言作为某种因素而牵涉到的无生命的客体	He cleaned the table with an antiseptic wipe .
方位格 LOCATION	动作或状态的处所或空间位置	They are in the building
来源格 SOURCE	动作所作用到的事物的来源或发生位置变化过程中的起始位置	He bought a book from Jeremy .
目标格 GOAL	动作所作用到的事物的终点或发生位置变化过程中的终端位置	He sold a book to Jeremy .
时间格 TIME	动作或状态的时间	In the winter , he saw snow.
伴随格 COMITATIVE	与施事共同完成动作的伴随者	He sang a song with Jeremy .
受益者格 BENEFICIARY	因动作的实行而受益的实体	He sang a song for Jeremy .
感受格 EXPERIENCER	知道谓语所描述的动作或状态，但不受该动作或状态控制	He saw snow.

例如：BREAK 可以放入如下格框架：
[(施事格) (受事格) (工具格) (方位格)]

例如：他在房间里用锤子打破了玻璃杯。

根据 BREAK 框架得到：
[BREAK [Case-frame:
[AGENT: 他
PATIENT: 玻璃杯
INSTRUMENT: 锤子
LOCATION: 房间
]
]]



在格语法中对于词库中词汇的每个词条需要标明其格特征，对于名词标明其可以作为的语义格（例如：“街道”需要标明 [+LOCATION]），对于动词需要标明其对应的格框架。

◆ 格表

C. J. Fillmore 在1968年的论文中认为，命题中的格包括6种：

- (1) **施事格(Agentive)**：动作的发生者。
- (2) **工具格(Instrumental)**：对动作或状态而言作为某种因素而牵涉到的无生命的力量或客体。
- (3) **承受格(Dative)**：由动词确定的动作或状态所影响的有生物。如，**He** is tall.
- (4) **使成格(Factitive)**：由动词确定的动作或状态所形成的客体或有生物。或理解为：动词意义的一部分的客体或有生物。如：John dreamed **a dream** about Mary.
- (5) **方位格(Locative)**：由动词确定的动作或状态的处所或空间方位。如：He is in the **house**.
- (6) **客体格(Objective)**：由动词确定的动作或状态所影响的事物。如：He bought **a book**.



在格语法中对于词库中词汇的每个词条需要标明其格特征，对于名词标明其可以作为的语义格（例如：“街道”需要标明 [+LOCATION]），对于动词需要标明其对应的格框架。

后来 Fillmore 在语言分析时又增加了一些格：

(7) 受益格(Benefactive)：由动词确定的动作为之服务的有生命的对象。

如：He sang a song for Mary.

(8) 源点格(Source)：由动词确定的动作所作用到的事物的来源或发生位置变化过程中的起始位置。如：
He bought a book from Mary.

(9) 终点格(Goal)：由动词确定的动作所作用到的事物的终点或发生位置变化过程中的终端位置。

如：I sold a car to Mary.

(10) 伴随格(Comitative)：由动词确定的与施事共同完成动作的伴随者。

如：He sang a song with Mary.

*** 格的数目和名称并不是确定的。**



在格语法中对于词库中词汇的每个词条需要标明其格特征，对于名词标明其可以作为的语义格（例如：“街道”需要标明 [+LOCATION]），对于动词需要标明其对应的格框架。

例: In the room, he broke a window with a hammer.

[BREAK

[Case-frame:

[Agentive: HE

Objective: WINDOW

Instrumental: HAMMER

Locative: ROOM]

[MODALs:

Time: past

Voice: active]]]



句子之间也存在各种语义关系，把句子当做一个整体，句子和句子之间的语义关系可以包含同义、反义、蕴含等。

- **同义关系 (Synonym)** 表示两个不同的句子表达相同的意义。
 - 例如：a. 他打碎了玻璃杯。 b. 玻璃杯被他打碎了。
- **反义关系 (Inconsistency)** 表示两个句子的意义只能有一个与客观事实相符。
 - 例如：a. 他打碎了玻璃杯。 b. 玻璃杯完好的放在橱窗里。
- **蕴含关系 (Entailment)** 表示两个句子的意义，前者为真时后者必然为真，前者为假时后者可能为真也可能为假。
 - 例如：a. 他拿着一本书去了校门口。 b. 书在他手里。
- **预设关系 (Presupposition)** 表示一个句子的意义是另外一个句子的前提。
 - 例如：a. 中山大学珠海校区管委会举办了迎新活动。 b. 中山大学有多个校区。

本章主要内容

4.1

语义学概述

4.2

语义表示

4.2.1 谓词逻辑表示法

4.2.2 框架表示法

4.2.3 语义网表示法

4.3

分布式表示

4.4

词义消歧

4.5

语义角色标注



语义表示 (Semantic Representation) 是语义的符号化和形式化的过程，主要研究语义表示的通用原则和方法。为了使得计算机能够处理自然语言的语义，就需要用恰当的模式对语义进行表示，因此语义表示方法也是自然语言理解的基础。

- 目前关于意义的定义和本质还没有定论，大量的语义学理论从不同角度开展讨论
- 已有的语义表示方法大多都是根据不同的语义学理论针对某项具体研究所提出的，有一定的针对性和局限性
- 适用于词汇、句子、篇章等各个层面各种应用的**通用语义表示方法**还是一个亟待解决的问题
- 本节中介绍常见的一阶谓词逻辑、框架、语义网等语义表示方法，分布式表示表示方法在下节中单独介绍



数理逻辑 (Mathematical Logic) 在知识的形式化表示和机器的自动定理证明方面都有广泛的应用和很好的表现，真值条件语言学中也是使用数理逻辑来研究自然语言的语义。

自然语言的语义表示中也经常采用数理逻辑的方法。其中常用的是**谓词逻辑 (Predicate Logic)** 和**命题逻辑 (Propositional Logic)**。

谓词逻辑可以更细致的刻画语义，可以表示事物的状态、属性、概念等事物性语义，也可以表示因果关系等规则性语义。



谓词一般用 $P(x_1, x_2, \dots, x_n)$ 表示, P 是谓词名, $x_1, x_2, \dots, x_n$ 表示某个独立存在的事物或某个抽象的概念。

- 如果谓词 P 中的所有个体都是常量、变量或函数, 则称该谓词为**一阶谓词 (First Order Predicate Logic)**
- 如果某个个体本身又是一个一阶谓词, 则称 P 为**二阶谓词**

例如:

谓词: $\text{Teacher}(x)$ 表示 x 是教师, 是一阶谓词。

句子: “老张是一名老师” 可以表示为 $\text{Teacher}(\text{老张})$



除了直接使用单个谓词和指代对象的常量、变量或者函数组成原子公式之外，还可以使用 5 种逻辑连接词和量词构造复杂的表示，就是谓词逻辑中的公式。原子公式是谓词演算的基本组块，运用连接词可以组合多个原子公式，以构成更加复杂的公式。

(1) 连接词

- $\neg$: “否定” (Negation) 或 “非”
- $\vee$: “析取” (Disjunction) 或 “或”
- $\wedge$: “合取” (Conjunction) 或 “与”
- $\rightarrow$: “蕴含” (Implication) 或 “条件”
- $\leftrightarrow$: “等价” (Equivalence) 或 “双向蕴含”

(2) 量词

- $\forall$: 全称量词 (Universal Quantifier), 表示对个体域中的所有 (或任意一个) 个体 x
- $\exists$: 存在量词 (Existential Quantifier), 表示在个体域中存在个体 x



a. “有机器人都是红色的”

谓词定义：ROBOT(X) 表示 X 是机器人；COLOR(X,Y) 表示 X 的颜色为 Y

谓词公式： $(\exists X)[\text{ROBOT}(X) \wedge \text{COLOR}(X, \text{RED})]$

b. “人人都爱护环境”

谓词定义：MAN(X) 表示 X 人；PROTECT(X,Y) 表示 X 保护 Y

谓词公式： $(\forall X)[\text{MAN}(X) \rightarrow \text{PROTECT}(X, \text{ENVIRONMENT})]$

c. “小明不在 3 号房间”

谓词定义：INROOM(X,Y) 表示 X 在 Y 中

谓词公式： $\neg \text{INROOM}(\text{XIAOMING}, \text{ROOM3})$

表 4.4 连接词真值表

P	Q	$\neg P$	$P \vee Q$	$P \wedge Q$	$P \rightarrow Q$	$P \leftrightarrow Q$
T	T	F	T	T	T	T
T	F	F	T	F	F	F
F	T	T	T	F	T	F
F	F	T	F	F	T	T



优点：谓词逻辑具有扎实的数学基础，一阶谓词逻辑具有充分的表达能力和完备的逻辑推理算法，其推理过程和结果的准确性可以得到有效保证，因此可以精密地表达语义。

缺点：使用一阶谓词逻辑表示语义并不简单，通常需要如下步骤：

- (1) 定义谓词及个体：确定每个谓词及个体的确切含义。
- (2) 变量赋值：根据所要表达的事物或概念，为每个谓词中的变量赋予特定的值。
- (3) 谓词公式构造：根据所表达的语义，用适当的连接符号和量词将各谓词连接起来。



框架 (Frame) 表示法是以框架语义理论为基础发展起来的一种语义表示方法。

框架用来表示所讨论对象（一个事物、概念或者事件）的语义。

每个框架由若干**槽 (Slot)** 组成，描述框架所讨论对象的某一方面的属性。

恐怖袭击事件框架：

框架名：恐怖袭击事件

槽 1：事件发生时间

槽 2：事件类型

槽 3：事件种类

槽 4：犯罪者

侧面 4-1：个人

侧面 4-2：组织

侧面 4-3：置信度

槽 5：实物目标

侧面 5-1：名称列表

侧面 5-2：数量

侧面 5-3：类型

槽 6：人目标

侧面 5-1：姓名列表

侧面 5-2：数量

侧面 5-3：类型

槽 7：事件发生地点

槽 8：对实物目标的影响

槽 9：对人目标的影响

利用“恐怖袭击事件”框架，句子“在位于巴黎11区的巴塔克兰剧院，多名武装分子在巴黎当地时间13日晚劫持了正在剧院观看演出的大约1500名观众并与警方展开对峙。”的语义可以表示为：

事件发生时间：巴黎当地时间 13 日晚

事件类型：劫持

事件种类：恐怖袭击

人目标：

类型：观众

数量：约 1500

事件发生地点：巴黎 11 区的巴塔克兰剧院



语义网络 (Semantic Network) 是一种用实体及其语义关系来表达知识和语义的网络图。语义网络由节点和弧组成：节点表示各种事件、事物、概念、属性、动作等，也可以是一个语义子网络；弧表示节点之间的语义关系，并且是有方向和标注的，方向表示节点间的主次关系且方向不能随意调换。





图 4.1 “大学” 的语言网表示样例

语义网除了可以描述事物间包括类属关系、聚集关系、时间关系、位置关系、推论关系等多种复杂语义关系外，还可以通过增加节点的方法**表示合取、析取、蕴含等语义表示**中常用的连接词。例如，句子“如果明天下雨，就去看电影或者唱歌”的语义网表示如图4.2所示




图 4.2 “如果明天下雨，就去看电影或者唱歌” 的语言网表示样例



对于比较复杂的语义还能涉及“每一个”、“有一个”等量词，使用语义网进行表示时可以通过引入分区技术进行实现。




图 4.3 “所有的学生都完成了课程设计” 的语言网表示样例

语义网可以较好的把事物的属性以及事物之间的各种**语义联系显式的进行表示**，也可以比较容易的实现语义检索。但是，由于语义网**没有公认的形式表示体系**，所表达的语义需要依赖分析算法对其进行解释，表示形式的不唯一又进一步增加了其处理的复杂性。

本章主要内容

4.1

语义学概述

4.2

语义表示

4.3

分布式表示

4.3.1 单词分布式表示

4.3.2 句子分布式表示

4.3.3 篇章分布式表示

4.4


词义消歧

4.5

语义角色标注




◆如何建立有效的词汇表示？



枯燥	无聊
$\begin{bmatrix} 0.24 \\ 0.15 \\ 0.42 \\ 0.51 \\ 0.21 \end{bmatrix}$	$\begin{bmatrix} 0.25 \\ 0.12 \\ 0.39 \\ 0.46 \\ 0.26 \end{bmatrix}$

Word2Vec
Word embedding



- 985个英语词汇在大脑中的分布图
- 语义加工在大脑左右半球基本上是对称的，打破了传统研究中认为语言加工左半球偏侧化的情况
- 不同个体大脑的整个语义网络“看起来特别相似”

Huth, A.G., De Heer, W.A., Griffiths, T.L., Theunissen, F.E. and Gallant, J.L., 2016. Natural speech reveals the semantic maps that tile human cerebral cortex. *Nature*, 532(7600), pp.453-458.



阿尔法小分队荣誉译制

翻\轴: @Brianee 校: @Olive-hex 压: @边-4

阿尔法科教粉丝讨论群 190062552 招募中

感谢北京科技视频网支持





■ One-Hot Representation

✧ 把每个词表示为一个长向量。这个向量的维度是词表大小，向量中只有一个维度的值为1，其余维度为0，这个维度就代表了当前的词。

✧ 例如：苹果 $[0, 0, 0, 1, 0, 0, 0, 0, 0, \dots]$

$$w^{aardvark} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, w^a = \begin{bmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, w^{at} = \begin{bmatrix} 0 \\ 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix}, \dots w^{zebra} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}$$



■ One-Hot Representation

✧ **优点:** 简单快捷

✧ **缺点:** 数据稀疏、耗时耗空间、不能很好地展示词与词之间的相似关系，且还未考虑到词出现的频率，因而无法区别词的重要性

- One-hot 的基本假设是词之间的语义和语法关系是相互独立的，仅仅从两个向量是无法看出两个词汇之间的关系，这种独立性不适合词汇语义的运算；
- 维度爆炸问题，随着词典规模的增大，句子构成的词袋模型的维度变得越来越大，矩阵也变得超稀疏，这种维度的爆增，会大大耗费计算资源。



✧ 词集模型

- 统计各词在句子中是否出现
- 例如 One-Hot Representation, 只要单个文本中单词出现在字典中, 就将其置为 1, 不管出现多少次

✧ 词袋模型

- 统计各词在句子中出现的次数
- 只要单个文本中单词出现在字典中, 就将其向量值加 1, 出现多少次就加多少次



■ 词袋模型(Bag of Words)

- ✧ 对于句子、篇章，常用的离散表示方法是词袋模型
- ✧ 词袋模型以 One-Hot 为基础，通过记录词表中的每一个词在该文本中出现的频次来表示该词在文本中的重要程度，解决了 One-Hot 未能考虑词频的问题

```
{  
  "John": 1,  
  "likes": 2,  
  "to": 3,  
  "watch": 4,  
  "movies": 5,  
  "also": 6,  
  "football": 7,  
  "games": 8,  
  "Mary": 9,  
  "too": 10,  
}
```

John likes to watch movies, Mary likes too.

John also likes to watch football games.

John likes to watch movies, Mary likes too.

[1, 2, 1, 1, 1, 0, 0, 0, 1, 1]

John also likes to watch football games.

[1, 1, 1, 1, 0, 1, 1, 1, 0, 0]



■ 词袋模型(Bag of Words)

- ✧ 对于句子、篇章，常用的离散表示方法是词袋模型
- ✧ 词袋模型以 One-Hot 为基础，通过记录词表中的每一个词在该文本中出现的频次来表示该词在文本中的重要程度，解决了 One-Hot 未能考虑词频的问题

```
{  
  "John": 1,  
  "likes": 2,  
  "to": 3,  
  "watch": 4,  
  "movies": 5,  
  "also": 6,  
  "football": 7,  
  "games": 8,  
  "Mary": 9,  
  "too": 10,  
}
```

John likes to watch movies, Mary likes too.

John also likes to watch football games.

John likes to watch movies, Mary likes too.

[1, 2, 1, 1, 1, 0, 0, 0, 1, 1]


John also likes to watch football games.

[1, 1, 1, 1, 0, 1, 1, 1, 0, 0]



■ 词袋模型(Bag of Words)应用

✧ 自然语言处理、信息检索、计算机视觉.....





■ 词袋模型(Bag of Words)

✧ 优点

- 方法简单，当语料充足时，处理简单的问题如文本分类，其效果比较好

✧ 缺点

- 数据稀疏、维度大
- 无法保留词序信息
- 存在语义鸿沟的问题



■ 词集模型和词袋模型的特点

- ✧ 都是基于词之间**保持独立性、没有关联为前提**，将所有文本中单词形成一个字典，然后根据字典来统计单词出现频数
- ✧ 其基本的特点是忽略了文本信息中的**语序信息**和**语境信息**，仅将其反映为若干维度的独立概念，这种情况有着因为模型本身原因而无法解决的问题，比如主语和宾语的顺序问题，词袋模型天然无法理解诸如“**我为**
你加油”和“**你为我加油**”两个语句之间的区别



分布式表示 (Distributed Representation) 旨在将文本表示为低维空间下稠密的向量，并在低维表示空间中利用表示向量之间的计算关系，体现文本间的语义关联。

向量空间模型 (Vector Space Model, VSM) 阐述了将单词和篇章表示为向量的思想。

- 对文本的处理可以直观地映射到向量空间，体现为对文本向量的加法、减法、距离度量等操作；
- 将向量化的文本作为输入，从而直接将统计学习与机器学习算法应用在自然语言处理应用上。

分布式表示提出之前，许多自然语言处理算法采用**独热表示 (One-hot Representation)**，其中每个维度表示某个单词是否在该文中出现。独热表示的维度和词表的大小一致，存在表示稀疏性的问题，而且无法表示单词之间的语义相似度

分布式表示通过将文本表示为**低维空间下稠密的向量**，有效地解决了这一问题。当应用在下游任务时，文本分布式表示也体现出良好的泛化能力，而且能有效地编码任务所需要的语法和语义信息



单词分布式表示 (Word Distributed Representation) 通过将单词表示为**定长低维稠密向量**，在向量空间建构单词之间的语义关系。

单词分布式表示的目标是建立单词嵌入矩阵 $W \in \mathbb{R}^{|V| \times d}$ ，其中矩阵的每一行对应一个单词，为单词的向量表示，即词向量。

例如：“计算机”表示为 $[0.16, 0.19, -0.28, \dots, 0.87]$

“电脑”表示为 $[0.20, 0.17, -0.21, \dots, 0.97]$

“冰激凌”表示为 $[-0.90, 0.72, 0.65, \dots, 0.06]$

相比于独热表示，分布式表示可以编码不同单词之间的**语义关联**。如上例中，如果采用独热表示，“计算机”与“电脑”以及“计算机”与“冰激凌”之间的相似度都相同。但是采用分布式表示可以使得“计算机”和“电脑”在大多数维度上相近，这样“计算机”和“电脑”的向量之间的距离可以远小于“计算机”和“冰激凌”之间的距离。



单词分布式表示的目标：在向量空间建构单词之间的语义关联，使含义相近的单词具有相似的向量表示。这自然地引出了两个问题：

(1) 如何衡量单词语义的相近； (2) 如何衡量表示的相似。

针对第一个问题，大部分单词分布式表示方法**遵从分布式假设**，即出现在相同上下文中的单词往往具有相似的语义。在分布式假设的基础上，这些方法侧重于还原单词之间的**共现关系**，即为**频繁出现在相同上下文中的词语之间赋予较高的表示相似度**。

针对第二个问题，根据下游应用场景的不同，可以根据表示向量的余弦相似度、L2范数距离等方式衡量表示向量的相似性。

4.3.1 单词分布式表示--基于共现矩阵奇异值分解的词向量模型



在分布式假设下，希望单词之间的相似度体现为两个词出现在相同上下文的频率。
可以采用针对**共现矩阵 (Co-occurrence Matrix)** 的矩阵分解方法。

隐式语义分析 (Latent Semantic Analysis, LSA) 模型采用**奇异值分解方法** (Singular Value Decomposition, SVD)，将单词文档共现矩阵 (Term-Document Co-occurrence Matrix) 或单词上下文共现矩阵 (Window based Co-Occurrence Matrix) 转换为单词向量表示。

共现矩阵 $A \in \mathbb{R}^{|V| \times |V|}$ ， A_{ij} 表示词表 V 中下标为 i 和 j 的单词出现在相同上下文中的次数。

代码 4.2: 基于共现矩阵奇异值分解的词向量模型^[177]

输入: 共现矩阵 $A \in \mathbb{R}^{|V| \times |V|}$ ，嵌入维度 d

输出: 词表示矩阵 $W \in \mathbb{R}^{|V| \times d}$

$U, \Sigma, V = \text{SVD}(A)$

// 由 A 是对称方阵，可知 $U = V$ ， Σ 是对角方阵

$U, \Sigma = U_{:, :d}, \Sigma_{:, :d}$

// 特征降维，保留最重要的 d 维， $A \approx U \Sigma U^T$

$\text{diag}(\sigma_1, \dots, \sigma_d) = \Sigma$

// Σ 包含最重要的 d 个奇异值 $\{\sigma_i\}_{i=1}^d$

$\sqrt{\Sigma} = \text{diag}(\sqrt{\sigma_1}, \dots, \sqrt{\sigma_d})$

// $\sqrt{\Sigma} \sqrt{\Sigma}^T = \Sigma$

$W = U \sqrt{\Sigma}$

// $WW^T = U \Sigma U^T \approx A$

return W

4.3.1 单词分布式表示--基于共现矩阵奇异值分解的词向量模型



Example corpus:

- I like deep learning.
- I like NLP.
- I enjoy flying.

使用一个size=1的窗口，对每句话依次进行滑动，相当于只统计紧邻的词

counts	I	like	enjoy	deep	learning	NLP	flying	.
I	0	2	1	0	0	0	0	0
like	2	0	0	1	0	1	0	0
enjoy	1	0	0	0	0	0	1	0
deep	0	1	0	0	1	0	0	0
learning	0	0	0	1	0	0	0	1
NLP	0	1	0	0	0	0	0	1
flying	0	0	1	0	0	0	0	1
.	0	0	0	0	1	1	1	0


- 共现矩阵的每一列，自然可以当做这个词的一个向量表示
- 这样的表示明显优于one-hot表示，因为它的每一维都有含义——共现次数，因此这样的向量表示可以求词语之间的相似度

这样表示存在什么问题？

4.3.1 单词分布式表示--基于共现矩阵奇异值分解的词向量模型



- 维度=词汇量大小，还是太大了
- 还是太过于稀疏，在做下游任务的时候依然不够方便



$$\mathbf{A} = \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix}$$

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T = \begin{pmatrix} 1/\sqrt{6} & 1/\sqrt{2} & 1/\sqrt{3} \\ 2/\sqrt{6} & 0 & -1/\sqrt{3} \\ 1/\sqrt{6} & -1/\sqrt{2} & 1/\sqrt{3} \end{pmatrix} \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}$$

选择U矩阵的前r维来作为词的向量表示


对于奇异值,它跟我们特征分解中的特征值类似，在奇异值矩阵中也是按照从大到小排列，而且奇异值的减少特别的快，在很多情况下，前10%甚至1%的奇异值的和就占了全部的奇异值之和的99%以上的比例。也就是说，我们也可以用最大的d个奇异值和对应的左右奇异向量来近似描述矩阵。

4.3.1 单词分布式表示--基于共现矩阵奇异值分解的词向量模型



```
import numpy as np
la = np.linalg
words = ["I", "like", "enjoy",
         "deep", "learnig", "NLP", "flying", "."]
X = np.array([[0, 2, 1, 0, 0, 0, 0, 0],
              [2, 0, 0, 1, 0, 1, 0, 0],
              [1, 0, 0, 0, 0, 0, 1, 0],
              [0, 1, 0, 0, 1, 0, 0, 0],
              [0, 0, 0, 1, 0, 0, 0, 1],
              [0, 1, 0, 0, 0, 0, 0, 1],
              [0, 0, 1, 0, 0, 0, 0, 1],
              [0, 0, 0, 0, 1, 1, 1, 0]])

U, s, Vh = la.svd(X, full_matrices=False)
```



可见，即使这么简单的三句话构建的语料，我们通过构建共现矩阵、进行SVD降维、可视化，依然呈现出了类似Word2Vec的效果

- 但是，由于共现矩阵巨大，SVD分解的计算代价也是很大的
- 另外，像a、the、is这种词，与其他词共现的次数太多，也会很影响效果



• 改善词向量

- 直接把一些常见且意义不大的词忽略掉；把极度不平衡的计数压缩到一个范围；使用皮尔森相关系数，来代替共现次数。因此就有了2005年的论文《An Improved Model of Semantic Similarity Based on Lexical Co-Occurrence》提出的COALS模型。这个模型训练得到的词向量，也表现出了很多有趣的性质，跟Word2Vec十分类似

COALS Word Vectors (2005)





- 它主要的问题在于两方面：


- SVD要分解一个巨型的稀疏矩阵（共现矩阵），计算开销大，甚至无法计算
- 需要进行复杂麻烦的预处理，例如计数的规范化、清除常见词、使用皮尔森系数等等

而Word2Vec的算法，不需要一次性处理这么大量的数据，而是通过迭代的方式，一批一批地进行处理，不断迭代词向量参数，使得我们可以处理海量的语料，构建十分稳健的词向量。所以在实验中，Word2Vec的表现，一般都要优于传统的SVD类方法


但是，基于共现矩阵的方法也有其优势，那就是充分利用了全局的统计信息。因为我们进行矩阵分解，是对整个共现矩阵进行分解，这个矩阵中包含着全局的信息。而Word2Vec由于是一个窗口一个窗口（或几个窗口）地进行参数的更新，所以学到的词向量更多的是局部的信息



文献 [178] 中提出了简化以往的神经网络语言模型 (Neural Probabilistic Language Model) 的 **Word2vec** 方法, **去除了非线性隐藏层**, 使用自监督的方式从大量无监督文本训练词表示模型构建了两个非常简单的神经网络模型结构: **连续词袋模型** (Continuous Bag Of Words, CBOW) 和**跳字模型** (Skip-Gram, SG)



CBOW




Skip-Gram

连续词袋模型: 给定上下文词, 需要我们来预测中间目标词


skip-gram 模型: 给定一个词语, 我们来根据这个词预测它的上下文



文献 [178] 中提出了简化以往的神经网络语言模型 (Neural Probabilistic Language Model) 的 **Word2vec** 方法，**去除了非线性隐藏层**，使用自监督的方式从大量无监督文本训练词表示模型。构建了两个非常简单的神经网络模型结构：**连续词袋模型** (Continuous Bag Of Words, CBOW) 和**跳字模型** (Skip-Gram, SG)




CBOW




Skip-Gram

连续词袋模型：给定上下文词，需要我们来预测中间目标词

skip-gram 模型：给定一个词语，我们来根据这个词预测它的上下文



CBOW



Skip-gram



✧ **语言模型：获取单词列表（假设是两个单词），并尝试预测它们后面的单词。**

input/feature #1

input/feature #2

output/label

Thou shalt

可以将模型想象成这个黑盒：

Input
Features

Output
Prediction

Thou

shalt

Trained Language Model

Task:

Predict the next word

not



但实际上，该模型不会只输出一个单词。它实际上输出它所知道的所有单词的概率得分

Input
Features

Thou

shalt

Trained Language Model

Task:

Predict the next word

Output
Prediction

0% aardvark

0% aarhus

0.1% aaron

...

40% not

...

0.01 zyzzzyva



经过训练后，早期的神经语言模型将分三步计算预测：

Input
Features

Trained Language Model

Task:

Predict the next word

Output
Prediction

Thou →

shalt →

1) Look up
embeddings


2) Calculate
prediction

3) Project
to output
vocabulary

0	aardvark
0	aarhus
0.001	aaron
...	
0.4	not
...	
0.0001	zyzzyva




当我们讨论嵌入时，第一步对我们来说是最相关的。训练过程的结果之一是这个矩阵，其中包含词汇表中每个单词的嵌入。在预测期间，我们只需查找输入单词的嵌入，并使用它们来计算预测：





语言模型训练:

1. 获得大量文本数据 (例如, 所有维基百科文章)
2. 然后有一个窗口 (例如, 三个单词), 可以在所有文本上滑动
3. 滑动窗口为模型生成训练样本





将前两个词作为特征，第三个词作为标签，生成了数据集中的第一个样本

Thou shalt not make a machine in the likeness of a human mind

Sliding window across running text

thou	shalt	not	make	a	machine	in	the	...
------	-------	-----	------	---	---------	----	-----	-----

Dataset

input 1	input 2	output
thou	shalt	not



依次将窗口滑动到下一个位置，就有了一个更大的数据集

Thou shalt not make a machine in the likeness of a human mind

Sliding window across running text

thou	shalt	not	make	a	machine	in	the	...
thou	shalt	not	make	a	machine	in	the	
thou	shalt	not	make	a	machine	in	the	
thou	shalt	not	make	a	machine	in	the	
thou	shalt	not	make	a	machine	in	the	

Dataset

input 1	input 2	output
thou	shalt	not
shalt	not	make
not	make	a
make	a	machine
a	machine	in



■ 连续词袋模型 (CBOW)

不仅可以查看目标单词之前的两个单词，还可以查看目标单词之后的两个单词

Jay was hit by a _____ bus in...

by	a	red	bus	in
----	---	-----	-----	----

实际上构建和训练模型的数据集将如下所示：

input 1	input 2	input 3	input 4	output
by	a	bus	in	red



■ Skip-gram 模型

是尝试使用当前单词来猜测相邻单词

Jay was hit **by a red bus in...**



粉色框具有不同的阴影，因为这个滑动窗口实际上在我们的训练数据集中创建了四个单独的样本：

Thou shalt not make a machine in the likeness of a human mind

thou	shalt	not	make	a	machine	in	the	...
------	-------	-----	------	---	---------	----	-----	-----

input word	target word
not	thou
not	shalt
not	make
not	a



■ Skip-gram 模型

依次将窗口滑动到下一个位置，得到更多的训练样例

Thou shalt not make a machine in the likeness of a human mind

thou	shalt	not	make	a	machine	in	the	...
------	-------	-----	------	---	---------	----	-----	-----

thou	shalt	not	make	a	machine	in	the	...
------	-------	-----	------	---	---------	----	-----	-----

thou	shalt	not	make	a	machine	in	the	...
------	-------	-----	------	---	---------	----	-----	-----

thou	shalt	not	make	a	machine	in	the	...
------	-------	-----	------	---	---------	----	-----	-----

thou	shalt	not	make	a	machine	in	the	...
------	-------	-----	------	---	---------	----	-----	-----


input word	target word
not	thou
not	shalt
not	make
not	a
make	shalt
make	not
make	a
make	machine
a	not
a	make
a	machine
a	in
machine	make
machine	a
machine	in
machine	the
in	a
in	machine
in	the
in	likeness



语言模型的训练过程

从数据集中的第一个样本开始。我们获取该特征并将其提供给未经训练的模型，要求其预测适当的相邻单词

input word	target word
not	thou
not	shalt
not	make
not	a
make	shalt
make	not
make	a
make	machine
a	not
a	make
a	machine
a	in
machine	make
machine	a
machine	in
machine	the
in	a
in	machine
in	the
in	likeness





■ 语言模型的训练过程


输出一个预测向量，计算预测误差。误差向量于更新模型

Actual Target		Model Prediction		Error
0		0	aardvark	0
0		0	aarhus	0
0		0.001	aaron	-0.001
...		...		...
0		0.4	taco	-0.4
1		0.001	thou	0.999
...		...		...
0		0.0001	zyzzyva	-0.0001



语言模型的训练过程


继续对数据集中的下一个样本执行相同的过程，直到覆盖数据集中的所有样本。一个训练周期就此结束。重复多次，就得到了经过训练的模型。从中提取嵌入矩阵并将其用于其他下游任务





■ 负采样

从计算的角度来看，第三步非常耗时 - 特别是知道我们将为数据集中的每个训练样本执行一次





■ 负采样

将目标分为两个步骤以提高性能：

- 生成高质量的词嵌入（不用担心下一个词的预测）
- 使用这些高质量的嵌入来训练语言模型（进行下一个单词预测）

将为了使用高性能模型生成高质量的嵌入，可以将模型的任务从预测相邻单词切换切换到一个模型，该模型接受输入和输出单词，并输出一个分数，指示它们是否是邻居（0 表示“不是邻居”，1 表示“邻居”）：

Change Task from

To:



这个简单的转换将需要的模型从神经网络更改为逻辑回归模型 - 因此计算变得更简单、更快



■ 负采样

切换数据集的结构

input word	target word
not	thou
not	shalt
not	make
not	a
make	shalt
make	not
make	a
make	machine

input word	output word	target
not	thou	1
not	shalt	1
not	make	1
not	a	1
make	shalt	1
make	not	1
make	a	1
make	machine	1



■ 负采样

在数据集中引入负样本——从词汇表中随机抽取不是邻居的单词样本

input word	output word	target
not	thou	1
not	aaron	0
not	taco	0
not	shalt	1
not	make	1

Pick randomly from vocabulary
(random sampling)

Word	Count	Probability
aardvark		
aarhus		
aaron		
taco		
thou		
zyzzyva		



■ 带负采样的 Skip-gram

Skipgram

shalt	not	make	a	machine
input		output		
make		shalt		
make		not		
make		a		
make		machine		


Negative Sampling

input word	output word	target
make	shalt	1
make	aaron	0
make	taco	0



■ Word2vec 训练过程

在训练阶段开始时，创建两个矩阵：一个Embedding矩阵和一个Context矩阵，并用随机值初始化这些矩阵






■ Word2vec 训练过程

在每个训练步骤中，采用一个正例及其相关的负例

dataset

input word	output word	target
not	thou	1
not	aaron	0
not	taco	0
not	shalt	1
not	mango	0
not	finglonger	0
not	make	1
not	plumbus	0
...	...	...


model





Word2vec 训练过程

现在我们有四个单词：输入单词`not`和输出/上下文单词：（`thou`实际邻居）、`aaron`和`taco`（反例）。我们继续查找它们的嵌入——对于输入单词，我们在`Embedding`矩阵中查找。对于上下文单词，我们查看矩阵`Context`（即使两个矩阵都嵌入了词汇表中的每个单词）






Word2vec 训练过程

计算输入嵌入与每个上下文嵌入的点积。在每种情况下，这都会产生一个数字，该数字表示输入和上下文嵌入的相似度

input word	output word	target	input • output
not 	thou 	1	0.2
not 	aaron 	0	-1.11
not 	taco 	0	0.74

input word	output word	target	input • output	sigmoid()
not 	thou 	1	0.2	0.55
not 	aaron 	0	-1.11	0.25
not 	taco 	0	0.74	0.68


input word	output word	target	input • output	sigmoid()	Error
not 	thou 	1	0.2	0.55	0.45
not 	aaron 	0	-1.11	0.25	-0.25
not 	taco 	0	0.74	0.68	-0.68



Word2vec 训练过程

可以使用此错误分数来调整`not`、`thou`、`aaron`、和的嵌入，`taco`以便下次进行此计算时，结果将更接近目标分数

input word	output word	target	input • output	sigmoid()	Error
not	thou	1	0.2	0.55	0.45
not	aaron	0	-1.11	0.25	-0.25
not	taco	0	0.74	0.68	-0.68




Update
Model
Parameters



Word2vec 训练过程

继续下一步（下一个正样本及其相关的负样本）并再次执行相同的过程



当多次循环整个数据集时，嵌入不断得到改进。然后可以停止训练过程，丢弃Context矩阵，并使用该Embeddings矩阵作为下一个任务的预训练嵌入



word2vec 训练过程中的两个关键超参数：窗口大小和负样本数量

Window size: 5



Window size: 15



Negative samples: 2

input word	output word	target
make	shalt	1
make	aaron	0
make	taco	0

Negative samples: 5

input word	output word	target
make	shalt	1
make	aaron	0
make	taco	0
make	finglonger	0
make	plumbus	0
make	mango	0

- 使用较小的窗口大小(2-15)会得到这样的嵌入：两个嵌入之间的高相似性得分表明这些单词是可互换的(注意，如果只查看附近距离很近的单词，反义词通常可以互换——例如，好的和坏的经常出现在类似的语境中)
- 使用较大的窗口大小(15-50，甚至更多)会得到相似性更能指示单词相关性的嵌入

- 原始论文认为 5-20 个负样本是比较理想的数量
- 它还指出，当你拥有足够大的数据集时，2-5 个似乎就已经足够了



LSA和word2vec算法的缺点:

- Skip-Gram和CBOW模型根据局部信息进行学习，不能很好地利用语料库的统计数据
- 而LSA模型则基于词共现矩阵全局信息得到词语表示，不能结合上下文语境，计算复杂度高

全局向量 (Global Vectors for Word Representation, GloVe) 模型则结合了上述模型的思想，从共现概率的角度分析并改进了Skip-Gram模型，即使用文本中局部的上下文信息，又对语料库的全局共现统计数据加以利用。



令 $P(k|w)$ 为单词 k 在单词 w 的上下文中出现的可能性

Probability and Ratio	$k = solid$	$k = gas$	$k = water$	$k = fashion$
$P(k ice)$	1.9×10^{-4}	6.6×10^{-5}	3.0×10^{-3}	1.7×10^{-5}
$P(k steam)$	2.2×10^{-5}	7.8×10^{-4}	2.2×10^{-3}	1.8×10^{-5}
$P(k ice)/P(k steam)$	8.9	8.5×10^{-2}	1.36	0.96

概率比率 ($F(w_i, w_j, \hat{w}_k) = \frac{p_{i,k}}{p_{j,k}}$)

$F(w_i, w_j, \hat{w}_k)$	w_j, w_k 相关	w_j, w_k 不相关
w_i, w_k 相关	趋近 1	很大
w_i, w_k 不相关	很小	趋近 1


GloVe模型的损失函数形式与上节介绍的Skip-Gram模型相似，同样以还原共现频率 p_{ij} 为目标，并在其基础上进行改进



“king” 一词的词嵌入 (在维基百科上训练的 GloVe 向量)

```
[ 0.50451 , 0.68607 , -0.59517 , -0.022801, 0.60046 , -0.13498 , -0.08813 , 0.47377 , -0.61798 , -0.31012 ,  
-0.076666, 1.493 , -0.034189, -0.98173 , 0.68229 , 0.81722 , -0.51874 , -0.31503 , -0.55809 , 0.66421 , 0.1961  
, -0.13495 , -0.11476 , -0.30344 , 0.41177 , -2.223 , -1.0756 , -1.0783 , -0.34354 , 0.33505 , 1.9927 ,  
-0.04234 , -0.64319 , 0.71125 , 0.49159 , 0.16754 , 0.34344 , -0.25663 , -0.8523 , 0.1661 , 0.40102 , 1.1685 ,  
-1.0137 , -0.21585 , -0.15155 , 0.78321 , -0.91241 , -1.6106 , -0.64426 , -0.51042 ]
```

根据单元格的值对单元格进行颜色编码 (如果接近 2, 则为红色; 如果接近 0, 则为白色; 如果接近 -2, 则为蓝色) :





“king”



“Man”




“Woman”



看看 “Man” 和 “Woman” 之间的相似程度，比他们与 “King” 的相似程度要高得多吗？


这些向量表示捕获了这些单词的大量信息/含义/关联





可以添加和减去词嵌入并得到有趣的结果

king - man + woman $\sim$ queen



“king-man+woman” 生成的向量并不完全等于 “queen”，但 “queen” 是我们在此集合中拥有的 400,000 个单词嵌入中最接近它的单词。



本章前几节所介绍的词表示模型都**依赖预先确定的词表 V** ，在编码输入词序列时，这些词表示模型只能处理词表中存在的词。

如果遇到不在词表中的**未登录词**，模型无法为其生成对应的表示，只能给予这些未登录词一个默认的通用表示。通常的处理方式是，词表示模型会预先在词表中加入一个默认的 “[UNK]” (unknown) 标识，表示未知词

一种直接的解决思路是为输入建立**字符级别表示**，并通过字符向量的组合来获得每个单词的表示。然而，单词中的词根、词缀等构词模式往往跨越多个字符，基于字符表示的方法**很难学习跨度较大的模式**。



子词表示模型提出了**子词 (Subword)** 的概念，子词表示模型会维护一个子词词表，其中既存在完整的单词，也存在形如 “c” , “re” , “ing” 等单词部分信息，称为子词。

对于输入的词序列，子词表示模型将每个词拆分为**词表内的子词**。

例如，将单词 “reborn” 拆分为 “re” 和 “born”

模型随后查询每个子词的表示，将输入重新组成为子词表示序列。

字节对编码模型 (Byte Pair Encoding, BPE) 是一种常见的子词表示模型。该模型所采用的词表包含**最常见的单词**以及**高频出现的子词**。在使用中，常见词通常本身位于 BPE 词表中，而罕见词通常能被分解为若干个包含在 BPE 词表中的子词，从而大幅度降低未登录词的比例。




图 4.7 BPE 模型中子词词表的计算过程



例如，对于单词“lowest”，首先通过匹配子词“est”将其切分为“low”，“est”的序列，再通过匹配子词“low”，确定其最终切分结果为“low”，“est”的序列。通过这样的过程，BPE尽量将词序列中的词切分成已知的子词。

对于使用了子词表示模型的自然语言处理系统，比如机器翻译系统，其**输出序列也是子词序列**。对于原始输出，根据终结符“</w>”的位置确定每个单词的范围，合并范围内的子词，将输出重新组合为词序列，作为最终的结果。



单词分布式表示模型的定量评估方法主要分为**内部评价** (Intrinsic Evaluation) 和**外部评价** (Extrinsic Evaluation) 两种方法。

内部评价方法通常基于一个特殊设计的辅助任务，这个辅助任务探测词向量应该具有的某种性质，如词义相关性、类比性等，并最终返回一个分数，来表示词向量的好坏，从而帮助我们理解词向量模型的特点。

外部评方法通常基于一个**实际应用任务**，通过将词向量作为该任务的输入表示，比较不同词向量模型在该任务上的性能，来选择适合于该任务的词向量模型。



词义相关性任务通过探索词向量对词义相关性的表达能力，来评价词向量的质量。

对于单词 w_i, w_j 及其词向量 $\mathbf{v}_i, \mathbf{v}_j$ ，简单地使用余弦相似度作为词义相似性的度量：

$$\text{sim}(w_i, w_j) = \cos(\mathbf{v}_i, \mathbf{v}_j) = \frac{\mathbf{v}_i \mathbf{v}_j}{\|\mathbf{v}_i\| \|\mathbf{v}_j\|}$$

通过直接将词义相似度作为目标，可以定量衡量词向量模型的性能。

表 4.5 语义相似度评测基准样本示例

单词 1	单词 2	相似度
dirty	narrow	0.30
student	pupil	9.40
win	dominate	5.68
smart	dumb	0.60
attention	awareness	8.73
leave	enter	1.38



类比性任务回答： w_a 之于 w_b ，相当于 w_c 之于？

$$w^* = \arg \min_{w' \in \mathbb{V}} \cos(\mathbf{v}^*, \mathbf{v}_c + \mathbf{v}_b - \mathbf{v}_a)$$

在由(man, woman)词对确定的类比关系下，可以为单词son检索类比词daughter，它们满足man之于woman，相当于son之于daughter的类比关系。



句子分布式表示主要用于句子级别的任务，如情感分析、文本推理、语义匹配等。对于句子级别表示的构建，不但要**考虑句子中所包含单词的语义**，也要考虑句子内部词之间的关系，即词的共现信息和句子语义之间的联系。还要**考虑句子和句子之间隐含的语义相似性**，以及其他的语义关系。这些性质对于句子级别的下游应用任务都很重要。



Skip-Thought模型的目的主要是建模句子与句子之间的上下文语义关系，从而构建句子表示模型。Skip-Thought模型借鉴了Skip-Gram模型的思想，认为**可以基于一个句子预测出其上下文的句子，并以此作为监督信号**，学习句子之间的语义关系，得到句子表示模型。




图 4.8 Skip-Thought 模型结构图



在自然语言处理和信息检索领域，部分任务会要求模型学习并表示**文档级别的特征**，如文档检索、文档去重、文档级情感分析、主题识别等任务。相对一般的自然语言处理任务，这类任务**不需要模型精确地捕获细粒度的词句信息**，但需要模型建模文档的**主题**、包含的**关键词**等信息。



词频-逆文档频率 (TF-IDF) 用来评估在特定文档中词的重要程度，其基本假设是文档中词重要程度随其在文档中出现的频率增加，同时也会随其在整个语料库中出现的频率而下降。

- 如果一个词在**特定文档的出现频率高**，则说明这个词与该文档的**主题具有比较强的相关关系**，因此该词相对于该文档的**重要性应该较高**
- 但是，如果一个词语在整个文档集合**很多文档上都出现了**，那么说明该词是**常见词语**，其区分性不好，因此其**重要程度应该较低**

$$\text{TF}(t, d) = \frac{\text{COUNT}(t, d)}{\sum_{t' \in \mathcal{V}} \text{COUNT}(t', d)}$$

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \text{IDF}(t)$$

$$\text{IDF}(t) = \log \frac{|\mathcal{D}|}{\sum_{d \in \mathcal{D}} \mathbf{1}^{t \in d}}$$



词频-逆文档频率 (TF-IDF)

$$\text{tf}_{t,d} = \log_{10}(\text{count}(t,d) + 1) \quad \text{idf}_t = \log_{10} \frac{N}{\text{df}_t}$$

$$\text{tf-idf}(t,d) = \text{tf}_{t,d} \cdot \text{idf}_t$$

$$\text{score}(q,d) = \sum_{t \in q} \frac{\text{tf-idf}(t,q)}{\sqrt{\sum_{q_i \in q} \text{tf-idf}^2(q_i,q)}} \cdot \frac{\text{tf-idf}(t,d)}{\sqrt{\sum_{d_i \in d} \text{tf-idf}^2(d_i,d)}} \quad \Rightarrow \quad \text{score}(q,d) = \sum_{t \in q} \frac{\text{tf-idf}(t,d)}{|d|}$$

Query: sweet love

Doc 1: Sweet sweet nurse! Love?

Doc 2: Sweet sorrow

Doc 3: How sweet is love?

Doc 4: Nurse!

Doc	d	tf-idf(sweet)	tf-idf(love)	score
1	.141	.060	.091	1.07
3	.274	.038	.091	0.471
2	.185	.038	0	0.205
4	.090	0	0	0


Document 1						Document 2					
word	count	tf	df	idf	tf-idf	word	count	tf	df	idf	tf-idf
love	1	0.301	2	0.301	0.091	love	0	0	2	0.301	0
sweet	2	0.477	3	0.125	0.060	sweet	1	0.301	3	0.125	0.038
sorrow	0	0	1	0.602	0	sorrow	1	0.301	1	0.602	0.181
how	0	0	1	0.602	0	how	0	0	1	0.602	0
nurse	1	0.301	2	0.301	0.091	nurse	0	0	2	0.301	0
is	0	0	1	0.602	0	is	0	0	1	0.602	0
$ d_1 = \sqrt{.091^2 + .060^2 + .091^2} = .141$						$ d_2 = \sqrt{.038^2 + .181^2} = .185$					

4.3.3 篇章分布式表示--fastText篇章表示模型



fastText模型旨在高效训练文本表示模型，采用字符n-gram特征

直接使用子词向量的和作为对应单词的词向量：
$$\mathbf{v}_w = \sum_{s \in \mathbb{V}_s(w)} \mathbf{z}_s$$





fastText 通常使用 Skip-Gram 模型的训练方式得到预训练的词级别表示

在将 fastText 句向量应用于文本分类任务时，通常以对数概率作为优化目标：

$$\mathcal{L}(x = w_1, \dots, w_N, y) = -y \cdot \log(\text{softmax}(\mathbf{W} \cdot \mathbf{v}))$$

$$\mathbf{v} = \frac{1}{N} \sum_{i=1}^N \mathbf{v}_i$$

本章主要内容

4.1

语义学概述

4.2

语义表示

4.3

分布式表示

4.4

词义消歧

4.4.1 基于目标词上下文的词义消歧方法

4.4.2 基于词义释义匹配的词义消歧方法

4.4.3 词义消歧评价方法

4.4.4 词义消歧语料库

4.5

语义角色标注



词义消歧 (Word Sense Disambiguation, WSD) 是指确定一个多义词在给定的上下文中的具体含义。根据本章第4.1.1节词汇语义学相关介绍，我们可以知道语言中一词多义现象十分普遍。

例如：水分既可以表示物体内含的水，也可以表示某些情况中夹杂的不真实的成分，可以使用**水分¹**和**水分²**分别表示两个含义

(1) 葡萄糖液可用来供给水分。单词义项：水分¹

(2) 这个报导有些水分，需要核实。单词义项：水分²

词义消歧任务核心就是根据词语所处的句子或者篇章，确定该词在当前环境下的确切含义。



对于待消歧的目标词，词义消歧方法通常**采用有监督分类**方法，将词语的每个词义项作为候选词义，**通过估计待消歧词义的概率分布从而完成目标词的词义消歧**。

基于目标词上下文的词义消歧方法利用待消歧**目标词的上下文**进行训练，预测上下文中目标词属于每个候选词义的条件概率。

自然语言处理中常用的统计机器学习方法和深度学习算法，均可用于构建基于目标词上下文的词义消歧方法。



使用 w 表示待消歧的目标词, c 表示目标词所处的句子, $\{s_i\}_{i=1}^N$ 为目标词的候选词义集合

通过估计条件概率 $P(s_i|c)$ 来预测目标词 w 的词义

给定句子 $c = \{w_k\}_{k=1}^K$, 可以将条件概率 $P(s_i|c)$ 通过贝叶斯公式转换为:

$$P(s_i|c) = \frac{P(c|s_i)P(s_i)}{P(c)} \propto P(c|s_i)P(s_i) \quad (4.33)$$

其中, $P(c|s_i)$ 的计算方式与语言模型类似。随着上下文长度的增加, 上下文 c 的数量指数级增长, 该概率值难以估计。因此, 需要引入单词独立假设, 近似地将概率估算为上下文中每个单词的独立出现概率:

$$P(c|s_i) = \prod_{k=1}^K P(w_k|s_i) \quad (4.34)$$

通过公式4.33和公式4.34, 词义分类可以根据如下公式选择最大条件概率的词义:

$$\hat{s} = \arg \max_{s_i} P(s_i|c) = \arg \max_{s_i} P(s_i) \prod_{k=1}^K P(w_k|s_i) \quad (4.35)$$



$P(s_i)$ 和 $P(w_k|s_i)$ 可以通过训练语料利用最大似然估计得到:

$$P(w_k|s_i) = \frac{\text{COUNT}(w_k, s_i)}{\text{COUNT}(s_i)}$$

$$P(s_i) = \frac{\text{COUNT}(s_i)}{\text{COUNT}(w)}$$


$\text{COUNT}(w_k, s_i)$ 是训练语料中目标词 w 以语义 s_i 在上下文中出现的次数

$\text{COUNT}(s_i)$ 是训练语料中语义 s_i 出现的总次数

$\text{COUNT}(w)$ 是训练语料中目标词 w 出现的总次数



深度神经网络算法可以很好地对句子和短语的语义进行表示。因此，也可以利用目标词**上下文的分布式表示**，建模目标词上下文语义，并基于上下文向量表示构建词义消歧算法。



基于上下文向量表示的最近邻方法将词义消歧任务形式化为**词义表示和上下文表示的相似度学习问题**。



在词义编码部分，首先考虑在词义消歧语料库中存在标注的语义。对于每一个标注词义，**在训练集中抽取全体包含该词义标注的样本**。随后，通过预训练上下文表示模型，计算词义对应的目标词在样本上下文中的表示。最后，以目标词表示的平均值作为词义的代表。

$$v_0, v_1, \dots, v_w, \dots, v_n = \text{Encoder}(c = c_0, c_1, \dots, w, \dots, c_n)$$

$$v = \frac{1}{|C(s)|} \sum_{c \in C(s)} v_w$$

$C(s)$ 为全体标记词义为 s 的样本集合，Encoder 代表使用预训练语言模型初始化的编码器，如ELMo、BERT 等。



针对未在词义消歧语料库中出现的词义，可以采用方法，利用**WordNet**中标注的**同义词、上位词和词性标注 (Lexname)** 等语义关系信息，寻找与目标词义相似或相关的词义，再以这些词义表示的平均值作为该词义表示。

以**同义词关系**为例，对于待确定表示的词义 s ，记 $S(s)$ 为 s 的同义语义集合。若 $S(s)$ 不是空集， s 的语义表示为 $S(s)$ 中同义语义的平均表示：

$$v = \frac{1}{|S(s)|} \sum_{s \in S(s)} v_s, \text{ if } |S(s)| > 0$$



当同义语义缺失时，可依次使用相同上位的语义或相同词性的语义作为近义语义集合，利用相似的方式计算目标语义的表示，具体计算公式如下所示：

$$v = \frac{1}{|H(s)|} \sum_{s \in H(s)} v_s, \text{ if } |H(s)| > 0$$

$$v = \frac{1}{|L(s)|} \sum_{s \in L(s)} v_s, \text{ if } |L(s)| > 0$$

在构建了所有词义的向量表示后，对于每一条输入的待进行词义消歧的样本，首先基于语言模型计算目标词的上下文表示，在此基础上，**计算上下文表示与全体候选词义表示的点积相似度**，选择相似度最大的语义做为分类结果，具体计算公式如下所示：

$$\hat{s} = \arg \max_s (v_w \cdot v(s))$$



以知网（HowNet）、WordNet等为代表的词汇知识资源中不仅包含了词义之间的关系，**还包含了词义的解释信息。**

例如：WordNet 3.1 中对 “table”给出了如下词义解释：

table1: a set of data arranged in rows and columns

table2: a piece of furniture having a smooth flat top that is usually supported by one or more vertical legs

table3: a piece of furniture with tableware for a meal laid out on it

table4: flat tableland with steep edges

table5: a company of people assembled at a table for a meal or game

table6: food or meals in general

这些释义与目标词上下文之间存在着非常强的联系。比如**table¹**所对应的“表格”含义，其上下文更多的对应的设计、制作、数据等词汇。而**table²**所对应的“桌子”含义，其上下文更多的对应的椅子、沙发等词汇。因此，也可以将词义消歧问题转化为目标词上下文和词义释义之间的语义匹配问题。



$$\text{精确率 (P)} = \frac{\text{算法输出的正确标记个数}}{\text{算法输出的全部标记个数}} \times 100\%$$

$$\text{召回率 (R)} = \frac{\text{算法输出的正确标记个数}}{\text{测试集中全部标记个数}} \times 100\%$$

$$\text{F 值 (F1)} = \frac{2 \times P \times R}{P + R}$$

$$\text{覆盖率} = \frac{\text{算法输出的全部标记个数}}{\text{测试集中全部标记个数}} \times 100\%$$



词义消歧义项分类标注语料库

SemCor 是基于WordNet 词义进行标注的语料库。SemCor 3.0 版本包含352 个文档和22 万余条手动语义注释，其原始语料从布朗（Brown）语料库获取，经过筛选后，参考WordNet 1.4 的词义清单进行词义标记

OMSTI (One Million Sense-Tagged Instances) 是自动标注的语料库，也常用于词义消歧系统的训练。OMSTI使用WordNet 3.0的词义进行注释，它是通过在大型英汉平行语料库（MultiUN 语料库）上使用基于对齐的词义消歧方法自动构建的。

WSDEval是统一词义消歧基准评测框架，将不同时期构建的采用不同词义注释构建的评测基准语料统一使用WordNet 3.0词义进行注释。



词义消歧义项相同判断标注语料库

WiC (Word in Context) 数据集是一个由专家标注的词义消歧数据集，每个样本对同一个目标词给出两个包含该词语的句子，并依据在两个句子中目标词的词义是否相同，给出T或F的分类标签。

WiC-TSV (Word in Context - Target Sense Verification) 对WiC的语料筛选和任务形式进行了改进，形成了新的跨越多个领域的词义消歧评测基准。WiC-TSV中的每个样本仅包含一个句子，其中标出待消歧的目标词。

本章主要内容

4.1

语义学概述

4.2

语义表示

4.3

分布式表示

4.4

词义消歧

4.5

语义角色标注

4.5.1 语义角色标注及其一般流程

4.5.2 语义角色标注评价方法

4.5.3 语义角色标注语料库



语义角色标注 (Semantic Role Labeling, SRL) 是一种浅层语义分析技术，目标是分析句子的谓词-论元结构，揭示句子中概念范畴之间的语义关系。

- 语义角色标注的主要语言学理论来源于题元理论(Thematic Theory)、格语法 (Case Grammar) 以及配价理论 (Valency Theory) 等句子语义理论等。
- 题元理论认为句子以谓语为中心，谓语决定了句子的基本结构。
- **论元 (Argument)** 是谓语所涉及的对象，担任了施事、客体、受事、地点或命题等不同的题元角色。语义角色标注任务核心是识别句子中谓语的论元，并确定论元的题元角色。

例如：[中国成飞公司]A0[正在]AM-T M P [制造]V [民用飞机]A1。

“制造”为谓词（V），代表了一个事件的核心行为；“中国成飞公司”和“民用飞机”为动作的施事者（A0）和受事者（A1）



语义角色标注算法虽然有很多类型，但是其基本基本流程都主要由**论元识别**和**论元分类**组成。基于句法分析的语义角色标注算法还需要先对句子进行句法分析。

论元识别的目标是从句子识别所有由连续几个单词组成的论元。

- 由于如果将句子中所有的连续单词片段都作为论元候选，其数量会过于庞大，因此早期的方法在进行论元识别前，通常还会引入基于规则的候选论元过滤方法，利用句法分析结果构造启发式规则对候选项进行大幅度删减


论元分类则是对论元和谓词之间的关系类型进行分类。

论元识别和论元分类通常采用有监督机器学习算法，将上述任务转换为分类问题。

两个任务之间可以采用流水线结构，也可以采用联合学习的方法。



◆语义角色标注的基本流程：





语义角色标注的评价指标包括精确率 (Precision, P)、召回率 (Recall, R) 和F 值 (F-Score) 得分。

在预测结果中，仅当论元范围和类型均预测正确时，才视为该论元预测正确，计为真正例 (True-Positives, TP) 。



框架网络 (FrameNet) 根据框架语义学理论，对英国国家语料库进行标注。FrameNet目前包括超过200,000个人工标注的句子，在句子中标注目标谓词的语义框架、语义角色，以及每个语义角色在句法层面的短语类型和句法功能。

命题库 (Propositional Bank, PropBank) 是论元角色语义知识库，针对动词性谓词，在语料中标注所在句的谓词-论元 (predicate-argument) 信息。PropBank对英文宾州树库中的WSJ (华尔街日报标注) 语料和一部分BROWN (布朗语料库标注) 语料进行了标注。

名词命题库 (NomBank) 关注并侧重名词性谓词的语义角色标注，对PropBank的涵盖范围进行了补充。NomBank对语料中的名词性谓词进行语义角色标注。其主要语料资源同样来自《华尔街日报》，研究人员对其中名词性的谓词对应的论元角色进行人工标注。



基于成分结构的语义角色标注评测

表 4.11 CoNLL05、CoNLL12 评测基准的统计数据

数据集 数据划分	CoNLL 2005				CoNLL 2012 (英文)			CoNLL 2012 (中文)		
	训练集	验证集	测试集	Brown	训练集	验证集	测试集	训练集	验证集	测试集
句子个数	39.8k	1.3k	2.4k	0.4k	75.2k	9.6k	9.5k	36.5k	6.1k	4.5k
谓词个数	90.8k	3.2k	5.3k	0.8k	188.9k	23.9k	24.5k	117.1k	16.6k	15.0k
论元个数	333.7k	11.7k	19.6k	3.0k	622.5k	78.1k	80.2k	365.3k	51.0k	46.7k

基于依存结构的语义角色标注评测

表 4.12 CoNLL09 评测基准的统计数据

数据集	训练集句数	训练集词数	平均句长	谓词比例	验证集句数	验证集词数
CoNLL 2009 (英文)	39.3k	958.2k	24.4	18.7%	2.4k	57.7k
CoNLL 2009 (中文)	22.3k	609.1k	27.3	16.9%	2.6k	73.2k

本章小结

语义问题也被大多数语言学家认为是语言的核心问题，同时也受到了包括哲学、逻辑学、心理学以及计算机等众多学科的广泛关注。本章首先介绍了语义学的基本概念和研究范畴，随后介绍了自然语言的语义表示方法，并介绍了自然语言处理中应用语义分析的词义消歧和语义角色标注任务。近年来，随着深度学习的应用和语言资源的逐步完善，语义表示和语义分析获得了很大的发展。