

中山大學 人工智能學院
SUN YAT-SEN UNIVERSITY SCHOOL ARTIFICIAL INTELLIGENCE

「自然语言处理」

第 5 章 篇章分析

赵宝全

中山大学人工智能学院

2026年春季学期

本章主要内容

5.1

篇章理论概述

5.2

话语分割

5.3

篇章结构分析

5.4

指代消解

本章主要内容

5.1

篇章理论概述

5.1.1 篇章的衔接

5.1.2 篇章的连贯

5.1.3 篇章的结构

5.2

话语分割

5.3

篇章结构分析

5.4

指代消解



■ 自然语言不同层次的处理

✧ 词法 (Morphology)

- 词的构成问题

✧ 句法 (Syntax)

- 词与词之间的结构关系

✧ 语义 (Semantics)

- 词的意义、词与词组合 (短语/句子) 意义

✧ 语篇 (Discourse)

- 句子之间的关系, 上下文的意义



篇章（语篇/话语，discourse）

- 由一个以上的句子（sentence）或语段（utterance）构成的有**组织**、**有意义**的自然语言文本整体。
- 构成语篇的句子（或语段）彼此之间在形式上**相互衔接**，在意义上**前后连贯**。

■ 小明学习刻苦，成绩每年进步，考上理想大学。😬

■ 花是红的，人工智能飞速发展，今天傍晚有雨。😬

■ 考上理想大学，成绩每年进步，小明学习刻苦。😬

■ （对话）

S1：电话铃响了

S2：我正在看书

S1：哦，好吧





篇章语言学是在二十世纪五十年代以后发展起来的一门新兴学科。传统语言学通常以句子本身及其组成成分为研究对象。但是随着语言学研究的进展，人们发现句子在不同的上下文和语境中也可以**有不同的意义或者具有不同交际功能**，多个合乎句法的句子也**并不是随意堆在一起就能构成一个合格的语篇**。

语言研究应该超越句子层次，**句子的组合受到语法以外的规则的制约**。Harris (1952) 在《Discourse Analysis》一书中首次提出了“话语分析”这一术语。W. Weinrich在1967年首次提出了“篇章语言学”这一概念，认为任何语言学研究都应该以语篇为描述框架。



■ 研究内容

✧ 超越单个句子范围的各种可能分析，包括：

- 句子（语段）之间的关系以及关系类型的划分
- 段落之间的关系判断
- 跨越单个句子的词与词之间的关系分析
- 话题的继承与变迁
-



■ 研究内容

✧ 语篇的衔接性 (Cohesion)

- 主要是分析词汇（或短语）之间的语义关联，如同义关系，反义关系，整体与部分关系、远程搭配关系以及指代关系等
- 话题的演化与推进很大程度上要借助于衔接性分析的结果
- 这就需要研究词汇层面的各种关系计算方法和支撑相关计算所需要的语言资源建设

✧ 语篇的连贯性 (Coherence)

- 主要以句子为出发点研究前后文的关联，以期揭示内容的推演过程以及前后文之间的逻辑关系
- 这就需要研究合理的关系表示和关系分析的有效计算模型



■ 衔接性 (Cohesion) vs 连贯性 (Coherence)

✧ Cohesion (衔接): 强调其构成成分 (主要是词或短语) 之间的关联性

- 例子: [s1]张三喜欢骑单车上班, [s2]李四通常步行去办公室
- 在词汇层面上相对容易处理

✧ Coherence (连贯): 强调整体上表达某种意义

- 例子:
 - [s3] A: 我有两张票, 想请你今晚看电影。
 - [s4-1] B:很遗憾, 我今晚不能看电影 (衔接+连贯, 简洁易懂)
 - [s4-2] B:我还有一大堆的作业没有完成 (连贯, 没有衔接)
 - [s4-3] B:我就不客气了 (连贯, 没有衔接)
 - [s4-4] B: 武汉又称江城 (不衔接、不连贯)
- 在处理上相对困难, 不容易切入



■ 语篇分析的应用

✧ 机器阅读理解

- 语篇分析也可以为词、短语和句子的分析提供更多有用的信息
- 例如：“你能穿多少就穿多少”
 - 分词结果1：(天气很热) “你/ 能/ 穿/ 多/ 少/ 就/ 穿/ 多/ 少”
 - 分词结果2：(天气很冷) “你/ 能/ 穿/ 多少/ 就/ 穿/ 多少”

✧ 机器翻译

✧ 自动会话

✧ 文本摘要与结构化

✧



■ 选自“人民日报”的一段话

①吉林省梨树县女农民蔡淑珍，②过去不懂技术，③养鸡鸡死，④养兔兔亡，⑤赔了几万元，⑥险些寻了短见。

若用 google 翻译器（2016年）翻译成英文，翻译结果为：

① Lishu female farmer Cai Shuzhen, ② in the past I do not understand technology, ③ chicken chicken died, ④ raising the death bunny, ⑤ lost several million, ⑥ almost to find a short-sighted.

翻译结果分析

- ✧ 首先，汉语的①与②联合构成一个完整的句子，①充当其中的主语。但是，在翻译结果中，②独立翻成了一个完整句子，这使得①的翻译成为多余；
- ✧ 其次，②中的“l”也不正确。翻译器将②看成缺失主语（零形式），并将零形式补充为“l”（当然，这一补充是错误的）。如果翻译器有原文语篇分析的功能，能分析出①与②共同构成一个句子，这一错误就可以避免。
- ✧ 再看后面 4 句，翻译结果中③④⑤⑥之间没有形成关联关系，这不符合英语的表达习惯；也没有补充缺失的零形式（主语）。可以推断，翻译器没有很好甚至缺乏对这 4 句进行语篇分析。



- 选自“人民日报”的一段话

①吉林省梨树县女农民蔡淑珍，②过去不懂技术，③养鸡鸡死，④养兔兔亡，⑤赔了几万元，⑥险些寻了短见。

若用 google 翻译器（2022年）翻译成英文，翻译结果为：

Cai Shuzhen, a female farmer in Lishu County, Jilin Province, used to be ignorant of technology, and died raising chickens and rabbits, and lost tens of thousands of yuan. She almost committed suicide.

若用Baidu翻译器（2022年）翻译成英文，翻译结果为：

Cai Shuzhen, a female farmer in Lishu County, Jilin Province, did not understand technology in the past. The chickens died and rabbits died. She lost tens of thousands of yuan and almost found a short opinion.



- 选自“人民日报”的一段话

①吉林省梨树县女农民蔡淑珍，②过去不懂技术，③养鸡鸡死，④养兔兔亡，⑤赔了几万元，⑥险些寻了短见。

若用 google 翻译器（2024年）翻译成英文，翻译结果为：

Cai Shuzhen, a female farmer from Lishu County, Jilin Province, did not know how to raise chickens and rabbits in the past. She lost tens of thousands of yuan and almost committed suicide.

若用Baidu翻译器（2024年）翻译成英文，翻译结果为：

Cai Shuzhen, a female farmer in Lishu County, Jilin Province, used to lack technical skills. She died when raising chickens and rabbits, and lost tens of thousands of yuan in compensation, almost finding her own shortcomings.



CHEAT SHEET FOR VISUAL NOTES

BASIC TEXT ORGANIZING

HEADING

SUB-HEADING

- main text
- main text

SUB-HEADING

- main text
- main text


(white space is your friend!)

USING COLOUR

- HEADING → ALL-CAPS, LARGE IN RED, BLUE, GREEN, PURPLE, OR OTHER BOLD COLOUR
- SUB-HEADING → CONTRASTING COLOUR TO THE HEADING
- MAIN TEXT → SMALLER FONT SIZE, IN BLACK, BLUE, BROWN
- HIGHLIGHTS → SHOULD BE A "POP" OF COLOUR THAT STANDS OUT. USE TO EMPHASIZE AN IDEA.

MOST OF ALL, STAY **CONSISTENT** IN YOUR COLOURS!

DIVIDERS & BULLETS




MANAGING TIME



15 MIN. 15 MIN.
15 MIN. 15 MIN.

IT CAN HELP TO DIVIDE UP THE PAGE BASED ON BLOCKS OF TIME SO YOU DON'T RUN OUT OF SPACE

ORGANIZING THE PAGE




BANNERS and BOXES



@thefuselight

HOW to SHARE your VISUAL NOTES





SCREEN SHARE IN MS TEAMS, ZOOM, ETC.

@thefuselight



SMART BOARD




FOR MORE INFO & TIPS ON VISUAL NOTES AND GRAPHIC RECORDING: [THEFUSELIGHT.COM](http://thefuselight.com)





HOW TO SUMMARIZE

1 LECTURE ON 1 PAGE





FATS ~ ESSENTIAL PART of HEALTHY DIET

- * TASTE & TEXTURE of FOODS
- * **MAJOR** SOURCE of ENERGY
- * CRITICAL to CELLS & TISSUES
- * HELP ABSORB VITAMINS
- * CONVERTED to PROSTAGLANDINS

HELP CELLS COMMUNICATE









张小龙微信之夜演讲

张小龙 | 腾讯高级执行副总裁，微信事业群总裁

内容来源：笔记侠——张小龙4小时完整演讲笔记 制图：素味平生 (V: h15629731188)







Sign in | Register | EN

Mind Maps Videos Events Webinars Courses Images PRO Partners Pricing

Real-time Event Mind Mapping

Improve participation, engagement and outputs from your next meeting or event!

Overview

If you are organising an in-house workshop, large conference event, or interactive discussion forum, our live real-time mind mapping could help you increase attendee participation, interaction, and post-event engagement. We help event organisers to capture and visually display ideas and discussions as they unfold, providing a unique and interactive visual record for attendees, through the use of leading-edge mind mapping software.




What type of events do you support?

Biggerplate supports a range of events, from large public conferences, to smaller internal workshops and meetings.


Mapping is most relevant and beneficial for the following type of sessions:

- Interactive workshops
- Panel Discussions



THE HISTORY OF buildingSMART (IAI)

by Artem Boiko, 2021
bigdataconstruction.com





衔接 (Cohesion) 是指篇章中的某一语言成分需要依赖另一语言成分进行解释

衔接是一种语义关系，使得篇章各组成部分在语义上相互联系，关系紧凑。衔接也被作为语篇连贯性的必要条件之一，在语篇中体现为**词汇衔接**和**语法衔接**。

- **词汇衔接**包括重述 (Reiteration)、搭配 (Collocation) 等衔接手段。
- **语法衔接**包括照应 (Reference)、替代 (Substitution)、省略 (Ellipsis)、连接 (Conjunction) 等衔接手段。



重述关系是通过词的重复、同义词或近义词、反义词、上下位词等词汇手段形成的篇章衔接关系。

例如：

(1) 苏州园林 据说有一百多处，我到过的不过十多处。其他地方的园林我也到过一些。倘若要我
说说总的印象，我觉得苏州园林是我国各地园林的标本，各地园林或多或少都受到苏州园林
的影响。因此，谁如果要鉴赏我国的园林，苏州园林就不该错过。

(2) 那棵树立在那条路边上已经很久很久了。当那路还只是一条泥泞的小径时，它就立在那里；
当路上驶过第一辆汽车之前，它就立在那里；当这一带只有稀稀落落几处老式平房时，它就立
在那里



搭配关系是指词的共现关系，包括一个词组或者一个句子内部的词之间的组合关系，也包括句子间或段落间的词的习惯性共现。

例如：

有一天早上，撒了三次网，什么都没捞着，他很不高兴。第四次把网拉拢来的时候，他觉得太重了，简直拉不动。他就脱了衣服跳下水去，把网拖上岸来。打开网一看，发现网里有一个胆形的黄铜瓶，瓶口用锡封着，锡上盖着所罗门的印。



社交的吃饭种类虽然复杂，性质极其简单。把饭给自己有饭的人吃，那是请饭；自己有饭可吃而去吃人家的饭，那是赏面子。交际的微妙不外乎此。反过来说，把饭给没饭吃的人吃，那是施食，赏面子就一变而成丢脸。这便是慈善救济，算不上交际了。（钱钟书：《吃饭》）。

起衔接作用的词

- 饭
- 交际（社交）
- 面子（赏面子、丢脸）
- 施舍（施食、救济）
- 复杂（简单）

应用：

- 利用词汇链，可以获取文本的关键词集合；形成文本的摘要
- 在时序性报道中，还可以检测新话题，跟踪已出现的话题



照应是指篇章中一个语言成分与另一可以与之相互解释的成分之间的关系，即一个成分作为另一个成分的参照点。

例如：

那只最后从蛋壳里爬出来的小鸭是那么丑陋，他处处挨啄，被排挤，被讪笑，不仅在鸭群中是如此，连在鸡群中也是这样。

照应性 (Phoricity) 是语言交际过程中一个普遍现象，用来指代篇章中的实体、概念或事件。照应可以分为两种：外指 (Exophora) 和内指 (Endophora)。

- **外指照应**是指篇章中的某个成分的参照点不在篇章本身，而是在语境中
- **内指照应**是指语言成分的参照点在篇章上下文中



替代是指用替代形式来取代上文中的某一成分。

例如：

各式各样的球鞋像装在万花筒里，在她面前转开了：白色的，蓝色的，高筒的，矮帮的，白色带红边的，白色带蓝边的。

省略是指将语言结构中某个成分在句子中去除。虽然省略结构在语法层面不完整，但是并不是不可理解的，并且表达更加精炼。

例如：

雨是最寻常的，一下就是三两天。可别恼。看，雨像牛毛，雨像花针，雨像细丝，密密地斜织着，人家屋顶上全笼着一层薄烟。



连接是通过连接成分体现篇章中逻辑关系。从逻辑语义关系类型上，可以细分为三大类：详述（Elaboration）、延伸（Extension）和增强（Enhancement）。

- **详述**是对上文内容进一步说明、评论或解释，主要包括同位语和阐明两种情况。
- **延伸**是从正面或反面增加新的陈述，包括添加、转折、变换等类型。
- **增强**则是指补充额外必要信息，达到加强语义并使其更加完整，包括时空、方式、因果与条件、话题等条件。

例如：

不必说碧绿的菜畦，光滑的石井栏，高大的皂荚树，紫红的桑葚；也不必说鸣蝉在树叶里长吟，肥胖的黄蜂伏在菜花上，轻捷的叫天子(云雀)忽然从草间直窜向云霄里去了。单是周围的短短的泥墙根一带，就有无限趣味。



连贯 (Coherence) 是指篇章在语义、功能和心理上构成一个整体，围绕同一个主题或意图展开。**连贯性 (Coherent)** 是衡量篇章质量的重要指标，只有连贯的句子集合才能够形成篇章。这也是篇章与无关的、随机的句子集合区分开的最主要因素。

篇章应该同时具有**局部连贯性 (Local Coherent)** 和**整体连贯性 (Global Coherent)**。局部连贯性是在微观层面，篇章中前后相连的命题在语义上的联系。整体连贯性是在宏观层面，篇章中的所有命题与篇章主题之间的联系。

例如：

- (1) 他点了一份外卖。
- (2) 外卖很快就送到了。



除了现实世界中自然顺序的限制，话语序列的语义结构还受到人们普遍认知规律的制约。人们认识和描述客观世界时通常遵循从一般到特殊、从整体到局部、从大到小，从集合到子集的认知模式。

例如：

单是周围的短短的泥墙根一带，就有无限趣味。油蛉在这里低唱，蟋蟀们在这里弹琴。翻开断砖来，有时会遇见蜈蚣；还有斑蝥，倘若用手指按住它的脊梁，便会啪的一声，从后窍喷出一阵烟雾。

上例符合整体到局部的排列顺序，从对百草园的“无限趣味”开始，再以局部的细节展开，详细描写了由“油蛉”、“蟋蟀”、“斑蝥”所带来的乐趣。这样的顺序与人们一般的认知规律和感知顺序相符合，从而也就更容易让人接受。



局部连贯说明篇章中相邻句子存在联系，但是仅有局部连贯是不够的，篇章在整体上还需要围绕一个主题展开，既需要具有整体连贯性。整体连贯性对篇章中句子之间的联系施加宏观制约。

例如：

[1]于一个在北平住惯的人，像我，冬天要是不刮风，便觉得是奇迹；济南的冬天是没有风声的。对于一个刚由伦敦回来的人，像我，冬天要能看得见日光，便觉得是怪事；济南的冬天是响晴的。自然，在热带的地方，日光永远是那么毒，响亮的天气，反有点儿叫人害怕。可是，在北方的冬天，而能有温晴的天气，济南真得算个宝地。

[2]母亲还从来没有一次给过我这么多钱。我也从来没有向母亲一次要过这么多钱。我来到母亲工作的地方，呆呆地将那些母亲扫视一遍，却没有发现我的母亲。背直起来了，我的母亲。转过身来了，我的母亲。褐色的口罩上方，一对眼神疲惫的眼睛吃惊地望着我，我的母亲



篇章的连贯是一个复杂的现象，有些现象不能完全从语义角度解释话语序列的连贯性，还需要从语用角度以及认知角度进行讨论。

围绕语篇的连贯也有很多理论和方法，包括从关联理论角度对微观层面连贯性研究，利用**修辞结构理论**（Rhetorical Structure Theory）进行语篇连贯性研究，运用**图式理论**（Schema Theory）的连贯性研究，**基于语篇策略**（Discourse Strategy）的连贯性研究等。



篇章同时具有线性结构和等级结构。篇章中的句子按照一定的线性规则排列在一起，因此篇章是线性的。同时，句子的组合可以构成更大的语言单位，因此篇章又是具有等级结构的。

[1]著名苏联作家高尔基曾经说过：“书是人类进步的梯。” [2]书是一个知识的殿堂，是人类最好的精神食粮，也是人鸿鹄高翔的羽翼。

[3]“书中自有黄金屋。”书本中的知识是无穷无尽的，读书是为了更好地获取更多知识，开阔自己的视野，帮助自己创造，实现自己的人生目标。[4]战国时期，苏秦去秦国以连横说进行游说，多次给秦惠王上书也未被采纳。[5]回到家中，父母妻嫂都不理睬他，于是他就找出许多书籍发奋研读。终于以合纵之策而身佩六国相印。

句子 [1][2] 组成了引论，句子 [3] 给出了第一个论点，句子 [4]-[5] 是论据



篇章超级结构 (Superstructure) 是采用规约化图式结构来表示篇章宏观内容组织形式的一种形式结构。只涉及篇章内容的组织方法，与篇章所表达的具体内容没有直接关系。不同类型的语篇往往具有不同的超级结构。




图 5.1 新闻篇章超级结构示例^[223]

篇章超级结构提供了组织相关类型语篇的基础纲要和架构。在具体的篇章中，结构也具有一定的灵活性，并不是所有的结构成分都要存在，结构成分的位置也是不固定的。




修辞结构理论 (Rhetorical Structure Theory, RST) 是Mann和Thompson于1987年提出的一种通过描述篇章各个组成部分之间的修辞关系来分析篇章结构的理论。

修辞结构理论将修辞关系定义在两个或多个文本单元 (Text Span) 之间。文本单元又称**基本篇章单元 (Elementary Discourse Unit, EDU)**，有两种主要类型：核心 (Nucleus) 和辅助 (Satellite)。

- **核心单元**是篇章中最重要的部分，表达作者的核心意图，并且具有相对完整的语义，能够独立解释。
- **辅助单元**则较少表达作者的核心意图，用于传达支撑其他信息，补充说明核心单元，通常只有在与核心单元关联时才能够被解释。

例如：[1]这个草莓真的好吃，[2]我吃了一大盆。





篇章中的修辞关系主要包括两种类型：（1）**不对称性的核心-辅助关系**（Nucleus-Satellite Relation），也称单核关系；（2）**无主次之分的多核心关系**（Multinuclear Relation）。




图 5.3 修辞结构理论中关系图示类型

环境 (Circumstance) 关系是单核心关系，弧线箭头指向核心单元。对比 (Contrast) 关系总是两个核心单元。序列 (Sequence) 关系则可以具有多个连续的单元，相邻的两个单元之间构成序列关系。联合 (Joint) 关系也可以具有多个单元，这些单元一起构成该关系。



篇章的修辞结构在总体上表现为等级结构，连贯的篇章可以由不同层次的修辞关系组织成层次结构，从而形成一个修辞关系树。





图 5.4 修辞结构关系树样例



修辞关系举例

- (1) 百合属拥有很广阔的分布区,
- (2) 在旧大陆上遍及欧洲多数地区、地中海盆地北部、亚洲大部分地区,
- (3) 而在新大陆的分布区则包括加拿大南部和美国全境等。

修辞结构树表示



- 句(2)与句(3)构成列表(list)的修辞关系,然后句(2)与句(3)合起来与句(1)形成详述(elaboration)关系。
- 其中详述关系的核心为句(1),用竖线作标志,卫星为句(2)和句(3),而列表关系属于多核心修辞关系,没有主次之分。



语篇模式 (Textual Pattern) 是指人们长期积累并根据经验形成的一些程式化的语篇组织形式或策略。

- 语篇模式是在一定的文化中形成的，因此往往带有不同文化积淀的内涵和文化规约性。
- 语言学家总结出了“问题-解决” (Problem-Solution)、 “概括-具体” (General-Specific) 等英语中常见的语篇模式。
- 语篇模式与小句关系之间存在着密切的联系，小句通过组合形成逻辑序列关系或匹配关系，通过这些关系小句又组合为更大的语篇单位。
- 语篇模式与具体的**篇章内容通常没有直接的联系**，但是每种语篇模式通常都具有特定的词汇标记。



[1]长征五号遥三运载火箭27日晚在海南文昌一飞冲天，将实践二十号卫星成功送入太空预定轨道。[2]“胖五”也以实际行动，诠释着中国俗语所说“哪里跌倒，就要从哪里爬起来”的坚持与坚韧。[3]2017年7月长征五号遥二火箭因发动机故障发射失利。[4]科研人员历经两年多的艰苦攻关、连续奋战，进行大量地面试验，完成遥二失利故障归零和遥三火箭各项工作，还采取一系列改进优化措施，切实提升火箭飞行任务可靠性。[5]长征五号遥三火箭在此背景下成功发射，对研制团队直面挑战、发现问题、解决问题的心理能力建设也是一次巨大考验，也为航天人才特别是青年人才树立起不怕失败、敢于挑战、勇于拼搏的榜样力量。

情景（句 [1]、句 [2]）



问题（句 [3]）



反应（句 [4]）



评价（句 [5]）

语篇模式示例

本章主要内容

5.1

篇章理论概述

5.2

话语分割

5.2.1 基于词汇句法树的统计话语分割

5.2.2 基于循环神经网络的话语分割

5.3

篇章结构分析

5.4

指代消解



根据修辞结构理论，篇章修辞关系定义在两个或多个基本篇章单元（EDU）之间。

话语分割（Discourse Segmentation）的目标就是将篇章分割为基本篇章单元，从而实现后续的篇章分析任务。

话语分割任务通常被形式化为序列标注任务或者单词级别的**二分类任务**，对每个单词位置输出预测其是否为一个基本篇章单元的**边界**。

输入：“The bank also says it will use its network to channel the investments”





图 5.6 话语分割样例



SynDS算法采用基于句法树的统计模型估计句子中每个词作为分界点的概率。

给定句子 $s = w_1 \ w_2 \ \dots \ w_n$ ，首先使用句法分析工具得到该句子的句法树 t ，随后对句子中的每个词 w_i ，使用最大似然估计的方法学习其作为分界点的概率 $P(b_i \mid w_i)$ ，其中 $b_i \in \{0, 1\}$ 。0表示为非边界，1表示为边界。

为了同时使用词汇及句法特征估计基本篇章单元分界，SynDS算法使用了词汇中心 (Lexical Head) 映射规则，将词汇成分引入句法树。对于每个词 w 来说，SynDS算法关注其**包含右兄弟节点的最高父节点**，使用其构建的特征决定当前词是否作为分界词。



判断词 “says” 是否为分界词时，使用该词本身对应的节点 $N_w = \text{VBZ (says)}$ 、其父节点 $N_p = \text{VP(says)}$ 及其右兄弟节点 $N_r = \text{SBAR (will)}$ 作为特征。

使用RST-DT语料的统计量估计每个词作为分界词的似然概率：

$$P(b|w, t) \simeq \frac{\text{Cnt}(N_p \rightarrow \dots N_w \uparrow N_r \dots)}{\text{Cnt}(N_p \rightarrow \dots N_w N_r \dots)}$$


图 5.7 基于词汇句法树的统计话语分割样例



输入句子:

"学生们在图书馆里认真学习，而老师则在办公室里批改作业。"


步骤1: 句法分析



步骤2: 特征提取

词	词性	树深度	依存关系	子树差异
而	连词	2	并列连接	大
,	标点	1	标点	大
学习	动词	1	谓语	中
其他词...	...	...	...	...

步骤3: 概率计算



步骤4-5: 分界点识别与句子分割

最终分割结果:

"学生们在图书馆里认真学习"


+

"而老师则在办公室里批改作业"

5.2.2 基于循环神经网络的话语分割



话语分割任务还可以转换为序列标注问题，给定一个输入句子，其输出中每个 y_t 表示第 t 个词是否为一个基本单元的开头，如果是，则 $y_t=1$ ，否则 $y_t=0$ 。可以采用基于BiLSTM-CRF模型实现这一任务。



本章主要内容

5.1

篇章理论概述

5.2

话语分割

5.3

篇章结构分析

5.3.1 修辞结构篇章分析

5.3.2 浅层篇章分析

5.4

指代消解



篇章结构分析的目标是分析篇章单元之间存在的连贯关系，从而服务于下游任务。

现有的篇章分析工作基于不同的篇章分析标注框架，主要可以分为两大类：**基于词汇的浅层篇章分析及基于语义或意图关系的完整篇章分析**。

- 浅层篇章分析代表是Penn Discourse Treebank (PDTB) 标注框架
- 完整篇章分析代表是RST Discourse TreeBank (RST-DT) 标注框架



RST-DT是篇章分析中的代表性标注框架，其标注基于修辞结构理论，将一个完整的篇章标注成由基本篇章单元组成的**层次树状结构**。其中，树的节点关系由相邻篇章单元之间的关系构成。在标注时，一个完整的篇章首先被切分成不相交的基本篇章单元（EDU）。在此基础上，根据修辞关系理论，将相邻的基本篇章单元连接，并标注为**78种**修辞关系的一种。




图 5.9 RST-DT 标注样例



Penn Discourse Treebank (PDTB) 是基于词汇化树型连接语法 (Discourse Lexical Tree Adjunct Grammar, D-LTAG) 理论构建的篇章分析标注框架，是篇章分析中的另一代表性框架。PDTB以篇章内**相邻或者跨度在一定范围内的片段**，以连接词为核心，对片段间关系进行标注。

相较于修辞结构理论将整个篇章构建为树结构而言，**PDTB则针对两个片段之间的关系**，因此也可以称为浅层篇章分析。

每个篇章关系由两个论据 (Argument) 及其之间的关系组成，两个论据分别标注为Arg1和Arg2。在相邻句子构成的关系中，Arg1和Arg2则反映论据之间的线性顺序，其中Arg1在Arg2之前。

根据连接词是否显式存在，PDTB标注的关系可分为**显式篇章关系**和**隐式篇章关系**两类。



显式篇章关系 (Explicit Discourse Relation) 由显式连接词定义，通过显式连接词连接Arg1和Arg2。在显式关系中，Arg2一般为句法上关联的论据，Arg1则为另一个论据，显式连接词由三种语法连接词产生：


- 从属连词，如because, when等
- 并列连词，如and, or等
- 语篇副词，如for example, instead等

*Third-quarter sales in Europe were exceptionally strong, boosted by promotional programs and new products –although **weaker foreign currencies reduced the company's earnings.***

*Most oil companies, when **they set exploration and production budgets for this year,** oreicast revenue of \$15 for each barrel of crude produced.*



CDTB对篇章语义关系的分类



李艳翠, 孙静, and 周国栋. "汉语篇章连接词识别与分类." 北京大学学报 (自然科学版) 2 (2015): 307-314.



隐式篇章关系 (Implicit Discourse Relation) 则是除显式篇章关系以外，需要靠读者通过推断判断的篇章关系

But a few funds have taken other defensive steps. *Some have raised their cash positions to record levels.* Implicit = BECAUSE **High cash positions help buffer a fund when the market falls.**


虽然没有显式连接词，但读者能够通过论据之间的语义判断出其之间表达的因果关系。在PDTB中，这样的隐式关系通常通过标注者插入一个连接词进行标注（例如上面例子中的BECAUSE被插入以表示因果关系）。

而当隐式关系无法使用一个隐式连接词进行标注时，则构成三种特殊的隐式关系：

- **AltLex**表示语篇关系已经由非连接词的词汇表达，额外插入连接词会构成冗余的情况
- **EntRel**表示句子之间只存在基于实体的连贯关系的情况
- **NoRel**表示句子之间不存在任何篇章关系或基于实体的连贯关系的情况



由于一个连接词在不同的篇章中可能表达不同的语义关系，PDTB中为显式关系、隐式关系和AltLex关系提供了三级语义标注（Sense Tag）：CLASS, TYPE, SUBTYPE





由于部分显式连接词在**不同语境下具有不同语义**，显式篇章分析的重点在于对显式连接词进行消歧，并将每一连接词分类为PDTB标注的四个一级语义类别（TEMPORAL、CONTINGENCY、COMPARISON、EXPANSION）

例如：下述两个包含since的句子

- (1) Guangzhou has a wide water area with many rivers and water systems since it is located in the water-rich area of southern China.
- (2) She has been living in since she graduated from Fudan University.

显式连接词“Since”在句子(1)中表示因果关系，属于CONTINGENCY语义类别；在句子(2)中则是TEMPORAL语义类别

本章主要内容

5.1

篇章理论概述

5.2

话语分割

5.3

篇章结构分析

5.4

指代消解

5.4.1 基于表述对的指代消解

5.4.2 基于表述排序的指代消解

5.4.3 基于实体的指代消解



■ 关于指代

✧ 假设有这样一组句子：

张三一大早就赶到了学校。张三先到食堂吃早餐，然后张三到张三的宿舍拿张三自己的教材和张三自己的笔记本。当张三匆忙来到教室时，张三发现张三的课本拿错了。

✧ 设想修改为这样表达：

张三一大早就赶到了学校。他先到食堂吃早餐，然后[X]到[X]宿舍拿自己的教材和[X]笔记本。当[X]匆忙来到教室时，他发现[X]课本拿错了。

✧ 哪一种表达更符合人们的习惯？

✧ 语言的表达追求“经济”与“变化”

✧ 不妨将指代、省略、替换都看称广义“指代”



■ 关于指代

✧ 假设有这样一组句子：

张三一大早就赶到了学校。张三先到食堂吃早餐，然后张三到张三的宿舍拿张三自己的教材和张三自己的笔记本。当张三匆忙来到教室时，张三发现张三的课本拿错了。

✧ 设想修改为这样表达：

张三一大早就赶到了学校。他先到食堂吃早餐，然后[X]到[X]宿舍拿自己的教材和[X]笔记本。当[X]匆忙来到教室时，他发现[X]课本拿错了。

✧ 哪一种表达更符合人们的习惯？

✧ 语言的表达追求“经济”与“变化”

✧ 不妨将指代、省略、替换都看称广义“指代”





■ 指代的五个概念

- ✧ **Anaphor: 指代语**。当语篇中提到某个实体后，再一次提及时，常用一种简洁的形式表示（如代词“他”），这一简洁的形式称为指代语
- ✧ **Entity (referent): 实体(指称对象)**。实际存在或传说存在（如，孙悟空）的对象，主要包括，人、机构、地方等
- ✧ **Reference: 指称**。用于指称实体的语言表示
- ✧ **Antecedent: 先行语**。语篇中引入的一个相对明确的指称意义的表述（如张三）
- ✧ **Coreference: 共指（同指）**。当两种表述均指称相同对象（实体）时，这两种表述具有共指关系



■ 指代举例



我姐送我她的猫。
我很喜欢它。



■ 指代举例

厨师 戴维·郭 在 加利福尼亚州 西科维纳 长大，小时候 他 和 兄弟们 常 在 自家 后院 一个 车库 改建 的 房间里 打电动。房 外 就是 祖母 的 菜园子，里面 种 着 丝瓜、韭菜、地瓜 叶 和 其他 台湾人 喜欢 吃 的 菜。但 郭 先生 的 父亲 经常 很 晚 才 下班，他 会 买 上 一 大 袋 教堂 炸鸡 带 回家，他们 一边 打电动，一边 啃 炸鸡。美国 的 炸鸡 有 骨头，与 郭 先生 去 台湾 探亲 时 在 路边摊 看到 的 不同。台湾 的 炸鸡 不 带 骨头，比如 上边 撒 着 炸 罗勒叶 的 盐 酥鸡，还有 将 无 骨 鸡 胸肉 拍 平 后 炸 的 大 鸡排。台湾 的 炸鸡 通常 先 用 酱油、米酒、大蒜 和 五香粉 等 佐料 稍 作 腌制，挂 上 地瓜 粉 后 油炸，最后 撒上 白 胡椒粉，台湾 炸鸡 通常 装 在 纸袋 里 卖，不 加 任何 酱汁，易 于 边 走 边 吃。郭 先生 在 洛杉矶 开 的 Little Fatty 餐厅 菜单 上 的 禽肉，给 人 以 一 种 即 熟悉 又 特别 的 感觉。郭 先生 做 的 盐 酥 鹌鹑，结 合 了 他 的 台湾 根源、他 的 美国 童年，以 及 他 的 高级 餐厅 背景，带 骨 的 炸 鹌鹑 上 点 缀 着 炸 罗勒叶，用 辛辣 的 蛋黄酱 蘸 着 吃。“很 明显，这 道 菜 是 台湾 美食 的 象征，但 对 我 来说，它 唤 起 记 忆，”郭 先生 说。“坐 在 电视机 前 吃 有 骨头 的 东西 是 最 有 趣 的 事情。”郭 先生 是 新 一 代 台商 美国 厨师 的 一 员，他 们 正 在 用 自 己 的 成 长 经 历 和 口 味 来 改 造 台湾 夜市 上 的 这 种 标 配 食 品，他 们 把 台湾 炸鸡 塞 进 三明治 和 馒头 里，放 在 白 面包 切片 上，配 上 泡菜，浇 上 酱汁，认 证 美国 的 地 区 特 色 和 他 们 生 活 经 历 的 独 特 性。



■ 指代与共指

✧ **指代(Anaphora)关系**: 强调指代语与另一个表述之间的关系。指代语的指称对象通常不明确, 需要确定其与先行语之间的关系来解释指代语的语义;

- 张先生走过来, 给大家看他**他**的新作品

✧ **共指(coreference)**: 强调一个表述与另一个表述是否指向相同的实体;

- 现任美国总统 与 特朗普

■ 两者的目标

✧ **指代消解**: 寻找指代语对应的先行语

✧ **共指消解**: 发现指向相同实体的语言表示单元 (包括多语篇)



■ 六类指称表示

1. Indefinite NPs (无定名词) : 一辆汽车
2. Definite NPs (有定名词) : 那个人
3. Pronouns (人称代词) : 它, 他
4. Demonstratives (指示代词) : 这, 那
5. One-anaphora (one指代) : one (in English)
6. Zero anaphora (0型指代) : 省略



■ 六类指称表示

1. Indefinite NPs (**无定名词**)

- ◆ 为读者引入一个新的实体时常用无定形式
- ◆ 引入的实体，可能的确存在（明确的），也可能不明确
- ◆ 两个例子：
 - ◆ 张先生娶了**一位法国太太** (Specific)
 - ◆ 史密斯想娶**一位中国姑娘** (non-specific)



■ 六类指称表示

2. Definite NPs (**有定名词**)

- ◆ 无论读者知道否，一定存在

- ◆ 首位进入太空的**宇航员**（即，前苏联宇航员尤里.加加林）；（通过某些知识可以知道）
- ◆ Look, how beautiful **the girl** is! (实际存在)
- ◆ 为了消除小兵兵对生人的陌生感，两位女记者带着**这个小男孩**逛街...(在上下文中)

最后一种情况需要指代消解

- ◆ 特点：定冠词（这/那）引导的名词短语



■ 六类指称表示

3. Pronouns (**人称代词**) : 它, 他

4. Demonstratives (**指示代词**)

- ◆ 典型的指示代词包括: 那, 这,...
- ◆ 当指示代词与后面的名词(短语)连用时, 此时变为了定冠词, 形成**有定**表示
- ◆ Eg: 刘博士刚买了一套房子, **那**是一套性价比相当好的房子



■ 六类指称表示

5. One-anaphora (**one指代, 替换**)

- ◆ 出现在英语中
- ◆ 表示某集合中的一个元素
 - He had a BMW before, now he got another **one**.
 - John has two BMWs, but I have only **one**.

朋友陈把手一拍，我们便看见一只大鸟飞过去，接着又看见**第二只**，**第三只**。我们继续拍掌。很快这个树林变得热闹了。到处都是鸟声，到处都是鸟影。**大的**，**小的**，**花的**，**黑的**，**有的**站在树上叫，**有的**飞起来，**有的**在扑翅膀（巴金：《鸟的天堂》）



■ 六类指称表示

6. Zero anaphora (**0型指代，省略**)

- ◆ 英语中的零指代很少见，但汉语中十分常见
 - 他们说[X]今天来帮我们修[X]房子
 - 他们说**他们**今天来帮我们修**我们的**房子（很少这样说）
- ◆ 需要在句子层面上判断哪些必须的成分省略了
 - (1) 美国宣布 (X) 部分取消 (X) 对朝鲜长达近半个世纪的经济制裁。
 - (2) **李向阳**机智地**组织游击队攻城并烧毁了敌人的粮库**，**(?)**迫使松井撤出了李庄。
 - (3) 我自来是**如此**，(X)从会吃饮食时便吃药，(X)到今未断。(X)请了多少名医，(X)修方配药，(X)皆不见效。



■ 以衔接为基础的篇章分析

✧ 分析单元

- 通常情况下是词
- 有时也可以是短语（或 term）

✧ 建立词汇之间的关系

- 形成词汇链（或词汇集合）

✧ 词汇链的形式定义

- 设文本T可以表示为词的集合 $T=\{w_1, w_2, \dots, w_n\}$ (有相同元素)
- 设衔接关系为 R，则 R 将 T 划分为：
 - $CL_1=\{w_{11}, w_{12}, \dots, w_{1m_1}\}$, $CL_2=\{w_{21}, w_{22}, \dots, w_{2m_2}\}, \dots$ 其中，对任意的 $w_{kp}, w_{kq} \in CL_k$ ，都有 $(w_{kp}, w_{kq}) \in R$
 - R可以看成为广义“等价”关系



■ 如何建立衔接关系

✧ 分析五种关系

- Reference (指代)
- Substitution (替换: 发现替换关系)
- Ellipsis (省略: 找回省略部分)
- **Conjunction (连接, 主要在连贯分析中使)**
- Lexical cohesion (词汇衔接)
 - 重复 (词的形式判断)
 - 近义+反义 (借助于词典)
 - 上下位义+整体部分义 (借助于词典)
 - 搭配 (词典+统计方法)



■ 指代消解方法

✧ 基于中心理论的指代消解

✧ 基于语言知识的指代消解

■ 过滤原则：

- 性别、单复数和人称的一致性规则；

■ 优选原则

- 距离近优先
- 句法、语义平行优先

■ 例子

- A 喜欢与 B 闲聊，**他**也喜欢与C闲聊
- A 喜欢与**B** 闲聊，C 也喜欢与**他**闲聊



■ 指代消解方法

✧ 基于机器学习的指代消解

■ 利用机器学习方法建立分类器

■ 方法

- 选取对共指消解产生影响的特征，主要包括：
- 两者的距离, 字符的匹配程度, 单复数一致性, 性别一致性, 语义类的一致性, 是否是别称....

[聂/nr 卫平/nr] 今天/t 取胜/v 不易/a 。/w 布局/vn 阶段/n 便/d 与/p
[实力派/n 人物/n] [刘/nr 小光/nr] 九/m 段/q 展开/v 激战/vn ，/w 棋
局/n 跌宕起伏/l ，/w 互/d 有/v 优劣/n 。/w 直到/v 官子/vn 阶段
/n ，/w [聂/nr 卫平/nr] 才/d 因/c [对手/n] 的/u 缓/a 手/n 而/c
最终/d 取胜/v 。/w

[对手/n] => [聂/nr 卫平/nr] 属于一类吗 ？

[对手/n] => [刘/nr 小光/nr] 属于一类吗 ？



指代消解任务通常关注两种指代类型：共指（Coreference）和回指（Anaphora）。**共指**表示两个表述指向真实世界中的同一实体。**回指**表示当前表述指向上文出现的另一表述。

指代上文的表述称为**照应词（Anaphor）**，将照应词指代的上文表述称为**先行词（Antecedent）**

例如：上海的卖腌腊的店铺里也卖咸鸭蛋，必用纸条特别标明：“高邮咸蛋”。

“咸鸭蛋”和“咸蛋”指代真实世界中的统一实体，因此为共指关系

例如：我围抱着火炉，烤热漫长一生的**一个时刻**。我知道**这一时刻**之外，我其余的岁月，我的亲人们的岁月，远在屋外的大雪中，被寒风吹彻。



“这一时刻”指代上文的“一个时刻”，为回指关系。其中“这一时刻”为照应词，“一个时刻”为先行词



指代消解任务将语篇中所有表示同一实体的指代分配到同一等价类中，并给出每一语篇中的所有等价类。

例如：其间有一个十一二岁的少年[1]，项带银圈，手捏一柄钢叉，向一匹獐[2]用力地刺去。那獐[2]却将身一扭，反从他[1]的胯下逃走了。

“一个十一二岁的少年”和“他”指代同一实体，属于同一等价类；

“一匹獐”和“那獐”指代同一实体，属于同一等价类。

指代消解任务的目标是发现文中的等价类[1]和[2]。



指代消解任务一般可分为两个步骤：**表述发现**（Mention Detection）和**指代消解**（Coreference Resolution）。

表述发现也称提及发现，旨在找出句子中所有可能存在指代关系的名词表述，一般包含人称代词（“你”、“我”、“他”等）、命名实体（人名、地名等）及一些名词短语（“那只猫”、“右边的女士”）等。


指代消解旨在对表述同一实体的表述聚合在一起，是这一任务的核心，也是最具挑战的步骤。



基于表述对的指代消解算法是将该任务**转换为二分类问题**，分别对每个表述与其所有先行词所构成的表述对是否构成指代关系进行分类。

例如：长妈妈，已经说过，是一个一向带领着我的女工，说得阔气一点，就是我的保姆。我的母亲和许多别的人都这样称呼她，似乎略带些客气的意思。

对于所选表述“她”，基于表述对的指代消解算法需要分别计算“她”和其所有先行词构成的表述对是否为指代关系进行分类。



代消解算法目标就是对上述所有表对是否为指代关系进行正确分类



基于一个训练得到的用于表述对分类的二分类器，对每个测试文本的指代消解推理可以视为一个**构造消解图（Coreference Graph）的过程**（也可视为聚类过程）：每个表述为图中的一个节点，当分类器预测一个对表述之间有指代关系时，则为这两个节点之间添加一条有向边。

根据上述方式构成的图，能够表示每两个表述之间是否互为指代。同时通过所有连接构成的传递闭包（Transitive Closure），我们能够找出所有等价类。

对于该先行词的选择策略，**基于最近原则（Closest-First）的算法**从后向前依次计算所有先行词与该表述构成的表述对为指代关系的分数，并**选择第一个大于阈值的先行词**。而**基于最优原则（Best-First）的算法**则计算所有先行词与该表述构成的表述对为指代关系的分数，并**选出分数最高的先行词进行连接**。



文献[244]提出了基于多类特征及感知器分类的表述对指代消解系统Feature-pair。

其构造的特征主要包括两个方面：表述特征及表述对特征

表述特征包括表述类型特征，例如其是否为专有名词（Proper Noun）、普通名词（Common Noun）或代词（Pronoun）等

表述对特征包括表述对的字符串关系特征（如一个字符串是否为另一个的子串）、语义相符性特征（例如性别、数字是否相符）、相对位置特征、实体类别特征等。



- **表述类型特征**：表述所属的类型，为专有名词（Proper Noun）、普通名词（Common Noun）或代词（Pronoun）。
- **字符串关系特征**：两个字符串之间是否存在一些共有特征，例如一个字符串是另一个字符串的子串等。
- **语义特征**：包括两个名词之间的性别是否相符、数字是否相符；两个名词是否为近义词、反义词、或上位词等。
- **相对位置特征**：两个表述之间的位置关系，例如将距离转化为二元特征（ $[\text{distance} \leq i]$ ， i 包括所有间隔值）、两个表述是否属于同一个句子等。
- **可学习特征**：基于可学习分类器得到的特征，例如使用分类器判断两个由同一修饰语修饰的表述，其修饰语之间是否存在指代关系。
- **修饰语对齐特征**：两个上位词相同的修饰语之间存在的关系，例如是否为子串、近义词、反义词等。
- **记忆特征**：选取一些常常构成指代关系的表述对构造特征（例如“the queen”和“Elizabeth II”），供模型记忆学习。
- **预测实体类别特征**：基于模版匹配预测实体所属的实体类别（人名、地名、机构名等），并基于预测类别构造两个表述之间实体类别是否匹配或是否相交等特征。



基于上述构造的特征，**Feature-pair**算法使用感知器对每一指代对是否构成指代关系进行分类。训练时，Feature-pair基于最近原则，选择当前表述m与其所指代的距离最近的先行词a所构成的表述对(a,m)作为正样本；选取在m之前所有和m不属于同一等价类的表述作为负样本。测试时，**Feature-pair**基于最优原则，每次选择与m构成分数最高的表述对的先行词：

$$a = \arg \max_{b \in B_m} (\text{PC}(b, m))$$

其中 $\text{PC}(\cdot)$ 为表述对分数计算函数，当 $\text{PC}(a, m)$ 大于某一预定义阈值时，则将 a 和 m 链接为同一等价类



基于表述对的指代消解基于二分类器分别对每个先行词和当前指代构成的表述对进行预测。这种做法对于不同先行词的预测是相互独立的，只能判断每个先行词相对当前指代的合理程度，**而无法直接通过比较判断哪个先行词是最正确的**

基于表述排序的指代消解算法的基本思路是使用一个多分类器，基于多个先行词候选计算出分数最高的先行词。




图 5.15 基于表述排序的指代消解示例

5.4.2 基于表述排序的指代消解--基于特征工程和最大熵分类器的表述排序指代消解

基于表述排序的指代消解算法RK将指代消解任务从基于指代对二分类器的多步推理（先分别计算各指代对的分数，再基于某种策略选出最高分的先行词），转化为**同时计算并比较所有先行词候选的单步推理过程**。

对每个先行词候选 α_i ，模型计算其为当前照应词 π 的先行词的条件概率 $\text{Pr}(\alpha_i | \pi)$ ，从而对于每个照应词 π ，通过比较多个候选先行词的条件概率即可以选出最可能和 π 构成指代关系的先行词：

$$P_r(\alpha_i | \pi) = \frac{\exp(\sum_{i=1}^n \lambda_i f_i(\pi, \alpha_i))}{\sum_k \exp(\sum_{i=1}^n \lambda_i f_i(\pi, \alpha_k))}$$

在测试时，考虑到大部分指代为局部指代，并为了节约测试时间，RK算法只选取照应词 π 所在的句子及所在句之前的3个句子内的表述作为候选。

5.4.2 基于表述排序的指代消解--基于特征工程和最大熵分类器的表述排序指代消解

RK算法通过最大熵分类器建模这一条件概率，其使用的特征包含三个类别：

- (1) **照应词特征**，描述待分类表述的特征，包括其代词类型特征、大小写特征等；
- (2) **候选先行词特征**，描述候选先行词的特征，包括其词性特征、其左右相关词的词性特征等；
- (3) **关系特征**，描述两个表述之间关系的特征，包括两个词之间的距离、两个词的语义相符性特征等。

表 5.1 RK 算法使用的部分特征^[248]

代词特征	
PERS_PRO	如果 π 是人称代词则为 T，否则为 F
POSS_PRO	如果 π 是所有格代名词则为 T，否则为 F
THIRD_PERS_PRO	如果 π 是第三人称代词则为 T，否则为 F
SPEECH_PRO	T 如果 π 是第一或第二人称代词则为 T，否则为 F
PRO_FORM	T 如果 π 是小写字母组成的代词则为 T，否则为 F
候选先行词特征	
ANTE_WD_LEN	α 中单词的数量
PRON_ANTE	如果 α 是代词则为 T，否则为 F
PN_ANTE	如果 α 是专有名词则为 T，否则为 F
INDEF_ANTE	如果 α 是无定名词短语 (indefinite NP) 则为 T，否则为 F
DEF_ANTE	如果 α 是有定名词短语 (definite NP) 则为 T，否则为 F
关系特征	
S_DIST	π 和 α 之间句子数量的分桶值 (Binned values)
NP_DIST	π 和 α 之间表述 (Mention) 数量的分桶值
NUM_AGR	如果 π 和 α 在单复数形式上符合则为 T，否则为 F 如果 π 或者 α 的单数复数形式不能确定则为 UNK
GEN_AGR	如果 π 和 α 性别一致则为 T，否则为 F 如果 π 或者 α 的性别不能确定则为 UNK



基于表述对和基于表述排序的两种指代消解算法旨在将一个表述与其所指代的一个表述相对应，通常只关注局部的指代信息。**基于实体的指代消解**则认为将单个表述归类至其指代的实体（通常对应一个表述的等价类）**能利用实体级别的全局信息**，因此能更好地实现指代消解任务。

基于实体的指代消解和基于表述的指代消解算法相似，区别在于基于表述的方法将当前表述分配到一个先行的表述，**而基于实体的方法将当前表述分配到先行的实体（表述等价类）上。**

本章小结

在本章中，我们介绍了话语分割、篇章结构分析和指代消解三个篇章分析任务。其中，话语分割和篇章结构分析帮助我们理解和分析篇章的结构，指代消解任务则帮助我们理解篇章的衔接，这些任务同时也直接影响许多下游自然语言处理应用。近年来，随着神经网络的发展，话语分割任务已经能够取得接近人类的准确率，因此研究人员更多地将注意力转移到基于话语分割的篇章结构分析任务。而指代消解作为自然语言处理中另一重要任务，也长期受到研究人员的关注。