

中山大學 人工智能學院
SUN YAT-SEN UNIVERSITY SCHOOL ARTIFICIAL INTELLIGENCE

「自然语言处理」

第 7 章 信息抽取

赵宝全

中山大学人工智能学院

2026年春季学期

本章主要内容

7.1

信息抽取概述

7.2

命名实体识别

7.3

关系抽取

7.4

事件抽取



本章主要内容

7.1	信息抽取概述
7.2	命名实体识别
7.3	关系抽取
7.4	事件抽取



严重的信息过载迫切需要一些自动化的工具对大量无结构的文本内容及时准确地进行抽取、过滤、归类和组织，帮助人们在海量内容中迅速找到真正需要的信息

Total number of active device connections worldwide



科学数据



金融数据



零售数据




社交网络数据




交通数据




物联网数据



结构化数据
(如SQL文件)



非结构化数据
(如音视频文件)




半结构化数据
(如邮件)

世界上75%~80%的数据都是非结构化的



信息抽取 (Information Extraction, IE) 的目标不是构建通用的句子或者篇章理解方法，而是针对特定的需求，从自然语言构成的**非结构化文本**中抽取指定类型的**实体、关系、事件**等信息，进而形成结构化数据



事件类型	发布会
时间	北京时间9月13日
公司	苹果公司
地点	史蒂夫·乔布斯剧院
人员	蒂姆·库克
产品	Iphone13、Apple TV
实体关系	苹果公司，蒂姆·库克，CEO



信息抽取包含:

- **命名实体识别 (Named Entity Recognition, NER) :**
 - 通常包括人员, 地点和组织, 但也包括从基因和蛋白质名称到大学课程名称的一些更具具体实体
- **关系抽取 (Relation Extraction, RE) :**
 - 查找和分类文本实体之间的语义关系, 通常是配偶, 子女, 就业, 从属和地理空间上的位置关系等二元关系
- **事件抽取 (Event Extraction) :**
 - 查找这些实体参与的事件, 例如, 美国两家航空公司的票价增加以及报告事件所述和引用的事件



信息抽取包含:

- **时间表达式识别 (Temporal Expression) :**
 - 例如星期几（星期五和星期四）、月份、节假日等 —— 以及相对表达式如现在或明年的两天以及3:30 PM 或中午。将这些时间表达映射到特定的日历日期或一天中的时间来及时定位事件
- **实体归一化 (Entity Normalization)**
 - 文本中提到的所有指代同一实体的字符串都映射到同一个标准形式的过程
- **话题检测与跟踪 (Topic Detection and Tracking, TDT)**



信息抽取包含:

- 模板填充 (Template Filling)

Citing high fuel prices, United Airlines said Friday it has increased fares by \$6 per round trip on flights to some cities also served by lowercost carriers. American Airlines, a unit of AMR Corp., immediately matched the move, spokesman Tim Wagner said. United, a unit of UAL Corp., said the increase took effect Thursday and applies to most routes where it competes against discount carriers, such as Chicago to Dallas and Denver to San Francisco.

可以提取价格为6美元，星期四为提高价格的日期，美国航空是随后提价的航空公司，从而形成如下所示的实用模板

FARE-RAISE ATTEMPT:	LEAD AIRLINE:	UNITED AIRLINES
	AMOUNT:	\$6
	EFFECTIVE DATE:	2006-10-26
	FOLLOWER:	AMERICAN AIRLINES



信息抽取的应用广泛，在阅读理解、机器翻译、知识图谱等任务中都发挥着非常基础和重要的作用

地址识别

快递单信息抽取 (AI +)

联系人信息

真实姓名 电话 - 分机号

城市 / 区域

详细地址 (例如: **街**号**)

公司名称 (选项)

语音识别

说出姓名、电话和详细地址

说完了

Step1: 语音识别

联系人信息

张三 18625584663

广东省 深圳市 南山区

百度国际大厦

公司名称 (选项)

☒ 设为默认收件地址 清空当前信息

张三18625584663广东省深圳市南山区百度国际大厦

图片识别 清空 识别

如何使用智能填写? 查看帮助 >

Step2: 信息抽取

“张三 15209XX1921
广东省深圳市南山区百度国际大厦”

抽取实体和实体标识	抽取结果
姓名 P	张三
电话 T	152099XX921
省 A1	广东省
市 A2	深圳市
区 A3	南山区
详细地址 A4	百度国际大厦

张三	18625584663	广东省	深圳市	南山区	百度国际大厦
P	T	A1	A2	A3	A4

标签	定义
P-B	姓名起始位置
P-I	姓名中间位置或结束位置
T-B	电话起始位置
T-I	电话中间位置或结束位置
A1-B	省份起始位置
A1-I	省份中间位置或结束位置
A2-B	城市起始位置
A2-I	城市中间位置或结束位置
A3-B	县区起始位置
A3-I	县区中间位置或结束位置
A4-B	详细地址起始位置
A4-I	详细地址中间位置或结束位置
O	无关字符



医疗场景-专病结构化

背景：抽取医疗病历中的信息，为医生科研，药企制药用

(右肝肿瘤) 肝细胞性肝癌 (II-III级, 梁索型和假腺管型), 肿瘤包膜不完整, 紧邻肝被膜, 侵及周围肝组织, 未见脉管内癌栓 (MVI分级: M0级) 及卫星子灶形成。(肿物 1个, 大小 $4.2 \times 4.0 \times 2.8\text{cm}$)。	肝癌级别	II-III级
	脉管内癌栓分级	M0级
	肿瘤的个数	1个
	肿瘤的大小	$4.2 \times 4.0 \times 2.8\text{cm}$





法律场景-判决书抽取


背景：通过抽取判决书中的信息，方便执法人员做相似案件查找归类





金融场景-收入证明、招股书抽取

背景：抽取收入证明和招股书中的信息可以帮助银行做自动审核校验等功能





公安场景-事故报告抽取

背景：抽取交通事故报告内容，建立公安大数据系统

交通事故报告

2223年4月1日16时55分左右…发生碰撞。事故造成张三、李四当场死亡，王五在被送往医院途中抢救无效死亡；其余1人受伤，其中赵六被送往夏县人民医院救治。事故原因正在调查中

发生时间

2223年4月1日16时55分左右

死亡人物

张三

李四

王五





旅游场景-宣传册、手册抽取

背景：抽取博物馆手册内容，组建博物馆知识图谱，可以做问答系统





画家 徐悲鸿（1895年7月19日—1953年9月26日），汉族，原名徐寿康，江苏宜兴县屺亭镇人，中国现代画家、美术教育家。 徐悲鸿被尊称为中国现代美术教育的奠基者，代表作品《愚公移山图》	出生日期	1895年7月19日
	画家	徐悲鸿
	代表作品	《愚公移山图》
	国家	中国

中国国家博物馆 门票价格 凭有效证件免费参观 现任馆长 王春法 馆藏精品 人面鱼纹陶盆 所属国家 中国 2013年末，中国国家博物馆总建筑面积近20万平方米，藏品100余万件，展厅48个。	博物馆	中国国家博物馆
	门票价格	免费
	藏品数量	100余万件
	现任馆长	王春法
	面积	20万平方米



知识增强的开源语言大模型框架



本章主要内容

7.1	信息抽取概述
7.2	命名实体识别
7.3	关系抽取
7.4	事件抽取



命名实体 (Named Entity) 是指具有特定意义的实体，主要包括人名、地名、机构名、专有名词等。**命名实体识别 (Named Entity Recognition, NER)** 目标就是从文本中抽取这些具有特定意义的实体词。

命名实体识别一般包含两个步骤，分别是**实体边界判断**和**实体类别判断**。其中实体边界判断是为了确定实体字符串在非结构化文本中的开始位置和结束位置，而实体类别的判断则是为了判断该字符串对应的实体类型。

实体名	标签	举例
人名	PER	[张钹] _{PER} 院士：抓住机会、掌握主动发展第三代人工智能
地名	LOC	2021 世界人工智能大会将于 7 月 8 日至 10 日在 [上海] _{LOC} 召开
机构名	ORG	[复旦大学] _{ORG} 校名取自《尚书大传》之“日月光华，旦复旦兮”
疾病名	DIS	[高血压] _{DIS} 已成为影响全球死亡率的第二大危险因素
药品名	DRU	[奥司他韦] _{DRU} 是治疗流感的首选药物



命名实体识别算法的**主要难度**在于处理**歧义**和**未登录词**问题。歧义问题是指同一个名称可以指代不同类型的实体。

例如： 我们明天在中山大学见。

中山大学共有广州、珠海、深圳三个校区。

上句中“中山大学”在不同的上下文中分别作为地名和机构名。

在英文中这种现象更加常见，比如，“Harvard”既可以是人名，也可以是机构名，还可以是地名，需要根据上下文对实体的类别进行判断。

未登录词问题与中文分词中定义一致，也是指在训练语料中没有出现或者词典当中没有，但是在测试数据中出现的实体。命名实体在语言中通常表现出表达随意、用法复杂、形式多变等特点，**未登录词问题相较于中文分词更加严重。**





命名实体从表现形式还可以进一步分为两种类型：**非嵌套命名实体 (Non-nested Named Entities)** 和**嵌套命名实体 (Nested Named Entities)**。

非嵌套命名实体就是普通的命名实体，每个单词只对应一个标签。

嵌套命名实体是指实体中存在嵌套的情况，每个的单词可能对应若干个标签。

例如，“中山大学中山医学院”整体上是机构名，

其中“中山”是人名，而“中山大学”是机构名。



7.2.1 非嵌套命名实体识别




非嵌套命名实体 (Flat Named Entity) 识别通常可以转换为**序列标注**问题。对给定序列中的每一个元素 (Token) 标注一个标签。

序列通常是一个句子，而元素指的是句子中的词语或者字。

标注的标签一般同时能表示实体的边界和类别信息。典型的标注格式是**BIO**标签体系，即将每个元素标注为“B-X”、“I-X”或者“O”。

其中，“B-X”表示此元素所在的片段属于X类型并且此元素在此片段的开头，“I-X”表示此元素所在的片段属于X类型并且此元素在此片段的中间位置，“O”表示不属于任何类型






在实际应用中，也有一些系统采用更复杂的**BIOES**标签体系，在**BIO**标签的基础上增加了**单字符实体S**和**字符实体的结束标识E**。同样的，在边界标签基础上需要与实体类别标签融合。

一组相邻且类别相同的元素构成的子序列**Span(start, end, type)**就构成了抽取出来的命名实体

通过这种转换，命名实体识别问题就转换为了序列标注问题。在前述章节介绍的包括隐马尔可夫（HMM）、条件随机场（CRFs）、长短时记忆网络（LSTM）等在内的很多算法都可以应用于该任务。



在自然语言处理算法中通常使用的线性链条件随机场，给定随机变量序列 X 的条件下，随机变量序列 Y 的条件概率分布 $P(Y|X)$ 满足**马尔可夫性**，即输出标签序列 y_i 仅与其周边的标签 y_{i-1} 和 y_{i+1} 相关。在输入序列 X 为句子中每个字的情况下，使用线性链条件随机场仅能表示局部依赖的特征。但是，在命名实体识别任务中往往依赖更多的**非局部特征**。



文献[339]提出了半马尔可夫条件随机场 (Semi-Markov Conditional Random Fields, Semi-CRFs)，从要求每个字的所对应分类标签满足马尔可夫性，放松到**仅需由邻接词组成的片段 (Segments) 间进行满足马尔可夫性即可**。将这种模型用于命名体识别任务时，可以更有效、更自由的利用各种有利于识别出命名体片段边界的特征，**如实体的长度、与实体相似的已知实体名称等**。



在建立一个条件随机场时，首先要定义一个特征函数集，该函数集内的每个特征函数都以文本作为输入，提取的特征作为输出，假设该函数集为：

$$\Phi(x_1 \dots x_n; y_1 \dots y_n)$$

其中 $x = \{x_1 \dots x_n\}$ 为 n 个字组成的输入文本序列， $y = \{y_1 \dots y_n\}$ 为对应的实体标签序列。条件随机场使用对数线性模型来计算给定观测序列下状态序列的条件概率：

$$P(y|x; w) = \frac{\exp(w \cdot \Phi(x, y))}{\sum_{y'} \exp(w \cdot \Phi(x, y'))}$$

其中 y' 是所有的状态序列， w 是CRF模型的参数，可以把它看成是每个特征函数的权重，CRF模型的训练可以看作是对参数 w 的估计。



CRF在处理"李明在中山大学工作"示例中的计算过程:

步骤1: 定义输入序列与目标标签序列

输入序列 $x = \{\text{李, 明, 在, 中, 山, 大, 学, 工, 作}\}$

目标标签序列 $y = \{\text{B-PER, I-PER, O, B-ORG, I-ORG, I-ORG, I-ORG, O, O}\}$

标签意义: B-PER(人名开始), I-PER(人名内部), B-ORG(组织名开始), I-ORG(组织名内部), O(非实体)

步骤2: 特征函数提取 (部分示例)

字符特征:

$f_1(x, y, 1) = 1$ (因为 $x[1] = \text{"李"}$ 且 $y[1] = \text{B-PER}$)

$f_2(x, y, 2) = 1$ (因为 $x[2] = \text{"明"}$ 且 $y[2] = \text{I-PER}$)

转移特征:

$f_4(x, y, 2) = 1$ (因为 $y[1] = \text{B-PER}$ 且 $y[2] = \text{I-PER}$)

$f_5(x, y, 3) = 1$ (因为 $y[2] = \text{I-PER}$ 且 $y[3] = \text{O}$)



CRF在处理"李明在中山大学工作"示例中的计算过程:

步骤3: 计算特征函数得分

假设训练得到的参数向量 $w = [1.5, 1.2, 0.8, 0.9, 0.7, 0.6, 1.1, 1.3, 1.0, \dots]$

计算 $w \cdot \Phi(x, y)$:

$$\begin{aligned} & w_1 \times f_1(x, y, 1) + w_2 \times f_2(x, y, 2) + w_4 \times f_4(x, y, 2) + w_5 \times f_5(x, y, 3) + \dots \\ & = 1.5 \times 1 + 1.2 \times 1 + 0.9 \times 1 + 0.7 \times 1 + \dots = \text{总得分} \end{aligned}$$

步骤4: 计算条件概率

$$P(y|x; w) = \exp(w \cdot \Phi(x, y)) / Z(x)$$

$$\text{其中 } Z(x) = \sum_{y'} \exp(w \cdot \Phi(x, y'))$$

通过前向-后向算法计算 $Z(x)$, 通过维特比算法找到最优标签序列



嵌套命名实体 (Nested Named Entity) 是指在实体的内部还存在一个或多个其他实体的类型。

“中山大学”属于组织机构名实体，同时其中的“中山”又是地名类型的实体；

“华为 P50 Pro”属于产品类型的实体，其中“华为”又是公司名类型实体。

嵌套命名实体识别问题可以形式化表示为：给定一个序列 $X = x_1x_2 \cdots x_n$ ，其中 x_i 表示序列的第 i 个词或字，该序列对应的标签为 $Y = y_1y_2 \cdots y_n$ ，其中 $y_i = \{y^1_i, y^2_i, \cdots, y^m_i\}$ ， m 为标签嵌套层数。

HMM、CRF等传统的序列标注方法只能对每个位置输出一个标签，无法解决多标签问题，因此不能直接应用于嵌套命名实体识别任务。此外嵌套命名实体的标签之间可能存在依赖关系，其嵌套层次数量也不确定，这都是嵌套命名实体识别需要解决的难点。




- 解决嵌套命名实体识别的基本方法可以采用基于非嵌套实体识别算法的**穷举法**，**将所有的可能的单词序列**都利用非嵌套实体识别算法进行识别和分类
- 还可以将原有标签修改为**组合形式**，将可能共同出现的所有类别进行组合，**产生新的标签体系**（如：将B-LOC与B-ORG组合构造B-LOC|ORG新标签）
- 也可以修改原有序列标注算法从**单一目标到多目标**，利用KL散度等做为损失函数进行参数训练等方法
- 这些基本方法虽然实现相对简单并且直接，但是存在计算消耗、标签量指数增加或者目标学习难度大等问题

7.2.2 嵌套命名实体识别--基于成分句法分析嵌套命名实体识别



嵌套命名实体识别任务可以类比成分句法分析任务，参考成分句法分析方法进行嵌套命名实体的识别



句子“他是北京大学学生”的成分语法树和嵌套命名实体分析



基于状态转移的嵌套命名实体识别的方法，其基本思想与**移进-规约**成分句法分析类似，从左到右扫描输入的句子，并**维护三个部分：堆栈S、动作序列A、队列Q**。**堆栈S**自底向上存储已规约的实体和待规约的单词，**动作序列A**存储规约动作的历史信息，**队列Q**存储尚未规约的单词。嵌套实体识别的移进-规约过程包含三种可能的动作：

- 移进 (Shift)：将非空队列Q最左端的单词移入堆栈S中；
- 规约-X (Reduce-X)：弹出堆栈S的两个元素 s_0 和 s_1 ，将它们合并标注为实体类型X后重新压入堆栈S中；
- 一元化-X (Unary-X)：弹出堆栈S的栈顶元素 s_0 ，将它标注为实体类型X后重新压入S中。

7.2.2 嵌套命名实体识别--基于成分句法分析嵌套命名实体识别



堆栈	动作	队列
∅	Shift	他 是 北京 大学 学生 \$
他	Shift	是 北京 大学 学生 \$
他 是	Shift	北京 大学 学生 \$
他 是 北京	Unary-LOC	大学 学生 \$
LOC 北京	Shift	大学 学生 \$
LOC 大学 他 是 北京	Reduce-ORG	学生 \$
ORG / \ LOC 大学 他 是 北京	Shift	学生 \$
ORG 学生 / \ LOC 大学 他 是 北京	Reduce-PER	\$
PER / \ ORG 学生 / \ LOC 大学 他 是 北京	Shift	\$
PER \$ / \ ORG 学生 / \ LOC 大学 他 是 北京	∅	∅

\$作为句子的结束符添加在所有句子的末尾。

堆栈S、动作序列A、队列Q用于表示当前系统的状态


算法通过其当前状态来判断接下来应该执行的动作，由此实现状态的转移，进而完成识别。

使用与句法分析相同的框架，将该问题转换为分类问题，**输入**为当前的系统状态[S,A,Q]，**输出**为下一步的动作。

通过正确的动作序列完成嵌套命名实体的识别。



基于跨度的嵌套命名实体识别 (Span-based Nested Named Entity Recognition) 方法通过对句子的子序列进行分类来识别嵌套实体。给定一个句子 $X = x_1 x_2 \dots x_n$ ，其中 x_i 表示句子的第 i 个词或字，该句子中最大包含 k 个词或字的所有连续子序列 $x_i x_{i+1} \dots x_j$ 都会进行判定是否为某类实体。



(a) 边界检测

(b) 跨度分类



非嵌套和嵌套的命名实体识别方法只能处理特定标注范式的实体，方法之间不具备普适性及迁移性。但实际应用时可能会遇到多种范式的实体，包括非嵌套命名实体、嵌套命名实体、不连续命名实体 (Discontinuous Named Entity) 等不同的子任务。针对这些任务需要分别采取序列标注、跨度以及转移等方法分别进行处理，这些算法很难同时处理上述所有子任务。针对上述问题，需要一个能同时处理不同实体范式的**统一命名实体识别方法**。

使用序列 $y = s_1^1 e_1^1 \dots s_j^1 e_j^1 t^1 \dots s_1^i e_1^i \dots s_k^i e_k^i t^i$ 表示，其中 s, e 分别是一个实体跨度的起止索引， t 表示实体类型。对于非嵌套和嵌套命名实体识别任务，每个实体只包含一个跨度，但是对于不连续 NER 任务，每个实体包含多个跨度

例如：输入：中山大学

输出：1 2 5 1 4 6

输出序列中1和2 表示第1个实体跨度的起止索引，5表示LOC实体类型，接下来输出序列中的1和4表示第2个实体跨度的起止索引，6表示ORG实体类型。

7.2.3 多规范命名实体识别

将标注任务转化为一个序列生成任务

$$\mathbf{E}^e = \text{TokenEmbed}(X) \quad (5)$$

$$\hat{\mathbf{H}}^e = \text{MLP}(\mathbf{H}^e) \quad (6)$$


$$\bar{\mathbf{H}}^e = \alpha * \hat{\mathbf{H}}^e + (1 - \alpha) * \mathbf{E}^e \quad (7)$$

$$\mathbf{G}^d = \text{TokenEmbed}(G) \quad (8)$$

$$P_t = \text{Softmax}([\bar{\mathbf{H}}^e \otimes \mathbf{h}_t^d; \mathbf{G}^d \otimes \mathbf{h}_t^d]) \quad (9)$$

S1: B-Per Barack I-Per Obama O was O born O in O the B-Loc US
 Person Location

(a) Sequence labelling for flat NER




(b) Span-based classification for nested NER

Actions: OUT OUT SHIFT SHIFT LEFT-REDUCE COMPLETE ...
 S3: have much muscle pain and fatigue
 Disorder Disorder

(c) Transition-based method for discontinuous NER


S1: Barack Obama <Person> US <Location>
 S2: The Lincoln Memorial <Location> Lincoln <Person>
 S2: muscle pain <Disorder> muscle fatigue <Disorder>





BART使用的字节对编码（Byte-Pair-Encoding，BPE）编码方式会将一个单词处理成若干子词，所以BART框架在使用时需要进行适当的修改，可以采用如下三种基于指针的实体表示来明确地定位原句子中的实体：

- Span：实体的每个起始位置与结束位置。
- BPE：实体中每个词的所有BPE对应的位置索引。
- Word：每个实体的字的第一个BPE对应的位置索引。



- Span: [0,2,5,5,PER], [0,7,LOC], [6,7,ORG]
- BPE: [0,1,2,5,PER], [0,1,2,3,4,5,6,7,LOC], [6,7,ORG]
- Word: [0,5,PER], [0,3,5,6,LOC], [6,ORG]

- 在大多数情况下，使用Word 实体表示的结果会更好
- 与Span 实体表示相比，由于BPE 实体表示与预训练任务更相似，所以效果比Span 实体表示效果更好
- 但是当数据集中一个实体被标记成很长的BPE 序列的时候，Span 实体表示的效果会优于其他两种

本章主要内容

7.1

信息抽取概述

7.2

命名实体识别

7.3

关系抽取

7.4

事件抽取



关系抽取 (Relation Extraction, RE) 最初是在1998年MUC-7会议上首次正式提出，**旨在从无结构文本中识别两个或多个实体之间的语义关系**，是信息检索、智能问答、人机对话等应用系统中不可或缺的基础任务，也是知识图谱构建所依赖的关键技术之一。

本节主要介绍**二元关系抽取**，关注两个实体之间的语义关系。**实体间的关系可以用<HEAD, RELATION, TAIL>三元组进行表示**，其中Head和Tail分别表示头实体和尾实体，Relation表示实体之间的关系类型。

例如：根据句子“刘翔出生于上海”

可抽取 <刘翔, 出生地, 上海>，表示“刘翔”和“上海”之间存在“出生地”关系。



- 关系抽取任务的**主要难度在于**关系类型**种类繁多**以及对**语义建模能力**要求高。
- 以Freebase知识库为例，其包含**4000种关系类型**和**7000种属性类型**。如果考虑多实体关系以及关系之间的重叠，关系类型将更加复杂。
- 面对如此庞大且不断增长的关系类型，目前大多数基于有监督方法的关系抽取任务通常根据应用的不同，**构建特定领域的关系抽取模型**，从而大幅度降低了模型的复杂程度。
- 但是在处理不同领域任务时，需要**重复进行**关系类型定义、标注数据收集、模型训练等环节，这在一定程度上**制约了关系抽取算法的通用性**。
- 此外，描述实体之间关系的**语言丰富，形式也多种多样**，这进一步增加了关系抽取任务的难度。



例如：(1) **中山大学**始创于1924年，位于中国**广州**。

(2) **中山大学** 地址：**广州市**新港西路135号

(3) **海珠区**域坐落着十余所各类高等院校，包括：**中山大学**、广州美术学院等

上述三个句子都表明了“中山大学”和“广州”之间存在“位于”关系，但是其**表达形式之间的差别却非常大**，如何能够建模这种长距离、丰富内容且形式变化多样的语义关系是关系抽取算法迫切需要解决难题。



关系抽取任务目标是识别实体间语义关系，因此依据是否已经在无结构文本中标记了实体类型，关系抽取方法可分为**联合式抽取**和**流水线式抽取**。

- **联合式抽取**是指利用单个算法完成从文本中同时完成命名实体识别和关系抽取。
- **流水线式抽取**则是首先使用命名实体识别算法识别文本中的实体，然后构造关系抽取模型识别实体对间的关系。
- 两种方法各有利弊：
 - **流水线式**方法可以将复杂的关系抽取任务拆解，从而降低单个模型的复杂程度，但是会带来**错误传递的风险**。
 - **联合式抽取**算法可以有效缓解错误传递的问题，但是**模型相对复杂**，文本中不仅包含有语义关联的实体对，也包含单纯的命名实体，这会造成模型学习难度的急速提升，影响模型学习效果。



根据关系类型是否需要提前预先定义，关系抽取算法可以分为**预定义关系抽取**和**开放关系抽取**两类。

- **预定义关系抽取**是针对一个或者多个领域内预先定义的实体间关系进行抽取。
根据所使用的训练数据是标注数据还是外部知识自动标注的情况细分为**有监督**和**远程监督**
- **开放关系抽取**则针对不限定领域的范围和关系类别的抽取任务。




有监督的关系抽取方法将关系抽取问题转换为**多分类问题**。其**输入为**文本内容和待判断的提及对（Mention Pair），**输出为**提及对之间根据给定的文本内容所表达的关系类型。

有监督的关系抽取方法需要大量的人工标注训练语料，通过设计有效的特征来构建各类分类模型。或者利用深度神经网络自动提出语义特征进行关系抽取。




关系抽取需要根据句子抽取实体之间的关系，句子的句法结构提供了捕捉单词之间的长距离关系的有效信息。文献[356]提出了通过图卷积神经网络（Graph Convolutional Network, GCN）有效利用句子依存句法树结构的关系抽取算法。通过图卷积操作对输入句子的依存结构进行编码，然后提取以实体为中心的表示，从而进行关系预测。模型结构如下图所示。





图卷积神经网络 (Graph Convolutional Network, GCN)




Convolution in CNNs

Convolutions in CNNs are inherently localized.
Neighbours participating in the convolution at the
center pixel are highlighted in gray.



图卷积神经网络 (Graph Convolutional Network, GCN)



Localized Convolution in GNNs

GNNs can perform localized convolutions mimicking CNNs. Hover over a node to see its immediate neighbourhood highlighted on the left. The structure of this neighbourhood changes from node to node.




图卷积神经网络 (Graph Convolutional Network, GCN)

Labeled graph	Degree matrix	Adjacency matrix	Laplacian matrix
	$\begin{pmatrix} 2 & 0 & 0 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix}$	$\begin{pmatrix} 0 & 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix}$	$\begin{pmatrix} 2 & -1 & 0 & 0 & -1 & 0 \\ -1 & 3 & -1 & 0 & -1 & 0 \\ 0 & -1 & 2 & -1 & 0 & 0 \\ 0 & 0 & -1 & 3 & -1 & -1 \\ -1 & -1 & 0 & -1 & 3 & 0 \\ 0 & 0 & 0 & -1 & 0 & 1 \end{pmatrix}$

图卷积的通式

任何一个图卷积层都可以写成这样一个非线性函数：

$$H^{l+1} = f(H^l, A)$$



$H^0 = X$ 为第一层的输入， $X \in R^{N \times D}$ ， N 为图的节点个数， D 为每个节点特征向量的维度， A 为邻接矩阵，不同模型的差异点在于函数 f 的实现不同。



图卷积神经网络 (Graph Convolutional Network, GCN)

实现一

$$H^{l+1} = \sigma(AH^lW^l)$$

其中 W^l 为第 l 层的权重参数矩阵, $\sigma(\cdot)$ 为非线性激活函数, 例如ReLU。

这种思路是基于节点特征与其所有邻居节点有关的思想。邻接矩阵 A 与特征 H 相乘, 等价于, 某节点的邻居节点的特征相加。这样多层隐含层叠加, 能利用多层邻居的信息。

但这样存在两个问题:

- 没有考虑节点自身对自己的影响;
- 邻接矩阵 A 没有被规范化, 这在提取图特征时可能存在问题, 比如邻居节点多的节点倾向于有更大的影响力。

因此实现二和实现三针对这两点进行了优化。



图卷积神经网络 (Graph Convolutional Network, GCN)

实现二

$$H^{l+1} = \sigma(LH^lW^l)$$

拉普拉斯矩阵 $L = D - A$ ，学名Combinatorial Laplacian，是针对实现一的问题1的改进：

- 引入了度矩阵，从而解决了没有考虑自身节点信息自传递的问题



图卷积神经网络 (Graph Convolutional Network, GCN)

实现三

$$H^{l+1} = \sigma(D^{-\frac{1}{2}} \hat{A} D^{-\frac{1}{2}} H^l W^l)$$

对于这里的拉普拉斯矩阵 $L^{sym} = D^{-\frac{1}{2}} \hat{A} D^{-\frac{1}{2}} = D^{-\frac{1}{2}} (D - A) D^{-\frac{1}{2}} = I_n - D^{-\frac{1}{2}} A D^{-\frac{1}{2}}$ ，学名Symmetric normalized Laplacian，也有论文或者博客写 $L = I_n + D^{-\frac{1}{2}} A D^{-\frac{1}{2}}$ ，就是一个符号的差别，但本质上还是实现一的两个问题进行的改进：


- 引入自身度矩阵，解决自传递问题；
- 对邻接矩阵的归一化操作，通过对邻接矩阵两边乘以节点的度开方然后取逆得到。具体到每一个节点对 i, j ，矩阵中的元素由下面的式子给出（对于无向无权图）：

$$L_{i,j}^{sym} := \begin{cases} 1 & \text{if } i = j \text{ and } \deg(v_i) \neq 0 \\ -\frac{1}{\sqrt{\deg(v_i) \deg(v_j)}} & \text{if } i \neq j \text{ and } v_i \text{ is adjacent to } v_j \\ 0 & \text{otherwise.} \end{cases}$$





其中 $\deg(v_i), \deg(v_j)$ 分别为节点 i, j 的度，也就是度矩阵在节点 i, j 处的值。



图卷积神经网络 (Graph Convolutional Network, GCN)



1
8
3
5
2
1



A Gentle Introduction to Graph Neural Networks

<https://distill.pub/2021/gnn-intro/>

Understanding Convolutions on Graphs

<https://distill.pub/2021/understanding-gnns/>



给定一个拥有 n 个节点的图，可以使用一个 $n \times n$ 的邻接矩阵 A 来表示这个图结构。其中，如果节点 i 到节点 j 之间存在一条边的话，则有 $A_{ij} = 1$ 。在一个拥有 L 层的图卷积网络中，假定第 l 层中节点 i 的输入向量为 $h_i^{(l-1)}$ ，输出向量为 $h_i^{(l)}$ ，那么一个图卷积操作可以表示为：

$$h_i^{(l)} = \sigma\left(\sum_{j=1}^n A_{ij} W^{(l)} h_j^{(l-1)} + b^{(l)}\right)$$

为了将图卷积操作应用于依存树，可以将每棵依存树转换成相应的邻接矩阵 A 。其中，如果单词 i 和 j 之间存在一条依存边的话，则有 $A_{ij} = 1$ 。然而，因为单词之间差别很大，简单地应用上述公式中的图卷积运算可能会导致**节点表示的幅值差异很大**。这可能会使句子表征偏向于高度节点，而忽略节点本身所携带的信息是什么。除此之外，因为节点在依存树中不会与自己相连接，所以 $h_i^{(l-1)}$ 的信息将永远不会传递给 $h_i^{(l)}$



为了解决上述问题，文献[356]提出在向图卷积网络输入非线性信息之前对其隐激活进行标准化，并向图中的每个节点添加自循环，具体做法如下：

$$\mathbf{h}_i^{(l)} = \sigma\left(\sum_{j=1}^n \tilde{A}_{ij} \mathbf{W}^{(l)} \mathbf{h}_j^{(l-1)} / d_i + b^{(l)}\right)$$

其中， $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}$ ， $\mathbf{I}$ 是 $n \times n$ 的单位矩阵，这就相当于给每个节点加自循环 $\mathbf{h}_i^{(l-1)}$ 的信息就可以传递给 $\mathbf{h}_i^{(l)}$ ； $d_i = \sum_{j=1}^n \tilde{A}_{ij}$ 是生成图中词元 i 的度，将它放在分母项就可以对节点的度进行标准化，解决了节点表示幅值差异过大的问题。

把上述操作叠加在 L 层上就形成了一个深层的图卷积网络。其中，将 $\mathbf{h}_1^{(0)}, \dots, \mathbf{h}_n^{(0)}$ 作为输入词向量， $\mathbf{h}_1^{(L)}, \dots, \mathbf{h}_n^{(L)}$ 作为输出词特征。



使用 $x = x_1 \dots x_n$ 表示输入句子，其中 x_i 是第 i 个单词。头实体表示为 $x_s = x_{s1} \dots x_{ns}$ ，尾实体表示为 $x_o = x_{o1} \dots x_{no}$ 。假如预先给定一个关系集合 R ，并且已经给出 x 、 x_s 、 x_o ，关系抽取的目标就是预测实体间的关系 $r \in R$ 或是“无关系”

在词向量上应用了L层GCN之后，可以获得每个单词的隐藏表示，这些单词在依存树中直接受其距离不超过L条边的邻居节点的影响。为了在关系抽取任务中利用这些词表示，首先定义句子表示：

$$h_{\text{sent}} = f(h^{(L)}) = f(\text{GCN}(h^{(0)}))$$

可以从 $h^{(L)}$ 获取到头实体和尾实体的隐藏表示，如下所示：

$$h_s = f(h_{s_1:s_2}^{(L)}) \quad h_o = f(h_{o_1:o_2}^{(L)})$$

通过连接句子和实体的表示，并且将其输入前馈神经网络从而获得用于分类的最终表示：

$$h_{\text{final}} = \text{FFNN}([h_{\text{sent}}; h_s; h_o])$$

将最终得到的隐藏表示输入到一个线性层中，然后再利用 Softmax 函数去获取关系的概率分布。最后，模型根据这个概率分布去推测出输入实体的最合适的关系。



有监督的关系抽取方法虽然准确率较高，模型结果更为可靠，但是需要人工标注数据集。然而，构造这样的数据集需耗费大量的人力和时间。由于关系种类相较于实体种类更加复杂多样，并且不断涌现，针对所有关系抽取都需要预先标注大量样本，制约了关系抽取的更广泛的应用。

为了实现自动化关系抽取，研究人员们提出了**远程监督 (Distant Supervision)** 方法。远程监督方法假设知识库中两个实体存在某种关系，那么**所有提及了这两个实体的句子都表达了这种关系**。

Freebase知识库

关系	头实体	尾实体
/business/company/founders	Apple	Steve Jobs
...	...	...

从文本中抽取训练样本

1. Steve Jobs was the co-founder and CEO of Apple and formerly Pixar.
2. Steve Jobs passed away the day before Apple unveiled iPhone 4S in late 2011.

根据远程监督方法的假设，在语料集中所有包含这两个实体的句子都会被标注为这种关系，并作为训练样本用于训练。



虽然利用远程监督方法可以迅速构建大量训练样本，但是远程监督方法构建标签的假设过于宽松，非常容易导致大量的错误标注，从而严重影响模型的性能。从上图中所给出的例子中也可以看到，虽然句子2中包含了“Apple”和“Steve Jobs”两个词语，但是该句并没有表达“/business/company/founders”关系。因此，大量的远程监督方法关注于如何缓解训练集中的噪音信号，从而获得高性能的抽取器。



传统的关系抽取算法，**目标都是针对预先定义**的关系类型在**限定语料中判定**实体之间是否存在预先定义的关系。

- 传统的关系抽取算法能够处理的关系数量有限，并且在处理不同领域时需要用户进行关系类别定义、数据标注以及模型训练等一系列工作。
- 在处理海量互联网和社会媒体数据时，传统关系抽取算法受到上述问题的制约，很难适应快速发展且不断演进的需求。

开放关系抽取 (Open Relation Extraction, ORE) 目标是在不需要预先关系定义的情况下，从非结构化文本中提取关系元组，并且不受语料库领域的限制。

实体关系仍然采用三元组形式表示：(Head, Relation, Tail)

例如：根据句子“卡塔尔发布本届世界杯吉祥物，正式取名叫做La'eeb。”

可抽取 <世界杯, 在, 卡塔尔>、<世界杯吉祥物, 是, La'eeb>

需要特别注意的是，**开放关系抽取所得关系类型描述并不是预先定义的**，而是根据所给定的文本截取或生成的。因此，与预定义关系抽取不同，**具有相同语义的关系类型可能存在多个描述形式**。

7.3.3 开放关系抽取--基于自监督学习和人工模板的开放关系抽取算法



TextRunner采用自监督学习方法，通过自监督的学习器、信息抽取器和基于冗余信息的评估器等三个主要部分完成开放信息抽取：

- **自监督学习器 (Self-Supervised Learner)**：利用从整个语料集中采样得到的小规模样本，根据自监督学习方法输出分类器，目标是对所有可能的抽取候选分类为“可信” (Trustworthy) 或“不可信” (Not Trustworthy)。
- **信息抽取器 (Single-Pass Extractor)**：对整个语料集中所有数据进行遍历并抽取出所有的关系三元组，并利用自监督学习器构建的候选分类器进行判别，保留分类为“可信”的三元组。
- **基于冗余信息的评估器 (Redundancy-Based Assessor)**：利用文献[360]所提出的模型利用文本中的冗余信息对三元组进行评价。



自监督学习器使用依存句法分析器解析句子的句法结构，抽取名词性短语组成三元组<Head, Relation, Tail>，并利用人工定义的规则将所抽取的三元组划分为正样本或负样本。如果三元组满足以下三个条件则被归类为正样本，否则被归类为负样本：

- Head 和 Tail 之间不超过一定长度；
- Head 和 Tail之间的路径不穿过句式边界（例如关系从句）；
- Head 和 Tail 不全是代词。

信息抽取器对整个语料库进行一次遍历，对所有句子进行词性标注，**并使用轻量级的名词短语分块器来识别名词短语**，进而识别出实体。**关系则是通过分析实体之间的文本**，通过人工定义的一系列启发式规则消除非必要的短语构成。



在对整个语料库完成提取操作后，**TextRunner**将**实体和规范化关系都相同的三元组进行合并**，并统计每个三元组在不同句子中出现的次数。利用上述信息，基于文献[360]所提出信息冗余的概念，对被抽取多次的三元组分配一个更高的置信度，说明**被抽取多次的三元组更有可能表示为一种关系**。最终根据置信度和预先设定的阈值输出所发现的实体和关系。

TextRunner开放关系抽取系统，虽然减少了人工标注训练数据的开销，并且可以在多个不同领域的语料上使用，但是**仍然存在一些不足**：

- **不连贯的抽取 (Incoherent Extractions)**：抽取的关系词语不连贯，并且没有可解释性的意义。
- **无意义的关系 (Uninformative Relations)**：抽取忽略了关键性的信息，没有处理好动词和名词组成的多词谓语，并且名词携带了谓词的语义信息。

针对以上的问题，文献[361]提出了Reverb算法，利用句法约束和词汇约束对抽取三元组进行限制。句法约束目的是为了排除不连贯的抽取的问题，同时通过动词结构捕捉关系短语。具体句法约束如下所示：

$$V \mid V P \mid V W^* P$$
$$V = \text{Verb Particle? Adv?}$$
$$W = (\text{Noun} \mid \text{Adj} \mid \text{Adv} \mid \text{Pron} \mid \text{Det})$$
$$P = (\text{Prep} \mid \text{Particle} \mid \text{Inf. marker})$$

本章主要内容

7.1

信息抽取概述

7.2

命名实体识别

7.3

关系抽取

7.4

事件抽取



事件抽取 (Event Extraction) 目标是从文本中发现特定类型事件，并抽取该事件所涉及的时间、地点、人物等元素。事件抽取任务可以为问答系统、文本摘要以及各类语言理解任务提供有效的结构化信息。根据美国国家标准技术研究所 (NIST) 组织的ACE (Automatic Content Extraction) 项目给出的定义，事件由**事件触发词 (Trigger)** 以及**事件论元 (Argument, 也称事件元素)** 组成。

例如：2022 年卡塔尔世界杯 (FIFA World Cup Qatar 2022) 是第二十二届国际足联世界杯足球赛，在当地时间 2022 年 11 月 20 日到 12 月 18 日间在卡塔尔国内 5 个城市的 8 座球场举行。

事件类型：体育赛事

触发词：举行

赛事名称：第二十二届国际足联世界杯足球赛

时间：2022 年 11 月 20 日到 12 月 18 日

地点：卡塔尔



限定域事件抽取需要**预先定义事件类型以及与之对应的事件论元**，抽取算法的目标就是从包含事件的文本中**识别特定类型的事件并提取相应的事件论元**。

- **事件类型**是标识事件的类别，如“会议”、“袭击”等。
- **事件触发词**是指最清楚和明显地表达事件发生的主要词，如“击打”、“结婚”等。
- **事件论元**是指事件中涉及的参与者，一般为实体、时间等。
- **论元角色**（也称元素角色）是指事件论元在事件中所扮演的角色。

例如：句子“小明2022年在上海与小李举行婚礼”中，事件触发词“举行婚礼”可以得到

事件类型：“结婚”

事件论元：

人物“小明”和“小李” --> 论元角色：结婚的人

时间“2022年” --> 论元角色：结婚时间

地点“上海” --> 论元角色：结婚地点



文献[368]提出了**将事件抽取任务分解成一系列的分类子任务**的方法，并针对不同子任务提出了特征构建方法，在基于记忆的分类算法以及最大熵分类算法上分别进行验证。

该方法将事件抽取任务转换为以下四个子任务：

- **触发词识别**：从文本中识别触发词，并根据触发词确定事件提及（Event Mention）类型；
- **论元识别**：针对每个事件提及，从文本中识别事件提及的相关论元，包括实体、时间等；
- **属性分配**：确定每个事件提及的模态、极性、概括性和时态等属性；
- **事件共指**：确定从文本发现的事件提及是否为同一事件。

对于以上子任务，文献[368]采用流水线处理框架，**其中触发词识别独立于其他任务，论元识别和属性分配任务依赖于触发词识别的结果**，在这三个子任务都处理完成后，进行事件共指判断。



针对事件触发词识别，由于在事件描述中，触发词往往由明显的单个词语组成，在ACE2005数据集中，就有超过95%的触发词都为单个单词，所以可以将**触发词识别转换为词分类任务**。

但是，由于文本中词语的数量非常多，逐个分类会非常影响触发词的提取效率，并且这种情况下正负例比例相差过于巨大。因此，需要根据一些规则对词语进行预先过滤。

由于触发词词性通常是由名词、动词、形容词组成，所以**可以利用词性信息对词语进行预先筛选**。使用词性标注算法获得输入文本中词语的词性信息后，再对相应词性的词进行分类。

触发词识别主要由两个阶段组成：**(1) 采用二分类分类器**，将经过词性标注筛选后的词依次输入在训练集中训好的二分类分类器中，**判断该词是否为触发词**；**(2) 采用多分类模型判断候选触发词的类型**。

在事件论元识别方面，事件论元识别可以简化为一个**成对分类 (Pair Classification) 任务**，将**包含事件描述的句子与同句中的事件论元内容组成待分类对**，再利用分类模型判断论元角色。


7.4.1 限定域事件抽取--基于循环神经网络的联合事件抽取方法



采用流水线框架，将事件抽取分解为多个子任务的模式容易造成**错误传递的问题**，同时传统机器学习方法还需要**依赖预先设计**好的语言工具来提取句子中的词汇和上下文特征。

基于神经网络的联合事件抽取方法需要**自主地标记事件触发词的位置**，并对**标记出的事件类别进行预测**。这种改进有助于消除模型对预处理的过度依赖以及流水线架构的错误传递问题，并获取更加通用的事件抽取模型。

JRNN方法，使用循环神经网络（RNN）来获取句子中不同事件触发词和事件论元间的长距离依赖关系



首次把神经网络模型应用到了Joint event extraction上
(后面的许多paper都将该模型作为baseline)

Nguyen, T. H., Cho, K., & Grishman, R. (2016, June). Joint event extraction via recurrent neural networks. In *Proceedings of the 2016 conference of the North American chapter of the association for computational linguistics: human language technologies* (pp. 300-309).

7.4.1 限定域事件抽取--基于循环神经网络的联合事件抽取方法



编码层由句子编码层和基于RNN的特征编码层两部分构成，以图中的句子“A man died when a tank fired in Baghdad”为例，在句子编码层中，输入文本被转化成由三个向量的拼接而成的编码结果：


1. **词编码 (Word Embedding)**：使用预训练的词嵌入表来获取每个词的向量表示
2. **实体类型编码 (Entity Type Embedding)**：通过查找预训练的实体类型嵌入表，使用BIO注释模式来提供当前词的实体信息
3. **依存关系编码 (Dependency Relation Embedding)**：使用训练得到的依存句法树获取某个词相对于其他词的依赖关系特征

为了在模型的预测层中联合预测触发词和论元角色，JRNN 利用额外的记忆向量来编码触发词标签和论元角色之间的依赖关系：使用二元记忆向量 G_i^{trg} 记录触发词之间的关联关系；使用二元记忆矩阵 G_i^{arg} 来记录论元间的关联关系；使用记忆矩阵 $G_i^{arg/trg}$ 来记录触发词和论元之间的关联关系。

7.4.1 限定域事件抽取--基于循环神经网络的联合事件抽取方法



在句子编码层中，输入文本被转化成由三个向量的拼接而成的编码结果：



- 1. 词编码 (Word Embedding) :** 使用预训练的词嵌入表来获取每个词的向量表示
- 2. 实体类型编码 (Entity Type Embedding) :** 通过查找预训练的实体类型嵌入表 (随机初始化)，使用 BIO 注释模式来提供当前词的实体信息
- 3. 依存关系编码 (Dependency Relation Embedding) :** 使用训练得到的依存句法树获取某个词相对于其他词的依赖关系特征 (一个二值向量，维度等于依存树中词之间的依存关系数量，与当前词相连的边对应的依存关系所在维度为 1，其余维度为 0)


7.4.1

限定域事件抽取--基于循环神经网络的联合事件抽取方法



BRNN

分类层的输入数据为编码后 x 的隐藏表示 $(h_1, h_2, \dots, h_n)$,



其中 $h_i = [\alpha_i, \alpha'_i]$ 满足


$$(\alpha_1, \alpha_2, \dots, \alpha_n) = \overrightarrow{RNN}(x_1, x_2, \dots, x_n)$$

$$(\alpha'_1, \alpha'_2, \dots, \alpha'_n) = \overleftarrow{RNN}(x_1, x_2, \dots, x_n)$$

7.4.1 限定域事件抽取--基于循环神经网络的联合事件抽取方法



记忆模块: 为了在模型的预测层中联合预测触发词和论元角色, 利用额外的记忆向量来编码触发词标签和论元角色之间的依赖关系



7.4.1 限定域事件抽取--基于循环神经网络的联合事件抽取方法





事件分类：分类采用前馈神经网络，其特征为 $R_i^{trg} = [h_i, L_i^{trg}, G_{i-1}^{trg}]$ ，其中 $L_i^{trg} = [w_{i-d}, \dots, w_i, \dots, w_{i+d}]$ 为窗口大小为 d 的临近词向量的拼接向量。

触发词预测层接收上述的编码结果，并将其作为输入来获取词“died”的置信度 $P_{i;t}^{trg}$ 。

$$P_{i;t}^{trg} = P_i^{trg}(l = t) = F_t^{trg}(R_i^{trg})$$

对于高置信度的词，模型将词的预测结果输入记忆矩阵来保存。这些保存的表示将在之后的论元预测中被提取以作为上下文信息表示。



所有记忆模块初始化为0，在每个时间步*i*进行*i*槽位的memory更新

Trigger Memory

该记忆模块用符号 $G^{trg} \in \{0, 1\}^{l \times n^T}$ 表示，其中 l 表示句子长度， n^T 表示事件类型数量（包括“Other”类型）， G_i^{trg} 表示包括当前时间步在内的预测的事件集合， $G_{ij}^{trg} = 1$ 当事件类型 j 在 $0 - i$ 时间步里被预测过。

Argument Memory

该记忆模块用 $G^{arg} \in \{0, 1\}^{k \times n^A}$ 表示，其中 k 表示句子中的实体数量， n^A 表示角色类型数量（包括“Other”类型）， G_i^{arg} 表示包括当前时间步在内的预测的角色集合， $G_{ij}^{arg} = 1$ 当角色类型 j 在 $0 - i$ 时间步里被预测过。

Argument/Trigger Memory

该记忆模块用 $G^{arg/trg} \in \{0, 1\}^{k \times n^T}$ 表示，其中 k 表示句子中的实体数量， n^T 表示事件类型的数量（包括“Other”类型）， $G_{ij}^{arg/trg} = 1$ 表示实体 i 在某个事件类型为 j 的事件作为某种角色实体。

7.4.1 限定域事件抽取--基于循环神经网络的联合事件抽取方法





角色分类: 采用前馈神经网络, 其特征为 $R_{ij}^{arg} = [h_i, h_{ij}, L_{ij}^{arg}, B_{ij}, G_{i-1,j}^{arg}, G_{i-1,j}^{arg/trg}]$, 其中

$L_{ij}^{arg} = [w_{i-d}, \dots, w_d, \dots, w_{i+d}, \dots, w_{i-j-d}, \dots, w_{ij}, \dots, w_{ij+d}]$, B_{ij} 表示先验信息的编码,

包括最短依存路径等, 由二进制特征通过前馈神经网络得到。

对于预测器输出的结果向量, 模型选取其中置信度最高的实体作为最终预测的论元实体。





开放域事件抽取 (Open Domain Event Extraction) 其目标是在没有任何预定义域假设的情况下，从非结构化文本中挖掘提取有意义的事件信息。

与限定域事件抽取任务不同，在没有预先定义的事件类型以及对应的事件论元情况下，早期开放域事件抽取目标不是精确地提取事件要素，而是使用聚类、语义分割等方法，**对文本内容进行分析基础上检测并跟踪事件。**

近年来，**也有一些工作试图给出更细粒度信息**，针对给定的一系列文本内容，输出事件集合，以及每个事件的触发词和对应的事件论元列表。



基于聚类的开放域事件抽取目标是从无结构文本中抽取若干主题的相关内容组成一系列事件，可以分为两个主要类型：回顾事件抽取（Retrospective Event Extraction）和在线事件抽取（Online Event Extraction）。

回顾事件抽取是将语料库中的文本内容进行分组，每一组文本被视为一个事件。

在线事件抽取是在回顾事件抽取的基础之上，对当前时刻给定的文本进行实时处理，判断当前文本是已有事件还是新事件。

回顾抽取和在线抽取分别采用离线和在线的聚类算法完成。



文献[373]提出了一种事件检测和跟踪算法。使用**基于词袋模型的传统向量空间模型对文档进行表示**。每一篇文档（新闻报道）是通过一个带权重项的向量来表示，在聚类算法中是将所有文档的规范化向量表示用于聚类。文档向量是使用频率（TF）和逆文档频率（IDF）进行统计加权，并进行适当的标准化，同时只保留每个向量的前k项。

文献[373]采用如下两种聚类算法完成回顾抽取和在线抽取：

GAC (**G**roup-**A**verage **C**lustering) 多层次的聚类算法，用于回顾事件抽取。

INCR (**I**Ncremental **C**luster**R**ing) 增量聚类算法，适用于回顾抽取和在线抽取。



GAC聚类算法采用**自底向上的贪心并结合分而治之的策略**，其目标是最大化聚类结果中每对文档之间的平均相似度。GAC算法的基本流程是：

- (1) 将文档集合中的每个文档都作为一个单独的事件类；
- (2) 将当前事件类簇集合中的事件类按**顺序连续并且不重叠地划分**到m个组中；
- (3) 每个组内部进行局部聚类，重复地合并组中的2个最相似的事件类，直到桶中类数量减少的比例达到预设的阈值 p ，或者任意2个类之间的相似度值均低于预设阈值 s 为止；
- (4) 将组之间的边界去除，并重复步骤(2)-(4)，直到最顶层的事件类数目达到了一个预定的数值为止。



INCR聚类算法则依次处理输入文本，然后依次扩大聚类的集合。

如果当前文档与某个事件类的中心之间的相似度高于预先选择的阈值，则新的文本会被加入到已经生成的相似度最高的事件类中；否则，该文档将被视为新事件类。

除此之外，还引入“新事件”和“旧事件”标签，通过该标签可以判断当前新闻是否是该时间点的新事件。

通过调整阈值，也可以得到不同粒度级别的集合。还可以额外利用输入数据的动态特性和事件的时间属性这两项信息，以达到提升算法效果的目的。

对于在线抽取算法，**时间窗口的引入能够限制前m个新闻事件文档**。对于按照序列依次处理的现有文档，每个在时间窗口文档相似度得分都会被计算，如果在窗口中相似度得分低于一个预定的阈值，那么将一个“新事件”的标签赋予给这个新闻文档。

ChatGPT 对于文本信息抽取的影响

以信息抽取为主的知识获取方式受到极大的挑战。传统知识获取主要以信息抽取为主要手段, 依据预设的知识结构, 从结构化、半结构化、非结构化数据中抽取目标知识 (例如实体识别、关系抽取、事件抽取等)。面对不断涌现的场景和领域, 这一方式只能采用“看到一类, 定义一类, 构建一类”的模式构建知识库。这种挤牙膏式知识库构建手段效率非常低下。其次, 这一类方法受到知识表示的限制, 只能对于已定义的知识类型进行抽取, 对于那些结构难以定义的知识类型毫无办法。再次, 已有知识抽取过程包含多个中间子任务 (实体/事件识别、实体/事件消歧、关系抽取、属性抽取等), 这种序列化且多步处理的抽取范式往往会引起错误传递和积累问题, 抽取准确率随着知识结构不断复杂而急剧下降, 需要大量人力进行校验, 保证知识准确性的要求。相对而言, 以 ChatGPT 为代表的预训练大模型采用无监督语言模型学习, 从海量数据中通过语言模型任务习得参数化的知识, 知识获取完全在连续数值空间进行, 有效减缓了上述基于信息抽取的知识获取范式的诸多问题。如果知识表示采用分布式数值表示为主, 那么知识获取方式从信息抽取转为语言模型, 将成为一个可预见的趋势。

本章小结

在本章中我们介绍了信息抽取的基本概念和发展历程。在此基础上详细介绍了信息抽取的三个主要任务：命名实体识别、关系抽取和事件抽取，并介绍不同场景下信息抽取的难点及主要算法。尽管基于深度学习的信息抽取已经取得了显著的进步，但实际应用中场景的多元化使得信息抽取依然面临着诸多挑战，低资源、开放领域下模型的抽取能力、如何融入视觉、听觉等多种模态来进一步提升信息抽取性能，以及如何改进框架将不同子任务统一建模，这些都值得进一步的探索。