

中山大學 人工智能学院
SUN YAT-SEN UNIVERSITY SCHOOL ARTIFICIAL INTELLIGENCE

「自然语言处理」

第 8 章 机器翻译

赵宝全

中山大学人工智能学院

2026年春季学期

本章主要内容

8.1

机器翻译概述

8.2

基于规则的机器翻译方法

8.3

基于统计的机器翻译方法

8.4

基于神经网络的机器翻译方法

8.5

译文质量评价

本章主要内容

8.1	机器翻译概述
8.2	基于规则的机器翻译方法
8.3	基于统计的机器翻译方法
8.4	基于神经网络的机器翻译方法
8.5	译文质量评价





巴别塔 (Tower of Babel)





- **机器翻译** (Machine Translation, MT) 是指利用计算机实现从一种自然语言到另外一种自然语言的自动翻译。被翻译的语言称为**源语言** (source language), 翻译到的语言称作**目标语言** (target language)



- **目标**: 建立有效的自动翻译方法、模型和系统, 打破语言壁垒, 最终实现任意时间、任意地点和任意语言的自动翻译, 完成人们无障碍自由交流的梦想
- 语言是人类智能的最高形式, 机器翻译是自然语言处理和人工智能领域的核心问题和**最具挑战**的任务之一



■ 研究内容和关键科学问题

✧ 机器翻译一般需要经过三个基本步骤

■ 源语言的理解（首要科学问题）

- 语言翻译本质上是利用目标语言准确地表达源语言语句所呈现的语义
- 源语言理解包括词语、短语、句子和语篇（对话）等多层次语言单位的处理

■ 源语言到目标语言的转换（最关键的问题）


- **翻译知识表示**：知识层次（词、短语、句子）；表示层次（离散、连续）
- **翻译知识获取**：理性主义（经验总结和手工编写）；经验主义（数据驱动）

■ 目标语言的生成

- 译文片段的组合方式

目标语言句子的流畅性

源文：我对你感到满意



译文：I am satisfied with you



■ 机器翻译的挑战

✧ 自然语言中普遍存在的歧义和未知现象

- 句法结构歧义/词汇歧义/语用歧义 ...
- 新的词汇、术语、结构、语义 ...

✧ 机器翻译不仅仅是字符串的转换

- 不同语言之间文化的差异
- 现有方法无法表示和利用世界知识和常识

✧ 机器翻译的解不唯一，而且始终存在人为标准

机器翻译是一项综合性的复杂技术，几乎自然语言处理中的所有问题在机器翻译中都会遇到



■ 食品或菜单名的翻译

(1) 红烧狮子头: **Fried Lion's Head**

→ **Braised pork balls**

(2) 夫妻肺片: **Husband and wife's lung slices**

→ **Fuqifeipian/ Spicy beef**

(3) 童子鸡: **Young lad chicken**

Boy chicken without sexual life

→ **Spring chicken/ Broiler chicken**

(4) 佛跳墙: **Buddha Jumps Over the Wall / Buddha's Temptation**



We do chicken right.

- (1) 我们做鸡是对的。
- (2) 我们做鸡正点耶。
- (3) 我们就是做鸡的。
- (4) 我们有做鸡的权利。
- (5) 我们只做鸡的右边。
- (6) 我们可以做鸡，对吧！
- (7) 我们行使了鸡的权利。
- (8) 我们只做右边的鸡。
- (9) 我们主张鸡权。
- (10) 我们公正地做鸡！

- (11) 我们要把鸡打成右派。
- (12) 我们做鸡肉权利。
- (13) 我们还是做鸡好。
- (14) 我们用正确的方法炸鸡。
- (15) 我们做鸡有理！
- (16) 我们让鸡向右看齐。
- (17) 我们肯定是鸡，对！
- (18) 我们做的鸡才是正宗。

..... 几十种翻译！

English - Detected English Spanish French ▼

We Do Chicken Right



19 / 5,000



↔ English Chinese (Simplified) Spanish ▼

我们做对了鸡肉



Wǒmen zuò duì le jī ròu



Send feedback



We Do Chicken Right 如何优雅地翻译肯德基的这句广告词?

Show drafts ▼

优雅地翻译肯德基的广告词 "We Do Chicken Right" 需要在传达原意、符合中文表达习惯的基础上，还要兼顾品牌形象和文化内涵。以下是一些建议：

1. 突出肯德基炸鸡的美味特点：

- “吮指原味，妙不可言”：这是肯德基中国官方的翻译，简洁明了，突出了炸鸡的美味特点，也符合中文的表达习惯。
- “炸鸡界的爱马仕，美味无可比拟”：这个翻译将肯德基炸鸡比喻为奢侈品品牌爱马仕，既体现了其高端品质，也突出了其独特的美味。

2. 强调肯德基炸鸡的专业性和正宗性：

- “炸鸡之道，唯肯德基”：这个翻译用简洁的语句表达了肯德基在炸鸡方面的专业性，也体现了其对炸鸡文化的传承。
- “秘制配方，地道风味”：这个翻译强调了肯德基炸鸡的独特配方和地道风味，也彰显了其悠久的历史和文化底蕴。

3. 体现肯德基炸鸡的品牌形象和文化内涵：

- “肯德基，炸鸡不止是美味，更是生活态度”：这个翻译将肯德基炸鸡上升到生活态度的高度，赋予其更深层的文化内涵。
- “与世界分享美味，与你分享快乐”：这个翻译体现了肯德基的品牌理念，不仅是分享美味，更是传递快乐。



4. 兼顾音译和意译：

- “咔咔脆，真滋味”：这个翻译保留了部分英文发音，同时也传达了炸鸡酥脆可口的特点。
- “妙脆鸡，真过瘾”：这个翻译将肯德基的招牌产品妙脆鸡与“过瘾”联系在一起，更加吸引人。

在实际应用中，可以根据不同的语境和目标受众选择合适的翻译版本。例如，在正式广告中可以使用更简洁明了的翻译，而在社交媒体上可以使用更具创意和趣味性的翻译。

总而言之，优雅地翻译肯德基的广告词需要在准确传达原意、符合中文表达习惯的基础上，进一步挖掘其文化内涵和品牌价值，从而更好地与目标受众产生共鸣。





玫珂菲



唐朝的李贺在《河南府试十二月乐词·七月》写到：“星依云渚冷，露滴盘中圆。”“云渚”指的是银河，好像有点关联。接下来的这句，意思就更明朗了，白居易在《题王处士郊居》说：“半依云渚半依山，爱此令人不欲还”。这里的“云渚”指的是山间的河流，汨汨清水，对应了“依云”的内涵和调性。





黛玉自在枕上感念宝钗……又听见窗外竹梢焦叶之上，雨声淅沥，消寒透幕，不觉又滴下泪来。
(《红楼梦》第45回)

As she lay there alone, Dai-Yu's thoughts turned to Bao-chai ...Then she listened to the insistent rustle of the rain on the bamboos and plantains outside her window. The coldness penetrated the curtains of her bed. Almost without noticing it she had begun to cry.

— 文学翻译家 David Hawkes




Send feedback





■ 机器翻译的发展历程

✧趋势：让机器更 **“自主”** 地学习如何翻译





■ 机器翻译的研究现状

✧ 自动化程度和智能化程度在不断提升，机器翻译质量也得到了显著改善，若干翻译系统已（接近）实用化

Google Translate



DeepL



Microsoft Translator



Baidu Translate



Amazon Translate



✧ 当今世界上有 7000 多种语言，其中只有**100多种**具有机器翻译系统

- As of November 2022, Google Translate supports 133 languages at various levels



Google I/O 2022



■ 机器翻译的研究现状

✧ “信达雅” 翻译理论


- **“信”**：翻译的目标语含义要与原文含义一致，在翻译的过程中，不可以出现漏译，错译的问题，也就是说译文必须要忠实原文含义
- **“达”**：翻译的过程中不拘泥于原文形式，译文整体要通顺流畅
- **“雅”**：选词得体，译文追求文雅

✧ 在奔向“信、达、雅”翻译目标的征程上，目前的机器翻译基本**挣扎在“信”的阶段**，很多理论和技术问题仍有待于更深入的研究和探索

✧ 仍面临若干问题

- 理论模型和方法
- 实现技术问题
- 用户认识问题

**应彻底消除对机器翻译的误解
让机器翻译系统翻译诗歌、散文和小说等高难度文艺作品是不现实的，也是不可能的。**



AI会取代人工翻译吗？

Translation and Interpretation is more of a lifestyle and art.

Life is short, but art is long.

本章主要内容

8.1

机器翻译概述

8.2

基于规则的机器翻译方法

8.3

基于统计的机器翻译方法

8.4

基于神经网络的机器翻译方法

8.5

译文质量评价



1957年美国学者V. Yingve在《句法翻译框架》(Framework for Syntactic Translation) 一文中提出了对源语言和目标语言均进行适当描述、把翻译机制与语法分开、用规则描述语法的实现思想，这就是基于规则的翻译方法。

How old are you?



基于规则的翻译过程分成6个步骤：


- (a) 对源语言句子进行词法分析
- (b) 对源语言句子进行句法/语义分析
- (c) 源语言句子结构到译文结构的转换
- (d) 译文句法结构生成
- (e) 源语言词汇到译文词汇的转换
- (f) 译文词法选择与生成



- 当翻译“我”时，从规则库中找到规则1，该规则表示遇到单词“我”就翻译为“I”；类似地，也可以从规则库中找到规则4，该规则表示翻译调序，即将单词“you”放到“be satisfied with”后面


资源：规则库

- 1: If 源 = 我, then 译 = I
- 2: If 源 = 你, then 译 = you
- 3: If 源 = 感到 满意, then 译 = be satisfied with
- 4: If 源 = 对... 动词 [表态度] then 调序 [动词 + 对象]
- 5: If 译文主语是 I then be 动词为 am/was
- 6: If 源语言是主谓结构 then 译文为主谓结构





■ 基于规则的机器翻译方法的四个层次




早期基于规则的方法属于词汇转换层



■ 基于转换规则的机器翻译

✧ 可以视作一个 “**独立分析→相关转换→独立生成**” 的过程



本章主要内容

8.1

机器翻译概述

8.2

基于规则的机器翻译方法

8.3

基于统计的机器翻译方法

8.4


基于神经网络的机器翻译方法

8.5

译文质量评价




■ 罗塞塔石碑



这个石碑制作于公元前196年，据说是可供考证的最久远的记载平行文字的历史遗迹。石碑由上至下刻有同一段埃及国王诏书的三种语言版本，最上面是古埃及象形文，中间是埃及草书，最下面是古希腊文。很多人认为罗塞塔石碑是标志翻译或人工翻译的一个起点。目前罗塞塔石碑保存于大英博物馆，并成为该馆最具代表性的镇馆之宝之一。



■ 玄奘（佛学家、旅行家，翻译家）



- 玄奘西行求法归来后把全部的心血和智慧奉献给了译经事业，在助手们的帮助下，共翻译佛教经论74 部，1335 卷，每卷万字左右，合计1335 万字，占去整个唐代译经总数的一半以上，树立了我国古代翻译思想的光辉典范。

平行语料库是破解语言奥秘的钥匙



■ 数据驱动的机器翻译

Garcia y asociados .
 | \ \ \ \
 Garcia and associates .

los clients y los asociados son enemigos .
 | \ \ \ \ \ \ \ \ \ \
 the clients and the associates are enemies .


sus asociados no son fuertes .
 | | \ / \ / \
 his associates are not strong .

Garcia y sus asociados no son enemigos .
 | \ \ \ \ \ \ \ \ \ \
 Garcia and his associates are not enemies .

西班牙语	英语
Garcia	Garcia
y	and
asociados	associates
.	.
los	the
clients	clients
son	are
enemigos	enemies
sus	his
no	not
fuertes	strong




■ 人工翻译 vs. 机器翻译





人工翻译 vs. 机器翻译



统计机器翻译的核心
由三部分构成——
建模、训练和解码




■ 统计机器翻译的基本框架



- **训练:** 从双语平行数据中学习翻译模型，记为 $P(t|s)$ ，其中 s 表示源语言句子， t 表示目标语句子。 $P(t|s)$ 表示把 s 翻译为 t 的概率。简言之，这一步需要从大量的双语平行数据中学习到 $P(t|s)$ 的准确表达。
- **解码:** 当面对一个新的句子时，需要使用学习到的模型进行预测。预测可以被视为一个搜索和计算的过程，也就是，尽可能搜索更多的翻译结果，然后用训练好的模型对每个翻译结果进行打分，最后选择得分最高的翻译结果作为输出。



- 在20多年的发展历程中，统计翻译方法经历了基于词、基于短语和基于句法树翻译模型的一系列转变。这些翻译模型可以简单归纳成如下金字塔图





■ 什么是单词翻译概率？

- 描述的是一个源语言单词与目标语言译文构成正确翻译的可能性，这个概率越高表明单词翻译越可靠
- 使用单词翻译概率，可以帮助机器翻译系统解决翻译时的“择词”问题，即选择什么样的目标语译文是合适的

源语言	目标语言	翻译概率
我	I	0.50
	me	0.20
	I'm	0.10
	we	0.05
	am	0.10
...	...	...



■ 如何从双语平行数据中进行学习？

$$\begin{aligned}
 P(x \leftrightarrow y; s, t) &\equiv P(x, y; s, t) \\
 &= \frac{c(x, y; s, t)}{\sum_{x', y'} c(x', y'; s, t)}
 \end{aligned}$$

s = 机器 翻译 就是 用 计算机 来 生成 翻译 的 过程

t = machine translation is a process of generating a translation by computer

$$\begin{aligned}
 P(\text{翻译}, \text{translation}; s, t) &= \frac{c(\text{翻译}, \text{translation}; s, t)}{\sum_{x', y'} c(x', y'; s, t)} \\
 &= \frac{4}{|s| \times |t|} \\
 &= \frac{4}{121}
 \end{aligned}$$

$$\begin{aligned}
 P(\text{机器}, \text{translation}; s, t) &= \frac{2}{121} \\
 P(\text{机器}, \text{look}; s, t) &= \frac{0}{121}
 \end{aligned}$$

平滑



■ 如何从双语平行数据中进行学习？

■ 假设有K个互译对

$$P(x, y) = \frac{\sum_{k=1}^K c(x, y; s^{[k]}, t^{[k]})}{\sum_{k=1}^K \sum_{x', y'} c(x', y'; s^{[k]}, t^{[k]})}$$

$s^{[1]}$ = 机器 翻译 就是 用 计算机 来 生成 翻译 的 过程

$t^{[1]}$ = machine translation is a process of generating a translation by computer

$s^{[2]}$ = 那 人工 翻译 呢 ？

$t^{[2]}$ = So , what is human translation ?

$$\begin{aligned} P(\text{翻译}, \text{translation}) &= \frac{c(\text{翻译}, \text{translation}; s^{[1]}, t^{[1]}) + c(\text{翻译}, \text{translation}; s^{[2]}, t^{[2]})}{\sum_{x', y'} c(x', y'; s^{[1]}, t^{[1]}) + \sum_{x', y'} c(x', y'; s^{[2]}, t^{[2]})} \\ &= \frac{4 + 1}{|s^{[1]}| \times |t^{[1]}| + |s^{[2]}| \times |t^{[2]}|} \\ &= \frac{4 + 1}{11 \times 11 + 5 \times 7} \\ &= \frac{5}{156} \end{aligned}$$




■ 基础模型

$$P(t|s) \equiv \frac{g(s,t)}{\sum_{t'} g(s,t')}$$

- **词对齐 (Word Alignment)**：描述了平行句对中单词之间的对应关系

- 本质上句子之间的对应是由单词之间的对应表示的



对于句对 (s, t) ，假设可以得到最优词对齐 $\hat{A}$ ：

$$g(s, t) = \prod_{(j, i) \in \hat{A}} P(s_j, t_i)$$

$$g(s, t) = P(\text{我}, \text{I}) \times P(\text{对}, \text{with}) \times P(\text{你}, \text{you}) \times \\ P(\text{感到}, \text{am}) \times P(\text{满意}, \text{satisfied})$$



■ 生成流畅的译文

- $g(s, t)$ 存在的问题是没有考虑词序信息
 - “I am satisfied with you”
 - “I with you am satisfied”

源语言句子“我对你感到满意”的不同翻译结果					$\prod_{(j,i) \in \hat{A}} P(s_j, t_i)$
$s =$ 我 ₁	对 ₂	你 ₃	感到 ₄	满意 ₅	0.0023
$t' =$ I ₁	am ₂	satisfied ₃	with ₄	you ₅	
$s =$ 我 ₁	对 ₂	你 ₃	感到 ₄	满意 ₅	0.0023
$t'' =$ I ₁	with ₂	you ₃	am ₄	satisfied ₅	



■ 生成流畅的译文

- **N-gram语言模型**：统计机器翻译中确保流畅翻译结果的重要手段之一

$$\begin{aligned}
 P_{\text{lm}}(t) &= P_{\text{lm}}(t_1 \dots t_l) \\
 &= P(t_1) \times P(t_2|t_1) \times P(t_3|t_2) \times \dots \times P(t_l|t_{l-1})
 \end{aligned}$$

$$g(s, t) \equiv \prod_{j, i \in \hat{A}} P(s_j, t_i) \times P_{\text{lm}}(t)$$

源语言句子“我对你感到满意”的不同翻译结果					$\prod_{(j,i) \in \hat{A}} P(s_j, t_i) \times P_{\text{lm}}(\mathbf{t})$
$s =$ 我 ₁	对 ₂	你 ₃	感到 ₄	满意 ₅	0.0023×0.0107
$t' =$ I ₁	am ₂	satisfied ₃	with ₄	you ₅	
$s =$ 我 ₁	对 ₂	你 ₃	感到 ₄	满意 ₅	0.0023×0.0009
$t'' =$ I ₁	with ₂	you ₃	am ₄	satisfied ₅	



■ 解码

✧ 解码是指在得到翻译模型后，对于新输入的句子生成最佳译文的过程

✧ 当给定任意的源语言句子 s ，解码系统要找到翻译概率最大的目标语译文 $\hat{t}$

$$\hat{t} = \arg \max_t P(t|s) \quad \hat{t} = \arg \max_t \frac{g(s, t)}{\sum_{t'} g(s, t')} \quad \hat{t} = \arg \max_t g(s, t)$$

简单遍历所有可能的译文并计算 $g(s, t)$ 的值是**不可行的**

句子长度 m	单词翻译候选数量 n	译文数量 $n^m \cdot m!$
1	1	1
1	10	10
2	10	200
10	10	362880000000000000
20	10	$2.43290200817664 \times 10^{38}$
20	30	$8.48300477127188 \times 10^{47}$



■ 解码

✧ 贪婪的机器翻译解码过程：每步只翻译一个单词，并保留当前“最好”的结果

输入：待翻译句子（已经分词）

我	对	你	感到	满意
$\downarrow \pi(1)$	$\downarrow \pi(2)$	$\downarrow \pi(3)$	$\downarrow \pi(4)$	$\downarrow \pi(5)$
I'm 0.4	to 0.3	you 0.7	ϕ 0.4	satisfy 0.3
I 0.3	with 0.3	your 0.3	feel 0.2	satisfied 0.2
me 0.1	for 0.2		feels 0.1	satisfies 0.2

$best.translation = \phi$

$best.j = -1$

$i = 1, j = 1$

$g(s, t)$ 翻译结果

h 存放临时翻译结果

$g(s, t)$	翻译结果

输入：待翻译句子（已经分词）

我	对	你	感到	满意
$\downarrow \pi(1)$	$\downarrow \pi(2)$	$\downarrow \pi(3)$	$\downarrow \pi(4)$	$\downarrow \pi(5)$
I'm 0.4	to 0.3	you 0.7	ϕ 0.4	satisfy 0.3
I 0.3	with 0.3	your 0.3	feel 0.2	satisfied 0.2
me 0.1	for 0.2		feels 0.1	satisfies 0.2

$best.translation = \phi$

$best.j = -1$

$i = 1, j = 1$

$g(s, t)$ 翻译结果

h 存放临时翻译结果

$g(s, t)$	翻译结果
.1744	I'm
.1674	I
.1041	me

Join

(a) $4:h = \phi$

(b) 6: if $used[j] = \text{false}$ then



■ 解码

✧ 贪婪的机器翻译解码过程：每步只翻译一个单词，并保留当前“最好”的结果

输入：待翻译句子（已经分词）

我	对	你	感到	满意
$\downarrow \pi(1)$	$\downarrow \pi(2)$	$\downarrow \pi(3)$	$\downarrow \pi(4)$	$\downarrow \pi(5)$
I'm 0.4	to 0.3	you 0.7	ϕ 0.4	satisfy 0.3
I 0.3	with 0.3	your 0.3	feel 0.2	satisfied 0.2
me 0.1	for 0.2		feels 0.1	satisfies 0.2

$best.translation = \phi$

$best.j = -1$

$i = 1, j = 2$

$g(s, t)$	翻译结果
.1744	I'm
.1674	I
.1041	me
.0561	to
.0013	with
.0013	for

(c) 7: $h = h \cup \text{Join}(best, \pi[j])$

输入：待翻译句子（已经分词）

我	对	你	感到	满意
$\downarrow \pi(1)$	$\downarrow \pi(2)$	$\downarrow \pi(3)$	$\downarrow \pi(4)$	$\downarrow \pi(5)$
I'm 0.4	to 0.3	you 0.7	ϕ 0.4	satisfy 0.3
I 0.3	with 0.3	your 0.3	feel 0.2	satisfied 0.2
me 0.1	for 0.2		feels 0.1	satisfies 0.2

$best.translation = \text{I'm}$

$best.j = 1$

$i = 1, j = 5$

$g(s, t)$	翻译结果
.1744	I'm ← top1
.1674	I
.1041	me
.0561	to
.0013	with
.0013	for
...	...
.1452	satisfies

(d) 8: $best = \text{PruneForTop1}(h)$



■ 解码

✧ 贪婪的机器翻译解码过程：每步只翻译一个单词，并保留当前“最好”的结果

输入：源语句子 $s = s_1 \dots s_m$

输出：找的最佳译文

Function WordDecoding(s)

1: $\pi = \text{GetTransOptions}(s)$

2: $best = \phi$

3: **for** i in $[1, m]$ **do**

4: $h = \phi$

5: **foreach** j in $[1, m]$ **do**

6: **if** $used[j] = \text{false}$ **then**

7: $h = h \cup \text{Join}(best, \pi[j])$

8: $best = \text{PruneForTop1}(h)$

9: $used[best.j] = \text{true}$

10: **return** $best.translatoin$

获取每个单词
的翻译候选



$best$ 用于保存当前最好的翻译结果

h 用于保存每步生成的所有译文候选

$\text{Join}(a, b)$ 返回

a 和 b 的所有组合

$$\begin{bmatrix} a_1 \\ a_2 \end{bmatrix} \times \begin{bmatrix} b_1 \\ b_2 \end{bmatrix} = \begin{bmatrix} a_1 b_1 & a_1 b_2 \\ a_2 b_1 & a_2 b_2 \end{bmatrix}$$

PruneForTop1

保留得分最高的结果

$$\begin{array}{r} \boxed{0.234} \leftarrow \text{top1} \\ \boxed{0.197} \\ \boxed{0.083} \end{array}$$

记录已经翻译过
的源语单词



本章主要内容

8.1

机器翻译概述

8.2

基于规则的机器翻译方法

8.3

基于统计的机器翻译方法

8.4


基于神经网络的机器翻译方法

8.5

译文质量评价



■ 神经机器翻译的现状



WMT (Workshop on Machine Translation) 冠军系统的数量



■ 神经机器翻译的现状

原文: This has happened for a whole range of reasons, not least because we live in a culture where people are encouraged to think of sleep as a luxury - something you can easily cut back on. After all, that's what caffeine is for - to jolt you back into life. But while the average amount of sleep we are getting has fallen, rates of obesity and diabetes have soared. Could the two be connected?

统计机器翻译 系统的结果

译文 1: 这已经发生了一系列的原因, 不仅仅是因为我们生活在一个文化鼓励人们认为睡眠是一种奢侈的东西, 你可以很容易地削减。毕竟, 这就是咖啡因是—你回到生命的震动。但是, 尽管我们得到的平均睡眠量下降, 肥胖和糖尿病率飙升。可以两个连接?

神经机器翻译 系统的结果

译文 2: 这种情况的发生有各种各样的原因, 特别是因为我们生活在一种鼓励人们把睡眠看作是一种奢侈的东西—你可以很容易地减少睡眠的文化中。毕竟, 这就是咖啡因的作用—让你重新回到生活中。但是, 当我们的平均睡眠时间减少时, 肥胖症和糖尿病的发病率却猛增。这两者有联系吗?




■ 神经机器翻译

- ✧ 在神经机器翻译中，词串被表示成**实数向量**，即分布式向量表示。此时，翻译就不再是在离散化的单词和短语上进行，而是在实数向量空间上计算
- ✧ 序列到序列的转化过程可以由**编码器-解码器**（Encoder Decoder）框架实现
 - 编码器把源语言序列进行编码，并提取源语言中的信息进行分布式表示
 - 解码器把这种信息转换为另一种语言的表达



■ 神经机器翻译

- ✧ 通过编码器，源语言序列经过多层神经网络编码生成一个向量表示，即图中的向量 (0.2, 1, 6, 5, 0.7, 2)
- ✧ 解码器把这个向量解码成目标语言序列



- ✧ 注意，目标语言序列的生成是逐词进行的，即在生成目标序列中的某个词时，该词的生成依赖之前生成的单词




■ 基于循环神经网络的翻译模型

✧ 神经机器翻译要解决的一个基本问题：**序列表示问题**

中午 没 吃饭 ， 又 刚 打 了 一 下 午 篮 球 ， 我 现 在 很 饿 ， 我 想_____。

对序列中某个位置的答案进行预测时需要记忆当前时刻之前的序列信息 → **循环神经网络**




对于序列中的任意时刻，都有一个循环单元与之对应，它会融合当前时刻的输入和上一时刻循环单元的输出，生成当前时刻的输出



■ 基于循环神经网络的翻译模型

✧ 模型结构



目标: 在给定源语言句子 x 的情况下, 找出翻译概率最大的目标语言译文 $\hat{y} = \arg \max_y P(y|x)$

用 $x = \{x_1, \dots, x_m\}$ 表示输入的源语言单词序列, $y = \{y_1, \dots, y_n\}$ 表示生成的目标语言单词序列

等价于


$$P(y|x) = \prod_{j=1}^n P(y_j | y_{<j}, x) \quad y_{<j} = \{y_1, \dots, y_{j-1}\}$$



■ 基于循环神经网络的翻译模型


✧ 求解 $P(y_j|y_{<j}, x)$ 的三个基本问题

- ① 如何对 x 和 $y_{<j}$ 进行分布式表示，即词嵌入。
- ② 如何在词嵌入的基础上获取整个序列的表示，即句子的表示学习
- ③ 如何得到每个目标语言单词的概率，即译文单词的生成（当前时刻所有单词的分布）



基于 RNN 的隐层状态 s_i
预测目标词的概率
通常，用 Softmax 函数
实现 $P(y_i|...)$

每个词的 One-hot
离散化表示都被转化为
实数向量，即词嵌入
($e_x()$ 和 $e_y()$ 函数)




源语编码器最后一个
循环单元的输出被
看作是句子的表示，
记为 C



■ 基于循环神经网络的翻译模型


✧ 长短时记忆 (Long Short-term Memory, LSTM) 网络

- 随着序列变长, RNN 的记忆信息的**损失**越来越严重
- RNN 模型的一种改进: 相比RNN 仅传递前一时刻的状态 h_{t-1} , LSTM 会同时传递两部分信息: 状态信息 h_{t-1} 和**记忆信息 c_{t-1}** (显性地记录需要记录的历史内容)
- LSTM 通过 “门” 单元来动态地选择遗忘多少以前的信息和记忆多少当前的信息



遗忘门
 $f_t = \sigma([h_{t-1}, x_t]W_f + b_f)$

记忆更新
 $c_t = f_t \odot c_{t-1} + i_t \odot \hat{c}_t$



输入门
 $i_t = \sigma([h_{t-1}, x_t]W_i + b_i)$
 $\hat{c}_t = \text{Tanh}([h_{t-1}, x_t]W_c + b_c)$

输出门
 $o_t = \sigma([h_{t-1}, x_t]W_o + b_o)$
 $h_t = o_t \odot \text{Tanh}(c_t)$




■ 基于循环神经网络的翻译模型

✧ 双向模型

- **单向模型的缺陷**：在处理一个单词的时候只能访问它前面的序列信息，从最后一个词来看，第一个词的信息可能已经很微弱

双向得到的结果融合后传递给解码器




基于双向循环神经网络的机器翻译模型结构



■ 基于循环神经网络的翻译模型

✧ 多层神经网络



- 单层循环神经网络对输入序列进行了抽象，为了得到**更深入的抽象能力**，可以把多个循环神经网络叠在一起，构成多层循环神经网络



基于双层循环神经网络的机器翻译模型结构



■ 基于卷积神经网络的翻译模型



0	0	0	0	0	0	0	0
0	0	0	1	0	2	1	0
0	0	1	2	4	2	2	0
0	2	0	1	4	0	0	0
0	1	2	3	2	0	0	0
0	2	0	0	1	5	2	0
0	1	1	2	0	2	2	0
0	0	0	0	0	0	0	0

0	1	1
1	0	0
0	1	0

0	1	2	5	2	4
2	1	3	8	7	3
2	7	9	9	8	2
4	2	7	8	7	2
4	8	7	2	3	7
2	1	2	8	7	4

输入: 8×8 (填充后)

卷积核: 3×3

输出: 6×6

1	0	4	5
5	6	7	8
3	2	1	0
1	2	3	4

6	8
3	4

输入: 4×4

输出: 2×2

(a) 最大池化

1	0	4	5
5	6	7	8
3	2	1	0
1	2	3	4

3	6
2	2

输入: 4×4

输出: 2×2

(b) 平均池化


在NLP任务中, 深层网络的特征向量包含的语义信息较多, 选取**平均池化**方法更适合




■ 基于卷积神经网络的翻译模型

■ 面向序列的卷积操作

- **RNN**: 每一时刻的计算都依赖于上一时刻的结果, **效率低**; 在处理较长的序列时, 串行的方式很难捕捉**长距离**的依赖关系
- **CNN**: 不同位置的卷积操作之间没有相互依赖; 可以通过堆叠多层卷积层来扩大**感受野**



(a) 循环神经网络的串行结构




(b) 卷积神经网络的层级结构

串行及层级结构对比 (e_i 表示词嵌入, 0 表示 0 向量, 方框里的 2、3、4 表示层次编号)



- 基于卷积神经网络的翻译模型
 - 序列卷积在文本分类模型中的应用




- 模型的输入是 $m \times O$ 的句子表示， m 表示句子长度， O 表示卷积核通道数，其值等于词嵌入维度；
- 模型使用多个不同（对应图中不同的颜色）的卷积核来对序列进行特征提取，得到了多个不同的特征序列



■ 基于卷积神经网络的翻译模型

■ 机器翻译中的序列卷积操作

- 基于CNN的神经机器翻译模型需要堆叠多个卷积层进行远距离的依赖关系的建模



- 针对一个长度 $m = 6$ 的句子，其隐藏层表示维度即卷积操作的输入通道数是 $O = 4$ ，卷积核大小为 $K = 3$ 。首先对序列进行填充，得到一个长度为8的序列，然后使用这些卷积核在这之上进行特征提取。一共使用了 $N = 4$ 个卷积核，整体的参数量为 $K \times O \times N$ ，最后的卷积结果为 $m \times N$ 的序列表示。



■ 基于卷积神经网络的翻译模型

✧ 基于卷积神经网络的翻译建模


- Convolutional Sequence to Sequence Learning (ConvS2S) 模型结构

多步注意力机制 (Multi-step Attention)
捕捉两个序列之间不同位置的对应关系

残差连接 (Residual Connection)
确保每个隐藏层输出都能包含输入序列中的更多信息，同时能够有效提高深层网络的信息传递效率

卷积层与门控线性单元
通过门控机制对卷积输出进行控制，使隐藏层状态能够获得长时间记忆

位置编码 (Position Encoding)
更好地引入序列的词序信息



2017年5月，Facebook AI Research发布了一篇论文《Convolutional Sequence to Sequence Learning》，宣告其在机器翻译任务中取得了state-of-the-art的成果。在该文章中，特别强调了该文章所提出的模型（简称ConvS2S）不仅仅在翻译任务上效果显著，而且所需训练时间也很短。然而，仅仅一个月之后，Google团队就发布了另一篇论文《Attention is All You Need》，将机器翻译任务中state-of-the-art的水平提高了2BLEU。而且，Google的这篇论文还特别强调了其不仅在翻译效果上超越了ConvS2S，而且，其模型（Transformer）所需的训练时间也比ConvS2S要更短。




■ 基于自注意力的翻译模型

✧ CNN & RNN

- 对序列中不同位置之间的依赖关系的建模并不直接
- 例如：CNN如果要对长距离依赖进行描述，需要多层卷积操作，而且不同层之间信息传递也可能有损失，这些都限制了模型的能力

✧ Transformer

- 不依赖任何循环单元或者卷积单元
- 使用一种被称作自注意力网络的结构来对序列进行表示
- 自注意力机制可以非常高效的描述任意距离之间的依赖关系，因此非常适合处理语言文字序列
- 机器翻译中最先进的架构之一



本章主要内容

8.1

机器翻译概述

8.2

基于规则的机器翻译方法

8.3

基于统计的机器翻译方法

8.4


基于神经网络的机器翻译方法

8.5

译文质量评价



一种对译文
置信度和可
能性的估计



当需要对系统进行准确的评估时，往往采用人工评价

本章小结

从基于规则、统计的模型到如今基于神经网络的模型，机器翻译任务已经经历了数十年的发展并取得了辉煌的成绩。伴随着硬件计算能力的提升和大规模训练数据的积累，我们在很多富资源语言的翻译问题上已经能够实现很好的翻译效果。尽管如此，机器翻译领域中仍存在着很多问题尚未解决，包括神经网络结构优化、低资源翻译、多模态翻译等方面。