



中山大學 人工智能学院
SUN YAT-SEN UNIVERSITY SCHOOL ARTIFICIAL INTELLIGENCE

「自然语言处理」

第 9 章 文本分类与情感分析

赵宝全

中山大学人工智能学院

2026年春季学期

本章主要内容

9.1

文本分类概述

9.2

传统的文本分类方法

9.3

基于深度学习的文本分类方法

9.4

情感分析

本章主要内容

9.1

文本分类概述

9.2

传统的文本分类方法

9.3


基于深度学习的文本分类方法

9.4

情感分析



- **文本分类** (Text Classification) 任务是根据给定文档的内容或主题，自动分配预先定义类别标签
- 文本分类是自然语言处理和文本挖掘的核心任务





■ 文本分类场景

- ✧ **多分类** 🧑 : 数据集的标签集含有两个或两个以上的类别, 所有输入句子/文本有且只有一个标签
- ✧ **多标签** 🧑 : 数据集的标签集含有两个或两个以上的类别, 输入句子/文本具有一个或多个标签
- ✧ **层次分类** 👤 : 数据集的标签集具有多级标签且标签之间具有层级结构关系, 输入句子/文本具有一个或多个标签

多分类(Multi Class)

7月5日, 周杰伦新专辑《最伟大的作品》开启预约, 目前, QQ音乐上已经有超过270万人参与了预约。据悉, 《最伟大的作品》7月6日迎来MV首播, 7月8日会开启专辑预售, 7月15日专辑将正式上线




多标签(Multi Label)

7月5日, 日本相机暨影像产品协会最新的统计报告出炉, 今年5月份全球数码相机出货量相较去年同期下跌63.7万台, 约10.4%。受全球芯片缺货的影响, 数码相机已经连续10个月出现市场萎缩迹象, 月总出货量连续18个月不足百万台。



层次分类(Hierarchical)

7月6日, 据《足球报》报道, 中超联赛大概率延期到8月6日前后开启, 参加东亚杯的国脚预计缺席一轮中超。






■ 文本分类的应用场景

- ✧ 情感分析: sentiment analysis (SA)
- ✧ 话题标记: topic labeling (TL)
- ✧ 新闻分类: news classification (NC)
- ✧ 问答系统: question answering (QA)
- ✧ 对话行为分类: dialog act classification (DAC)
- ✧ 自然语言推理: natural language inference (NLD)
- ✧ 关系分类: relation classification (RC)
- ✧ 事件预测: event prediction (EP)




■ 邮件分类





商品正负面评论识别





商品管理


- “夏装雪纺条纹短袖t恤女春半袖衣服夏天中长款大码胖mm显瘦上衣夏” → “女装/女士精品>>蕾丝衫/雪纺衫”






■ 智能客服QA平台意图识别

- 自动识别用户反馈的问题的类别，如产品质量问题、快递问题、产品描述问题等，并基于问题类别自动回复内容





- ✧ What 6.5 million of #coronavirus tweets and Deep Topological Analysis reveal about people' s thoughts during the pandemic





■ 其它

- **内容审核**（广告检测、灌水评论检测等）
- **商品正负面评论识别**
- **购买意愿识别**（根据用户发表的微博等信息判断是否有购买某商品的意愿）
- **案件描述分类**（根据民警的案件录入信息，自动判断案件是什么类型的案件，如短信诈骗、网络诈骗、熟人诈骗等）
-

本章主要内容

9.1

文本分类概述

9.2

传统的文本分类方法

9.3


基于深度学习的文本分类方法

9.4

情感分析



- 整个文本分类问题拆解为**特征工程**和**分类器**两个主要部分





■ TF-IDF (term frequency-inverse document frequency)

- ✧ 一种用于信息检索与数据挖掘的常用加权技术，常用于挖掘文章中的关键词，而且算法简单高效
- ✧ **基本思想**：如果某个单词在一篇文章的出现的频率很高，同时在其他文章中很少出现，则认为该单词大概率是一个关键词

$$\text{tf-idf}(w) = \text{tf}(d, w) * \text{idf}(w)$$

文档d中w的词频

$$\log \frac{N}{N(w)}$$

考虑单词w的重要性

N: 语料库中文档总数

N(w): 词语w出现在多少个文档?



■ TF-IDF (term frequency–inverse document frequency)

句子1: 今天 上 NLP 课程

句子2: 今天 的 课程 有 意思

句子3: 数据 课程 也 有 意思

词典的长度 |词典|=9 :

[今天, 上, NLP, 课程, 的, 有, 意思, 数据, 也]

把每个句子用TF-IDF向量表示


$$S1 = (\frac{1}{4} * \log \frac{3}{2}, \frac{1}{4} * \log \frac{3}{1}, \frac{1}{4} * \log \frac{3}{1}, \frac{1}{4} * \log \frac{3}{3}, 0, 0, 0, 0, 0)$$

$$S2 = (\frac{1}{5} * \log \frac{3}{2}, 0, 0, \frac{1}{5} * \log \frac{3}{3}, \frac{1}{5} * \log \frac{3}{1}, \frac{1}{5} * \log \frac{3}{2}, \frac{1}{5} * \log \frac{3}{2}, 0, 0)$$

$$S3 = (0, 0, 0, \frac{1}{5} * \log \frac{3}{3}, 0, \frac{1}{5} * \log \frac{3}{2}, \frac{1}{5} * \log \frac{3}{2}, \frac{1}{5} * \log \frac{3}{1}, \frac{1}{5} * \log \frac{3}{2})$$



■ 基于决策树的文本分类器



本章主要内容

9.1

文本分类概述

9.2


传统的文本分类方法

9.3

基于深度学习的文本分类方法

9.4

情感分析



- **前馈网络**。将文本视为词袋
- **基于RNN的模型**。将文本视为一系列单词，旨在捕获文本单词依存关系和文本结构
- **基于CNN的模型**。经过训练，可以识别文本分类的文本模式（例如关键短语）
- **胶囊网络**（Capsule networks）。解决了CNN在池化操作所带来的信息丢失问题





- **注意力机制**。可有效识别文本中的相关单词，并已成为开发DL模型的有用工具
- **内存增强网络**（Memory-augmented）。将神经网络与某种外部存储器结合在一起，该模型可以读取和写入
- **图神经网络**。旨在捕获自然语言的内部图结构，例如句法和语义解析树
- **暹罗神经网络**（Siamese）。专门用于文本匹配，这是文本分类的特殊情况
- **混合模型**（Hybrid models）。结合了注意力，RNN，CNN等以捕获句子和文档的局部和全局特征
- **Transformers**。比RNN拥有更多并行处理，从而可以使用GPU高效的（预）训练非常大的语言模型
- **监督学习之外的建模技术**，包括使用自动编码器和对抗训练的无监督学习，以及强化学习



■ ReNN-based 模型 (Recursive Neural Network 递归神经网络)


- ◇ 递归地学习**文本语义**和**句法树结构**，而不需要人为的设置人工特征。文本当中的单词被视作树的叶子节点，所有节点基于权值计入父亲节点当中，如此递归计算，最终形成整篇文章表征，用于预测类别标签





■ 基于多层感知机的方法 (MLP-based methods)


- ✧ 一种用于自动捕获特征的简单神经网络结构
- ✧ 包含一个输入层、一个对应所有节点带有激活函数隐藏层，一个输出层。每个节点都连接一个具有一定权重的 w_i 。它将每个输入文本视为一个词袋 (bags_of_word)





■ 基于循环神经网络的方法 (RNN-based methods)


- ✧ 利用词嵌入技术，将输入的每个词用一个特定的向量表示
- ✧ 将嵌入词向量逐个输入 RNN 单元。RNN 单元的输出与输入向量的维数相同，并馈入下一隐含层。
RNN 在模型的不同部分共享参数，并且对每个输入词具有相同的权重
- ✧ 隐藏层的最后一层输出可以预测输入文本的标签





■ 基于卷积神经网络的方法 (CNN-based methods)


- ✧ 将输入文本的词向量拼接成一个矩阵
- ✧ 将矩阵输入卷积层(Conv), 卷积层包含几个不同维度的滤波器
- ✧ 卷积层的结果经过池化层(Pooling), 并将池化结果连接起来(Concat), 得到文本的最终向量表示





■ 基于注意力机制的方法 (Attention-based methods)

- ✧ CNN 和 RNN 在文本分类相关的任务上提供了很好的结果，但缺点在于，这些模型不够直观，**可解释性较差**，特别是对于一些分类错误，由于隐藏数据的不可读性，无法解释



pork belly = delicious . || scallops? || I don't even like scallops, and these were a-m-a-z-i-n-g . || fun and tasty cocktails. || next time I in Phoenix, I will go back here. || Highly recommend.


@稀土掘金技术社区

核心目标：从众多信息中选择出对当前任务目标更关键的信息



■ 基于注意力机制的方法：HAN (Hierarchical Attention Network)


- HAN 包括两个编码器和两个层次的注意层
- 先将关键词聚合成句子向量
- 再将关键句子向量聚合成文本向量
- 通过这两个层次的注意，可以了解每个单词和句子对分类判断贡献多少





■ 基于 Transformer 的方法


- ✧ Transformer 是一种**预训练的语言模型**，可以有效地学习**全局语义表示**，并显著提高包括文本分类在内的 NLP 任务
- ✧ 通常使用**无监督**的方法自动挖掘语义知识，然后构造预训练目标，使机器能够学习理解语义





■ 基于图神经网络的方法 (GNN-based methods)

- ✧ 传统的深度学习方法在处理**非结构空间数据**上的表现难以令人满意
- ✧ 可用于学习大规模相互连接的图结构信息数据的模型
- ✧ 基于 GNN 的模型可以学习句子的句法结构，也可以进行文本分类



首先，将四个输入文本和文本中的单词定义为节点，构造成图结构。图节点由黑体边连接，黑体边表示文档—单词边和单词—单词边。每个词的权重通常是指它们在语料库中的共现频率。然后，通过隐藏层表示单词和文本。最后，可以用图预测所有输入文本的标签。

本章主要内容

9.1

文本分类概述

9.2

传统的文本分类方法

9.3

基于深度学习的文本分类方法

9.4


情感分析



人类在语言交流过程中通常富含**丰富的情感信息**，如何自动理解人类语言信息中的情感，是自然语言处理领域的研究热点与难点。

情感分析 (Sentiment analysis) 又称观点挖掘 (Opinion Mining)，目标旨在从文本中分析得到人们关于主题或实体的评价、观点或态度，还包括分析文本所表达的**情绪信息**。

情感分析包含了**评论挖掘、评价抽取、主观性分析、情绪分析**等多种不同的任务，在舆情分析、情报挖掘、电子商务、对话系统等领域具有广泛的应用。



评论	动力	外观	空间	油耗
2.0T涡轮增压发动机动力强，高速120超车没压力；外观是我和老婆都比较喜欢的款；后排空间有点小；有点费油啊。	😊	😊	😞	😞



情感分析主要包含两个主要任务：

- (1) 分析文本中针对某个主题或实体的**评价或观点**；
- (2) 分析文本中所表达的情绪类的**情感**。

虽然针对观点分析和情绪分析任务所采用的**自然语言处理算法非常类似**，但是在语言学和心理学理论中，上述问题还是有非常大的不同。

本节中将介绍常见的**观点类**和**情绪类理论模型**。



观点 (Opinion) 是指从某一立场或角度出发对事物所持的看法或态度，是一种表达了感觉、看法、信念的陈述。**观点的情感倾向**也称为**极性**，可以是正面（褒义）、负面（贬义）或中立。每种不同的情感倾向还具有不同的**强度**。

- 比如“完美”比“好”表达的褒义程度更强。

很多**副词**也具有**增强或者减弱情感倾向**的作用。

- 常见的增强词包括：{很}、{非常}、{very}、{extremely}等。常见的减弱词包括：{可能}、{一定程度上}、{slightly}、{a little bit}等。

为了区分情感的强度，还是进一步可以采用**情感评分的方法**，使用离散化的评分表达情感的强度。

- 比如，可以将情感分为5档（1-5分），1分表示强烈负面，2分表负面，3分表示中立，4分表示正面，5分表示强烈正面。

观点从语言学、心理学等不同角度划分为不同类型，包括：**常规型观点**和**比较型观点**、**显式观点**和**隐式观点**、**感性观点**和**理性观点**等。



常规型观点通常简称为观点，是指通过直接或间接的方式对事物所表述的观点。

- 例如：
- (1) 这家餐厅非常差。
 - (2) 更换了这台显示器后，我的眼睛感觉非常舒服。

句子 (1) 是直接观点，直接针对餐厅表述了句子作者的负面评价；句子 (2) 是间接观点，通过描述眼睛的感受，间接的表达了对显示器的正面评价。

比较型观点 (Comparative Sentiment) 通常简称为观点，是指对两个或更多事物之间的相同或者不同点进行比较，并表达了观点持有者对其中一个事物的态度。

- 例如：
- (1) 这家餐厅的环境比人民路上那家的好很多。
 - (2) 新一代的显卡的显存相较于上一代有了大幅度的提升

两句中，虽然都没有对实体直接给出评价，但是对实体在某个属性上给出排序。



显式观点 (Explicit Sentiment) 是指在句子中通过常规观点或比较型观点句子直接对观点、看法、感受进行表达的句子。

- 例如：
- (1) 不错，交通便利，方便出行！
 - (2) 展馆太小了，场景少，一般般。

观点持有者直接表达了自己的感受和评价，都属于典型的显式观点。

隐式观点 (Implicit Sentiment) 是指在客观或者真实的事实陈述中蕴含的常规型或比较型的观点。

- 例如：
- (1) 该款电动车续航里程可达1000公里。
 - (2) 雪山脚下的一个景点，从进门到出去给了半个小时游览。

两个句子都是在描述事实，虽然没有使用包含情感的词语，但是也表达了观点持有者的态度。隐式观点虽然在观点句中的占比不高，但是由于是否包含观点以及观点极性分类通常需要依赖常识，使得隐式观点的识别和分类的难度很高。



理性情感 (Rational Sentiment) 是指观点来源于理性的推理，不包含主观情绪。

- 例如：
- (1) 笔记本电池不错，可以连续使用40小时。
 - (2) 酒店环境很好，距离沙滩仅有200米。

虽然都包含主观性表达的观点，但都是根据相对理性的方式以客观事实为依据的理性推理。

感性情感 (Emotional Sentiment) 是指观点来源于观点持有者的感性的主观表达。

- 例如：
- (1) 这个酒店太垃圾了。
 - (2) 这是最好的车。

与理性情感相比，感性情感通常更加强烈，在整体评论中的数量也更多。



情绪 (Emotion) 是人们对外界刺激所产生的反映，由多种感觉、思想以及行为综合产生的生理和心理状态。包括喜爱、欢乐、悲伤等。

由于自然语言的复杂性和人类情绪的多边形，不同领域的研究学者对情绪类别的划分也有不同。我国古代《礼记》中就对人的情绪进行了“七情”划分：喜、怒、哀、惧、爱、恶、欲。心理学的理论学者Parrott把情绪进行了更细粒度的花费，不仅仅给出了基本情绪，还给出了二级乃至三级等更细粒度的情绪。

基本情绪	二级情绪类型	三级情绪类型
Anger	Disgust	Contempt, loathing, revulsion
	Envy	Jealousy
	Exasperation	Frustration
	Irritability	Aggravation, agitation, annoyance, crosspatch, grouchy, grumpy
	Rage	Anger, bitter, dislike, ferocity, fury, hatred, hostility, outrage, resentment, scorn, spite, vengefulness, wrath
	Torment	Torment
Fear	Horror	Alarm, fear, fright, horror, hysteria, mortification, panic, shock, terror
	Nervousness	Anxiety, apprehension(fear), distress, dread, suspense, uneasiness, worry
Joy	Cheerfulness	Amusement, bliss, gaiety, glee, jolliness, joviality, joy, delight, enjoyment, gladness, happiness, jubilation, elation, satisfaction, ecstasy, euphoria
	Contentment	Pleasure
	Enthrallment	Enthrallment, rapture
	Optimism	Eagerness, hope
	Pride	Triumph
	Relief	Relief
	Zest	Enthusiasm, excitement, exhilaration, thrill, zeal

Love	Affection	Adoration, attractiveness, caring, compassion, fondness, liking, sentimentality, tenderness
	Longing	Longing
	Lust/sexual desire	Desire, infatuation, passion
Sadness	Disappointment	Dismay, displeasure
	Neglect	Alienation, defeatism, dejection, embarrassment, homesickness, humiliation, insecurity, insult, isolation, loneliness, rejection
	Sadness	Depression, despair, gloom, glumness, grief, melancholy, misery, sorrow, unhappy, woe
	Shame	Guilt, regret, remorse
	Suffering	Agony, anguish, hurt
Surprise	Sympathy	Pity, sympathy
	Surprise	Amazement, astonishment

表 9.1 基本情绪类型、二级情绪和三级情绪^[455]。



2001年，心理学家Plutchik基于进化规则的综合理论，提出了多维度情绪模型。该模型定义了8种基本情绪，分为4对双向组合：高兴与悲伤、愤怒与恐惧、信任与厌恶、诧异与期望（Joy vs. Sadness, Anger vs. Fear, Trust vs. Disgust, Surprise vs. Anticipation）。




图9.1 给出了Plutchik模型的情绪类别在“情绪轮”上的排序，其中颜色深浅代表这种情绪的饱和度，离圆心的远近代表情绪的强度。

在Plutchik情绪理论中，每种情绪都可以分为3度，比如，宁静（Serenity）是最小程度的高兴，是不饱和状态；狂喜（Ecstasy）是最高程度的高兴，是饱和状态。此外，Plutchik还提出一种假设，认为两种相邻的基本情绪可以组合成一种**复合情绪**，比如，快乐（Joy）+ 预期（Anticipation）= 乐观（Optimism）。



情感分析包含非常多各种类型任务，从任务的类型层面可以划分为情感分类和情感信息抽取两大类。从语言单元层面又可以划分为**篇章级情感分析** (Document-Level Sentiment Analysis)，**句子级情感分析** (Sentence-Level Sentiment Analysis) 和**属性级情感分析** (又称方面级情感分析，Aspect-Level Sentiment Analysis) 。




图 9.2 基于维度空间表示方法



情感分类任务 (Sentiment Classification) 的目标是根据给定文本内容，识别所蕴含的情感或观点，并确定情感的类别或观点倾向性。

主要任务包括：**主客观识别、情感极性判断、情感强度判断、情绪分类等。**

主客观分类 (Subjective Classification)，又称观点识别 (Opinion Identification)，目标是判断给定的文本是否包含情感或观点，即判断文本是主观性 (Subjective) 还是客观性 (Objective)。

例如：(1) 味道不错！团购很实惠。

(2) 复旦大学校名取自《尚书大传》之“日月光华，旦复旦兮”。

句子(1)是主观性句子，表达了用户的观点；句子(2)是客观性句子，没有表达任何观点或态度。



极性分类 (Polarity Classification) 目标是判断给定的文本情感或观点的情感极性，即判断文本的情感是**正面（褒义）**、**负面（贬义）**还是**中性**。

例如： (1) 环境相当不错，业务水平很专业。
(2) 实在是很坑的一个景区。
(3) 地理位置也还可以。

句子(1)是正面评价；句子(2)是负面评价；句子(3)是中性评价。需要特别说明的是中性评价不等同于客观性文本，只是句子所表达的情感极性并不能归于正面和负面。

情绪分类 (Emotion Classification) 目标是判断给定的文本蕴含的情绪类别，即判断文本中情绪是喜、怒、哀、恶等。情绪类别需要根据在上节中介绍的情绪模型进行选择。

例如： (1) 我的心里绽开了朵朵鲜花，就要蹦出来似的。
(2) 钟表，可以回到起点，却已不是昨天。

句子(1)是表达了快乐的情绪；句子(2)表达了悲伤的情绪。



情感强度判别 (Sentiment Strength Detection) 目标是判断给定文本的情感强度，即判断文本的情感是强烈正向、正向、中性、负向、强烈负向等。根据上节中介绍的观点模型，也可以采用分数表示情感强度。

- 例如：
- (1) 这地方交通不太方便了。
 - (2) 这地方交通实在是太不方便了。

句子(1)表达了负面的情感；句子(2)表达了强烈的负面情感。

根据语言单元粒度不同，上述情感分类任务可以划分为篇章级、句子级和属性级，即篇章级主客观分类、句子级情绪分类、属性级情感强度判别等。

- **篇章级和句子级**的主要不同在于所处理的**文本粒度不同**。
- **属性级的情感分类**任务所处理的文本可能是篇章或者句子，但是目标并不是判断整个句子或者篇章整体的情感，**而是判断文本内容中关于该属性的情感类别或情感极性**。



情感信息抽取 (Sentiment Information Extraction)，也称评价要素抽取 (Opinion Elements Extraction)，目标是抽取文本中表达情感的核心要素，如**评价词**、**评价对象**、**观点持有者**、**评价搭配**等。

相较于情感分类任务，情感信息抽取**可以获得结构化的情感信息**。

情感信息抽取任务也与**属性级情感分类任务**有紧密联系，可以在情感抽取的基础上完成属性级观点识别等任务，利用抽取出的评价词以及评价搭配使得属性级观点识别**具有一定的可解释性**。

例如： 懂车会：车窗 采用无边框玻璃设计，很酷，但吹毛求疵一点，隔音 不算太好。

观点持有者 评价对象 评价词 评价对象 评价词



评价词抽取 (Opinion Word Extraction) 目标是抽取文本中所使用的评价词。上例中，“很酷”和“不算太好”都属于评价词。

评价搭配抽取 (Opinion Collocation Extraction) 目标是识别文本中评价对象所对应的评价词。可以使用二元组表示<评价对象, 评价词>。上例中,<车窗, 很酷>以及<隔音, 不算太好>都属于评价搭配。

评价搭配极性判别 (Opinion Collocation Polarity Classification) 目标是判断某个评价搭配的情感极性。上例中,“车窗”与“很酷”是正面评价,“隔音”与“不算太好”是负面批评价。

观点持有者抽取 (Opinion Holder Extraction) 目标是抽取文本中观点的持有者。

上例中,“懂车会”作为作者给出了上述评价,属于观点持有者。大部分情况下观点持有者是文章的作者,不一定体现在当前的文本中。还有一些文章中引用了他人的评价,观点持有者就应该是所引用的内容的作者。

例如: 懂车会: 车窗 采用无边框玻璃设计, 很酷, 但吹毛求疵一点, 隔音 不算太好。

观点持有者 评价对象 评价词 评价对象 评价词



观点摘要 (Opinion Summarization) 是以评价对象以及以针对评价对象的观点为中心进行的单文档或多文档摘要。

观点摘要不仅可以与普通文本摘要类似，由抽取的重要句子或生成的文本构成摘要，还可以采用情感信息抽取获得的结构化数据进行综合后可可视化的形式。




图9.3 基于属性的观点摘要样例



辩论立场检测 (Stance Detection) 目标是从辩论文本中识别用户对于某个辩论主题的立场，即用户是支持这个主题还是反对这个主题。

这项工作与属性级关系分析较为类似，但是不同是产品的属性通常是预先定义的有限集合，而论辩主题多种多样，通常无法预先定义。

例如：“爆竹声中一岁除，春风送暖入屠苏。”春节燃放烟花爆竹，自古以来就是中国人的传统习俗。不过近几年来，随着“双禁”的规定越发严格，过年没有鞭炮声，过年越来越没有年味儿了。

垃圾评论检测 (Spam Review Detection) 目标就是根据评论内容和评论发布者的行为等信息识别虚假信息。不同于其他垃圾信息识别，虚假评论仅从内容层面非常难进行判断，**需要结合用户个体和群体行为**才能进行有效的判别。



篇章级情感分析 (Document-level Sentiment Analysis)，也称为文档级情感分析

主要任务包括**篇章级主客观分类**、**篇章级极性分类**、**篇章级情绪分类**以及**篇章级情感强度判断**等情感分类任务。相关分类的目标可以根据本章情感分析概述部分所介绍的观点模型和情绪模型决定。但是，无论分类目标如何，篇章级情感分析任务的可以定义为：**对于给定的篇章，预测其所对应的情感标签。**

篇章级情感分析将整篇文档看做一个整体，**通常假设整个文档仅对一个实体进行评论**，并不对文档中具体的实体或属性进行细粒度分析。

- 篇章中不仅包含主观性的评论内容，**也包含客观性的事实描述**。比如，电影评论中很可能包含一些对电影情节的描述内容，而这些细节描述中也可能包含大量的情感用语。
- 篇章中除了包含对主要实体或主题的整体评论描述外，也很可能**包含对其属性的评价以及其他相关事物的评价**。



篇章级情感分析通常转换为**文本分类**问题，因此**绝大多数有监督机器学习**方法都可以应用于该任务。基于特征的统计机器学习方法，包括朴素贝叶斯、最大熵、支持向量机（Support Vector Machine, SVM）等也都适用于该任务。

对于给定数据集 $\mathbb{D} = \{(d_1, y_1), (d_2, y_2), \dots, (d_m, y_m)\}$ ， d_i 表示篇章内容， $y_i \in \{-1, +1\}$ 是分类标签。

情感极性分析， $y_i = +1$ 表示褒义， $y_i = -1$ 表示贬义

主客观分析， $y_i = +1$ 表示主观， $y_i = -1$ 表示客观

首先将文档 d_i 转换为特征表示，在此基础上利用机器学习算法进行分类



应用于情感分析任务的常见特征：

词性：每一个词的词性特征。形容词和副词是观点和情感的主要承载词，因此可以通过词性信息的引入使得模型可以利用该特征给相关词语更高的权重。

情感词和情感短语：在语言中表达了积极或者消极情感的词语。例如：好、很棒等是褒义词，坏、糟糕等是贬义词。可以利用情感词典将此类单词识别后加入特征。


观点的规则：文本结构和语言成分可以表示隐含情感和观点。可以通过人工设计的规则抽取此类特征加入向量表示中。

情感转置词：可以反转文本中情感倾向的词语或短语。比如否定词可以把正面的情感倾向改变为负面的情感倾向。这类词语可以单独加入提取后加入到向量表示中。

句法分析树：通过句法分析获得的句法分析树或者子树。可以通过将句法路径、句法树片段使用类似n-gram的方法转换为向量加入向量表示。此外，SVM中树核（Tree Kernel）方法也可以直接在树结构上进行计算。



利用上述方法将文档 d_i 转换为对应的特征表示 $\mathbf{x}_i$ 后，可以采用SVM方法构建分类算法。




$$\min_{w,b} \frac{1}{2} \|\mathbf{w}\|^2$$

$$\text{s.t. } y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m$$

9.4.3 基于层次结构的篇章级情感分析



篇章具有层次结构，由单词组成句子，再由句子构成篇章。基于这种层次结构，文献[469]中提出了**层次注意力网络模型**（Hierarchical attention networks, HAN）用于篇章级别情感分析方法。



HAN算法的神经网络结构如左图所示，主要包含四个部分：单词序列编码，单词级别注意力，句子序列编码，句子级别注意力。



🏠 HanLP / 🔄 演示 / 📖 情感分析

📖 情感分析


请输入一段中文文本：

“这是一部男人必看的电影。”人人都这么说。但单纯从性别区分，就会让这电影变狭隘。《肖申克的救赎》突破了男人电影的局限，通篇几乎充满令人难以置信的温馨基调，而电影里最伟大的主题是“希望”。当我们无奈地遇到了如同肖申克一般囚禁了心灵自由的那种囹圄，我们是无奈的老布鲁克，灰心的瑞德，还是智慧的安迪？运用智慧，信任希望，并且勇敢面对恐惧心理，去打败它？经典的电影之所以经典，因为他们都在做同一件事——让你从不同的角度来欣赏希望的美好。

215/1000

情感分析

情感极性



<https://hanlp.hankcs.com/demos/sentiment.html>



句子级情感分析 (Sentence-level Sentiment Analysis) 主要任务包括**句子级主客观分类**、**句子级极性分类**、**句子级情绪分类**以及**句子级情感强度判断**等情感分类任务。

给定一个句子 s ，句子级情感分析旨在预测句子对应的情感标签 y 。与篇章级情感分析类似， y 一般指**积极**、**消极**或者**中性**标签。也可以采用**连续分数**的形式对句子的情感程度进行评分。

与篇章级情感分析任务类似，句子级情感分析虽然包含很多任务，但是所采用的方法非常类似。

相较于篇章级情感分析，句子级情感分析则更精细化一些，将每个句子看做一个整体。通常情况下一个句子级仅对一个实体进行评论。相较于篇章级情感分析中需要对主次实体进行区分的难题，由于该现象在单个句子中出现次数较少，因此句子级情感分析中该问题造成影响相对并不严重。



句子级情感分析还要**面临新的难题**，主要包含以下几个方面：

- 1) 句子**长度短**；
- 2) **隐式情感**表达占比高；
- 3) 条件、对比等复杂情况多。

句子中包含的单词数量少很多，还包含反讽、双重否定等复杂语言现象，这就要求模型必须具备充分利用句子中有效的语义信息。

隐式观点表达相较于包含明确情感词的显式观点表达的识别难度大很多，很多情况下还需要基于尝试才能对情感极性进行判断，而**隐式观点在句子级情感分析中的占比很高**，根据在SemEval-2014语料集占比**达到30%左右**，这也对句子级情感分析带来了很大的困难。此外，句子级情感分析主要关注一般性的分类问题，但是对于条件、对比等复杂观点句型缺乏处理能力。




SO-CAL (Semantic Orientation CALculator) 是利用**情感词典对文本的情感极性进行分析**的方法，其核心是基于对文档中的每个单词或短语根据词典和规则进行评分，在此基础上综合得到文档情感倾向性极性和强度。SO-CAL采用了情感字典、情感强化和情感否定等三个方面构建了词典和规则。

- **情感字典**包含形容词（形容词短语）、名词、动词和副词。SO-CAL所采用的情感字典包含2,252个形容词，1,142个名词，903个动词和745个副词。对于表达正面情感的词和短语给了一个正的值，而对于表达负面的词给一个负的值。具体地，每一个情感词被赋予 -5（极度否定）到 +5（极度肯定）的一个值。
 - 例如：monstrosity -5 hate (noun and verb) -4 relish (verb) 4 masterpiece 5
- **情感强化**归纳了情感加强词（比如：非常、很）会增强相邻情感词的语义强度，以及情感弱化词（比如稍微、有点）会减弱相邻情感词的语义强度。文本的情感得分需要结合情感加强词来进行计算。
 - 例如：slightly -50, somewhat -30, pretty -10, really +15
- **情感否定**包含会反转情感词对应的情感极性词汇。在情感分析任务中具有重要作用。情感否定词包括not、none、nobody、never、nothing以及其他的单词
 - 例如： 这个服务并不是特别好。 特别好： +5， 并不： -4， 句子整体： $+5-4 = 1$




句子级情感分析主要是依据句子的语义内容对情感进行分类。**递归神经网络 (Recursive Neural Network, RNN)** 可以有效利用句法结构，递归的计算句子和短语组合向量表示。因此可以使用递归神经网络进行句子级情感分析。



$$p_1 = f \left(W \begin{bmatrix} b \\ c \end{bmatrix} \right), p_2 = f \left(W \begin{bmatrix} a \\ p_1 \end{bmatrix} \right)$$



基于递归神经张量网络 (Recursive Neural Tensor Network, RNTN) 在原有的单词向量表示基础上, 增加了基于张量的组合函数用于描述单词之间的组合关系。




$$p_1 = f \left(\left[\begin{matrix} b \\ c \end{matrix} \right]^T V^{[1:d]} \left[\begin{matrix} b \\ c \end{matrix} \right] + W \left[\begin{matrix} b \\ c \end{matrix} \right] \right)$$

$$p_2 = f \left(\left[\begin{matrix} a \\ p_1 \end{matrix} \right]^T V^{[1:d]} \left[\begin{matrix} a \\ p_1 \end{matrix} \right] + W \left[\begin{matrix} a \\ p_1 \end{matrix} \right] \right)$$



通用预训练模型在绝大部分自然语言处理任务上都取得了很好的效果，基于知识增强的预训练方法进一步提升了预训练模型在一些自然语言处理任务上的效果。文献[481]提出了**情感知识增强的预训练模型SKEP** (Sentiment Knowledge Enhanced Pre-training for Sentiment Analysis) 方法应用于句子级情感分析。





SKEP方法也希望通过掩盖识别输入序列中的情感信息的方法进行模型预训练。但是大规模的情感信息不能通过人工标注完成，因此SKEP方法中提出了使用**基于点互信息（Pointwise Mutual Information, PMI）的无监督方法识别情感信息**，根据词语的共现信息识别出**情感词、情感词的极性和属性词-情感词对**等情感信息。掩盖的步骤分为如下三步：

- (1) **掩盖属性词-情感词对**：在句子中随机选择最多两对属性词-情感词对掩盖。
- (2) **掩盖情感词**：在句子中随机选择不超过当前句子总词数10%的情感词进行掩盖。
- (3) **掩盖通用字**：如果情感词所占的词比例没有10%，随机选择单词补充达到总10%的掩盖比例。

SKEP预训练采用的损失函数 $\mathcal{L}$ 由三个部分组成：情感词预测目标 $\mathcal{L}_{sw}$ 、情感词极性预测目标 $\mathcal{L}_{wp}$ 和属性词-情感词对预测目标 $\mathcal{L}_{ap}$

$$\mathcal{L} = \mathcal{L}_{sw} + \mathcal{L}_{wp} + \mathcal{L}_{ap}$$

最终模型预训练完成后，应用于句子级情感分析时，使用[CLS]位置输出代表句子整体表示，在编码器上增加分类层，利用句子级情感分析语料进行模型精调。



属性级情感分析 (Aspect-level Sentiment Analysis, ABSA) 目标包含**属性级情感分类任务**和**情感信息抽取任务**两大类。

产品或实体通常具有一个或多个属性。例如，“这款手机的电池容量非常好”。这里“电池容量”就是手机的一个属性。

属性级情感分类任务包括属性级**主客观分类**、**属性级极性分类**、**属性级情感强度判断**。

- 与篇章级和句子级情感分类不同，属性级情感分类任务的输入不仅包含**文本内容 d** ，还有**目标属性 a** ，输出则为文本内容中关于目标属性的**评价词 o** 和**情感标签 y** 。

情感信息抽取任务目标则是抽取文本的中表达情感的核心要素，包括**评价词**、**评价对象**、**观点持有者**、**评价搭配**等。



相较于篇章级和句子的情感分析，属性级情感分析粒度更小，因此也称为**细粒度情感分析（Fine-grained Sentiment Analysis）**。

属性级情感分类任务有效解决了篇章级和句子级情感分类中只能对整体观点进行分析所存在的问题。在实际评论中，虽然整个篇章或句子对某个实体给出了正面评价，但不代表对每个属性都给出正面评价，反之亦然。

由于属性级情感分析任务更加精细，因此难度相较于句子级和篇章级情感分析也更大。属性级情感分析不仅要面临**句子长度短、隐式情感表达占比高**等句子级情感分析所面临的问题。在分析时还要处理句子中包含的大量与给定属性无关的内容。



情感信息抽取主要包含**属性抽取**、**观点抽取**和**情感预测**三个子任务。具体来说，给定一个文本序列 $s = w_1 \dots w_{|s|}$ ，情感信息抽取任务是抽取文本中包含的所有的属性、观点、极性三元组 $T = \{(a_i, o_i, p_i)\}_{i=1}^{|T|}$ ，其中 $|T|$ 表示样本中三元组的个数， a_i ， o_i 分别是第 i 个属性和观点，是文本序列 X 的一个子串， p_i 是该属性对应的情感极性。

传统基于无监督的情感信息抽取模型主要基于句法信息来抽取文本的属性词和评价词。一般属性词多为名词，而评价词多为形容词，且评价词往往用来修饰属性词。

例如：“华为手机拍出来的照片很好看！”。

形容词“好看”直接通过修饰语依赖于名词“照片”。通过句法修饰关系，可以知道“好看”（评价词）直接与“照片”（属性）相联系。

由于**形容词通常被认为是闭类词**，通常比较稳定，一个语言中通常很少增加新的形容词。因此，可以通过构造词典的方法来收集评价词，进而挖掘属性。



文献[486]提出通过句法规则来解决评价词字典扩展和属性扩展。通过使用依存句法分析器去扩展评价词字典和挖掘属性，使得评价词和属性建立联系。

使用双向循环的方法来使信息在评价词和属性之间不断传播。**这种方法的好处就是只需要一个初始的评价词字典即可。**

评价词字典就是包含许多的评价词的词典，例如good、excellent、poor和bad。但是使用评价词字典的缺陷就在于不可能去囊括所有的意见和领域。并且一个词可能在这个领域是积极的，在另一个领域可能就是中性的。

基于句法规则的情感信息抽取方法从已知和通过之间的迭代获得的评价词和属性中，通过识别语义上的联系，提取评价词和属性。这种使得信息在评价词和属性之间来回流动的方法称为**双向传播 (Double Propagation)**。



属性级情感分类任务关注句子中**评价对象的特定属性的情感**，也称细粒度情感分类、属性级情感分类和属性感知的情感分类。一个句子中可能包含评价对象的多个属性，并且句子中对于不同属性所表达情感可能不一致，甚至完全相反。

例如：我买了一台新相机，照片质量很好，但是电池寿命太短。


该句中关于相机的“图片质量”和“电池寿命”这两个属性的情感极性不同，同时评价词“很好”和“太短”分别用来修饰这两个属性，表达了积极和消极的情感。

属性级别情感分析任务目标是预测句子对于给定属性的情感。可以形式化定义为：给定一个包含 $|s|$ 个**单词的句子** $s = w_1 w_2 \dots w_{|s|}$ 以及一个包含 $|A|$ 个**属性的列表** $A = \{a_1, \dots, a_{|A|}\}$ ，其中每一个属性 $a_i = w_{i_1} \dots w_{i_{|a_i|}}$ 是句子 s 的一个子序列。目标是**输出**属性列表中每个属性在当前文本中的**情感极性** $P = \{p_1, \dots, p_{|A|}\}$ 。



属性级情感分类通常转化为情感要素抽取和分类两个步骤，但是两个任务级联会导致错误的传播，从而影响最终结果。

为了解决上述问题，文献[490]提出了基于生成框架的情感信息抽取和属性级情感分析统一框架，其神经网络结构如下图所示。该模型将属性级情感分析任务分为抽取和分类两个子任务，可以分别表示为指针索引和类别索引。将这两个子任务形式化到统一的生成框架下。





使用a, s, o分别表示属性词, 情感极性和评价词。上标 s 和 e 分别表示一个词开始和结束索引。例如: o^s 和 a^e 表示评价词 o 的开始索引和属性词 a 的结束索引, s^p 表示情感极性类别的索引, 根据上述标签, 每个子任务对应的目标序列如下:


属性词抽取 (AE) : $Y = [a_1^s, a_1^e, \dots, a_i^s, a_i^e, \dots]$,

评价词抽取 (OE) : $Y = [o_1^s, o_1^e, \dots, o_i^s, o_i^e, \dots]$

属性级情感分类 (AESC) : $Y = [a_1^s, a_1^e, s_1^p, \dots, a_i^s, a_i^e, s_i^p, \dots]$,

二元组抽取: $Y = [a_1^s, a_1^e, o_1^s, o_1^e, \dots, a_i^s, a_i^e, o_i^s, o_i^e, \dots]$,

三元组抽取: $Y = [a_1^s, a_1^e, o_1^s, o_1^e, s_1^p, \dots, a_i^s, a_i^e, o_i^s, o_i^e, s_i^p, \dots]$,



子任务	目标序列
AE	1, 2, 12, 12, </s>
OE	4, 4, 7, 8, 14, 14, </s>
ALSC	<u>1</u> , <u>2</u> , POS, </s> <u>12</u> , <u>12</u> , POS, </s>
AOE	<u>1</u> , <u>2</u> , 4, 4, 7, 8, </s> <u>12</u> , <u>12</u> , 14, 14, </s>
AESC	1, 2, POS, 12, 12, NEG, </s>
Pair	1, 2, 4, 4, 1, 2, 7, 8, 12, 12, 14, 14, </s>
Triplet	1, 2, 4, 4, POS, 1, 2, 7, 8, POS, 12, 12, 14, 14, POS, </s>