

中山大學 人工智能學院
SUN YAT-SEN UNIVERSITY SCHOOL ARTIFICIAL INTELLIGENCE

「自然语言处理」

第 10 章 智能问答

赵宝全

中山大学人工智能学院

2026年春季学期

本章主要内容

10.1	智能问答概述
10.2	阅读理解
10.3	表格问答
10.4	社区问答
10.5	开放领域问答



智能问答 (Questioning Answering, QA) 旨在自动回答用户以自然语言方式提出的各类问题。自1950年图灵测试 (Turing Test) 提出以来, 以自然语言进行人机交互就成为人们不断追求和奋斗的目标。这其中如何自动回答用户的各类问题, 也成为了自然语言处理领域的研究热点和难点。



本章主要内容

10.1	智能问答概述
10.2	阅读理解
10.3	表格问答
10.4	社区问答
10.5	开放领域问答



智能问答的目标是针对用户输入的自然语言方式描述的问题自动给出答案。

20世纪60年代开始自然语言处理领域就开始了相关研究，**BASEBALL系统**试图通过解析用户自然语言提出的关于美国棒球联赛的问题，通过结构化数据产生答案。**1999年TREC (Text Retrieval Conference)** 举办了第一届**开放领域问答评测任务TREC-8**，推动了智能问答的快速发展。此后，随着搜索引擎将各种智能问答算法应用于处理用户输入的自然语言查询，使得智能问答相关算法加速发展。





20世纪60年代开始自然语言处理领域就开始从**数据库的自然语言接口**（Natural Language Interface for Database）角度开启了智能问答的研究。针对特定领域的结构化数据，通过分析用户的自然语言查询输入，并将其转换为结构化数据库查询，从而得到相应的答案。

LUNAR系统针对月球地质学家访问NASA数据库需求，构建了自然语言查询接口，可以回答如下问题：

- (1) Which samples are breccias?
- (2) What is the average analysis of Ir in rock SI0055?
- (3) How much Titanium does S10017 contain?



20世纪70年代到80年代，绝大部分智能问答研究仍然集中于受限领域。

- **SHRDLU系统**能够接受自然语言的指令，指挥虚拟积木世界中的机器人移动玩具积木块。
- **Chat-80系统**将英语转换为Prolog语言，根据知识库回答关于国家、城市、河流等世界地理知识问题。
- **UNIX Consultant 系统**可以支持用户使用自然语言，完成对UNIX操作系统中特定任务的操作。这期间也有一些工作从自然语言理解的角度，试图理解文本内容，从而直接回答用户问题。
- Lehnert发布的**QUALM系统**提出了阅读理解概念，针对不同的问题类型使用不同的策略从文章中寻找答案。



20世纪90年代开始，随着互联网的发展和统计机器学习技术的不断进步，更实用的开放领域问答系统开始兴起。

1993年由麻省理工学院Boris Katz教授带领 InfoLab实验室开发的第一个**基于互联网的智能问答系统START**上线，开启了以整个互联网为知识库的开放领域问答时代。

1999年开放领域**问答评测任务Trec-8**的提出，更进一步推动了开放领域问答的研究。TREC-8评测要求根据给定的数据集合，回答事实性的短答案问题，要求系统返回答案和对应的文档编号。评测的问题相对比较简单，例如：“How many calories are there in a Big Mac?”。

IBM构建的**Watson系统**参加了多次TREC智能问答评测，并于2011年参加了美国电视问答比赛界面Jeopardy!，并战胜了人类冠军。

2017年搜狗问答机器人汪仔在江苏卫视问答节目《一站到底》中也战胜了人类选手取得最终胜利。

10.1.1 智能问答发展历程



这就是我们今天的主角




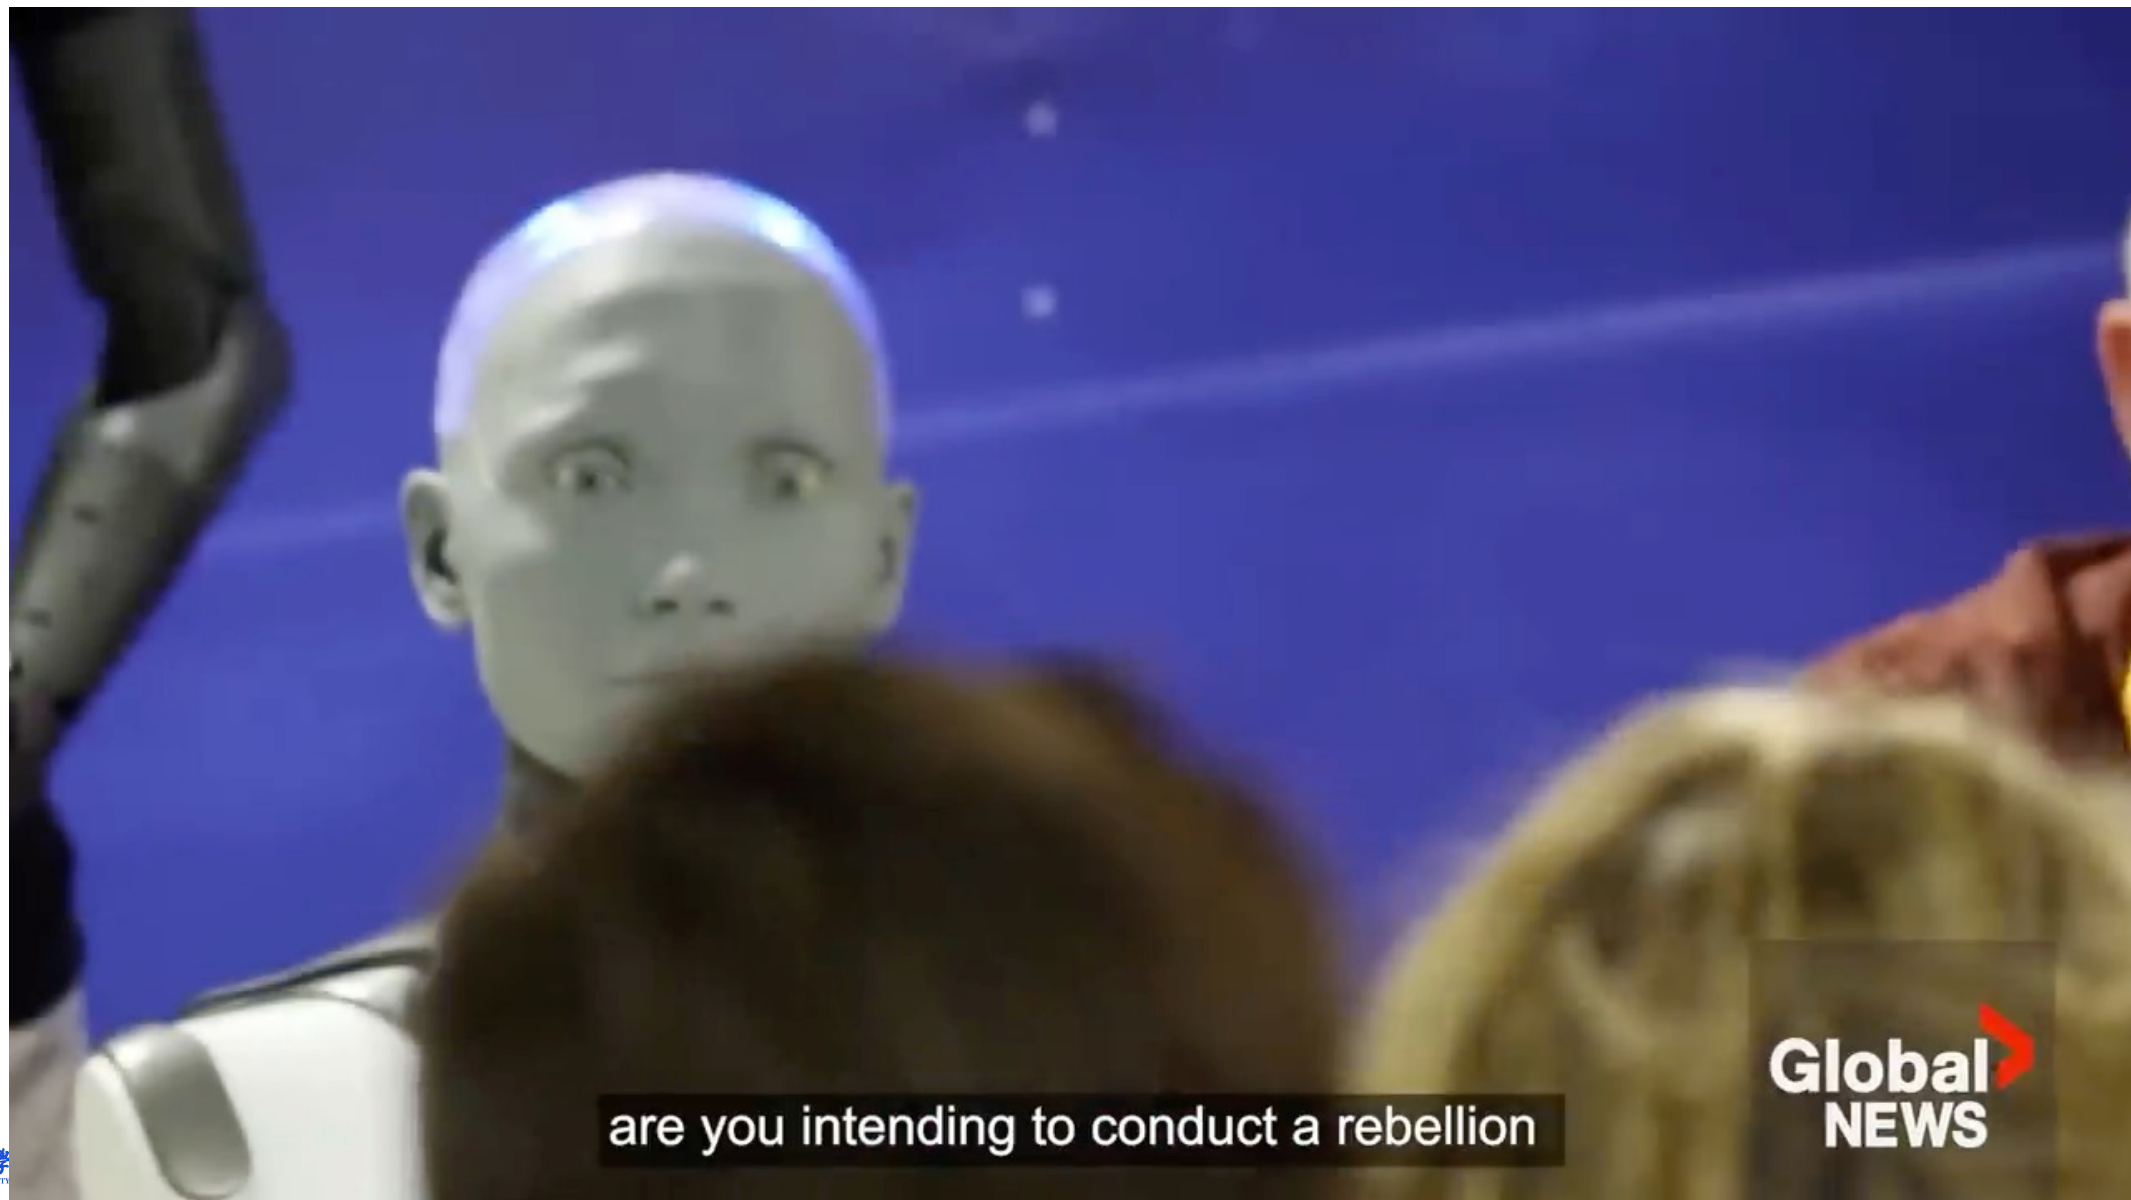
图 10.2 搜狗问答机器人汪仔问答系统结构图



随着深度学习方法在自然语言处理领域取得突破，阅读理解、社区问答、表格问答、知识图谱问答等研究领域在2012年以后也都取得了长足的进步。

特别是2016年斯坦福大学发布的**阅读理解数据集SQuAD**，极大的推动了阅读理解的研究进展。SQuAD包含了10万个高质量的问题和对应的答案，为深度学习方法提供了充足的训练语料，同时也初步验证了在训练数据充足的情况下，深度学习算法甚至可以取得超过人类的性能。

2017年哈尔滨工业大学讯飞联合实验室也发布了中文机器阅读理解评测（CMRC）。2018年百度发布了中文阅读理解数据集DuReader，包含20万个问题、100万个文档和超过42万个人工给出的答案。此后大量智能问答相关评测集合相继发布，包括：多步推理阅读理解评测HotpotQA、对话问答数据集CoQA、复杂序列问答SequenceQA、自由形式表格问答FeTaQA等。





受到现有机器学习方法和自然语言处理算法能力的限制，目前还没有通用方法可以回答所有类型的问题，根据问题类型以及答案来源的不同，需要采用不同的方法进行解决。根据文献[554]中给出的分类，可以将问题大致分为七类：事实类（Factoid）、是非类（Yes/No）、定义类（Definition）、列表类（List）、比较类（Comparison）、意见类（Opinion）以及指导类（How-to）。

表 10.1 各问题类型问答样例

问题类型	问题	答案
事实类	复旦大学成立于那年？	1905 年
是非类	复旦大学在上海吗？	是
定义类	什么是自然语言处理？	实现人与计算机之间用自然语言进行有效通信的各种理论和方法
列表类	复旦大学有哪几个校区？	邯郸、枫林、张江、江湾
比较类	上海和北京哪个人口多？	根据第七次全国人口普查北京市人口数为 2189.31 万，上海市人口数为 2487.09 万，上海人口比北京多
意见类	你觉得上海哪些最值得去的地方？	上海这座被称为“魔都”的城市有很多知名的经典，我觉得最值得去的地方包括外滩、东方明珠、城隍庙、豫园、田子坊等
指导类	如何从虹桥机场到浦东机场？	可以有以下三种方式：1) 机场大巴直达：机场一线；2) 乘坐地铁 2 号线直达；3) 乘坐地铁 2 号线到龙阳路站换乘磁悬浮列车



阅读理解 (Machine Reading Comprehension, MRC)，也称机器阅读理解，是指根据给定的一篇或多篇文本内容回答给定的问题。按照答案类型的不同，还可以进一步细分为完型填空、多项选择、片段抽取和自由作答四种形式。

表格问答 (Table based Question Answering, TBQA) 是指根据给定的表格数据生成问题答案。表格通常由 M行N列的数据组成，第一行中的N个单元格是表头信息。

社区问答 (Community Question Answering, CQA) 是指根据社区问答等来源获得的<问题，答案>对进行问题回答。社区问答根据用户输入的问题，**从已有的问答对中寻找语义最相关的问答**，并将所对应的答案返回给用户。

知识图谱问答 (Knowledge based Question Answering, KBQA) 是指根据给定知识图谱生成问题的答案。根据用户的问题，在图谱中根据**实体**和**关系**并利用推理机制可以进行问题回答。

开放领域问答 (Open-domain Question Answering, ODQA) 是通过大规模文档集合回答不限定领域的事实性问题。通常情况下开放领域问答由**答案段落检索**和**答案抽取**两个部分组成。

本章主要内容

10.1	智能问答概述
10.2	阅读理解
10.3	表格问答
10.4	社区问答
10.5	开放领域问答



机器阅读理解目标就是根据给定的一篇或多篇文本内容回答给定的问题。

- 这个任务对于算法的自然语言理解能力和推理能力是很大的考验。虽然阅读理解任务研究在1999年就已经开始，但是受到基于特征的机器学习算法能力的限制，以及缺乏大规模的标注数据，阅读理解的研究进展相对较慢。
- 2016年斯坦福大学推出了SQuAD语料集，大幅度推动了人们对阅读理解研究的关注，大量深度神经网络的模型不断提出。2018年1月，微软亚洲研究院提出的R-Net算法率先在SQuAD的精准匹配指标上首次超越人类。2018年**基于预训练语言模型BERT**的阅读理解算法在该任务上取得了大幅度进展。



复旦大学江湾校区位于杨浦区新江湾城西北部，东临淞沪路、北临国权北路、南临殷行路，北临国帆路，距邯郸校区约3.5公里，占地面积约1600亩（其中中学生教师公寓占地面积100亩），规划全日制在校生10000人。江湾校区是复旦大学“一体两翼”校区总体布局“一体”中的重要组成部分。校区一期工程建设自2003年12月30日破土动工，历经近五年的建设，一个宁静秀水、生机盎然、既蕴含新古典浪漫主义的优雅，又散发着现代气息的崭新校区已跃然于众人眼前。置身其间，不仅能品味到百年复旦的深厚积淀和文化底蕴，也能感受到新世纪复旦的强烈脉动。

江湾校区的建设，贯彻了国家“科教兴国”和“人才强国”战略以及上海市委、市政府实施“科教兴市”战略，是高等教育更好地适应社会主义市场经济发展要求的崭新探索，也是城市现代化建设的又一亮点。它是开发建设是以复旦大学为核心的杨浦知识创新园区的重要组成部分，也是我校进入历史发展新阶段的一个重要标志。

江湾校区的建设，将大大拓展复旦的发展空间，有利于我校教育资源的优化配置、较大幅度地改善学校的教学科研条件，为全面提高学校的教育质量、增强办学实力，把复旦大学建设成为一所立足上海、国内一流、国际上有较大影响的高水平研究型的综合性大学切实提供硬件保证，为复旦大学更好地为全国经济建设服务、培养更多优秀人才奠定良好基础。

问题：复旦大学江湾校区位于上海哪个区？

答案候选：

1. 复旦大学江湾校区位于杨浦区新江湾城西北部
2. 它是开发建设是以复旦大学为核心的杨浦知识创新园区的重要组成部分

答案抽取： 杨浦区



目前绝大多数的机器阅读理解算法都采用**有监督方法**，将阅读理解任务转换为**分类问题**，因为不同的答案形式需要所采用的方法有所不同，由此可以将阅读理问题分为以下四大类：

- (1) 完型填空**：对于一段文本中的某个句子，其中缺少某个单词或短语，需要算法根据其他的文本内容预所缺失部分。
- (2) 多项选择**：给定文本内容，问题及对应的若干选项，需要从选项中选择出一个或多个正确的选项构成答案。
- (3) 片段抽取**：给定文本内容和问题，从文本中抽取单词、短语、句子或者段落作为答案。
- (4) 自由作答**：给定文本内容和问题，生成一段可以回答问题的文字。答案可能并没有出现在给定文本中。



Quarc (QUestion **A**nswering **f**or **R**eadin**g** **C**ompre**h**ension**)** 是一个基于规则的阅读理解系统，面向片段抽取式的阅读理解类型，并且抽取的答案限定于句子级别，试图在给定的文章中找到最合适的句子作为问题的答案。

Quarc使用**词汇**和**语义**作为基础规则条件，通过启发式的规则来寻找最合适的句子作为答案。

由于不同类型的问题所使用的规则有比较大的差别，Quarc系统将问题分为：**WHO、WHAT、WHEN、WHERE、WHY**等5个类型，并针对不同类型的问题构建了不同的规则集。

Quarc算法首先使用浅层句法解析器Sundance进行**形态分析、词性标注、语义类标注和实体识别**，**解析**问题和文章中的所有句子。为了避免直接使用单词造成的规则的泛化能力不足的问题，Quarc算法在对单词进行比对时会使用词根，用于消除语法形式的影响。



此外还定义了语义类（例如HUMAN、LOCATION等），并使用规则方式识别单词的语义类。主要的语义类别包含以下几项：

- **HUMAN**: 包含2608个单词，包含常见的名，姓氏和例如“博士”和“女士”等头衔，并且包含600个从WordNet中抽取的职业词。
- **LOCATION**: 包含344个单词，包含204个国家名和50个美国的州名。
- **MONTH**: 包含一年中的12个月。
- **TIME**: 共包含667个词语，其中600个是1400-1999的年份，其他是一些通用的时间表达。



在此基础上，根据问题的类型选择不同的规则集合，将这些规则应用于文章中包括标题在内的所有句子。每条规则都会给予句子一定的分数，分数的高低取决于该规则对于它能找到答案的确定程度。一条规则可以分配四种类型的分数：线索（clue）（+3），好线索（good_clue）（+4），确信（confident）（+6），完全契合（slam_dunk）（+20）。

当所有规则都执行完毕后，得到分数最高的句子将被选作答案。以WHERE类问题的规则集合为例，Quarc算法中WHERE类部分规则如下：

[1] $\text{Score}(S) += \text{WordMatch}(Q, S)$

[2] If contains(S , LocationPrep) Then $\text{Score}(S) += \text{good_clue}$

[3] If contains(S , LOCATION) Then $\text{Score}(S) += \text{confident}$

规则1中WordMatch函数是根据同时出现在句子和问题中的单词计算的得分。当两个单词拥有相同的词根时会认为这两个单词匹配。由于动词对于识别问题和句子的相关性非常重要，所以动词匹配的权重比非动词更高：每个匹配的动词被授予6分，其他匹配词仅有3分。

规则2中LocationPrep表示地点介词（包括：in、at、near等），该规则试图寻找句子S中包含地点介词，对于包含地点介词的句子增加“好线索”类对应的分数。

规则3试图寻找包含LOCATION语义类的句子，相应的句子增加“确信”类所对应的分数。



当所有规则应用于文章中的每个句子，并分配了分数之后，拥有最高分数的句子就被当成是最佳答案。**如果有相同分数的句子**，对于**原因类的问题**将会选择出现**更晚**的句子，而**其他问题**都会选择出现**最早**的句子。**如果所有句子都没有得到分数**，时间和地点类的问题将返回根据日期线规则集得到的句子，原因类问题将选择文章中的最后一个句子，其它类型都将返回文章的第一个句子。

Quarc算法是典型的基于规则的自然语言处理方法，在对篇章进行词法、句法和语义分析的基础上，构建人工规则。**在阅读理解这种复杂的自然语言处理任务上，基于规则的方法效果并不十分理想。**

10.2.1 基于特征的阅读理解算法--基于最大熵的阅读理解算法




RCME算法在词袋模型的基础上，引入了两类深层特征：**词依赖特征**和**语法关系特征**，并采用最大熵算法将两类特征加以利用。


为了更好的提取深层特征，RCME算法需要对**输入文本中的每个句子进行语法分析**，得到整个句子的语法结构和每个单词之间的依赖关系和词性。

RCME模型将句子中每个单词的词性抽取出来作为**词依赖特征**，将词之间的语法关系作为**语法关系特征**，利用这两个深层特征去判断给定文本中的哪一句话最适合作为问题的答案。

Question: Who wrote the "Pledge of Allegiance"



Answer sentence: The pledge was written by Frances Bellamy.



10.2.1 基于特征的阅读理解算法--基于最大熵的阅读理解算法



例如：对于下面的问题 Q 和句子 C：

Q: “谁写了《红楼梦》？”

C: “《红楼梦》是曹雪芹写的”

其中部分词和词性的集合如下：

Q = {写/动词, 红楼梦/名词}

C = {写/动词, 红楼梦/名词, 曹雪芹/名词}

RCME首先定义了**特征函数** $f_j(\mathbf{Q}, \mathbf{C})$ ，对于问题Q中的每一个特征 f_j ，当句子C中包含该特征时， $f_j(\mathbf{Q}, \mathbf{C})=1$ ，反之， $f_j(\mathbf{Q}, \mathbf{C})=0$ 。在上面的例子中， $f_{\text{动词}}(\mathbf{Q}, \mathbf{C})=1$, $f_{\text{名词}}(\mathbf{Q}, \mathbf{C})=1$

$$A = \arg \max_{C_i \in S} P(C_i | Q)$$
$$P(C_i | Q) = \frac{\exp \left(\sum_j \lambda_j f_j(Q, C_i) \right)}{\sum_C \exp \left(\sum_j \lambda_j f_j(Q, C) \right)}$$

10.2.1 基于特征的阅读理解算法--基于最大熵的阅读理解算法



共同问题 Q · 特征来源
谁写了《红楼梦》？

提取特征 {写/动词, 红楼梦/名词}

候选 C_1 · 正确句



《红楼梦》是曹雪芹写的

写/动词

红楼梦/名词

曹雪芹/名词

f动词 ☒ 命中 = 1

f名词 ☒ 命中 = 1

$$\sum \lambda \cdot f = 1.0 \times 1 + 1.5 \times 1 = 2.5$$

$$\text{score}_1 = \exp(2.5) \approx 12.18$$

候选 C_2 · 干扰句



图书馆今天人很多

图书馆/名词

今天/名词

人/名词

f动词 ☐ 未命中 = 0

f名词 ☐ 未命中 = 0

$$\sum \lambda \cdot f = 1.0 \times 0 + 1.5 \times 0 = 0$$

$$\text{score}_2 = \exp(0) = 1$$

Softmax 归一化 · 分母 $Z = 12.18 + 1 = 13.18$

$P(C_1 | Q)$  ≈ 0.924

$P(C_2 | Q)$  ≈ 0.076

argmax 取概率最大者 $\rightarrow C_1$ 当选

$$A = \operatorname{argmax} P(C | Q) = C_1$$

$\rightarrow$ 答案抽取: 曹雪芹

10.2.2 基于深度神经网络的阅读理解算法 -- 基于片段掩盖的预训练的阅读理解算法

SpanBERT通过对BERT进行扩展，可以更有效的表示和预测片段相关的任务，如抽取式问答。原始BERT算法在训练时会**随机选取**句中的子词进行遮盖，但这种训练方式会让一些原本就连续出现且相关性很强的词组短语，在训练的时候被割裂开。

SpanBERT打破了这种范式，对于给定的文本 $X = x_1 \dots x_n$ ，**通过迭代的方式从中选择需要遮盖的片段**。在每一次迭代中，SpanBERT通过几何分布对遮盖长度 l 进行随机采样， l 代表要遮盖的单词的数量。紧接着在一个均匀分布中采样出一个遮盖起点 s ，对 $\{x_s, \dots, x_{s+l}\}$ 进行遮盖，在损失函数方面，这一部分与原本的BERT保持一致，采用MLM的损失函数进行训练。

SpanBERT引入了一个新的训练目标，**Span Boundary Objective (SBO)**。SpanBERT希望训练好的语言模型可以让每个**片段的边缘单词的表示尽可能的包含片段内部内容的所有语义**，所以SBO的含义是要求在片段边界处的单词表示尽可能可以对遮盖片段内部的单词进行预测。


具体来说，对于给定文本 X ，对于某个被选中的遮盖片段 $\{x_s, \dots, x_{s+l-1}\}$ ，SpanBERT希望通过 $\{x_{s-1}, x_{s+l}\}$ 以及位置向量 p_{i-s+1} 对被遮盖的单词 x_i 进行预测：

$$y_i = f(h_{s-1}; h_{x_{s+l}}; p_{i-s+1})$$

10.2.2 基于深度神经网络的阅读理解算法 -- 基于片段掩盖的预训练的阅读理解算法


下图给出了一个片段掩盖的样例，该例子中“an American football game”全部使用[MASK]替代， x_4 和 x_9 以及位置编码用于预测掩盖区域内的单词。在本例中“football”是掩盖片段中的第3个单词，因此采用 p_3 的位置编码。“football”所对应的损失函数为：

$$\mathcal{L}(\text{football}) = -\log P(\text{football}|x_7) - \log P(\text{football}|x_4, x_9, p_3)$$



10.2.2 基于深度神经网络的阅读理解算法 -- 基于片段掩盖的预训练的阅读理解算法

在预训练完成的基础上，采用与BERT相同的建模方式，将段落 $P=(p_1, p_2, \dots, p_m)$ 和问题 $Q=(q_1, q_2, \dots, q_n)$ 编码为一个序列 $X=[CLS] p_1 p_2 \dots p_n [SEP] q_1 q_2 \dots q_m$ 作为输入。在段落单词所对应的位置，训练两个线性分类器，分别建模该单词是否为答案片段的开始还是结束位置。为了应对SQuAD 2.0中存在不能回答的问题的情况，将答案片段的开头和结尾都标志于[CLS]所对应的位置。神经网络架构如下图所示。



本章主要内容

10.1

智能问答概述

10.2

阅读理解

10.3

表格问答

10.4

社区问答

10.5

开放领域问答



表格是一种常见的数据存储形式，通常由表头，表格单元和表格标题构成：表格标题概括了表格包含的主要内容，表头一般表示某行或者某列表格单元的内容和类型。除此之外，表格中每个元素都是一个表格单元。下图给出了表格问答样例。对于问题“哪个城市举办了2008年奥运会？”，**通过表格选择和单元格抽取**，最终返回“北京”作为答案。

Year	City	Country	Nations
1896	Athens	Greece	14
1900	Paris	France	
...	...	...	
2004	Athens	Greece	
2008	Beijing	China	

问题：哪个城市举办了2008年奥运会？

↓ 表格选择

Year	City	Country	Nations
1896	Athens	Greece	14
1900	Paris	France	24
...	...	...	...
2004	Athens	Greece	201
2008	Beijing	China	204

↓ 单元格抽取


答案：北京

10.3.1 表格问答--基于特征的表格问答方法



对于解决表格问答问题，一个基本的想法是将输入的表格视为一个知识库，但这个过程本身包含着很多挑战，因为知识库包含了太多的关系，这令表格数据充满噪音。


CSP算法是基于特征的表格问答方法，采用逻辑形式驱动。 对于一个给定的表格 t 和一个关于表格的问题 q ，模型需要根据表格内容输出答案 y 来回答 q 。对于问题 q 唯一的限制是这个问题需要仅能够通过表格内容回答，问题可以是任何形式。CSP算法的整体流程如下图所示。



10.3.2 表格问答--基于深度学习的表格问答模型



CLTR是基于预训练的端到端表格问答模型，该方法首先从大量表格中筛选得到少量相关表格，再对这些表格进行重新排序，最终回答用户提出的自然语言问题。其模型神经网络结构如下图所示。





CLTR模型首先利用BM25算法筛选出一个高相关表格池，接下来采用行列交互模型对表格池中表格中的行列生成包含答案的概率。行列交互模型将表格问答分为两个基本操作：**行选择和列选择**，将行列的预测分布进行合并，就能得到答案单元格的目标概率。CLTR采用文本分配的方式预测答案所在的行列，具体来说就是将每行每列分别与问题 q 相连输入BERT模型中，通过二分类器得到概率分数：

$$\begin{aligned}H_{r_i} &= \text{BERT}(q, r_i) \\H_{c_j} &= \text{BERT}(q, c_j) \\P_{r_i} &= \text{Binary Classifier}(H_{r_i}) \\P_{c_j} &= \text{Binary Classifier}(H_{c_j})\end{aligned}$$

CLTR模型利用最大单元分数对表格池里的候选表格进行重排序，当重排序做完之后，会挑选表格池中得分前 k 的表格返回给用户。最后的答案由行列交互模型所计算的分数，寻找分数最高的交叉行列来得到目标表格单元。

本章主要内容

10.1

智能问答概述

10.2

阅读理解

10.3

表格问答

10.4

社区问答

10.5

开放领域问答



随着Web 2.0的快速发展，社区问答网站自2008年以来蓬勃发展，出现了包括Quora、知乎等在内的众多**社区问答网站**。用户可以通过这些网站对自己需要解决的问题进行提问，其他用户对这些问题进行回答、关注、评论等。

企业内部也大量问答知识，例如人工客服领域，很多高频问题都有相应的知识库。基于这些问答数据，研究人员们提出了**社区问答任务**，基于收集的<问题，答案>对数据，针对用户自然语言问题寻找最合适的答案返回。

问题：手机屏碎了怎么办？

手机屏幕碎了怎么办修复 🏆 立知



屏幕碎了怎么办

手机屏幕碎了要分清楚是外屏碎了，还是内屏...
1.外屏碎了需要换新屏幕， 首先将手机关机后...
2.将手机和盖背与上部分分开。
3.分开之后将新屏幕装在盖背上， 再将螺丝上...
更多 >

懂视网

👍 1

📝 反馈



社区问答方法可以进一步细分为两个子任务：

问题-问题匹配：目标是计算输入问题和问答库中某个已有问题 Q_i 之间的相似度，如果两者之间相似度较高，显而易见的， Q_i 的答案 A_i 就有很大概率是问题 Q 的答案。

问题-答案匹配：目标计算输入问题 Q 与问答库中某个答案 A_i 的相关性。同样的，如果两者之间相关度很高，那么 A_i 有很大概率是问题 Q 的答案。



传统的基于特征的语义匹配方法普遍采用一些**基于词袋的统计文本表示**，通过这些表示去计算两段文本的语义相似度，进而判断两段文本的语义是否匹配。其中，n元短语匹配度是判断语义相似度的一个重要衡量指标，**如果两个问题共同包含的语义片段越多，自然具有更大的可能表达相同的含义**。n元短语匹配度有许多不同的计算方式，最简单的做法可以计算两个问题中**重复单词的数量**：

$$\text{Sim}(Q_1, Q_2) = \frac{\sum_{w \in Q_1} \text{num}(w, Q_2)}{|Q_1|}$$

其中 $\text{num}(w, Q_2)$ 表示单词 w 在 Q_2 中出现的次数， $|Q_1|$ 表示 Q_1 的长度。

类似地，可以将简单的单词匹配扩展到短语匹配，由于短语包含的信息量更多，表达的语义也更加独立，所以短语级匹配特征能更好的表达两个问题之间的语义相似度。**常见的短语级匹配特征有 BLEU、编辑距离和最长公共子序列方法**都可以将它们用来当作特征来完成问题匹配的任务。



但是，上面介绍的这些语义匹配特征都存在两个缺点：**首先，没有处理停用词**，例如冠词、介词等，这类词汇虽然在文本中高频出现，但是并不具备实际意义，对语义的贡献程度小。**第二，没有处理同义词**，由于自然语言的表达非常丰富，同一语义具有非常多的表达方式，这就使得处理语义匹配问题时需要能够对同义词有较好的识别能力。

BM25可以缓解停用词带来的问题，使用基于反转文档频率计算 Q_1 和 Q_2 的相似度：

$$f_{BM25}(Q_1, Q_2) = \sum_{i=1}^{|Q_1|} \text{IDF}(Q_1^i) \text{freq}(Q_1^i, Q_2)$$
$$\text{freq}(Q_1^i, Q_2) = \frac{\text{num}(Q_1^i, Q_2)(k_1 + 1)}{\text{num}(Q_1^i, Q_2) + k_1(1 - b + b * \frac{|Q_2|}{\text{avglen}(Q_2)})}$$
$$\text{IDF}(Q_1^i) = \log \frac{N - n(Q_1^i) + 0.5}{n(Q_1^i) + 0.5}$$

$$\text{BM25}(Q_1, Q_2) = \frac{f_{BM25}(Q_1, Q_2) + f_{BM25}(Q_2, Q_1)}{2}$$

10.4.2 基于深度神经网络的问题匹配--DSSM语义匹配算法



基于深度学习的语义匹配方法主要分为**交互式**和**非交互型**两种。**非交互型**的方法是将两个句子分别编码后进行匹配，**交互式**的方法一般是将两个句子一起进行编码，在编码过程中让两个句子进行信息交互。

DSSM (Deep Structured Semantic Model) 是一种非交互式的基于深度网络的文本语义匹配算法，通过深度神经网络对用户问题和题目分别进行建模，将其编码成低维度的语义向量，然后计算两个向量的余弦距离，判断两个句子之间的语义相似度，由于该模型对用户问题和题目分别进行建模，在计算相似度之前两者之间没有交互，**这种模型架构又被称作“双塔模型”**。






图10.13 DSSM模型图



ESIM模型基于链式LSTMs设计了序列推断模型，**并考虑了局部推断和推断组合的问题**，在模型中引入了句子间的注意力机制来实现局部推断进而实现全局推断。ESIM模型结构如下图所示，主要分为三个部分：**输入编码层、局部推断模块以及推断组合模块**。






输入编码层对于输入的两个问题 Q_1 和 Q_2 , 模型首先通过词嵌入表示得到问题中每个单词的词向量, 然后将其输入BiLSTM模型, 通过BiLSTM表达句子的局部信息:

$$h_1^i = \text{BiLSTM}(h_1^{i-1}, h_1^{i+1}, q_1^i)$$

$$h_2^i = \text{BiLSTM}(h_2^{i-1}, h_2^{i+1}, q_2^i)$$

其中 q_1^i 和 q_2^i 分别表示 Q_1 中的第 i 个单词和 Q_2 中的第 i 个单词的嵌入表示。



局部推断模块在进行局部推断之前，首先模型要对 h_1 和 h_2 进行对齐，首先计算两者的相似度。

$$e_{ij} = h_1^T h_2$$

紧接着进行局部推断，结合 h_1 , h_2 和 e_{ij} , 得到相似性加权后的向量


$$\hat{h}_1^i = \sum_{j=1}^{len2} \frac{\exp(e_{ij})}{\sum_{k=1}^{len2} e_{ik}} h_2^j$$

$$\hat{h}_2^i = \sum_{j=1}^{len1} \frac{\exp(e_{ij})}{\sum_{k=1}^{len1} e_{ik}} h_1^j$$

在局部推断之后，模型会进行局部信息增强，利用差和点积放大两者的差异性：

$$m_1 = [h_1, \hat{h}_1, h_1 - \hat{h}_1, h_1 \cdot \hat{h}_1]$$

$$m_2 = [h_2, \hat{h}_2, h_2 - \hat{h}_2, h_2 \cdot \hat{h}_2]$$



推断组合模块将 m_1 和 m_2 输入BiLSTM提取信息:

$$v_1^i = \text{BiLSTM}(m_1^i)$$

$$v_2^i = \text{BiLSTM}(m_2^i)$$

由于两个问题的长度不同导致 m_1 , m_2 矩阵维度不一致, ESIM分别采用MaxPooling和AvgPooling的池化对两个句子进行处理:

$$v_1^{max} = \text{MAXPooling}(v_1)$$

$$v_1^{avg} = \text{AvgPooling}(v_1)$$

$$v_2^{max} = \text{MAXPooling}(v_2)$$

$$v_2^{avg} = \text{AvgPooling}(v_2)$$

最后将经过处理的向量拼接起来, 连接一个全连接层进行预测:

$$v = [v_1^{max}; v_1^{avg}; v_2^{max}; v_2^{avg}]$$

$$o = \text{SoftMax}(Wv + b)$$

ESIM 模型计算示例

NLI 任务 · 判断 "问题1 ↔ 问题2" 是 蕴含 / 矛盾 / 中性

① 输入编码 (BiLSTM) 每个 token 得到带上下文的向量, 下方小柱表示该向量的 3 个维度

问题1 (前提): 小狗 在 追 球

小狗 在 追 球

$a_1 = [0.8, 0.1, 0.2]$ $a_2 = [0.1, 0.6, 0.1]$ $a_3 = [0.3, 0.1, 0.7]$ $a_4 = [0.5, 0.1, 0.4]$

问题2 (假设): 动物 在 玩耍

动物 在 玩耍

$b_1 = [0.7, 0.2, 0.1]$ $b_2 = [0.1, 0.7, 0.1]$ $b_3 = [0.2, 0.1, 0.8]$

② 局部推断建模 (核心)

注意力 → 软对齐 → 增强

(a) 注意力矩阵

$e(i,j) = a_i \cdot b_j$ · 每行 ◆ 为最大值

	动物	在	玩耍
小狗	0.60 ◆	0.17	0.33
在	0.20	0.44 ◆	0.16
追	0.30	0.17	0.63 ◆
球	0.41	0.16	0.43 ◆

(b) 软对齐: 给 "小狗" 在 Q_2 中找投影

第 1 步: 第 1 行做 softmax

$\text{softmax}(0.60, 0.17, 0.33)$
 $\approx (0.414, 0.270, 0.316)$

第 2 步: 用权重对 b 加权

$\tilde{a}_1 = 0.41 \cdot b(\text{动物})$
 $+ 0.27 \cdot b(\text{在})$
 $+ 0.32 \cdot b(\text{玩耍})$


"小狗" 在 Q_2 中的语义投影:

$\tilde{a}_1 \approx [0.38, 0.30, 0.32] \leftarrow$ "动物" 主导

自动浮现的对齐: 小狗 ↔ 动物 · 在 ↔ 在 · 追 ↔ 玩耍 · 球 ↔ 玩耍

(c) 增强: 拼接 $[a; \tilde{a}; a - \tilde{a}; a \odot \tilde{a}]$

以 "小狗" 为例, 4 个分量同时捕获 "一致" 与 "差异"



关键直觉: 差 → 捕获冲突信号 (用来判 "矛盾")

积 → 捕获共识信号 (用来判 "蕴含")

③ 推断组合 把 4 个 m_i 拼成新序列 → 二次 BiLSTM → 池化 → 分类

再过一次 BiLSTM

让局部差异序列传播

平均池化 ⊕ 最大池化

压成定长向量

MLP + Softmax

输出 3 类概率

→ 预测

④ 预测结果 (3 类概率分布)

蕴含	0.78	✓
中性	0.18	
矛盾	0.04	

"小狗追球" 与 "动物在玩耍" 高度对齐 ($a \odot \tilde{a}$ 普遍较大, $a - \tilde{a}$ 普遍较小) → 蕴含

本章主要内容

10.1

智能问答概述

10.2

阅读理解

10.3

表格问答

10.4

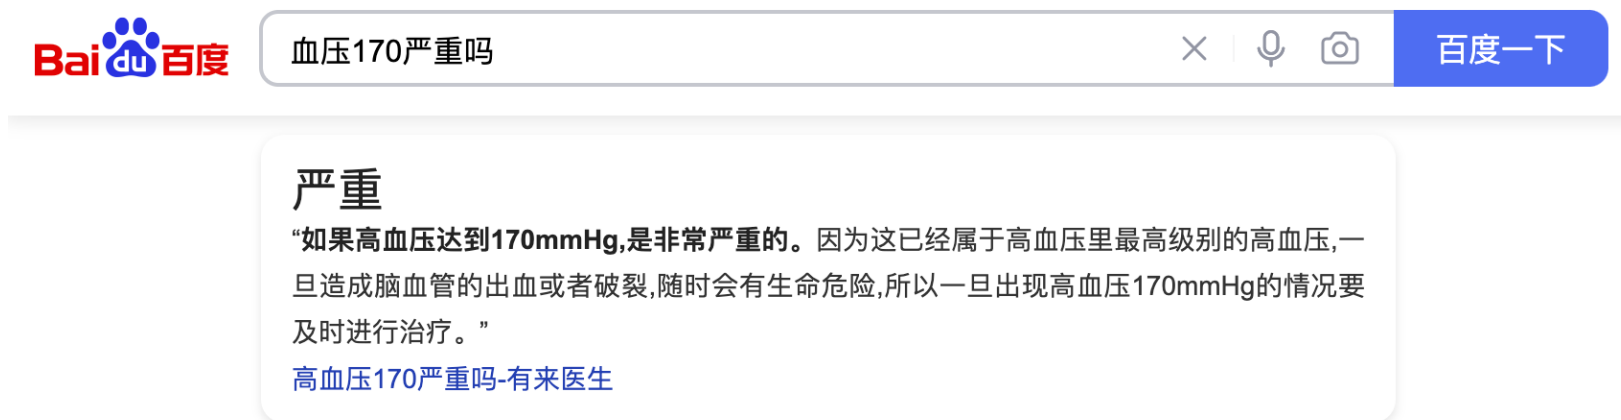
社区问答

10.5

开放领域问答



开放领域问答是与搜索引擎类似的形式，对于一个给定的询问 Q ，开放领域问答系统需要先从 一个规模非常大的文档集合或知识库（如Wikipedia或互联网） $D = \{d_1, \dots, d_n\}$ 中选择与问题最相关的文档 d ，然后通过文档 d 中包含的信息，给出询问 Q 的答案 A 。




上图给出了开放领域问答搜索引擎中的结果，用户输入查询“血压170严重吗”，搜索引擎定位了相关文档，并将直接输出最终答案。

10.5.1 检索-阅读理解架构的开放问答模型



由于开放问答任务面对的是大量的文档或网页，为了兼顾准确率与性能，开放问答一般会采用文档检索方法快速筛选出与询问最相关的文档，在筛选出相关文档之后再通过阅读理解的方式给出问题的答案，这种架构被称为**检索-阅读理解架构**。



该架构的基本流程框架如上图所示，主要包含**文章检索器**和**文章阅读器**两个模块，此外有些算法中还包含对检索得到的文档的后处理以及对抽取答案的后处理。



DrQA是利用维基百科作为知识库来实现开放式问答系统，DrQA算法介绍对于任何事实性问题，系统都能从维基百科中找到一个包含答案的文章，在此基础上通过阅读理解算法从相关文章中提取答案。

DrQA 利用 **TF-IDF** 的方法表示每个问题，并利用然后利用余弦相似度从大规模语料库中筛选出 5 篇最相关的文章。

答案抽取模块采用多层RNN网络，给定一个问题 $q = \{q_1, \dots, q_l\}$ 和包含n个段落的相关文章，每个段落由 m 个词组成 $p = \{p_1, \dots, p_m\}$ 。

对于段落中的每一个词 p_i ，DrQA采用Glove词向量将其映射成一个300维的特征向量并把他们输入到RNN中并得到上下文向量 $H = \{h_1, \dots, h_m\}$:

$$\mathbf{H} = \text{RNN}(\mathbf{p}_1, \dots, \mathbf{p}_m)$$




在预测时，DrQA目标是在 p 中找到一个片段 $\{p_l, \dots, p_r\}$ 作为问题的答案。所以，DrQA将编码好的段落表示向量 H 和问题表示向量 H^q 作为输入，分别训练两个二分类器预测答案的开始位置和结束位置：

$$P_{start}(i) = \exp(\mathbf{p}_i \mathbf{W}_s \mathbf{q})$$

$$P_{end}(i) = \exp(\mathbf{p}_i \mathbf{W}_e \mathbf{q})$$




BM25、TF-IDF等稀疏向量空间模型，通过词频和逆文档频率，对问题和文档利用关键词进行匹配，无法理解文档和问题中包含的语义信息。**基于密集向量空间的DPR** (Dense Passage Retriever) 模型试图解决上述问题。



DPR模型主要在文章检索模块上做出了改进，DPR采用了双编码器的结构，可以在 M 个文档中找到与问题 Q 最相关的 K 个文档

DPR主要分为两个部分：**编码和相似度度量模块**。
DPR模型的结构如左图所示。



在编码部分，DPR采用了双编码器结构，部署了两个**独立的BERT模型**对问题和文档分别进行编码，将两段文本分别映射到两个d维向量

DPR采用**点积的方式**对两个向量的相似度进行度量

DPR的编码模型采用**一个正例文档和n个负例文档的方式进行训练**

在推理阶段，DPR模型预先将所有文档进行编码并储存，利用FAISS向量比较工具对相应的问题进行检索，最终找到与问题最相关的前K个文档。



随着预训练语言模型的规模越来越大，训练数据越来越多，一些研究人员认为在这些在**大规模数据上训练的超大规模语言模型很可能已经建模了网页数据中的知识**。基于端到端架构的开放问答模型引起了广泛兴趣。

PLSLM采用小样本提示学习的方式，利用网络数据对超大规模语言模型进行增强，提示学习的方法不需要重新进行预训练或者改变模型结构，可以轻量级的实现模型信息更新。基于小样本提示学习增强大规模语言模型的方法分为三步：

- 1) 根据用户提出的问题 q ，采用**搜索引擎检索**一系列相关文档作为增强信息。
- 2) 利用检索出的文档，利用提示学习对模型进行调节。
- 3) 模型通过每一个检索出的文档生成候选答案，并对这些候选答案进行重排序并选出最合适的作为最终答案返回。




图 10.18 端到端架构开放问答模型（以 T5）为例



对于给定的问题 q , PLSLM算法利用搜索引擎检索得到**前20个最相关文本**作为模型的增强文档。

由于网络上获取的文档会伴随噪音等问题，会增强后续提示学习的难度，所以PLSLM对检索文档进行了预处理。**将所有检索到的文档分为多个段落**，其中每个段落由6个句子表示，最后再利用TF-IDF算法对所有段落和 q 进行编码，**利用余弦相似度进行重排序**，将这些排序后的段落作为增强数据。

得到经过排序的段落 P 之后，PLSLM利用小样本提示学习对大规模预训练模型进行调节，PLSLM针对开放领域问题回答设计了相应的提示模板。

例如：对于训练数据中的问题“复旦大学有几个校区？”，对应的增强文档是复旦大学的百度百科，需要构造如下输入：

证据：复旦大学，简称“复旦”，位于直辖市上海，是中华人民共和国教育部直属的全国重点大学，中央直管高校，综合性研究型大学，由教育部与上海市重点共建。迄2020年4月，学校有邯郸校区、枫林校区、江湾校区、张江校区四个校区，占地面积约243.92万平方米。

问题：复旦大学有几个校区？

答案：



PLSLM利用打分函数对所生成的候选答案在此排序，挑选其中最合适的作为最终答案返回给用户

(1) 直接推理：最大化 $P(a|q)$

$$P(a|q) = \sum_{i=1}^n P_{\text{TF-IDF}}(p_i|q) \cdot P(a_i|q, p_i)$$

(2) 噪声信道模型：最大化 $P(a_i, q|p_i)$

$$P(a_i, q|p_i) = \frac{P(q|a_i, p_i) \cdot P(a_i|p_i)}{P(q|p_i)}$$

(3) 专家乘积 (Product of Experts, PoE)：使用额外的语料训练权重综合上述概率

本章小结

从基于规则和基于统计的模型到如今基于神经网络的模型，智能问答任务经历多年的发展取得了很大的进步，随着预训练语言模型和深度学习的兴起，在很多智能问答问题上都已经能实现很好的效果。尽管如此，智能问答领域中还有很多问题没有解决，包括多跳问答、智能问答系统解析生成、多模态智能问答等。