

中山大學 人工智能學院
SUN YAT-SEN UNIVERSITY SCHOOL ARTIFICIAL INTELLIGENCE

「自然语言处理」

第 11 章 文本摘要

赵宝全

中山大学人工智能学院

2026年春季学期

本章主要内容

11.1

文本摘要概述

11.2

抽取式文本摘要

11.3

生成式文本摘要

11.4

文本摘要的评测

11.5

文本摘要语料库



文本摘要 (Text Summarization) 是一种利用算法自动实现文本分析、内容提炼并生成摘要的技术。由于互联网的快速发展，当前时代的信息量出现了指数级的增长，并远超于人类的对信息地处理和利用能力，从而导致我们无法快速地挑选和有效地运用信息，这种现象称为**信息过载 (Information Overloading)**。而文本摘要技术可以对信息进行简化，帮助人们快速获取和理解新的信息。

本章主要内容

11.1	文本摘要概述
11.2	抽取式文本摘要
11.3	生成式文本摘要
11.4	文本摘要的评测
11.5	文本摘要语料库



从狭义角度来看，文本摘要的目标是为文档提炼关键信息，并构造出代表原文档中最重要或相关内容的子集（摘要）。**从广义来看**，除了文本形式的信息，我们还可以为图像或视频等多模态的信息进行总结，并产生以自然语言形式描述的摘要。

文本摘要可以追溯到1957年Hans Peter Luhn的基于统计方法的研究[588]。随着互联网的高速发展，大量信息以复杂多样的形式存在于人们的日常生活中。文本摘要作为信息甄别和过滤的核心技术之一，受到学术界和企业界越来越多的关注。

以机器学习方法为代表性的抽取式文本摘要技术的研究成果不断涌现，应用落地场景日趋广泛。随着深度学习技术的不断发展，特别是基于大规模数据的预训练大模型范式的成功，文本摘要领域的研究变得更为活跃，并**逐渐转向生成式摘要和实时摘要**。

此外，随着互联网中图像、短视频等图像视频内容的不断增加，一些**基于多模态信息的摘要**研究也成为近年来研究热点，例如图像摘要和视频流摘要等。



1958年, Hans Peter Luhn 《The Automatic Creation of Literature Abstracts》, 揭开了通过计算机来实现自动文本摘要的序幕。

之后的几十年时间里, **文本摘要主要依赖于信息检索中常见的特征**, 例如词频 (Term Frequency) 以及词频-逆文档频率 (TF-IDF) 等, 通过统计信息来进行关键信息的提取。在1990年之前的方法中, 文本摘要大都是**通过规则和统计信息从原始文本中直接抽取 (复制) 内容**, 而不是生成新的内容和抽象的摘要。

随着机器学习技术的快速发展, 有相当**多有监督和无监督**的自动摘要方法被提出来。2002年文献 [590]提出**将自动文本摘要视为一个二分类问题**, 如果一个句子出现在抽取式的参考摘要中, 则认为它是“正确的”, 否则就被认为是“不正确的”。**无监督方法**则通过定义相关的特征进行关键信息的筛选, 从而不需要依赖人工构造的摘要。



自2014年开始，以**深度学习和神经网络**为代表的文本摘要技术逐渐兴起，它们与传统技术相比具有更加卓越的性能。2019年Alami等人构建了一个基于词嵌入的文本摘要系统[591]。其次，使用深度自编码器 (Auto-Encoder, AE) 从词频输入计算隐特征也可以为句子或单词产生表示。以深度神经网络为支撑的表示学习，为单词、句子、文档提供了高质量的语义表示，并大大促进了文本摘要的发展。

DUC-2003和DUC-2004竞赛为文本摘要任务提供了标准，由此生成式文本摘要技术迎来了快速发展。原文本和摘要都是单词序列，因此可以用**序列到序列模型** (Seq2Seq) 处理输入的文本序列和输出的摘要序列。机器翻译问题与文本摘要具有明显的相似性，它们的区别在于**机器翻译是信息无损的，而文本摘要是有损的**。因此，一些早期的生成式文本摘要方法直接使用了机器翻译模型。早期的Seq2Seq模型主要是基于循环神经网络 (RNN) 结构。2017年，以Transformer为代表的自注意力模型凭借强大的文本建模能力和并行效率，逐渐成为了**生成式文本摘要的主流**。



文本摘要广泛应用于多种任务和场景中，按照任务进行划分，可以将文本摘要分为**单文档摘要**、**多文档摘要**、**对话摘要**、**跨语言文本摘要**和**多模态文本摘要**等。

单文档摘要是最基本的摘要任务，给定一篇文档作为输入，模型输出它的核心内容，且长度明显短于输入文档。

- 根据输入文档的内容长度，可以将单文档摘要分为两类：**短文本摘要**和**长文本摘要**。
 - **短文本摘要**中文本类型可以是新闻文本、评论文本、邮件文本等短文本。
 - **长文本摘要**则是面向学术论文、专利文档、书籍等长文本的摘要。
- 与短文本摘要相比，长文本的信息量更多，但文档结构更加规范化。还可以根据文档类型的不同，制定针对性的摘要策略。例如，新闻摘要关注新闻的人物、时间、地点、事件等信息；评论摘要关注产品的特性、用户的情感倾向；学术论文摘要则要更关注问题的定义、方法的描述、实验的结果等等。



多文档摘要目标是对同一主题下的**多个文档**提炼主要信息并输出摘要。

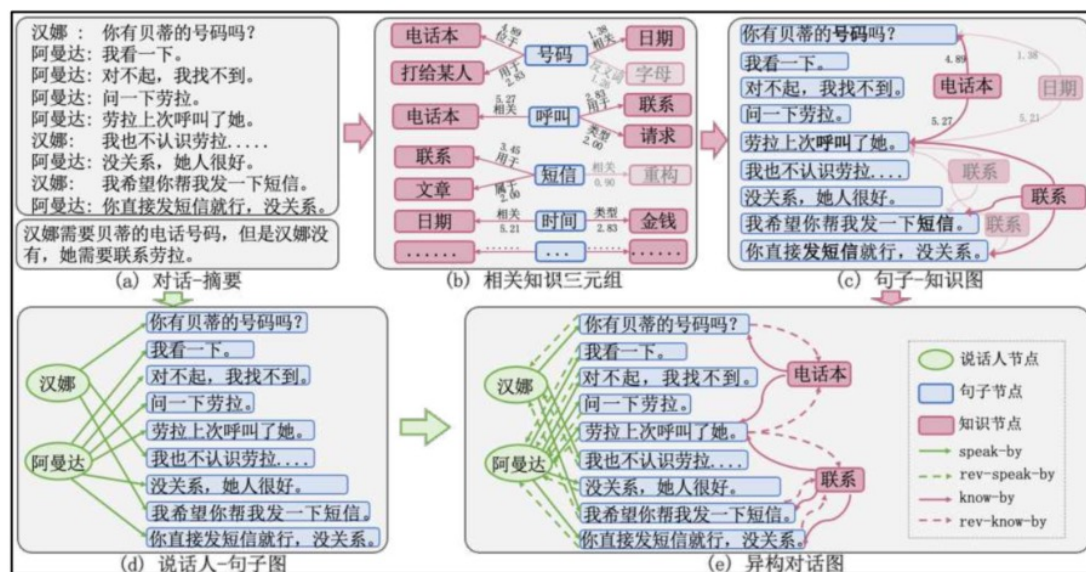
- 从应用的角度来看，**对于某一新闻事件**，互联网上的某个新闻单位会针对此事件进行系列报道，或者多个新闻单位对同一事件进行同时报道。对这些相关性很强的多文档提炼出一个覆盖性强、形式简短的摘要就具有重要的意义。
- 另一种应用场景是**商品评论的摘要**。对于某一种商品来说，商家分析其售后评论并总结出用户关注的方面和特性，有助于商家针对性地优化产品。对于**多文档的学术论文摘要**，我们可以通过对多篇文章的研究内容进行归纳总结，得到相关研究主题的主要挑战、主流方法和未来趋势等等。

11.1.2 文本摘要主要任务



对话摘要的目标是为多种类型的对话生成摘要，包括会议、通话记录、在线聊天和客服对话等场景。

- 从参与者的角度来看，对话与新闻文档最大的不同点在于**对话信息涉及两个以上的参与者**。除此之外，**对话摘要会涉及更多的对话语义消歧、指代消解、信息补全等问题和挑战**。
- 相比新闻摘要和论文摘要，对话的摘要**很难直接从现有的内容中获取**，而新闻的标题和论文的摘要可直接作为参考结果并进行大规模的摘要数据收集，因此构建对话摘要的数据集更加困难。
- 除此之外，**对话会涉及音频、视频等信息**，因此对话摘要还会涉及多模态信息的建模和理解。





跨语言文本摘要是指输入源语言（如英文）文档，输出目标语言（如中文）摘要的任务。它的主要应用场景在于为非母语者生成摘要。

- 一个常见的跨语言摘要数据集是Global Voices[593]，它是多语言新闻的英文摘要，主要包含15种语言的新闻及其摘要。一般而言，跨语言文本摘要可拆分为文本摘要和机器翻译两个子任务进行处理。

多模态摘要目标也是输出摘要内容，但是模型的输入和输出不仅局限于文本，还包括图像、视频、语音等多媒体数据。

- 例如，新闻文档中包含的图像、会议记录中的语音、电影字幕对应的视频等等。在多模态摘要中，各个模态的信息可能有重合或互相补充，如何对这些信息进行对齐、识别、筛选，做到摘要内容的不重复和不遗漏，是进行多模态文本摘要的重点。
- MSMO数据集[594]是一个常见的多模态新闻摘要数据集，其中所包含的带有图像的新闻文档，是内容对齐的，即图像和文本描述了同样的内容。

本章主要内容

11.1	文本摘要概述
11.2	抽取式文本摘要
11.3	生成式文本摘要
11.4	文本摘要的评测
11.5	文本摘要语料库



抽取式文本摘要中的关键内容是从**原始文本中提取的**，同时所提取的内容通常不会以任何方式进行修改。关键内容包括可用于“标记”或索引文本文档的短语，或共同组成摘要的关键句（包括标题）。

关键文本的抽取类似于略读的过程，人们在决定是否要详细阅读一篇文档之前，会倾向于选择阅读其中的摘要（如果有）、标题、副标题、数字、文档的第一段和最后一段，以及段落中的第一句和最后一句。

常见的抽取式文本摘要方法可分为两大类：**基于排序的方法**和**基于序列标注的方法**。



基于排序的抽取式文本摘要的基本思想是：

- 对于一篇文档，首先按照一定的规则将其拆分为多个语义单元（如短语、句子、段落等）
- 通过某种重要性评估方法为每个语义单元进行评分
- 按照重要性分数的大小将语义单元进行排序，最后选取分值较高的语义单元作为关键内容并组成摘要。

一般而言，会选取句子作为内容提取的基本语义单元，而如何衡量句子的重要性以及如何设计合适的评分方法，则是影响排序效果好坏的关键。



对于大部分类型的文档，句子在文档中的位置是一个重要的判断依据。一般而言，**文档的起始句段会进行总述，结尾句段会进行总结**。因此，最简单的启发式排序方法就是**按照句子的位置选择关键句作为摘要**。

Lead-3算法会**选取文档的前三句内容作为摘要**。这种方法虽然简单直接，但在某些场景中（如新闻文本摘要）非常有效。因此，Lead-3常常作为一个基线方法，并将其视为文本摘要方法的性能下界。



TextRank[595]是一个经典的基于排序的抽取式摘要方法，它的核心思想来自PageRank 算法。

- PageRank 是一个基于图的排序算法，用于将网页进行排序，目的是尽可能地将重要的网页排在靠前的位置。这一类基于图的排序算法，可以递归地从图中提取全局信息，并根据节点间的某种关系来衡量节点的重要性，为节点评分排序。
- PageRank 算法将网页作为有向图的节点，将网页之间可跳转的超链接作为图的有向边。当页面A能跳转到页面B时，我们可以将其视为页面A为页面B “投票” 。一个页面获得的票数越多，该页面的重要性就越高。
- PageRank模型会根据投票页面的重要性，决定其投票的权重。因此，一个页面的重要性得分取决于获得的票数，以及为其投票的节点分数。PageRank模型节点重要性迭代计算公式如下：

$$S(V_i) = (1 - d) + d * \sum_{j \in In(V_i)} \frac{1}{|Out(V_j)|} S(V_j)$$



受到PageRank算法的启发，在进行文本摘要任务时，TextRank算法将文档中的句子作为节点，以句子间的相似度作为边，通过迭代更新节点的重要性分数。句子之间相似度表示计算公式如下：

$$\text{Sim}(S_i, S_j) = \frac{|\{w_k | w_k \in S_i, w_k \in S_j\}|}{\log(|S_i|) + \log(|S_j|)}$$

其中，S和w分别代表句子和句子中的单词，|S|代表句子S中的单词数量，分子部分表示同属于两句的单词数量。相应的，对于句子节点的评分，采用如下公式：

$$S(V_i) = (1 - d) + d * \sum_{V_j \in \text{In}(V_i)} \frac{\text{Sim}(V_j, V_i)}{\sum_{V_k \in \text{Out}(V_j)} \text{Sim}(V_j, V_k)} S(V_j)$$

使用边的权值，迭代更新节点的重要性分数直到收敛，最后选取N个得分最高的节点句子，作为摘要进行输出。



除了人工设定规则的方法外，也可以使用统计机器学习方法结合特征工程来进行句子抽取。一个常见的方法是使用朴素贝叶斯模型，根据人工构建特征，以及预先标注的训练语料完成句子抽取。常见的句子级别用于抽取式摘要的文本特征包括：

- **长度**：句子的长度一定程度上可以反映信息量的大小。当句子超过或短于一定长度时，通常是不适合作为摘要的。
- **位置**：基本上所有类型的文本都有其约定俗成的写作规范。句子的内容和其位置在一定程度上是有关联的。例如，文章结尾通常包含整篇文章的总结综述。
- **关键词**：当某个句子包含该类型文本的关键词，那么这个句子很有可能是摘要的一部分。
- **提示语**：在某些类型的文档中，关键的概括和总述性语句前会有明显的提示语，例如，“综上所述”，“To conclude”一类的短语之后会紧跟重要的句子。

根据预先进行人工标注，标明句子是否为摘要句的训练集合上，根据设计好的特征值集合和标签，就可以训练朴素贝叶斯分类器，并用它来计算每个句子属于摘要的概率：

$$P(label|f_1, f_2, f_3, \dots, f_n)$$



抽取式文本摘要的另一种方法是将句子抽取问题转化为**序列标注任务**。

首先要将文档分割成独立的语义单元，并将其组成语义单元序列。**算法的目标就是对每个语义单元给出一个标签**，来表明该部分是否要被提取出来组成摘要。一般来说，会选取句子作为基本语义单元，并使用二元标签（0和1）来表明句子被抽取的状态。


- “1” 表示该句子可以需要被抽取出来作为摘要句
- “0” 表示该句子不需要作为摘要句

与排序式文本摘要的不同点在于，**基于序列标注的方法直接对句子进行二元分类，而不需要预先设计并计算句子的重要性分数**，所以可以直接使用有监督学习的方法进行训练。

11.2.2 基于序列标注的方法--SummaRuNNer算法



SummaRuNNer算法就是一种基于RNN的抽取式摘要模型，该模型是一个采用两层基于门控循环单元（Gated Recurrent Unit, GRU）的双向循环神经网络，其模型结构如下图所示，主要包含**输入层、单词层、句子层以及分类层**。





SummaRuNNer算法逐级对文本进行处理，使用双向GRU进行建模。输入层将句子单词转换为词向量表示。

- **单词层**在词级别对文本进行处理，双向地依次根据每个单词的词嵌入以及历史隐状态来计算每个单词的隐状态。
- **利用平均池化方法**将句子中所有单词的隐状态融合为句子表示，并作为句子层的输入。
- **句子层**则是在句子级别对文本进行处理，同样使用双向GRU进行建模，然后利用所有句子的隐状态通过如下公式计算出文本的整体表示：

$$\mathbf{d} = \tanh(\mathbf{W}_d \frac{1}{N_d} \sum_{j=1}^{N_d} [\mathbf{h}_j^f, \mathbf{h}_j^b] + \mathbf{b})$$



SummaRuNNer算法的最后一层是**分类层**，从第一句开始，结合句子的隐状态以及文本的整体表示，依次判断各个句子是否需要提取出来作为摘要的一部分，最终实现摘要的抽取。具体的分类方法如下公式所示：

$$P(y_j = 1 | \mathbf{h}_j, \mathbf{s}_j, \mathbf{d}) = \sigma(\mathbf{W}_c \mathbf{h}_j + \mathbf{h}_j^T \mathbf{W}_s \mathbf{d} - \mathbf{h}_j^T \mathbf{W}_r \tanh(\mathbf{s}_j) + \mathbf{W}_{ap} \mathbf{p}_j^a + \mathbf{W}_{rp} \mathbf{p}_j^r + \mathbf{b})$$

其中， $\mathbf{h}_j$ 是通过对 $[\mathbf{h}_j^f, \mathbf{h}_j^b]$ 进行非线性变换得到的第 j 个句子的嵌入表示， $\mathbf{s}_j$ 是摘要在处理第 j 句子时的动态表示，通过如下公式计算得到：

$$\mathbf{s}_j = \sum_{i=1}^{j-1} \mathbf{h}_i P(y_i = 1 | \mathbf{h}_i, \mathbf{s}_i, \mathbf{d})$$

$\mathbf{W}_c \mathbf{h}_j$ 反映句子的信息量， $\mathbf{h}_j^T \mathbf{W}_s \mathbf{d}$ 反映句子对于文章的重要性， $\mathbf{h}_j^T \mathbf{W}_r \tanh(\mathbf{s}_j)$ 反映句子对于已提取部分的冗余程度， $\mathbf{W}_{ap} \mathbf{p}_j^a$ 和 $\mathbf{W}_{rp} \mathbf{p}_j^r$ 分别考虑了句子的在文本中的绝对位置（实际的句子数）和相对位置（将文本分割成固定数量的段，句子所属的段数就是相对位置）， $\mathbf{P}^a$ 和 $\mathbf{P}^r$ 也是需要学习得到的模型参数，分别是句子绝对位置和相对位置的嵌入表示。



根据上述公式得到模型的预测结果后，SummaRuNNer算法采用如下损失函数，对模型参数进行学习：


$$\mathcal{L}(W, b) = - \sum_{d=1}^N \sum_{j=1}^{N_d} (y_j^d \log P(y_j^d = 1 | \mathbf{h}_j^d, \mathbf{s}_j^d, \mathbf{d}_d) \\ + (1 - y_j^d) \log(1 - P(y_j^d = 1 | \mathbf{h}_j^d, \mathbf{s}_j^d, \mathbf{d}_d)))$$

其中，N 表示训练集中的文档数量， N_d 表示文档 d 中句子的数量。

11.2.2 基于序列标注的方法--BERTSum-Ext算法



BERTSum-Ext[601]是一个基于BERT编码器的抽取式摘要模型。由于原始的BERT是针对字词进行编码，而基于序列标注的抽取式文本摘要是一句操作和分类，在做句子级别的序列标注时，要对输入BERT的内容做一定调整，需要进一步计算句子的向量表示。BERTSum-Ext的模型结构如下图所示：



11.2.2 基于序列标注的方法--BERTSum-Ext算法



BERTSum-Ext与BERT一样，同样也是**使用了[SEP]标记来分隔句子**，而不同之处在于两者的[CLS]标记的含义。在原始BERT中，[CLS]标记被添加在文本序列的开始，该位置整合了输入序列中的全局信息。在BERTSum-Ext中，**[CLS]标记被添加在每一个句子的开始位置**，该句子的有效信息将会被整合到对应[CLS]标记位置的字段上。此外，BERTSum-Ext**会为位置是奇数和偶数的句子分别赋予不同的段嵌入(Segment Embeddings)**，即第1, 2, 3, 4...句将分别被赋予段嵌入 $E_A, E_B, E_A, E_B \dots$ 。

得到不同位置的[CLS]向量 t_i 来表示各个句子，然后将其输入到后续的Transformer模块中进行更新：

$$\begin{aligned}\tilde{h}^l &= \text{LN}(h^{l-1} + \text{MHAtt}(h^{l-1})) \\ h^l &= \text{LN}(\tilde{h}^l + \text{FFN}(\tilde{h}^l))\end{aligned}$$

使用顶层输出的句子嵌入作为最终输入分类器的表示。分类器可以为每个句子表示计算并预测二元分类结果，表示各个句子是否需要被提取出来作为摘要的一部分：

$$\hat{y}_i = \sigma(\mathbf{W}_o \mathbf{h}_i^L + \mathbf{b}_o)$$

本章主要内容

11.1

文本摘要概述

11.2

抽取式文本摘要

11.3

生成式文本摘要

11.4

文本摘要的评测

11.5

文本摘要语料库



抽取式文本摘要所获得的结果都来源于原始文本，因此所得到摘要文本中每个单句的语义准确性和语法正确性都可以得到很好的保证。但是由于原始的句子来源于不同的段落甚至篇章，所生成的摘要中句子之间的**连贯性则很难保证，造成摘要整体的可读性较差。**

生成式文本摘要则可以**产生原始文档中不存在的新文本**。通常生成式文本摘要算法需要首先构建原始文档的抽象语义表示（编码过程），然后使用此语义表示创建出接近人类表达方式的摘要（解码过程）。该类算法通常能产生更精简凝练并且更具有连贯性的摘要。

语义表示过程也可应用于图像和视频，因此**生成式摘要方法也可用来处理多模态文本摘要。**

生成式摘要比抽取式摘要更具挑战性，它不仅涉及自然语言生成，还涉及依赖领域知识对原始文档的深入理解。



在2014年，Google Brain团队首次提出了序列到序列生成结构（Sequence-to-Sequence，Seq2Seq）来进行文本生成任务。序列到序列生成结构主要由**编码器（Encoder）和解码器（Decoder）组成**，其中编码器负责将输入文本中所需要的语义信息编码成向量，解码器则负责从编码向量中解码出语义信息并生成特定文本。

对应到生成式文本摘要，可以将原始文档输入编码器，编码器进行文档的理解并将其中的关键信息进行编码，解码器则将关键信息进行解码并生成对应的文本摘要。



BERTSum-Abs[601]是结合了预训练语言模型的Seq2Seq摘要生成方法。它的基本框架也是基于Transformer结构，其区别在于，**编码器是预训练语言模型（如BERT），而解码器则采用参数随机初始化的多层Transformer神经网络结构**。这样的设计虽然可以很好的利用了预训练语言模型，能够对文本内容进行很好的编码。但是会导致**编码器和解码器之间存在着参数状态不匹配的问题**，即编码器的模型参数是经过预先训练的，而解码器的模型参数是随机初始化的。由于在相同的优化策略下，解码器相比于编码器更难收敛，这可能会使训练阶段的微调过程不稳定。

为了解决这一问题，BERTSum-Abs设计了一个**新的微调范式，用不同的优化策略对编码器和解码器进行微调**。BERTSum-Abs采用的方法是将解码器的学习率设置更大，使其参数更新的幅度更大，逐渐缩小两者不匹配的参数状态。



具体来说，BERTSum-Abs对编码器和解码器分别使用了不同的Adam优化器参数，它们具有不同的预热步数（Warm Up Step）和学习率：

$$lr_{\mathcal{E}} = \tilde{lr}_{\mathcal{E}} \cdot \min \left(\text{step}^{-0.5}, \text{step} \cdot \text{warmup}_{\mathcal{E}}^{-1.5} \right)$$
$$lr_{\mathcal{D}} = \tilde{lr}_{\mathcal{D}} \cdot \min \left(\text{step}^{-0.5}, \text{step} \cdot \text{warmup}_{\mathcal{D}}^{-1.5} \right)$$

其中 $lr_{\mathcal{E}}$ 为编码器学习率， $lr_{\mathcal{D}}$ 为解码器学习率。

随着预训练语言模型的不断发展，陆续出现了对**编码器和解码器联合预训练的解决方案**，其可以直接被应用在适合序列到序列生成架构的文本生成任务中，并在生成式文本摘要任务中展现了更好的性能，比如BART等。由于BART预训练方法本身是一个去噪自编码器，与摘要任务的形式有一定的关联性，即去除文档中的冗余和无关的信息，只保留关键信息。因为这种上游预训练形式与下游任务相关的特性，BART在生成式文本摘要中可以获得更好的效果。



抽取式文本摘要和生成式文本摘要都存在着各自的优势，于是研究员人们也尝试将抽取式方法和生成式方法结合，并形成一类新的方法。

这一类方法的算法流程为：首先对原文档的内容进行抽取，得到初步的摘要内容；再将抽取的结果输入生成器，经过优化得到最终的摘要。


我们可以根据第一步中抽取内容的粒度（如字词、句子）对这一类方法进行区分：词粒度抽取与生成结合方法、句子粒度抽取与生成结合方法

11.3.2 抽取与生成结合式文本摘要--词粒度抽取与生成结合方法



Bottom-Up是一种以字词为抽取粒度的方法，其思路是将摘要生成分成如下图所示两个主要步骤：

(1) 通过自底向上的注意力机制从文本中抽取可以作为摘要的单词； (2) 用第一步抽取出的单词辅助生成摘要。



本章主要内容

11.1

文本摘要概述

11.2

抽取式文本摘要

11.3

生成式文本摘要

11.4

文本摘要的评测

11.5

文本摘要语料库



与文本分类、命名实体识别等其他自然语言处理任务的评测相比，由于关键信息的选取和文摘的表述没有统一的标准答案，因此文本摘要的人工评测和自动评测都困难很多。与机器翻译、对话系统等面向内容生成（Content Generation）的任务一样，**文本摘要也有多维度的评价系统，包括人工评测方案和自动评测指标。**

文本摘要的评测按照与任务的相关性可以分为两类：

- **内在评价（Intrinsic Evaluation）**与摘要任务相关，它通过直接分析摘要的质量来评价摘要系统，一般从总体和细分维度两个粒度进行评估。其中，总体评估是指从总体上评价摘要的质量，并给出一个综合分数。细分维度一般可以从“与参考标准的一致性”和“类人性”两个角度来考虑，多方面地对摘要的质量进行评价。
- **外在评价（Extrinsic Evaluation）**则是一种间接的评价方法，与系统的功能对应，将摘要应用于下游任务或者实际应用系统中，根据摘要在这些任务和系统中产生的实际效果来间接评估摘要的质量。这里我们仅讨论内部评价方法。



在评测文本摘要的质量时会关注以下5个细分维度

(1) 信息量 (Informativeness)，即摘要的内容含量，它可以衡量一段文本所提供的新信息的程度。文献[615] 对信息量作出了直观上的定义：阅读者一般都拥有背景知识和常识，如果一段摘要能使其获得新信息或者产生认知上的变化，则可认为此摘要具有丰富的信息量。

(2) 非冗余性 (Non-redundancy)，它体现了摘要精简的特性，即不能反复使用重复或相似的文本描述同一个关键点。

(3) 流畅度 (Fluency)，它包含了摘要结构的连贯性和语法的正确性两个方面。

(4) 忠实度 (Faithfulness)，也称为相关性 (Relevance)，即摘要内容是否忠于原文。作为原文的子集，摘要不能包含凭空产生的信息，也不能包含与原文和事实相悖的内容。

(5) 聚焦程度 (Focus)，也称为显著性 (Saliency)，它衡量了摘要包含关键信息的程度。除了主要信息，原文档往往具有大量的细节描述和补充内容等次要信息。通过聚焦程度，可以评估一个摘要系统的甄别并捕捉原文主要信息的能力。



人工评测按照执行方式一般分为两类：

逐点评估 (Point-wise)：评估者对系统产生的每一个结果按照预定义的维度进行评估评分。一个常见的方案是李克特五点量表 (Likert Scale)。给定原始文档和模型输出的摘要，评估者会按照1 ~ 5分对摘要某一方面的评测维度进行评分。假设评测维度是流畅度，则1 ~ 5的分值依次对应：非常不流畅、不流畅、一般、流畅、非常流畅五种程度。但是，逐点评估具有很强的主观性，导致评估者之间的偏差较大，一致性很低。

逐对评估 (Pair-wise)：给定相同的原始文档和两个不同系统的输出摘要A和B，评估者需要判断A与B相比哪个更好。与逐点评估的多选项评分相比，逐对评估采用两两比较的方式，降低了评估难度，可以提高评测结果的一致性。但是，如果存在多个需要评测的摘要系统，总评估次数会随着系统数目的增加而呈 $O(N^2)$ 的复杂度上升，成本较高。



人工评测存在主观性，包括摘要任务本身的主观性和评估者自身的主观性。为了尽可能消除人工评测的主观性偏差，一般会让多个评估者对同一条数据进行独立重复评分。因此，衡量多个评估者之间的评测一致性是一个重要的过程。一致性不仅可以体现人工评测质量的高低，还能反映评测任务的难易程度。Fleiss卡帕系数 (Fleiss's κ)，也称Kappa系数，是度量多个系统一致性的方法，也经常被用于计算人工评测的一致性。

Fleiss卡帕系数在不同的区间显示不同的一致性程度。系数小于0时表示没有一致性，0 ~ 0.20表示轻微 (Slight) 一致，0.21 ~ 0.40表示一般 (Fair) 一致，0.41 ~ 0.60表示中等 (Moderate) 一致，0.61 ~ 0.80表示显著 (Substantial) 一致，0.81 ~ 1.00表示完美 (Perfect) 一致。



人工评测虽然可以提供丰富的信息，但是大规模的人工评测耗时长、工作量大、成本高。自动评测则可以提供高效、低成本、一致的评测，在模型开发过程中这些特点都受到研究人员青睐。随着评测技术的发展，自动评价结果也具有了更好的指导意义。

ROUGE (Recall-Oriented Understudy for Gisting Evaluation)，称为面向召回率的要点评估，也是文本摘要中最常用的自动评价指标之一。ROUGE与机器翻译的评价指标BLEU的类似，能根据机器生成的候选摘要和标准摘要（参考答案）之间词级别的匹配来自动为候选摘要评分。

ROUGE包含一系列变种，其中应用最广泛的是ROUGE-N，它统计了n-gram词组的召回率，通过比较标准摘要和候选摘要来计算n-gram的结果。



ROUGE是基于候选文本与参考文本之间的精准匹配来评价文本的质量。但是在一些情况下，不同的词语或短语可以表达同一种语义。例如，“立刻”和“马上”，两者的含义相同，但是基于n-gram的匹配就会失效。一个常用的解决方案为**基于嵌入表示的度量**（Embedding-Based Metrics），使用分布式词嵌入来计算词语之间的相似度，具体来说包括静态词向量和上下文相关的词向量两种方案。

本章主要内容

11.1

文本摘要概述

11.2

抽取式文本摘要

11.3

生成式文本摘要

11.4

文本摘要的评测

11.5

文本摘要语料库



如前所述文本摘要被广泛应用于多种场景中，任务类型包括单文档摘要、多文档摘要、对话摘要、跨语言文本摘要和多模态文本摘要等多种类型。

单文档摘要语料库：

CNN/DailyMail: 该数据集是被广泛关注和研究的短文本摘要数据集，它包含了311,672个新闻/摘要对，新闻数据来源是美国有线电视新闻网和《每日邮报》。新闻平均长度为766个词（29.74个句子），摘要的平均长度为53个词（3.72个句子）。

LCSTS: 该数据集是常用的中文短文本摘要数据集，包含240万个新闻/摘要对，数据来源为微博认证的官方新闻。

Arxiv/PubMed: 这两个数据集是被广泛应用的长文本数据集，分别来源于arXiv和PubMed的学术网站上的论文和摘要。ArXiv数据集包含21.5万个论文/摘要对，论文平均长度为4938个词，摘要平均长度为220个词。PubMed数据集包含13.3万个论文/摘要对，论文平均长度为3016个词，摘要平均长度为203个词。



多文档摘要语料库：

Multi-News: 该数据集是大规模的多文档摘要数据集，场景是新闻文档，数据来源是Newsr网站。此网站上的新闻稿会引用多个新闻源，这些新闻源被归为输入文档集合。Multi-News共包含56216个文档集合/摘要对，文档集合的平均长度为2103个词，摘要的平均长度为264个词。

WikiSum: 该数据集是基于英文维基百科的多文档摘要数据集。在每个实例中，输入由维基百科主题（文章标题）和非维基百科参考文档的集合组成，目标是生成维基百科文章的精简文本。数据集以8：1：1的比例被划分为训练集、验证集和测试集，分别包含1,865,750、233,252和232,998个样本。

本章小结

文本摘要是一种利用算法自动实现文本分析、内容提炼并生成摘要的技术。尽管基于深度学习尤其是预训练技术的文本摘要已经取得了显著的进展，但在真实场景大规模应用文本摘要仍面临着诸多挑战。首先是数据资源的问题，取得高质量的摘要数据往往成本高昂，有时候我们必须面临低资源情况下训练数据缺乏的问题。其次是摘要的场景丰富多样，不仅包括文本的类别（新闻、评论、学术论文等），还包括多模态数据（对话、图像、视频等），这些场景领域差异大，导致训练好的摘要模型难以迁移。最后，文本摘要的评估也是亟待解决的难题，设计合理的高效的评估方法能促进模型的迭代，但其具有很大的挑战性。