

中山大學 人工智能学院
SUN YAT-SEN UNIVERSITY SCHOOL ARTIFICIAL INTELLIGENCE

「自然语言处理」

第 12 章 知识图谱

赵宝全

中山大学人工智能学院

2026年春季学期

本章主要内容

12.1	知识图谱概述
12.2	知识图谱表示与存储
12.3	知识图谱获取与构建
12.4	知识图谱推理
12.5	知识图谱问答



知识图谱 (Knowledge Graph) 是谷歌公司于2012首次提出的概念，但是其研究历史可以追溯到费根鲍姆教授 (B.A. Feigenbaum) 在1977年提出的知识工程 (Knowledge Engineering) 以及20世纪90年代后期开始的语义网 (Semantic Web)。知识工程、语义网以及知识图谱都属于人工智能中知识这一核心命题。

知识图谱并不是单一技术的研究，而是一个系统工程，其研究内容涵盖知识表示、知识存储、知识推理、图谱构建、图谱问答等方面，还涉及自然语言处理、机器学习、图数据库、逻辑推理等多个交叉领域。自然语言和知识密切相关，**知识**是实现计算机对自然语言真正理解必不可少的一部分。

本章主要内容

12.1	知识图谱概述
12.2	知识图谱表示与存储
12.3	知识图谱获取与构建
12.4	知识图谱推理
12.5	知识图谱问答



知识图谱 (Knowledge Graph, KG) 是指采用图结构表示实体（包括物体、事件或抽象概念）及其之间关系的知识库 (Knowledge Base)。在知识图谱中，图的**节点表示实体**，图的**边表示实体之间的关系**。




图 12.1 知识图谱样例



2012年谷歌公司在提出知识图谱概念的同时，发布了其知识搜索产品。目前绝大部分搜索引擎都将知识图谱作为重要的底层支撑技术，对于很多用户查询，也采用了基于知识图谱的问答算法直接回答用户问题。



针对“金庸和徐志摩是什么关系？”的问题，搜索引擎直接通过知识图谱给出了“表兄弟”关系，并通过生日计算得到了他们的年纪差。



知识图谱按照其所描述的主要内容可以分为四类：**事实知识图谱**，**概念知识图谱**，**语言知识图谱**和**常识知识图谱**。

- **事实知识图谱**包含了现实世界中各实体之间的关系，比如：“梅西”出生于“阿根廷”。
- **概念知识图谱**描述概念之间的子类关系，比如：“老虎”是“哺乳动物”，“足球运动员”属于“运动员”。
- **语言知识图谱**是人类语言中蕴含的词法、句法、语义和语用等知识，比如：WordNet、HowNet都可以认为是一种词法知识图谱。
- **常识知识图谱**描述人类与世界交互积累的经验与知识，比如：“猫爱吃鱼”、“冬天可能会下雪”。



知识图谱一般由<头实体，关系，尾实体>组成的三元组为基本元素构成。

- **实体**一般为世界上的具象事物或者抽象概念，而**实体之间的联系**则定义为关系。
- 以“刘备是刘禅的父亲”的世界知识为例，知识图谱将其存储为三元组<刘备，父亲，刘禅>，其中“刘备”为头实体，“刘禅”为尾实体，而“父亲”则为关系。

通过扩展这样的三元组，最终会形成一张巨大的知识网络，网络的节点为实体，边则为实体之间的关系，这样的知识网络即为知识图谱。知识图谱可以形式化的定义为： $\mathcal{G} = \{\mathcal{E}, \mathcal{R}, \mathcal{F}\}$

$\mathcal{E}$ 表示为实体集合, $\mathcal{R}$ 表示为关系集合, 而 $\mathcal{F}$ 表示为事实集合。

知识图谱中的一个事实即为上文中提到的三元组 $\langle h, r, t \rangle \in \mathcal{F}$, h 表示头实体, r 表示关系, t 表示尾实体, $h, t \in \mathcal{E}$, $r \in \mathcal{R}$



虽然知识图谱的概念在2012年才被首次提出，但是关于知识表示和知识推理的研究一直贯穿于整个自然语言处理和人工智能的发展过程中。

自20世纪70年代中期开始，人工智能领域开始逐渐认识到知识在智能系统的重要性，并提出**知识工程**的概念，自此知识表示、知识获取、知识推理等知识相关研究就成为了人工智能领域的研究重点和难点。

20世纪80年代开始哲学领域的**本体（Ontology）**概念引入人工智能，是指用规范化方法描述概念、实体、术语及其相互关系。同一时期，研究人员们也提出了**语义网络（Semantic Network或 Semantic Net）**用于形式化地表示知识。语义网络使用有向或者无向图中的顶点表示概念，边表示概念之间的语义关系。企业界和学术界构造了包括CYC、WordNet、BFO（Basic Formal Ontology）、HowNet等在内的大量通用和领域本体库。

 **中山大學 人工智能學院**
SUN YAT-SEN UNIVERSITY SCHOOL ARTIFICIAL INTELLIGENCE



2012年谷歌公司以“Things, Not Strings!”为主题发布了知识图谱搜索产品，希望解决用户使用传统搜索引擎需要阅读文章并自行寻找答案，即字符串（Strings）级别搜索。试图构建事物（Things）对象级别搜索，通过构建大规模结构化的事物精确描述以及事物之间的关联，使得用户可以直接得到答案或对象级精准搜索。

近十年来，知识图谱快速发展，大量超大规模的知识图谱陆续发布。**百度在2020年**发布的多源异构中文知识图谱，覆盖超过50亿实体和5500亿事实。**阿里巴巴**构建的数字商业知识图谱AliOpenKG，包含1600万实体、67万的核心概念、2681类关系以及18亿三元组。**美团**构建的餐饮娱乐知识图谱包含23类概念、16亿实体、486亿三元组。**谷歌**的知识图谱也从2021年发布时的5亿实体，35亿关系，增长到2020年包含50亿实体，5000亿关系。

知识图谱已经成为了搜索引擎、推荐系统、智能问答等应用系统中不可获取的基础组件。



知识图谱研究涉及多个领域，是典型的交叉领域研究。




图 12.4 知识图谱研究涉及领域



由于知识图谱涉及到多个交叉研究领域，相关知识点繁多，我们从知识图谱表示、存储、构建、推理、应用等几个技术维度对知识图谱所涉及的研究内容进行介绍。

- 1. 知识图谱表示：**知识图谱根据使用场景和应用需求，可以采用有向图、有向标记图（Directed Labelled Graph）、本体描述语言等方式在逻辑层面进行表示。
- 2. 知识图谱存储：**随着知识图谱规模不断扩大，如何能够高效存储和检索包含百亿级顶点千亿级边规模的图是知识图谱应用必不可少的基础工作。
- 3. 知识图谱构建：**知识广泛存在于自然语言文本、半结构化以及结构化的数据中，知识图谱构建主要目标就是研究如何利用实体识别、关系抽取等信息抽取技术，从自然语言文本中抽取实体、属性、关系、事件等知识图谱要素的方法，以及属性补全、实体链接、实体对齐等知识图谱扩展和融合方法。
- 4. 知识图谱推理：**知识图谱不仅可以提供知识的存储和检索，更重要的是可以根据构建的已知知识进行归纳、推断和预测未知的事实。
- 5. 知识图谱应用：**在构建了大规模高质量知识图谱后，如何将知识与不同的自然语言处理任务进行深度融合，构建基于知识图谱的智能推荐系统、基于知识图谱的智能问答以及知识增强的自然语言处理算法是知识图谱应用所重点研究的内容。

本章主要内容

12.1	知识图谱概述
12.2	知识图谱表示与存储
12.3	知识图谱获取与构建
12.4	知识图谱推理
12.5	知识图谱问答



知识图谱应用需要使用一种合理的知识表达方式，保证结构化的知识可以被计算机正确处理。从某种意义上可以说，知识表示是贯穿知识库的构建与应用全过程的关键问题。

- **传统的知识图谱表示方法一般以符号式为主**，包括属性图、RDF、OWL本体语言等。符号表示方法的特点是可解释性强，但是依赖知识描述的准确性。
- 近年来，随着深度神经网络研究的兴起，**基于向量式的表示方法逐渐引起人们重视**。向量式的方法容易捕获隐式知识，计算效率高，但是可解释性差。此外，向量式表示本质上属于统计模型，对没见过的实体表示质量较差，而自然界的实体一般呈长尾分布，这也在一定程度上限制了向量式表示方法的应用。

知识图谱存储对应知识在物理层面上如何被计算机组织存放。显然，想要在下游任务方便地利用知识图谱，**只有其逻辑描述方法还不够，还需要将其在物理介质上进行存储**。设计知识图谱的存储方法，要结合知识图谱的图结构模型，即图的结构信息，还要考虑节点与边的属性所包含的语义信息。在此基础上，也要针对知识存储的空间利用率以及检索查询效率等问题进行合计。



知识图谱需要建模各种实体、概念之间的关系，图因为其直观性和扩展性，自然地成为知识图谱描述数据的首选方法。图由点和边构成，图上的点可以建模实体，边则可以对应实体对之间的关系。图的表示方法除了降低了知识的理解难度之外，也便于机器存储。

在简单的应用场景下，无向图即可满足需求。若要进一步增强知识图谱的表达能力，给实体和边添加属性，则可以选择有向标记图。常用的有向图模型有两种：**属性图**和**RDF图模型**。在更加复杂的场景下，比如建模传递关系、自反关系，有向标记图仍然不能满足需要，这时候可以选用**RDFS/OWL本体语言作为描述语言对RDF进行扩展**。本节中，我们会分别对这几种常见的知识图谱表示方法进行介绍。

12.2.1 知识图谱的符号表示--属性图



属性图 (Property Graph) 是一种有向标记图，包含三个要素：节点 (Vertex)、边 (Edge)、属性 (Property)。节点对应知识图谱中的实体，边则是实体对之间的关系描述（需要注意的是边是有向的且有类型区别），其出发的节点为源节点，到达节点为目标节点，相应的边的类型则对应实体之间的关系标签。属性本质上是一个键值对，属性图可以灵活地为节点和边添加任意属性。




图 12.5 属性图示例



属性图模型在工业界广泛使用，一般通过图数据库Neo4J等实现。

属性图的优点是直观、灵活，可以根据使用需求任意给节点或者边添加属性。此外，Neo4J的图数据库中有大量针对图结构进行的优化工作，使得其查询效率有显著提升，具体信息将在知识图谱存储章节进行详细介绍。

属性图与无向图表示的不同之处在于，在属性图的模型中，关系被提升到了与实体一样重要的程度。属性图提供了一个丰富的视角，即不同种类的数据如何相关，而这些数据依赖关系在普通的关系型数据库中难以直接展示。

属性图的缺点则是无法建模深层次的语义信息，这直接限制了其语义推理能力。



资源描述框架 (Resource Description Framework, RDF)，是由国际万维网联盟W3C制定，用于描述实体/资源的数据模型。RDF的基本组成单元为一个SPO三元组<主体 (Subject, 谓词 (Predicate), 客体 (Object) >，用来表示一条客观世界的逻辑描述或客观事实。知识图谱正是由一些相互连接的实体和属性构成，换言之，一条三元组就对应了知识图谱中的一条知识。

例如：“<梅西，是，足球运动员>”。多个三元组首尾相连，就构成了一个RDF图，如下图所示。




图 12.6 RDF 示例图



基于符号表示的大规模知识图谱在实际应用中面临两个问题：（1）**知识表达能力差**，因为知识图谱中的实体一般符合长尾分布，许多实体仅有少数关系相连，对于这些稀疏的实体与关系，很难做到充分、完整的知识表达；（2）**计算效率低**，基于图结构的知识表示方便人类理解，但是将其应用于下游任务时需要设计相应的图算法，这些算法计算复杂度往往较高，使得大规模知识图谱的应用门槛大大提高。

知识表示学习 (Knowledge Representation Learning) 即如何构建高质量的向量表示。知识表示学习通过将三元组中的语义信息投影到稠密的低维向量空间，构造实体和关系的分布式表示向量。这种表示向量单独地看每一维度并没有明确含义，但是综合各维度形成的向量却能够表示对象的语义信息。这种**知识表示方法相对符号式表示有如下几个优点：**（1）**知识表达能力强**，分布式向量可以更好地建模对象之间的关系，语义相似的对象往往其表示向量也更接近，可以缓解长尾分布的知识表达问题；（2）**计算效率更高**，对于计算机来说，已经提前计算好的蕴含语义知识的低维数值向量显然比复杂的知识图谱更高效；（3）**适用于深度学习算法**，通过将知识映射到语义空间中，使得不同来源的知识可以很方便地互相融合。



研究人员们先后提出了多种模型学习知识库中实体和关系的表示向量，其中最常见的是**基于距离度量的知识表示学习方法**。基于距离度量的方法表示通过计算实体之间的距离来评价事实三元组的置信度。

距离模型 (Distance Model) 又可称为平移模型 (Translational Model)，该类模型将知识图谱中的**每个关系看作从头实体向量到尾实体向量的一个平移变换**。通过最小化平移转化的误差，将知识图谱中的实体和关系类型映射到低维空间。

12.2.2 知识图谱的向量表示--知识图谱向量表示学习TransE算法



本书第4章介绍了CBOW和Skip-Gram等分布式单词向量表示，在其研究中发现词向量空间存在平移不变现象，例如：

$$v(\text{man}) - v(\text{woman}) \approx v(\text{king}) - v(\text{queen})$$

这里 $v(w)$ 表示单词 w 的词向量。换言之，词向量捕获到了 man 和 woman、king 和 queen 之间的近似关系。

受该现象的启发，文献[647]提出了TransE模型用于学习实体和关系的向量表示。TransE模型将关系看做是表示空间中的平移（Translation）。如下图所示，在表示空间中，对于三元组 $\langle h, r, t \rangle$ ，头实体 h 的向量加上关系 r 的向量等于尾实体 t 的向量。




图 12.7 TransE 模型



尽管知识图谱是用图的形式描述，但**图数据库并不是存储知识图谱的唯一方案**。在工业界，很多成熟的数据库都是基于关系模型，知识图谱的数据可以通过一定的设计，从而可以利用关系型数据库存储。

基于关系型数据库的知识图谱存储方案主要可以分为四种：

基于**三元组**的知识图谱存储

基于**属性表**的知识图谱存储

基于**垂直表**的知识图谱存储

基于**全索引**的知识图谱存储

12.2.3 基于表的知识图谱存储--基于三元组的知识图谱存储



利用关系型数据存储知识图谱最简单的办法就是构建一个由**主体**、**谓词**和**客体**三列构成的表，将知识图谱中的每个SPO三元组看做该表中的一条记录，直接存储到关系型数据库中，如下表所示。

表 12.1 基于三元组的知识图谱存储

主体	谓词	客体
利昂内尔·梅西	出生地	阿根廷
利昂内尔·梅西	isA	足球运动员
利昂内尔·梅西	生日	1987-06-24
利昂内尔·梅西	效力	巴黎圣日耳曼足球俱乐部
利昂内尔·梅西	荣誉	金球奖
杰西·林加德	出生地	英格兰
杰西·林加德	isA	足球运动员
杰西·林加德	效力	曼彻斯特联足球俱乐部
科比·布莱恩特	出生地	美国
科比·布莱恩特	isA	篮球运动员
科比·布莱恩特	效力	洛杉矶湖人队
科比·布莱恩特	荣誉	NBA 总决赛
足球运动员	subClassOf	运动员
篮球运动员	subClassOf	运动员
金球奖	英文名	Ballon d'Or
NBA 总决赛 MVP	英文名	NBA Finals MVP

本章主要内容

12.1	知识图谱概述
12.2	知识图谱表示与存储
12.3	知识图谱获取与构建
12.4	知识图谱推理
12.5	知识图谱问答



构建知识图谱**最简单直接的方式是使用人工直接构建**，但是这种方法得到的知识图谱规模和知识的覆盖面往往有限，而且不同专家的知识认知也不尽相同，难以用统一的标准精准地刻画专家知识，使得基于人工构建的知识图谱具有高度的不确定性、不准确性。**如何构建大规模、高质量的知识图谱，实现海量知识的准确抽取和有效聚合**，是知识图谱领域最重要的问题之一。

知识图谱的数据来源是多种多样的，包括**结构化数据、半结构化数据以及非结构化数据**等。

- **结构化数据**，可以通过一定的规则来提取其中的知识，比如关系型数据库，其行（Row）可能代表知识图谱中的实例（Instance），列（Column）可能表示属性（Property），单元（Cell）对应属性值，外键（Foreign Key）则可以表示指代关系。
- **半结构化数据**，比如维基百科，可以制定解析规则，将页面上的字段映射为知识图谱中的实体或者属性。如下图所示，维基百科中IBM词条的InfoBox区域包含了大量可以直接转化为知识图谱的信息。



知识图谱的数据来源是多种多样的，包括**结构化数据**、**半结构化数据**以及**非结构化数据**等。

- **非结构化数据**，即纯文本数据
 - 首先需要从文本中挖掘出目标知识图谱所需的实体，可以应用命名实体抽取等技术；
 - 基于已知实体信息，还需要从文本中识别出它们之间的关系，这对应了SPO三元组中的谓词关系，需要使用关系抽取技术；
 - 除了实体和关系信息，还需要抽取属性信息，需要使用属性补全技术；
 - 更复杂的场景下需要对事件信息进行抽取，可以看作一组三元组的联合抽取过程。

考虑到自然语言的歧义性，比如“苹果”，在某些场景下指的是“苹果公司”，有的时候则表示的是水果，因此还需要引入实体链接技术消除不同文本中实体指称的一词多义问题。

现实世界中的实体并不总是单一存在，往往伴随许多**属性对其进行修饰**

例如，复旦大学有在校师生数、校庆日等属性。准确地掌握实体的属性信息，能够多方位地描述实体特征，提升知识的建模能力。

属性补全的目的就是自动地从文本中提取出实体所具备的属性，特别是在电子商务等垂直领域下，属性补全有着重要的应用，如下图所示，若能自动从产品描述中提取出产品的属性，将能更好的描述产品特征，优化产品搜索和推荐效果。

First Aid Beauty Ultra Repair Cream: Vegan and Gluten-Free Intense Moisturizer for Dry Sensitive Skin. Perfect for Skin Conditions and Eczema. Pink Grapefruit (14 ounce)



About this item

- HEAD-TO-TOE: Head-to-toe moisturizer that provides instant relief and long-term hydration for dry, distressed skin, even eczema. The beautiful, whipped texture is instantly absorbed with no greasy after-feel. Grapefruit has a bright citrus fruit scent that is fresh, juicy and sparkling.
- CLINICALLY PROVEN: Formulated with Colloidal Oatmeal, Shea Butter, Ceramide 3 and the FAB Antioxidant Booster, it provides immediate relief and visible improvement for parched skin and it is clinically proven to increase hydration by 169% immediately upon application.

Product description

Banish dry skin with First Aid Beauty's Ultra Repair Cream. Suitable for all skin types, especially dry, flaky skin, this hydration wonder leaves skin feeling smooth, hydrated and comfortable after just a single use.

Mentioned Attributes:

Brand

SkinType

Scent

Quantity



属性补全方法**通常采用抽取式方法**，类似于命名实体识别，将属性补全转为序列标注任务，即对句子中的每个字进行分类，在此基础上基于字的分类结果解析得到属性值。但如果简单地将其等价于普通的序列标注任务，将属性类型等价于实体类型，会带来两个问题：

- (1) 普通的命名实体识别模型一般只建模数个实体类型，而领域知识图谱可能包含成千上万的属性种类，且这些属性往往符合二八法则（Power Laws），**直接应用普通的序列标注模型，由于标签数量巨大，会造成性能的显著下降；**
- (2) 知识图谱的构建需要保证拓展性，保留属性集合扩展的可能，而当前实体识别模型一般是**基于封闭世界假设，无法识别新的实体种类**，若直接应用，同样无法识别未标注过的新属性。



实体链接 (Entity Linking) 目标是将文本中的实体指代和它们在知识图谱中的对应实体进行对应。对已有知识图谱扩充的时候，也需要实体链接任务将文本中的实体指代与其知识图谱中真正对应的实体完成映射。除此之外，实体链接任务也是很多下游应用的预处理工作，如问答、关系抽取、内容分析等。

实体链接的任务的难点主要有两个：(1) **实体的歧义性**，“MJ”可能表示篮球运动员“Michael Jordan”，也可能是美国歌手“Mj Rodriguez”；(2) **实体表达的多样性**，即一个命名实体有不同的表示形式，如全称、缩写、别名等等，例如：“NYC”和“Big Apple”是命名实体“New York City”的缩写和昵称。

歧义性和多样性的消除需要依据上下文语义信息以及实体属性和关系信息。



基于传统机器学习的实体链接算法，一般分为两步：

- (1) 提取人工设计的特征，如实体的TF-IDF值、局部上下文兼容性和文档级的实体引用全局一致性的特征等等。
- (2) 将特征输入给实体排序模型，进行最后的链接预测。

这种方法有两个不足：一是需要进行大量细致而繁琐的特征工程；二是由于特征设计过程对特定知识库或者领域知识强烈依赖，很难将已有的实体链接方法推广到其他知识库或者领域。



知识图谱包含描述**抽象知识的本体层**和描述**具体事实的实例层**。

- 本体层一般为抽象知识，如概念、属性、公理等。
- 实例层则描述具体实体、实体间的关系，即事实数据。

知识工程早期希望可以构建一个包含所有知识的统一的知识库，但是在实际情况下面临很多很困难。**首先就是不同领域的知识存在差异性**，同时不同专家对知识定义的主观性，使得无法构建统一的本体知识。**其次，知识本身会随着时间发生演变**，在不同时间，使用者会构建不同的知识本体，对相同实体的指代称呼也会发生变化，如下图所示。这种现象称之为本体和实例的异构性。




图 12.17 知识图谱融合样例图



针对知识图谱的异构性问题，研究人员们提出了**知识融合技术**，其目标就是为不同知识图谱的实例或者对象建立关联，可以高效合并多个不同来源的知识图谱。

知识融合技术的两个基本任务是**本体匹配**和**实体对齐**，两个任务的目的类似，只是匹配对象不同，前者用来匹配本体层的抽象知识，后者用来匹配实例层中相同对象的不同实体指代。

实体对齐 (Entity Alignment) 也称作实体匹配 (Entity Matching)，旨在发现多源知识图谱中等价的实体对。

基于表示学习的实体对齐，核心思想就是在低维空间中用向量的距离来计算不同来源的实体之间的相似度。

本章主要内容

12.1	知识图谱概述
12.2	知识图谱表示与存储
12.3	知识图谱获取与构建
12.4	知识图谱推理
12.5	知识图谱问答



推理是从一个或几个已有判断中推导出新判断的过程，是人类有别于普通物种的重要能力之一。**推理能力**是实现通用人工智能的最终目标中必不可少的路径，而推理过程必须依赖于先验知识和已有经验。常见的推理方法可以分为三类演绎推理，归纳推理和溯因推理：

- **归纳推理 (Inductive Reasoning)** 是一种自下而上的推理方法，即根据观察所得到客观知识进行总结归纳，从而得到更一般的结论。比如，观察发现看到的电脑都安装了Windows，于是归纳出所有的电脑使用的都是Windows操作系统。显然，这种归纳未必一定正确。生活中这种推理方式十分有用，因为观察样本足够多时，人们可以通过这种方式推理出大概率会发生的事件。
- **演绎推理 (Deductive Reasoning)** 是一种自上而下的推理方法，即根据已知的一般或普遍性前提推理得到必然成立的结论。比如，已知“没有电力供应电脑就不会正常工作”，同时知道“今天停电了”，那么就可以推理出“今天没有办法正常使用电脑”。
- **溯因推理 (Abductive Reasoning)** 是从现象出发的推理方法，即结合已有的观察和知识，推断出有可能的解释过程。假如已知知识“没有电力供应电脑就不会正常工作”，同时观察到电脑没法正常启动，我们推断出“可能是因为停电了”。




图 12.20 演绎推理、归纳推理和溯因推理示例



基于知识图谱的**知识推理 (Knowledge Reasoning)**，旨在从图谱中已存在的关联关系或事实推断出未知的关系或事实。推理得到的知识又可以反过来丰富知识图谱，为下游的应用提供更好的支持。随着知识图谱的普遍应用，基于知识图谱的推理受到了工业界和学术界的广泛关注。

从推理方法的角度，**知识图谱推理方法可以分为两类**，一种是**演绎推理**，主要是基于符号逻辑的知识图谱推理，依赖于专家显示制定的知识描述和逻辑推导方法；另一种是**归纳推理**，代表方法为基于表示学习的知识图谱推理，更多地依赖于大规模数据和统计学习算法。

本章主要内容

12.1

知识图谱概述

12.2

知识图谱表示与存储

12.3

知识图谱获取与构建

12.4

知识图谱推理

12.5

知识图谱问答



知识图谱问答 (Knowledge Base Question Answering, KBQA) 也称 Knowledge Graph Question Answering (KGQA), 旨在以知识库为知识源来回答自然语言问题。与文本问答相比, 知识图谱的结构化知识能够提供更加精准的答案, 并且方便扩展。知识图谱问答在许多智能应用中发挥着重要作用, 引起了研究人员的广泛关注。


知识图谱问答方法大概可以分为两类:

- (1) 基于语义解析的方法**, 即将自然语言组织的问句转化为知识库可以识别的结构化查询语句, 然后在知识库中查询得到答案。而这个问句到结构化查询的映射, 可以通过规则定义的模板或者训练过的自然语言解析器来完成;
- (2) 基于信息检索的方法**, 通过对问句中的实体和关系识别锁定问题的主题实体, 然后根据主题实体得到知识图谱中的候选实体, 最后对候选进行排序得到最终答案。随着深度学习技术的成熟, 深度学习技术也开始在知识图谱问答中广泛应用, 用来提升语义解析和检索排序方法的效果。



基于语义解析的方法是通过自然语言进行语义分析，将其转化为计算机可以处理的语义表示，进而利用知识库对问句进行推理查询，得到最后的答案。在第4章中我们介绍了多种语义表示方法，逻辑表达式就是其中一种常用于知识图谱问答的语义表示方法。

如下图所示。自然语言问句 “who is Justin Bieber's brother?” 转化为Lambda算子表示，谓词 `sibling_of` 表示兄弟姐妹关系，谓词 `gender` 表示性别。





结合知识库来回答自然语言问题的另一种思路是，**首先**定位出自然问句中的主题实体，**然后**从知识库中的该实体相邻节点中选出候选答案，**再对**候选实体进行排序得到最后的答案。

这种基于检索的知识图谱问答有**两个核心问题**：

- 主题实体的识别，如果主题实体定位错误，之后的候选实体很大可能也是错误的。当知识图谱较复杂时，这需要通过实体链接将文本中的实体指代与其知识图谱中真正对应的实体完成映射；
- 排序模型的效果，候选实体的得分也直接决定最终结果，排序模型可以采用规则或者深度学习的方法实现。

本章小结

人类的知识是真正理解语言的基石，随着知识表示学习、知识获取技术和各种知识感知应用的出现，表示实体之间结构关系的知识图谱已成为认知智能的主流研究方向。本章对以知识图谱表示与存储、知识图谱获取与构建、知识图谱推理以及知识图谱问答等四个方面的基础概念和经典方法展开了介绍。虽然学术界和工业界在知识图谱的上述方面都开展大量系统的研究，但是在分布式的知识表示学习方法、知识图谱动态扩展以及知识图谱推理等方面仍有很多开放问题等待解决。